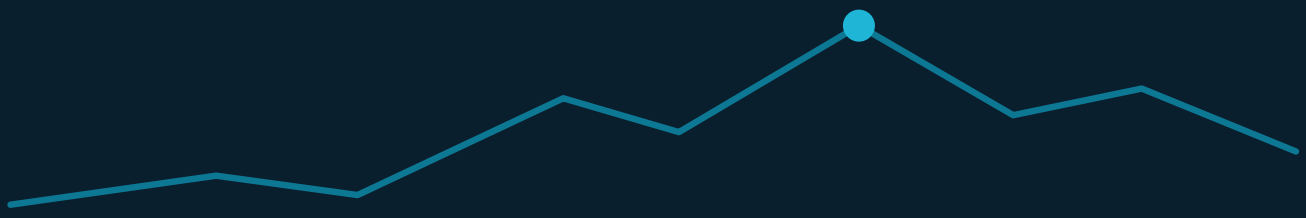
FrioAndes

DOCUMENTO DE ARQUITECTURA

Plataforma cloud para la operación de cadena de frío

Gobierno, seguridad, red híbrida, automatización, cargas de trabajo, migración, observabilidad, Microsoft Fabric y sistema de diseño



Preparado para
Arquitecto cloud de FrioAndes

Preparado por
Equipo de arquitectura cloud del proyecto

Fecha
20 de octubre de 2026

Versión
d0a03d8

Caso de estudio académico · Universidad Icesi

Información del documento

Documento	Plataforma cloud para la operación de cadena de frío
Versión	Generada desde el commit d0a03d8
Fecha	20 de octubre de 2026
Preparado para	Arquitecto cloud de FríoAndes
Preparado por	Equipo de arquitectura cloud del proyecto
Clasificación	Uso interno de FríoAndes
Fuente	Repositorio frioandes-platform/planning, carpeta docs/

Historial de versiones

Versión	Fecha	Cambios
d0a03d8	20 de octubre de 2026	Versión generada desde el repositorio

Contenido

Visión general **1**
Visión general de la arquitectura 1
1. Gobierno de la plataforma **7**
FríoAndes — Gobierno y landing zone de Azure 7
FríoAndes — Auditoría, retención y facturación interna 11
2. Seguridad **16**
FríoAndes — IAM de mínimo privilegio, MFA y cifrado 16
Datos personales, perímetro público y detección de actividad anómala 20
3. Red híbrida y preparación para una segunda nube **40**
Red híbrida, subnetting en la nube y verificación de no solapamiento 40
Firewall de nube, transición del firewall de Cali y publicación del portal de rastreo 75
Acceso remoto administrativo y preparación para una segunda nube 99
4. Automatización y DevOps **107**
Automatización y DevOps: ambientes, pipeline, secretos y cambio 107
5. Cargas de trabajo **112**
Arquitectura de la plataforma de operación logística (Carga A) 112
Telemetría de cadena de frío: ingesta, alerta e historial 116
Estrategia de migración del núcleo y escenario de campaña (Carga C) 137
Siembra y transferencia del archivo de 1,2 PB (Carga C) 156
6. Observabilidad **170**
Observabilidad, objetivos de servicio y transición desde Zabbix 170
7. Inteligencia artificial de la torre de control, sobre Microsoft Fabric **188**
Microsoft Fabric: espacios de trabajo, ingesta sin duplicar y región 188
Microsoft Fabric: acceso, usos de inteligencia artificial, observabilidad y capacidad 202
8. Sistema de diseño **215**
Logo y paleta de color — FríoAndes 215
9. Cronograma general del proyecto **219**
Cronograma general del proyecto 219
Anexo. Registro de supuestos **227**
Registro de supuestos 227

Visión general

Visión general de la arquitectura

FríoAndes opera la cadena de frío de alimentos desde un datacenter en Cali, con ocho centros regionales, 120 camiones y una torre de control que despacha de 04:00 a 22:00. Este documento propone la plataforma que la reemplaza en Azure: una plataforma logística nueva, la telemetría de temperatura y ubicación en tiempo cercano al real, la migración del núcleo y del archivo de 1,2 PB sin detener el despacho, y una estrategia de Microsoft Fabric para que la torre de control use inteligencia artificial. Este capítulo muestra la solución en una sola vista y dice dónde se desarrolla cada parte.

1. Punto de partida

Hoy	Qué exige el reto
Un datacenter en Cali con VMware, tres clústeres y desarrollo, pruebas y producción en el mismo clúster de aplicación	Ambientes separados, con promoción controlada y código de infraestructura
Un firewall en Cali concentra políticas, VPN con los centros y NAT del rastreo; internet de 400 Mbps simétricos, sin enlace dedicado a una nube	Ruta redundante para Cali, despacho fuera de internet y un firewall de nube con tabla de políticas
Temperatura cargada por lote; sin alerta en tiempo real	Alerta de excursión visible en un minuto, de día en la torre y de noche en la guardia de calidad
Archivo de 1,2 PB en FTP y NFS (1,05 PB de video), que crece 12 TB al mes	Llevarlo a la nube sin copiarlo por un enlace de 400 Mbps y sin duplicarlo en Fabric
Zabbix vigila la plataforma	Observabilidad de nube con dos objetivos de servicio y transición desde Zabbix
Campañas de fin de año, Semana Santa y mitad de año en las que el despacho se degrada	Crecer en campaña y no hacer cambios productivos durante ella ni de 04:00 a 22:00
Sin manual de marca	Un sistema de diseño común a la torre y al portal

La convivencia entre Cali y la nube dura como máximo 90 días y termina con Cali apagada. Las evidencias de entrega y la trazabilidad de temperatura se conservan cinco años por contrato.

---

2. La solución en una vista

FríoAndes en Azure: la solución completa y los ocho puntos del reto

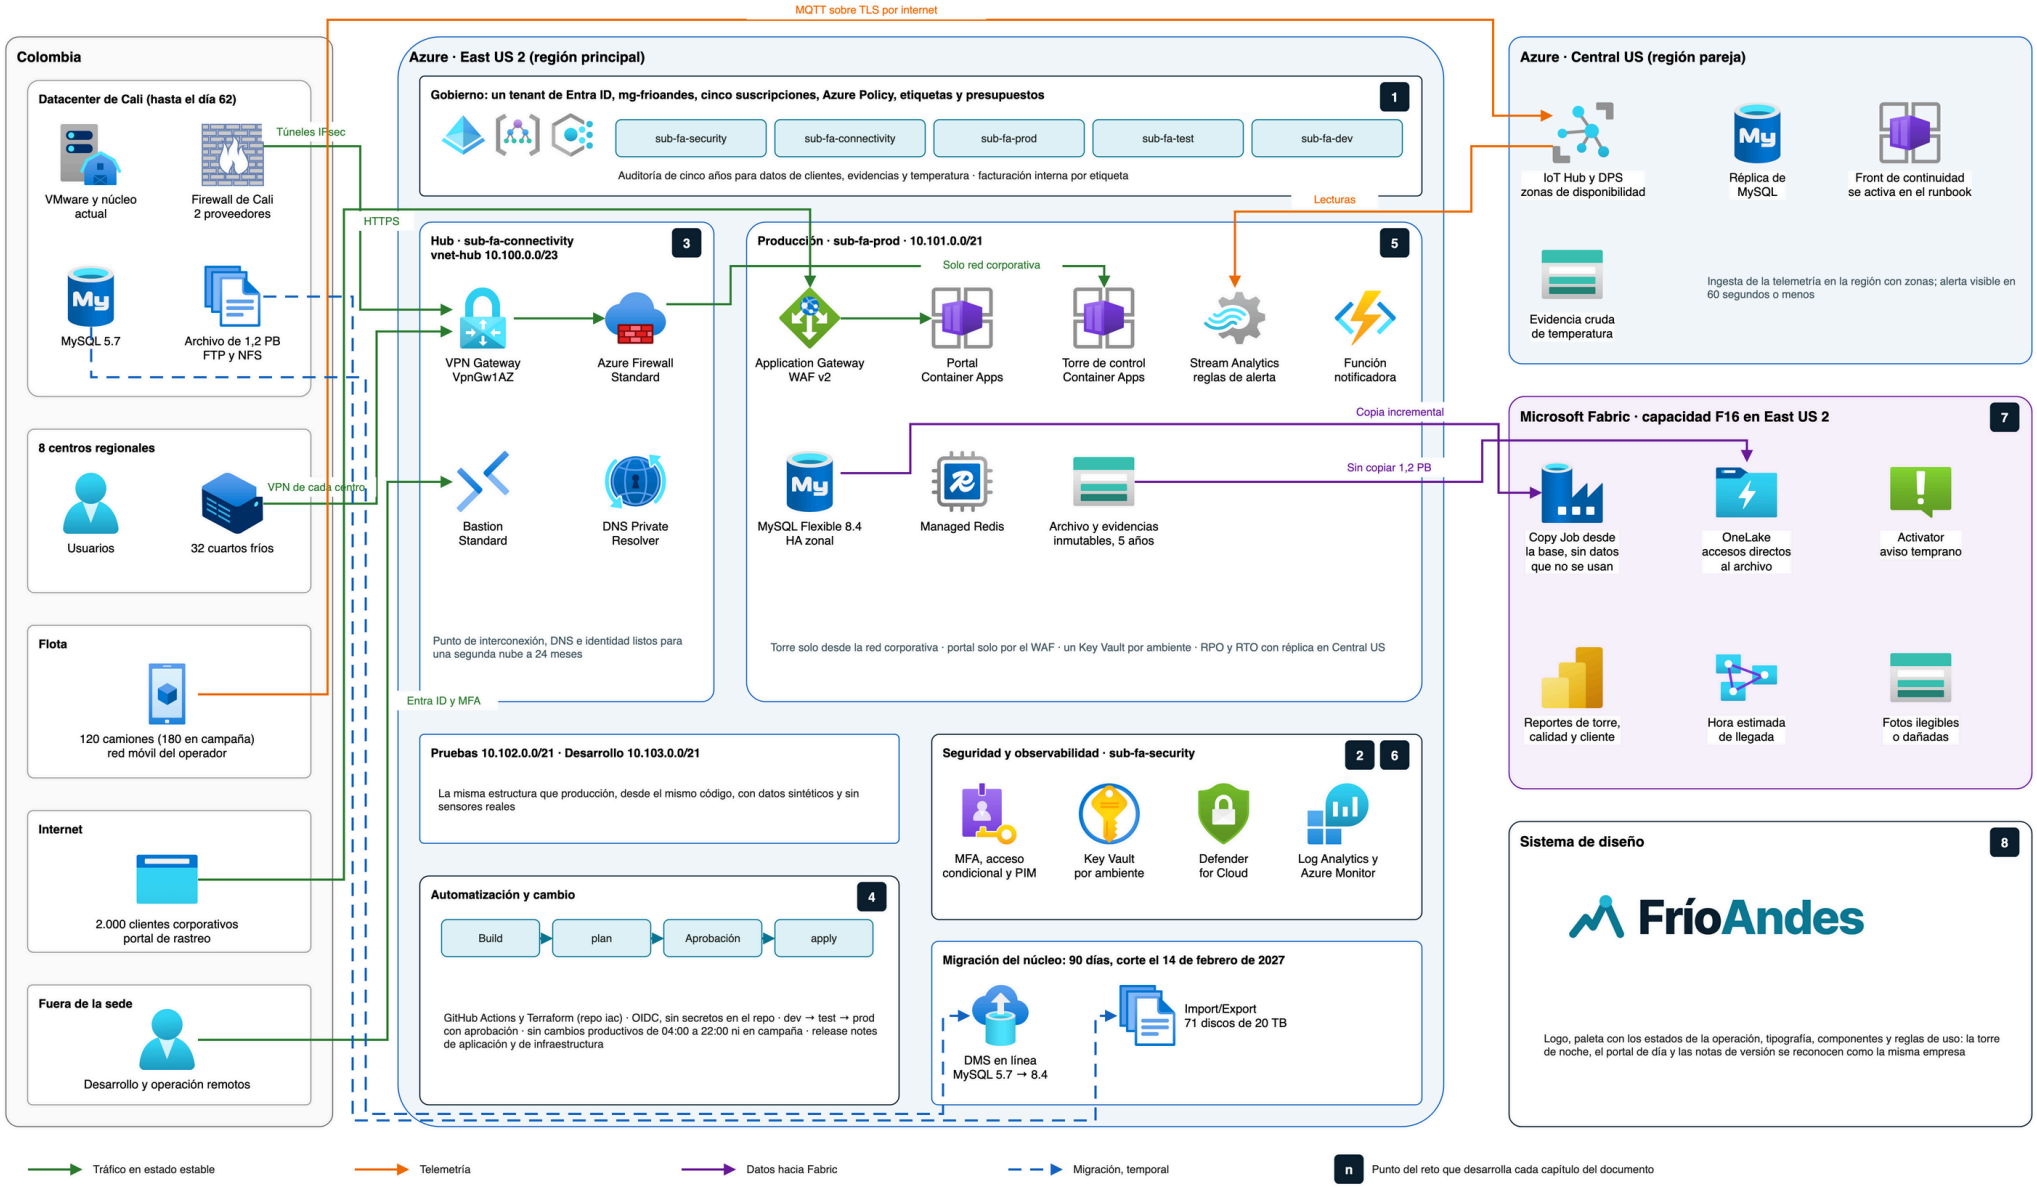


Figura 1: FríoAndes en Azure: la solución completa, con los ocho puntos del reto numerados

El número de cada recuadro es el punto del reto y el capítulo de este documento que lo desarrolla:

1. **Gobierno.** Un tenant de Entra ID y un grupo de administración `mg-frioandes` con cinco suscripciones: seguridad, conectividad, producción, pruebas y desarrollo. Azure Policy, etiquetas y presupuestos se aplican desde ahí, y cada costo se asigna a operación, telemetría, pruebas o Fabric. La auditoría guarda cinco años de accesos a datos de clientes, evidencias y temperatura.
2. **Seguridad.** Mínimo privilegio por grupo, MFA para administradores y para la consola de despacho, PIM para los cambios productivos, un Key Vault por ambiente y cifrado en tránsito y en reposo. Los datos personales de conductores y destinatarios tienen dueño, plazo y lugar; el portal tiene límites de solicitudes para el pico de campaña y Defender for Cloud detecta la actividad anómala.
3. **Red híbrida.** Hub y spoke en East US 2: el hub tiene el VPN Gateway, el Azure Firewall, el DNS Private Resolver y Bastion. Cali se conecta por dos proveedores y cada centro directo a Azure. La torre solo se alcanza desde la red corporativa y el portal solo por el WAF. Las direcciones no se solapan con Cali, y el hub, el DNS y la identidad quedan listos para una segunda nube.
4. **Automatización.** Terraform y GitHub Actions despliegan los tres ambientes desde el mismo código, con OIDC, aprobación para producción y un bloqueo que impide desplegar de 04:00 a 22:00 o en campaña. Dos plantillas de release notes, una de aplicación y otra de infraestructura, gobiernan cada cambio.
5. **Cargas.** La torre y el portal corren en Container Apps sobre MySQL Flexible Server 8.4 con alta disponibilidad zonal y réplica en Central US. La telemetría entra por IoT Hub en Central US y Stream Analytics genera la alerta. El núcleo se migra con DMS en línea y un corte de 2 horas un domingo; el archivo llega en 71 discos con Import/Export y una copia continua cubre lo nuevo.
6. **Observabilidad.** Azure Monitor y Log Analytics recogen la salud de la plataforma y de los enlaces, las trazas de despacho, rastreo e ingesta, y las señales de seguridad. Dos objetivos de servicio: el portal y la alerta de temperatura. Zabbix sigue vigilando Cali hasta el día 61.
7. **Fabric.** Una capacidad F16 en East US 2. Fabric lee la base con un Copy Job incremental y el archivo con accesos directos, sin una segunda copia de 1,2 PB. Tres usos en el primer release: aviso temprano de excursión o sensor caído, hora estimada de llegada y fotos ilegibles o dañadas.
8. **Sistema de diseño.** Logo, paleta con los estados de la operación, tipografía, componentes y reglas de uso para la torre de noche, el portal de día y las notas de versión.

---

3. Decisiones principales

Decisión	Por qué	Capítulo
Azure, con East US 2 como región principal y Central US como pareja	Fabric es obligatorio y vive en Azure; East US 2 dio la mejor latencia medida desde Cali	3
Cinco suscripciones bajo un solo grupo de administración	Separa seguridad, red, producción y no productivo sin multiplicar directorios	1
Hub y spoke con Azure Firewall Standard y el WAF en paralelo	Un solo punto de control para todo lo que no es el portal, y el WAF delante del único servicio público	3
Centros directo a Azure por su propia VPN, con la VPN hacia Cali de respaldo hasta el día 56	Los centros no dependen de Cali cuando Cali se apaga	3
Container Apps para la torre y el portal, con Kubernetes como variante documentada	Menos operación para el mismo patrón de red; la red reserva el espacio de la variante	5
IoT Hub en Central US	Es la región pareja con zonas de disponibilidad para IoT Hub; la alerta es crítica	5
Siembra del archivo con discos (Import/Export) y no por la red	Copiar 1,2 PB por 400 Mbps tardaría más de nueve meses y competiría con la operación	5
Un solo corte, el domingo 14 de febrero de 2027, con 21 días para volver atrás	Torre, portal y servicios comparten la base; cambiar por partes obligaría a sincronizar dos bases	5
Fabric sin copiar el archivo: accesos directos y solo lo que piden los usos	El camino por defecto no puede ser una segunda copia de 1,2 PB	7

Decisión	Por qué	Capítulo
Capacidad de Fabric con reducción fuera de campaña	Se mide el primer mes y se baja a F8 si el uso lo permite	7

4. Cifras que dimensionan el diseño

Cifra	Valor	Dónde pesa
Usuarios internos	450, unos 180 en los centros (supuesto)	Torre, VPN, licencias
Clientes corporativos	Unos 2.000	Portal e identidades externas
Portal	800 solicitudes por minuto en pico normal, 2.000 en campaña durante unas 4 horas	WAF, Application Gateway, réplicas
Camiones	120, 180 en campaña	Telemetría
Cuartos fríos	32 en 8 centros	Telemetría y alertas
Mensajes de telemetría	Unos 486.000 al día, 682.000 en campaña	IoT Hub y Stream Analytics
Archivo	1,2 PB (150 TB de documentos y 1.050 TB de video), más 12 TB al mes	Siembra, almacenamiento y Fabric
Retención	Cinco años para evidencias, temperatura y auditoría de accesos	Inmutabilidad y registros
Continuidad	RPO de 15 minutos y RTO de 4 horas	Réplica en Central US
Objetivos de servicio	Portal: 99,9 % de minutos buenos en 28 días. Alerta: 99 % visible en 60 segundos o menos	Observabilidad y guardia
Convivencia	Máximo 90 días; día 0 el 11 de enero de 2027 y Cali apagada el 14 de marzo	Migración

5. Alineación con Well-Architected

El enunciado pide alinear la estrategia con los cinco pilares de un marco Well-Architected. Esta tabla dice qué decisiones del diseño cumplen cada pilar y dónde se desarrollan.

Pilar	Qué lo cumple en este diseño	Capítulos
Excelencia operacional	Todo se despliega desde Terraform y GitHub Actions, con los mismos módulos en los tres ambientes; cambios solo de 22:00 a 04:00 y fuera de campaña, con release note, aprobación y vuelta atrás; observabilidad con alertas por guardia, tableros de operación y la transición desde Zabbix probada; un ensayo completo del corte antes del corte real	4, 5 (Parte C), 6
Seguridad	Identidades de Entra ID con mínimo privilegio, MFA y PIM; segmentación por subred y NSG, Azure Firewall para todo lo que no es el portal y WAF delante del portal; cifrado en tránsito y en reposo con un Key Vault por ambiente; auditoría de accesos de cinco años; datos personales con dueño, plazo y lugar; Defender for Cloud	1, 2, 3
Confiabilidad	MySQL con alta disponibilidad zonal y réplica en Central US para un RPO de 15 minutos y un RTO de 4 horas; IoT Hub en la región con zonas; dos proveedores de internet en Cali y VPN directa de cada	3, 5, 6

Pilar	Qué lo cumple en este diseño	Capítulos
	centro; un corte reversible con 21 días de Cali en espera; objetivos de servicio medidos en 28 días	
Eficiencia del rendimiento	Tamaños calculados con las cifras del caso (800 y 2.000 solicitudes por minuto, 486.000 mensajes al día, 1,2 PB); escalado por calendario solo en la capa que crece en campaña; caché administrada; región elegida por latencia medida desde Cali; Fabric dimensionado por unidades de capacidad medidas	3, 5, 7
Optimización de costos	Siembra con discos en vez de copiar 1,2 PB por la red; Fabric sin una segunda copia del archivo; niveles Cool y Cold y LRS para el video; capacidad de Fabric reducida fuera de campaña; facturación interna por etiqueta y presupuestos por suscripción; cada cifra con su supuesto	1, 5, 7 y el documento de costos

---

6. Costo

El costo va en su propio documento (`docs/costs/costs-frioandes.pdf`), con cada cifra trazable a su supuesto:

Concepto	USD	Fuente
Costos únicos del proyecto: equipo por rol y fase, capacitación, consultoría, migración y 15 % de contingencia	419.354,89	`docs/costs/costo-total-proyecto.md`
De ellos, la migración con la siembra del archivo	153.417,32	`docs/costs/costo-migracion.md`
Mes estable de la nube, con el archivo (mes 1)	17.239,76	`docs/costs/costo-mes-estable-y-campana.md`
Fabric, mes normal y mes de campaña	2.891,89 y 2.938,13	`docs/costs/costo-fabric.md`
Costo total de propiedad a 1, 3 y 5 años	864.359,86, 1.748.583,59 y 2.625.095,25	`docs/costs/costo-total-proyecto.md`

Las 25 decisiones de diseño que bajan el costo, con su costo evitado, están en `docs/costs/decisiones-ahorro.md`.

---

7. Cómo leer este documento

Los capítulos siguen los ocho puntos del reto. Cada uno reúne los documentos de diseño de su tema tal como están en el repositorio, con sus diagramas, tablas y supuestos.

Capítulo	Punto del reto	Documentos
1	Gobierno de la plataforma	Landing zone; auditoría, retención y facturación interna
2	Seguridad	IAM, MFA y cifrado; datos personales, perímetro y detección
3	Red híbrida y segunda nube	Topología y subnetting (con la tabla de subnetting); firewall de nube y publicación del rastreo (con la tabla de políticas); acceso remoto y segunda nube
4	Automatización y DevOps	Ambientes, pipeline, secretos y estrategia de cambio
5	Cargas de trabajo	Plataforma logística (Parte A); telemetría (Parte B); migración del núcleo y siembra del archivo (Parte C)

Capítulo	Punto del reto	Documentos
6	Observabilidad	Observabilidad, objetivos de servicio y transición desde Zabbix
7	Inteligencia artificial sobre Microsoft Fabric	Espacios, ingesta y región; acceso, usos de IA y capacidad
8	Sistema de diseño	Logo y paleta
9	Cronograma	Cronograma general del proyecto
Anexo	Supuestos	Registro de supuestos de todo el diseño

Cuando un documento cita otro archivo del repositorio (un CSV, un script o un documento de costos), el nombre aparece en `letra de código`. Lo necesario para leer el diseño está dentro de este documento; esos archivos son la fuente que verifica las tablas.

1. Gobierno de la plataforma

FríoAndes — Gobierno y landing zone de Azure

Estado: propuesta de arquitectura para revisión del equipo. Fecha: 4 de octubre de 2026. Historia cubierta: #5 (F1-01).

1. Objetivo y alcance

Establecer una estructura común para gobernar recursos, accesos y costos en Azure, separando seguridad, red compartida, producción y ambientes no productivos. El diagrama de jerarquía está en la sección 2; este documento describe y justifica su contenido. La jerarquía no representa la topología de red ni un despliegue realizado.

El contexto proporcionado indica que desarrollo, pruebas y producción comparten actualmente el clúster de aplicación del datacenter. Esto dificulta delimitar permisos, cambios y consumo por ambiente. La propuesta crea ámbitos distintos y conserva una administración corporativa común.

Azure es la nube principal definida en esta historia. Los nombres, cinco suscripciones y umbrales siguientes son decisiones propuestas, no cifras obligatorias del caso. La HU de red fija East US 2 como región principal y Central US como región emparejada; según el resumen de su entrega, una medición de latencia desde Cali confirmó East US 2. Los valores de esa prueba y los montos de presupuesto se consultan en los documentos respectivos.

2. Cómo leer el diseño

- **Tenant de Microsoft Entra ID:** directorio corporativo que autentica identidades. No es una suscripción de recursos ni una cuenta de facturación.
- **Management Group (MG):** agrupa suscripciones para aplicar reglas comunes.
- **Subscription (SUB):** ámbito para administrar recursos, permisos, cuotas y seguimiento de costos.
- **Resource Group (RG):** conjunto de recursos con un ciclo de vida relacionado dentro de una suscripción.

En el PNG, las líneas indican pertenencia e herencia de gobierno. No indican conexiones de red ni flujos de datos. Las políticas asignadas a un grupo se aplican a sus descendientes; el acceso de una persona se concede mediante RBAC en el ámbito que necesita.

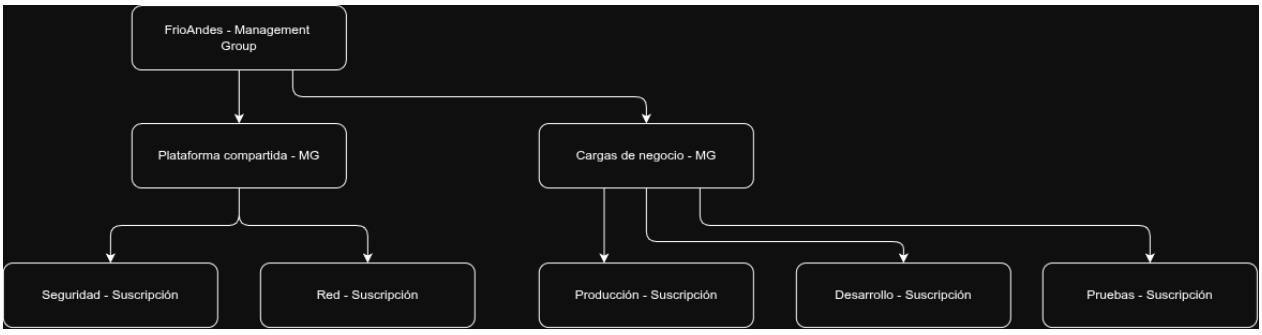


Figura 2: Jerarquía de gobierno: tenant de Entra ID, grupos de administración y las cinco suscripciones

3. Jerarquía de gobierno

Se propone una jerarquía poco profunda dentro del tenant corporativo: `mg-frioandes` contiene `mg-fa-platform` (plataforma compartida) y `mg-fa-workloads` (cargas de negocio). El primero agrupa las suscripciones de seguridad y conectividad; el segundo agrupa producción, desarrollo y pruebas. Los ambientes se separan con suscripciones bajo el mismo MG de cargas; no se crean MG únicamente para representar dev/test/prod. El PNG entregado junto a este documento debe mostrar estas mismas relaciones.

Las suscripciones propuestas se vinculan al mismo directorio Entra ID. La separación dev/test/prod se realiza mediante suscripciones, permisos, identidades de despliegue y controles de red independientes.

Suscripción	Dominio y recursos previstos	Administración propuesta
`sub-fa-security`	Seguridad y observabilidad central: Log Analytics y herramientas de investigación; archivo de auditoría a definir en su historia	Equipo de seguridad/plataforma; lectura limitada para auditoría
`sub-fa-connectivity`	Red compartida: hub, Azure Firewall, conectividad con Cali y DNS híbrido; los controles del portal y de los flujos que no pasan por el firewall se precisan en la HU de firewall	Equipo de redes
`sub-fa-prod`	Cargas productivas: logística, portal, datos, archivo e ingesta de telemetría	Operadores autorizados e identidad de despliegue de producción
`sub-fa-dev`	Desarrollo con datos sintéticos o anonimizados	Desarrolladores dentro de RG autorizados
`sub-fa-test`	Pruebas de integración y validación previa a producción	QA y automatización dentro de RG autorizados

Ejemplos de RG: `rg-fa-logistica-prod`, `rg-fa-telemetria-prod`, `rg-fa-archivo-prod`, `rg-fa-logistica-dev` y `rg-fa-logistica-test`. Las llaves y secretos de cada carga permanecen en su ambiente; centralizar la política no implica compartir secretos.

Se agrupan inicialmente seguridad y observabilidad en una suscripción de plataforma para reducir complejidad. Esto adapta el patrón de landing zones de Microsoft; no reproduce toda su jerarquía de referencia. Una suscripción adicional de administración podrá incorporarse si la separación de responsabilidades lo exige. No se crea una suscripción de identidad únicamente para alojar Entra ID.

4. Identidades y responsabilidades

Un tenant corporativo evita crear directorios independientes para cada ambiente. Los grupos de Entra ID se asignan a roles Azure RBAC por suscripción o RG. Una identidad única no significa permisos iguales en todos los ámbitos.

Grupo propuesto	Ámbito y permiso previsto	Restricción
`grp-fa-governance`	Gestión de políticas y jerarquía mediante roles adecuados	Sin acceso de lectura de datos por defecto
`grp-fa-security`	Visibilidad de seguridad e investigación autorizada	Sin modificación de cargas de negocio por defecto
`grp-fa-network`	Network Contributor en conectividad	Sin administración de bases o aplicaciones
`grp-fa-dev`	Contributor en RG de desarrollo necesarios	Sin permisos productivos; Contributor no permite asignar roles
`grp-fa-qa`	Lectura y permisos específicos de ejecución en test	Sin administración de producción
`grp-fa-ops-prod`	Roles de operación específicos en producción	Elevación temporal para acciones privilegiadas
`grp-fa-finops`	Cost Management Reader en las suscripciones pertinentes	Sin modificación de infraestructura

No se concede Owner global a desarrolladores o QA. Se proponen MFA, acceso condicional y elevación temporal mediante PIM para administradores, sujetos al licenciamiento correspondiente. La matriz completa de usuarios y cifrado pertenece a la tarea 4.

Los pipelines usarán identidades distintas por ambiente con federación de identidad cuando sea compatible. Los permisos de acceso a datos deben configurarse por servicio: un rol de gobierno o de lectura de recursos no sustituye la autorización de la aplicación. El acceso a la consola de despacho se diseñará por separado.

5. Etiquetado obligatorio

Se aplican claves y valores normalizados en minúsculas a los RG y recursos compatibles. No se incluyen nombres de clientes, documentos, secretos ni otros datos personales.

Dimensión	Clave	Valores permitidos propuestos	Ejemplo
Ambiente	`ambiente`	`prod`, `dev`, `test`, `shared`	`prod`
Carga	`carga`	`logistica`, `telemetria`, `archivo`, `red`, `seguridad`, `analitica`	`telemetria`
Línea de costo	`costo`	`operacion`, `telemetria`, `pruebas`, `compartido`, `fabric`	`telemetria`
Criticidad	`criticidad`	`alta`, `media`, `baja`	`alta`
Responsable	`responsable`	Identificador del equipo propietario	`equipo-plataforma`

Ejemplo para la ingesta productiva: `ambiente=prod`, `carga=telemetria`, `costo=telemetria`, `criticidad=alta`, `responsable=equipo-plataforma`.

Dev/test se clasifican como `costo=pruebas`, incluso si allí se prueba telemetría. Esto evita contar el mismo recurso simultáneamente como telemetría productiva y pruebas. Red y seguridad comunes usan `costo=compartido`; su reparto interno se definirá en la tarea 3. La capacidad de Fabric tendrá una línea separada, mediante su ámbito de facturación y filtros disponibles, sin asumir que todos sus cargos admiten las mismas etiquetas.

Los recursos no heredan automáticamente etiquetas del RG o la suscripción. Terraform las aplicará explícitamente y Azure Policy verificará su cumplimiento. Para recursos existentes compatibles podrá usarse `Modify` con identidad administrada y remediación. Los recursos sin soporte de etiquetas se clasifican por suscripción/RG y un inventario de excepciones.

6. Políticas concretas de Azure Policy

Las políticas se agrupan en iniciativas versionadas. Los efectos siguientes son objetivos de implementación: se seleccionarán definiciones integradas o personalizadas y se comprobarán sus tipos de recurso y aliases al construir IaC.

Política	Ámbito	Efecto previsto	Resultado y ejemplo
P-01. Etiquetas y valores obligatorios	`mg-frioandes`, para tipos compatibles	`Deny`	Rechazar un RG sin `ambiente` o un recurso etiquetable sin `costo`; validar valores según suscripción
P-02. Regiones autorizadas	`mg-frioandes`	`Deny`	Impedir despliegues regionales fuera de la lista aprobada; tratar recursos globales según la definición
P-03. Datos sin acceso público	`sub-fa-prod`, sobre servicios de datos seleccionados	`Deny` donde exista soporte	Rechazar almacenamiento/base de datos con acceso público incompatible con el diseño; el ingreso público autorizado del portal se trata aparte
P-04. Diagnósticos centralizados	Suscripciones de cargas y conectividad	`DeployIfNotExists` en servicios compatibles	Crear configuración de diagnóstico hacia el destino autorizado; usar identidad administrada y remediación para recursos existentes
P-05. Transporte seguro en almacenamiento	Suscripciones de cargas	`Deny` para propiedades compatibles	Exigir HTTPS y TLS mínimo 1.2 en cuentas de almacenamiento; otros

Política	Ámbito	Efecto previsto	Resultado y ejemplo
			servicios tendrán controles específicos

P-02 toma East US 2 y Central US como regiones iniciales para recursos regionales, sujeto a excepciones justificadas para servicios globales y a las definiciones compatibles con cada tipo de recurso. Antes de activar su efecto de bloqueo se comprueba el alcance exacto de la política. P-04 no garantiza por sí sola registrar accesos de negocio: la aplicación debe emitir los eventos definidos en la tarea 3. También se debe coordinar con la HU de firewall el envío central de registros de Azure Firewall, WAF y flujos de red virtual, incluidos los recorridos que no atraviesan el firewall.

Se verifica primero la compatibilidad de cada política en dev/test. Las excepciones deberán registrar recurso/ámbito, justificación, responsable, control compensatorio y vencimiento. No se excluirá toda producción para resolver un error puntual.

7. Presupuestos y seguimiento de costos

Se propone un presupuesto mensual por suscripción, filtros para las líneas de negocio y una vista consolidada para finanzas con permisos sobre todos los ámbitos necesarios. Los MG organizan gobierno; no sustituyen el contrato ni la cuenta de facturación.

Presupuesto	Alcance	Responsable
Seguridad	`sub-fa-security`	Seguridad y FinOps
Conectividad	`sub-fa-connectivity`	Redes y FinOps
Producción	`sub-fa-prod`, con vistas separadas por `costo`	Operaciones y FinOps
Desarrollo	`sub-fa-dev`	Desarrollo
Pruebas	`sub-fa-test`	QA
Fabric	Capacidad y cargos asociados identificados por facturación	Analítica y FinOps

Como decisión inicial, se proponen alertas al 80 %, 100 % y 120 % del gasto real, y al 100 % del gasto previsto. Los montos se obtendrán del documento de costos; no se presentan valores inventados como cotización. Los periodos de campaña tendrán límites aprobados antes de su inicio.

Los presupuestos notifican; no son topes que apaguen automáticamente recursos. Ante una alerta se investiga el consumo y se aprueban acciones. No se detendrá despacho ni telemetría por una alerta financiera. El seguimiento tiene retraso y no sustituye monitoreo operativo en tiempo real.

8. Cómo resuelve la situación actual

Problema actual	Cambio propuesto	Condición para que funcione
Dev/test/prod comparten clúster de aplicación	Suscripciones y recursos propios por ambiente	No reutilizar el mismo cómputo, base o identidad de despliegue entre ambientes
Permisos sin delimitación común	Tenant corporativo y grupos RBAC con ámbitos separados	Validar permisos efectivos y evitar herencia excesiva
Red y cargas administradas juntas	Conectividad compartida bajo responsabilidad de redes	Definir segmentación, rutas y firewall en la historia de red
Costos mezclados	Etiquetas, presupuestos por suscripción y vistas por línea	Controlar cargos sin etiquetas y distribuir costos comunes
Auditoría dispersa	Destino central y políticas de diagnóstico	Definir eventos, acceso y retención en la tarea 3

Una suscripción no es un firewall. El aislamiento requiere redes y reglas explícitas; tampoco prohíbe por sí sola que alguien configure conexiones entre ambientes. Los controles de red y los datos de prueba deberán respetar la separación propuesta.

9. Validación y cierre de la historia

Este documento permite revisar el diseño sin contratar ni desplegar servicios. La implementación posterior verificará que un desarrollador de dev no pueda modificar producción, que una creación sin etiquetas sea rechazada, que un recurso regional no autorizado sea bloqueado y que el consumo pueda agruparse por las líneas acordadas.

Criterio de aceptación	Evidencia en este documento
Jerarquía con seguridad, red, prod y no-prod	Diagrama de la sección 2 y descripción y tabla de cinco suscripciones en la sección 3
Cuatro dimensiones de etiquetas y tres políticas concretas	Cinco dimensiones en sección 5 y cinco políticas en sección 6
Explicar cómo se resuelve la mezcla de clústeres e identidades	Modelo de accesos en sección 4 y comparación en sección 8

Antes de marcar Done: revisión del equipo, confirmación de nombres y responsables, incorporación a `docs/architecture/gobierno-landing-zone.md` en el repositorio y verificación de que el PNG adjunto coincide con la sección 3. Los importes siguen abiertos para las historias de dimensionamiento/costos; no cambian la jerarquía propuesta. El plan de direcciones, las rutas y las reglas detalladas son responsabilidad de las HU de red y firewall.

La tarea 3 y la tarea 4 pueden continuar después de aprobar esta base. La tarea 1 requiere además la historia de redes referida como #8. Confirmar que #5 corresponde a esta historia de gobierno antes de ajustar vínculos del tablero.

10. Fuentes técnicas

Las decisiones de FríoAndes son propuestas del equipo. Las fuentes explican el comportamiento de los servicios y no certifican que este diseño esté desplegado.

- Microsoft Learn — Management groups y diseño de landing zones
- Microsoft Learn — Azure Policy
- Microsoft Learn — Etiquetas de recursos
- Microsoft Learn — Crear y administrar presupuestos

Consulta técnica: 4 de octubre de 2026. Datos del caso: historias de usuario proporcionadas en el backlog.

FríoAndes — Auditoría, retención y facturación interna

1. Alcance y relación con la landing zone

FríoAndes necesita responder **quién accedió, a qué, cuándo y con qué resultado** en tres ámbitos: datos de clientes, evidencias de entregas y lecturas de temperatura. También necesita separar el gasto de operación, telemetría y pruebas, y mostrar la capacidad de Microsoft Fabric por separado. Las evidencias y la trazabilidad de temperatura se conservan **cinco años** por contrato. No se tratan datos de tarjetas de pago.

La landing zone (#5) propone cinco suscripciones: `sub-fa-security`, `sub-fa-connectivity`, `sub-fa-prod`, `sub-fa-dev` y `sub-fa-test`. El espacio central de Log Analytics reside en `sub-fa-security`; las etiquetas `ambiente`, `carga`, `costo`, `criticidad` y `responsable`, junto con los presupuestos, son la base de la facturación interna. Este documento concreta la política P-04 de diagnósticos y la distribución del costo compartido. Las identidades y sus permisos específicos se detallan en #7.

2. Eventos que deben poder reconstruirse

El registro del perímetro identifica IP, ruta y regla aplicada, pero por sí solo no sabe qué cliente o guía consultó un usuario. Cada servicio de negocio debe emitir **un evento estructurado por acceso**, exitoso o denegado, y enviarlo al espacio central; los logs de plataforma aportan evidencia adicional. Un cambio de datos o de permisos también queda registrado.

Tipo de evento exigido	Origen principal y acciones	Datos mínimos para investigar	Corroboración técnica
Acceso a datos de clientes	Consola interna, API y portal: iniciar sesión, consultar guía/cliente, exportar, modificar y denegar una consulta ajena	Identidad o cuenta de servicio, rol, cliente y guía identificados por claves internas, acción, resultado, motivo de denegación y correlación de solicitud	Inicio de sesión en Entra ID, eventos del portal, Application Gateway y WAF; consultar MySQL por la clave interna cuando proceda
Acceso a evidencias	Servicio de archivo y portal: listar, leer, descargar, agregar, corregir mediante anotación y solicitar borrado de foto, comprobante o video	Actor, cliente/guía, identificador de objeto, operación, resultado y correlación; autorización aprobada	Registros de acceso de Blob (`StorageRead`, `StorageWrite`, `StorageDelete`) y cambios de permisos en Azure Activity Log
Acceso a lecturas de temperatura	Calidad, torre, API y cliente: consultar, exportar, vincular a reclamo y reconocer alerta	Actor, cliente/guía o cuarto/camión, intervalo consultado, operación, resultado, identificador de alerta y correlación	Accesos a la cuenta de telemetría y evidencia cruda de IoT Hub; la identidad del sensor acredita el origen de la lectura, no el lector humano

Esquema común propuesto para la tabla de auditoría de negocio: `TimeGenerated` en UTC, `event_id` único, `actor_id` o identidad de servicio, `actor_type`, `role`, `action`, `resource_type`, `resource_id`, `client_id` cuando aplique, `outcome`, `reason_code`, `correlation_id`, `source_app` y `source_ip` cuando exista. En reclamos, la consulta por `client_id`/`resource_id` y período reúne el evento de acceso, la evidencia original y el acuse de alerta. Se registra el identificador del objeto, **sin copiar al log** el documento de identidad, el contenido de la guía, la posición completa, la temperatura en bruto, la firma, el video, credenciales o tokens. Se limita la exposición de IP y se restringe su consulta.

Los servicios producen los eventos en una tabla personalizada de Log Analytics mediante una regla de recopilación de datos y la API de ingesta de Azure Monitor, o mediante una canalización equivalente validada en la implementación. La identidad administrada de cada servicio obtiene permiso solo para escribir en esa regla. `event_id` permite detectar duplicados; se supervisan errores de envío y se reintentan sin bloquear la operación. La prueba de aceptación debe comprobar expresamente que un acceso denegado también queda registrado. Los diagnósticos de Azure no reemplazan estos eventos de aplicación.

3. Centralización y acceso a los registros

Fuente	Configuración propuesta	Destino y propósito
Servicios de aplicación: despacho, portal, archivo y calidad	Instrumentación del evento de negocio anterior, incluida identidad y resultado	Tabla de auditoría de negocio del Log Analytics central
Azure Activity Log de las cinco suscripciones	Diagnóstico de ámbito de suscripción para cambios de recursos, RBAC y configuración	Mismo espacio; investigar quién cambió controles
Microsoft Entra ID	Diagnósticos de inicio de sesión y auditoría de identidad, categorías disponibles según licencia	Mismo espacio; corroborar autenticación, MFA y cambios de identidad
Azure Firewall, Application Gateway/ WAF y flujos de red virtual	Categorías relevantes en modo de tabla específica por recurso cuando estén disponibles; evitar duplicados	Mismo espacio; tráfico, bloqueos y cambios de perímetro definidos en #9
Cuentas Blob de evidencias y telemetría	Diagnósticos **del servicio Blob**, incluidas categorías de lectura, escritura y borrado; verificar los campos de identidad disponibles	Mismo espacio; contrastar acceso directo a objetos y cambios. Los registros no sustituyen el control de acceso de la aplicación

Fuente	Configuración propuesta	Destino y propósito
IoT Hub, Stream Analytics y alertas de temperatura	Categorías diagnósticas aplicables y eventos de alerta/acuse del servicio	Mismo espacio para investigación; la evidencia cruda y la tabla Delta siguen en las cuentas de datos de #13
Defender for Cloud	Alertas de seguridad y notificaciones según los planes definidos por #10	Investigación por seguridad; no se presume que activar Defender registre accesos de negocio

La política P-04 de #5 aplica `DeployIfNotExists` a recursos compatibles y apunta al **mismo Log Analytics en `sub-fa-security`**. Hay que configurar aparte diagnósticos de ámbito de suscripción y de Entra ID, además de la instrumentación de aplicación. Se comprueba la compatibilidad de categorías, permisos y suscripciones cruzadas antes de habilitar la política. El equipo de plataforma valida cada mes que los recursos nuevos tengan diagnóstico y que lleguen eventos de ejemplo desde las cinco suscripciones; una ausencia de eventos es una alerta, no prueba de ausencia de accesos.

Seguridad conserva el control administrativo del espacio. Auditoría tiene lectura de las tablas que necesita y de las evidencias por un procedimiento autorizado; FinOps ve costos sin permisos de lectura de datos o logs sensibles. Las aplicaciones y desarrolladores no reciben lectura global del espacio. Las consultas de investigación y los cambios de retención quedan registrados; la matriz detallada de RBAC y MFA se alinea con #7.

4. Retención, integridad y eliminación

Información	Ubicación	Retención propuesta	Consulta y salida
Evidencias de entrega y trazabilidad cruda de temperatura, alertas y acuses	Contenedores de evidencia de Blob del diseño de cargas	**Cinco años contractuales** con política de inmutabilidad bloqueada, según el servicio que la almacena	Acceso autorizado para reclamos; eliminación al vencer el plazo y si no hay obligación adicional
Eventos de acceso a datos de clientes, evidencias y lecturas de temperatura	Tabla de auditoría de negocio en Log Analytics	**Cinco años de retención total**, con **90 días consultables** para operación y el resto a largo plazo	Investigación histórica mediante búsqueda sobre retención a largo plazo; comprobar que el evento existe durante todo el plazo contractual
Eventos de acceso directo a Blob y cambios de identidad/permisos relevantes para esos tres tipos de acceso	Tablas de recurso, actividad e identidad seleccionadas	**Cinco años de retención total** para las categorías necesarias para reconstruir un reclamo; 90 días consultables inicialmente	Reducir categorías de alto volumen después de medir, sin perder las que prueban lectura, escritura, borrado y cambios de permisos
Diagnósticos de funcionamiento y tráfico sin relación directa con reclamos (por ejemplo, solicitudes permitidas del firewall)	Tablas técnicas del mismo espacio	**90 días** como propuesta inicial; los eventos de seguridad que exijan más tiempo se clasifican por tabla	Análisis operativo; no se les atribuye automáticamente la obligación contractual de cinco años
Posiciones de camiones y tabla analítica de temperatura	Tabla Delta de análisis descrita en #13	Según #10 y #13, con posibilidad de corregir y borrar datos personales cuando proceda	No se vuelcan masivamente al log ni a un contenedor inmutable de auditoría

La retención en Log Analytics se fija **por tabla**, separando el período de consulta habitual de la retención total. El plazo de cinco años es una **decisión de diseño para la pista de auditoría relacionada con reclamos**; FríoAndes debe confirmar su alcance contractual y de protección de datos antes de bloquear una política de inmutabilidad. Si se abre un litigio o una investigación, seguridad preserva el conjunto concreto con el procedimiento de conservación aplicable y deja constancia de su entrega. Una política de retención de

Log Analytics, por sí misma, no vuelve inmutables los logs: la evidencia contractual inmutable vive en los contenedores de Blob definidos por las cargas.

Se revisan mensualmente volumen, costos, consultas a registros antiguos y fechas de expiración. El borrado al vencimiento se implementa en el almacén correspondiente y se registra; no se crean copias permanentes en Fabric ni en informes descargados. Para los registros que contienen datos personales, #10 define las solicitudes de acceso, corrección y supresión y las excepciones justificadas por obligaciones contractuales.

5. Modelo de facturación interna

Azure Cost Management agrupa primero por suscripción y después por `costo`, `ambiente` y `carga` de #5. Cada cargo se cuenta **una sola vez**. Los costos de plataformas comunes y los cargos sin etiqueta se muestran durante la conciliación, para que el total de las líneas internas coincida con el total facturado. No se asignan importes ficticios: los presupuestos y valores monetarios se tomarán de #25 a #28.

Línea visible a finanzas	Regla para costos directos	Ejemplos
Operación	En `sub-fa-prod`, `costo=operacion`; incluir `carga=logistica` y `archivo` que soporta la operación	Consola, portal, base, archivo histórico
Telemetría	En `sub-fa-prod`, `costo=telemetria`, aunque IoT Hub se ubique en Central US	IoT Hub, Stream Analytics, función de alerta y cuentas de telemetría
Pruebas	Todo costo de `sub-fa-test` y `sub-fa-dev` se reporta en esta línea por `ambiente=test/dev`, incluso cuando `carga=telemetria`	Sensores simulados, cómputo temporal, WAF de pruebas
Fabric	Identificar aparte los cargos de la capacidad de Microsoft Fabric por **recurso y medidor de facturación** en Cost Management, en la suscripción que la aloje; excluirlos de Operación/Telemetría	Capacidad F y cargos asociados que identifique #27; no asumir que cada cargo admite etiquetas
Compartido, antes de repartir	`sub-fa-security` y `sub-fa-connectivity`, más recursos `costo=compartido` de otras suscripciones	Log Analytics central, firewall, VPN Gateway, DNS

Regla de reparto propuesta para el informe interno: cada mes, después de excluir Fabric y Pruebas, calcular los costos directos de Operación (`O`) y Telemetría (`T`). Distribuir los costos compartidos (`S`) proporcionalmente: `Operación final = O + S × O/(O+T)` y `Telemetría final = T + S × T/(O+T)`. Se registra el valor de `O`, `T`, `S`, la regla aplicada y cualquier cargo no clasificado en la conciliación. Si `O+T=0`, se deja `S` como Compartido sin reparto. Es un criterio inicial de **showback**, sujeto a aprobación de FinOps; el porcentaje se sustituye por medidores de consumo más representativos si existen. Las reglas de asignación de Cost Management pueden hacer el reparto en el ámbito de facturación compatible; si no está disponible, se aplica al export mensual sin alterar la factura oficial. No se reparte ni se factura dos veces el mismo cargo.

La cuenta de evidencia de telemetría en Central US sigue siendo **Telemetría**, no un costo de infraestructura común. El historial del archivo de 1,2 PB sigue siendo **Operación**; si Fabric lo consulta mediante accesos directos, no se contabiliza una segunda copia del archivo. Los presupuestos por suscripción de #5 se mantienen (alertas propuestas al 80 %, 100 % y 120 % del gasto real, y 100 % previsto) y la vista de Fabric tiene presupuesto propio. Las alertas financieras no detienen recursos de despacho ni telemetría. La atribución se revisa con #27 y el consolidado de #28.

Conciliación mensual: FinOps exporta el costo real o amortizado de un período consistente; clasifica Fabric por recurso/medidor, luego dev/test, después producción por etiquetas, y finalmente reparte Compartido. Compara la suma final con el total del ámbito facturado, identifica cargos sin etiqueta o sin recurso y corrige la clasificación con un propietario. Las etiquetas de RG no se suponen heredadas automáticamente por los recursos: se aplican según #5; cuando un tipo no admite etiquetas se usa suscripción, RG y un registro

de excepciones. Se documenta por separado cualquier compra de reserva o crédito que cambie el costo efectivo.

6. Verificación y decisiones abiertas

Prueba para la implementación	Resultado que se debe demostrar
Consultar una guía propia y una ajena; leer una evidencia; consultar un intervalo de temperatura; reconocer una alerta	Los eventos permitidos y denegados tienen actor, objeto, hora UTC, resultado y correlación; la evidencia original se localiza sin guardar su contenido en el log
Acceder directamente a un blob y cambiar una regla de acceso	Los diagnósticos del servicio Blob y el Activity Log registran las operaciones; seguridad puede relacionarlas con el evento de negocio cuando hay correlación disponible
Simular alta de recurso en cada suscripción y pérdida de diagnóstico	P-04 y las configuraciones complementarias envían eventos al espacio de `sub-fa-security`; la falta de recepción genera incidencia
Buscar un evento fuera de los 90 días de consulta habitual	Se recupera mediante la retención a largo plazo antes de los cinco años; se prueba el procedimiento y su autorización
Comparar Cost Management con las cuatro líneas y el reparto	Operación + Telemetría + Pruebas + Fabric iguala el ámbito conciliado, incluyendo Compartido repartido y excepciones explicadas

Confirmaciones de FríoAndes: responsable de auditoría y personas autorizadas; alcance exacto de los contratos de cinco años para los logs de acceso; procedimiento de conservación por litigio; ubicación definitiva de datos personales; suscripción y modalidad de compra de Fabric; presupuesto mensual y criterio de showback compartido. No se presenta ninguna prueba de consulta, costo o retención como ejecutada: este documento establece qué debe verificarse al implementar.

7. Referencias técnicas

- Microsoft Learn — diagnósticos y destinos de Azure Monitor
- Microsoft Learn — políticas integradas para enviar diagnósticos a Log Analytics
- Microsoft Learn — API de ingesta de logs de aplicación
- Microsoft Learn — retención por tabla de Log Analytics
- Microsoft Learn — supervisión de Blob Storage
- Microsoft Learn — asignación de costos compartidos
- Microsoft Learn — facturación de la capacidad Fabric

2. Seguridad

FríoAndes — IAM de mínimo privilegio, MFA y cifrado

1. Objetivo y límites de confianza

Los 450 usuarios internos y los aproximadamente 2.000 usuarios de clientes corporativos no deben compartir los mismos privilegios. La consola de despacho muestra ubicación de cargas y datos de clientes: solo es accesible desde la red corporativa por el camino privado definido en #8 y #9, y exige autenticación multifactor (**MFA**). El portal público pasa por el WAF, pero una sesión válida solo puede consultar las guías de su propio cliente; ni el WAF ni una etiqueta de Azure sustituyen esa autorización de negocio.

Se utiliza el **tenant corporativo de Microsoft Entra ID** de #5, con grupos distintos y permisos explícitos en aplicaciones y Azure. Para los clientes se propone colaboración B2B: usuarios externos invitados como *guest* a la aplicación del portal en el mismo tenant. El alta y baja las aprueba un administrador de cada cliente y FríoAndes; no se conceden roles Azure RBAC a esos invitados. Antes del despliegue se validan licencias, experiencia de acceso y el sistema de identidad real de los clientes. Si se escogiera un servicio de identidad para consumidores en otro tenant, habría que actualizar este diseño, las políticas y la integración con Fabric.

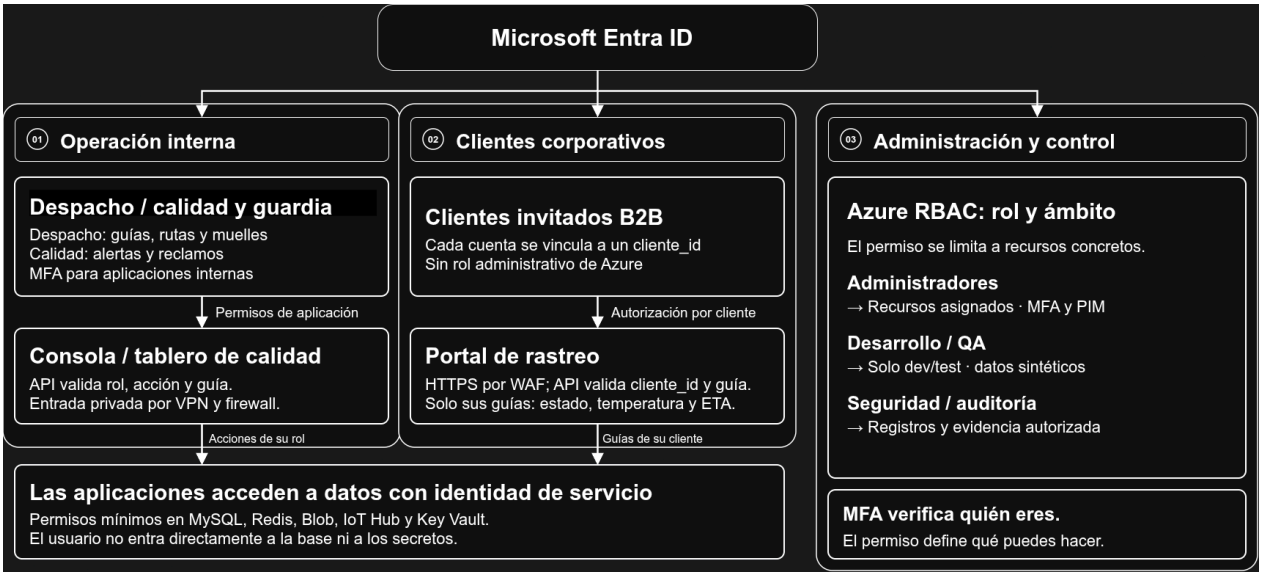


Figura 3: Identidades y permisos: operación interna, clientes corporativos y administración, sobre Microsoft Entra ID

2. Matriz de roles y autorizaciones

grp-fa-governance, grp-fa-security, grp-fa-network, grp-fa-dev, grp-fa-qa, grp-fa-ops-prod y grp-fa-finops gobiernan Azure por suscripción o grupo de recursos. Los siguientes roles funcionales se asignan a grupos de Entra ID y se traducen a permisos dentro de cada servicio. La aplicación siempre verifica `cliente_id`, guía y acción en el servidor; nunca confía solo en lo que muestra la interfaz.

Rol	Consola / portal	Datos y evidencias	Azure y ambientes	MFA y condición de acceso
Administradores de plataforma (`grp-fa-ops-prod` y grupo de gobernanza según función)	No reciben permisos de despacho por administrar Azure	Sin lectura rutinaria de datos de clientes ni secretos; acceso excepcional aprobado y auditado	Rol Azure específico para cada recurso y suscripción; elevación temporal para cambios productivos	**Obligatorio** con política de acceso condicional; método resistente a phishing para privilegios altos cuando esté

Rol	Consola / portal	Datos y evidencias	Azure y ambientes	MFA y condición de acceso
				disponible; activación con PIM según licencias
Despachadores (`grp-fa-despacho`)	Consola interna: crear y actualizar guías, asignar ruta/muelle y consultar estado de la flota; sin administración del portal	Datos de las guías necesarias para operar y posición en vivo; no video completo salvo procedimiento de reclamo autorizado	Ningún rol de administración de Azure	**Obligatorio en la consola**, además de origen en red corporativa; acceso remoto a la consola solo si #11 define y autoriza esa contingencia
Calidad y guardia (`grp-fa-calidad`, turno de guardia controlado por la aplicación)	Tablero de calidad; reconocer alertas según horario de #13; no asignar rutas	Temperatura, alertas, evidencias y video necesarios para un reclamo, con acceso registrado; sin modificación de la evidencia inmutable	Ningún rol de administración de Azure	MFA obligatorio para aplicaciones internas con datos sensibles; el turno de guardia no amplía permisos de Azure
Desarrolladores (`grp-fa-dev`)	Servicios y datos sintéticos en desarrollo; sin consola productiva	Sin datos personales reales ni acceso al archivo productivo	Contributor solo en RG autorizados de `sub-fa-dev`; despliegue productivo por identidad del pipeline con aprobación	MFA en acceso interactivo a Azure; sin Owner global ni asignación de roles
QA (`grp-fa-qa`)	Ejecutar pruebas en `sub-fa-test` con usuarios y sensores simulados	Datos sintéticos o anonimizados; sin evidencias de producción	Lectura y permisos de ejecución específicos en test; sin administración de producción	MFA en acceso interactivo a Azure
Clientes corporativos (invitados B2B y vínculo a un `cliente_id`)	Solo portal: estado, temperatura y ETA de **sus** guías	Comprobante propio únicamente si #10 lo confirma; sin flota completa, posición exacta, datos del conductor, video ni guías ajenas	Ningún rol Azure RBAC, ni acceso a torre, Fabric administrativo o Key Vault	Inicio de sesión en Entra ID; MFA según política para invitados y riesgo del portal; sesiones y revocación definidas por FríoAndes
Seguridad y auditoría (`grp-fa-security`)	No operan despacho por pertenecer a seguridad	Lectura autorizada de registros y evidencia para investigaciones, con trazabilidad; sin edición de evidencia	Permisos de investigación limitados en `sub-fa-security`; sin modificar cargas de negocio por defecto	**Obligatorio** para administradores de seguridad; elevación temporal para operaciones privilegiadas

FinOps (`grp-fa-finops`) solo lee Cost Management y no recibe acceso a datos o secretos. Redes (`grp-fa-network`) administra recursos de `sub-fa-connectivity`, sin privilegios de base de datos. Los permisos por grupo no se heredan automáticamente a las otras suscripciones. Las identidades de los servicios no son usuarios humanos: se definen por separado en la sección 4.

2.1 Cómo se hace cumplir

1. **Inicio de sesión:** Entra ID autentica usuarios internos y invitados. Acceso condicional exige MFA para administradores y para la aplicación de la consola; prueba primero las políticas en modo de informe antes de habilitarlas. Se preservan cuentas de emergencia controladas, excluidas solo de la política que podría bloquear una recuperación y vigiladas con alertas.

2. **Red:** la consola solo acepta solicitudes desde la red corporativa privada, con las reglas de #8 y #9. MFA no convierte un origen de internet en una red corporativa. El portal público se publica únicamente por el WAF y no ofrece una ruta hacia la torre.
3. **Autorización de negocio:** las API validan el token de Entra ID (emisor, audiencia y vigencia), el rol y la relación del usuario con el `cliente_id`/guía de **cada solicitud**. El cliente corporativo no elige el `cliente_id` confiable mediante un parámetro; la aplicación lo resuelve desde su vínculo administrado. Las consultas de Fabric del portal aplican filtrado por cliente como se describe en #13.
4. **Revisión:** baja inmediata al terminar empleo/contrato, revisión trimestral de accesos productivos e invitados; cambios de rol, lecturas sensibles y accesos denegados se registran según gobierno-auditoria--facturacion. Se prueba con una cuenta por rol y con intentos de consultar una guía ajena.

3. Cifrado en tránsito y en reposo

La red privada limita quién puede conectarse; **el cifrado protege los datos que viajan o se almacenan**. Se deshabilitan protocolos y accesos inseguros donde el servicio lo permita. Azure cifra por defecto los servicios de datos indicados; Key Vault custodia los secretos, certificados y las claves administradas por FríoAndes cuando se decida usarlas. Usar Key Vault para un secreto de aplicación no significa que ese servicio use automáticamente una clave administrada por cliente para todo su almacenamiento.

Datos / servicio	Tránsito	Reposo y llaves	Acceso a la llave o secreto
Base transaccional: Azure Database for MySQL Flexible Server	TLS 1.2 como mínimo entre servicios y base, con validación de certificado; solo conexión privada desde servicios autorizados. TLS 1.3 tras comprobar compatibilidad de MySQL y conectores	Cifrado del servicio para datos, logs y copias. Si FríoAndes exige control de llaves propio, CMK en el Key Vault de producción con identidad administrada del servidor y prueba de restauración; la pérdida de acceso a la llave afecta la disponibilidad	Aplicaciones con identidad propia y permisos de base mínimos; credenciales que todavía hagan falta en Key Vault, sin contraseñas en repositorio
Caché: Azure Managed Redis	TLS 1.2/1.3; deshabilitar conexiones sin TLS y usar endpoint privado	Si se habilita persistencia, cifrado de discos del servicio; CMK solo si el plan y la necesidad contractual lo justifican. El contenido en memoria no se protege por cifrado de disco: TTL corto y evitar guardar más datos personales de los necesarios	Identidades de los servicios autorizados; secretos residuales en Key Vault si el mecanismo de autenticación elegido los requiere
Archivo histórico y evidencias: Azure Blob Storage	HTTPS obligatorio y TLS mínimo 1.2, incluso para copia y lectura; acceso por endpoints privados según #8 y #9	Cifrado de Azure Storage en reposo; CMK de Key Vault para cuentas de evidencias si se requiere control de llaves del cliente. La retención inmutable de cinco años, cuando aplique al tipo de evidencia, se define por separado: el cifrado no impide el borrado	Identidades administradas con roles Blob limitados por cuenta/contenedor; no distribuir claves de cuenta ni SAS de larga vida
Telemetría: IoT Hub, procesamiento y cuentas Blob de evidencia/tabla Delta	Camiones por red móvil y cuartos fríos por VPN, ambos con MQTT/AMQP/HTTPS sobre TLS 1.2 y	IoT Hub cifra el contenido almacenado con llaves del servicio; las cuentas Blob de evidencia cruda (Central	DPS e IoT Hub autentican dispositivos; la credencial por camión/cuarto no es la identidad de un usuario

Datos / servicio	Tránsito	Reposo y llaves	Acceso a la llave o secreto
	credencial única por dispositivo según #13. IoT Hub público para camiones y privado para centros	US) y análisis (East US 2) cifran en reposo, con CMK en Key Vault regional si se aprueba. Las posiciones no van al contenedor inmutable, conforme a #13	humano. IoT Hub y Stream Analytics escriben a sus cuentas con identidades administradas y reglas de instancia definidas en #13
Portal, consola y administración	HTTPS extremo a extremo; Application Gateway y portal por HTTPS interno; sesiones administrativas por Bastion sin publicar SSH/RDP	Certificado público del portal en Key Vault del ambiente, leído por identidad administrada de Application Gateway como define #9; secretos operativos y del pipeline en bóvedas separadas por ambiente	Solo las identidades de servicio que lo consumen; renovación y alertas por vencimiento y acceso fallido

Decisión de claves: se propone cifrado administrado por Azure como base para todos los servicios y CMK en producción para los almacenes de evidencia contractual y, sujeto a confirmación de FríoAndes, la base de datos. Se prueba el comportamiento de restauración y conmutación antes de activar CMK en servicios críticos; CMK añade dependencia de disponibilidad y costo de operación de Key Vault. La capacidad de CMK en Redis e IoT Hub se evalúa únicamente si una obligación la exige y el SKU usado la admite. No se asume que Key Vault cifre directamente cada lectura: entrega o protege las llaves que utiliza el servicio compatible.

4. Gestión de secretos, certificados y permisos de servicio

- **Bóvedas por ambiente:** `kv-fa-prod`, `kv-fa-test` y `kv-fa-dev` como nombres propuestos, dentro de sus suscripciones; no compartir secretos productivos con dev/test. Las claves para CMK que se necesitan en Central US se ubican y replican según los requisitos del servicio y el plan regional, sin prometer que una sola bóveda regional resuelve por sí misma la continuidad.
- **Protección:** Azure RBAC como modelo de acceso a la bóveda, endpoint privado, eliminación temporal y protección contra purga. Separar el administrador de la bóveda del lector de secretos y del usuario de claves. Registrar lectura/rotación/borrado en el Log Analytics central de #6.
- **Aplicaciones:** identidad administrada por carga y ambiente. Por ejemplo, la identidad del Application Gateway solo lee el certificado del portal, la del servicio de guías solo sus secretos y datos, y la de la función de alertas solo lo necesario para notificar y registrar acuses. No conceder `Key Vault Administrator` a los servicios.
- **Pipeline:** identidad de despliegue distinta para dev, test y prod, preferiblemente con federación OIDC en lugar de un secreto duradero en GitHub. Leer desde Key Vault únicamente los secretos que una herramienta no pueda reemplazar por identidad; aprobación y permisos mínimos para producción.
- **Rotación:** fechas de vencimiento y alertas para secretos/certificados; rotar de forma controlada y probar consumidores antes de retirar versiones. La rotación de una CMK debe conservar acceso a versiones anteriores mientras existan datos/copia cifrados con ellas. Ninguna llave, cadena de conexión o certificado privado se sube a Git.

5. Verificación y decisiones por confirmar

Prueba de aceptación del diseño	Evidencia esperada al implementar
Administrador sin MFA intenta entrar a Azure y despachador sin MFA intenta abrir la consola	Acceso denegado en ambos casos; la consola tampoco responde desde internet aunque se tenga una sesión válida

Prueba de aceptación del diseño	Evidencia esperada al implementar
Cliente A consulta una guía de B; despachador intenta abrir el video completo; dev intenta cambiar producción	Denegación en aplicación/RBAC y evento de auditoría; un permiso administrativo no equivale a un permiso de lectura de negocio
Aplicación lee MySQL, Redis, Blob y telemetría	Conexión TLS válida; protocolos inseguros rechazados; datos persistidos cifrados; restauración de base y lectura de evidencia verificadas
Identidad de Application Gateway, pipeline y servicios solicita secretos ajenos	Acceso denegado por RBAC de Key Vault; acceso autorizado queda auditado; expiración/rotación generan alerta
Se retira temporalmente el acceso a una CMK en pruebas	Se documenta el fallo y el procedimiento de recuperación antes de usar CMK en producción

6. Referencias técnicas

- Microsoft Learn — MFA resistente a phishing para administradores
- Microsoft Learn — colaboración B2B en un tenant de empleados
- Microsoft Learn — seguridad de MySQL Flexible Server
- Microsoft Learn — seguridad de Azure Managed Redis
- Microsoft Learn — cifrado de Azure Storage
- Microsoft Learn — TLS en IoT Hub
- Microsoft Learn — protección de Azure Key Vault
- Microsoft Learn — federación OIDC para GitHub Actions

Datos personales, perímetro público y detección de actividad anómala

Este documento identifica los datos personales de conductores y destinatarios que maneja la plataforma de FríoAndes, dice dónde viven, quién los ve y cuánto tiempo se conservan, y los concilia con la retención contractual de cinco años y con la Ley 1581 de 2012. También define cómo se protege el portal de rastreo frente al abuso, con límites de solicitudes dimensionados para el pico de campaña, y cómo se detecta la actividad anómala. Parte de la red, del firewall, de la telemetría y de la landing zone ya diseñados, y usa sus mismos nombres.

Términos usados

Término	Significado en este documento
Titular	La persona a quien se refieren los datos: un conductor, un destinatario, un usuario de un cliente corporativo o un empleado
Responsable del tratamiento	Quien decide sobre los datos y para qué se usan (Ley 1581, artículo 3)
Encargado del tratamiento	Quien trata los datos por cuenta del responsable, por ejemplo un proveedor de nube (Ley 1581, artículo 3)
Dato sensible	Dato que afecta la intimidad o puede generar discriminación, como los datos de salud o los biométricos (Ley 1581, artículo 5)
Transmisión	Envío de datos a un encargado, dentro o fuera de Colombia, para que los trate por cuenta del responsable (Decreto 1377 de 2013, artículo 3)
Transferencia	Envío de datos a otro responsable, dentro o fuera de Colombia (Decreto 1377 de 2013, artículo 3)
Guía	El documento de cada envío: remitente, destinatario, carga y estado
Comprobante de entrega	La constancia que firma el destinatario al recibir, con su foto o PDF

1. Contexto y alcance

1.1 Qué resuelve este documento

Este documento responde dos necesidades de seguridad de FríoAndes:

Necesidad	Qué implica	Dónde se responde
Datos personales	Tratamiento de datos personales de conductores y destinatarios. No hay datos de pago con tarjeta. Las evidencias y la trazabilidad de temperatura se conservan cinco años por contrato con los clientes de alimentos	Secciones 2 y 3
Perímetro público	Protección del perímetro público (el portal de rastreo) y detección de actividad anómala	Secciones 4 y 5

Las cifras para dimensionar el portal: unos 2.000 clientes corporativos habilitados, un pico ordinario de cerca de 800 solicitudes por minuto y, en campaña, 2.000 solicitudes por minuto durante unas cuatro horas.

La residencia de los datos personales que toca Microsoft Fabric la define `fabric-workspaces-ingesta-region.md` (sección 7), con el inventario y la posición sobre la ubicación de los datos de este documento (sección 3).

1.2 Quién usa el portal

El portal de rastreo está publicado en internet; la consola de despacho, en cambio, solo se usa desde la red corporativa. Lo usan los unos 2.000 clientes corporativos habilitados: cada uno se identifica y consulta solo sus guías, en una vista acotada.

Los destinatarios son titulares de datos y no tienen acceso al portal, y no hay consultas de guías sin identificarse. Por eso este documento diseña un portal en internet, de uso exclusivo de los clientes corporativos habilitados, donde cada uno ve solo sus guías. No está definido si los 2.000 clientes son empresas o usuarios; la sección 4 lo trata como supuesto.

1.3 Qué toma de los otros diseños

Ya definido	Dónde
La plataforma vive en East US 2 y la telemetría usa además Central US. Que los datos queden en Estados Unidos es un supuesto por confirmar	Red, secciones 3.5, 3.7 y 3.8
Torre, portal, ingesta y analítica tienen subredes propias. La torre no tiene ninguna entrada desde internet	Red, sección 5
El portal se publica con Application Gateway WAF v2 (Default Rule Set 2.2, Bot Manager 1.1, modo prevención), con 20 unidades de capacidad reservadas para el pico de campaña. El Application Gateway entrega la IP real del cliente	Firewall, secciones 3.3 y 3.4
Los registros del firewall, del Application Gateway y del WAF van al espacio de Log Analytics de la plataforma	Firewall, sección 6.1
La posición de los camiones queda en una copia de evidencia inmutable por cinco años en Central US. La vista del cliente muestra estado, temperatura y hora estimada de llegada, sin la flota ni la posición exacta del camión	Telemetría, secciones 4.3, 4.4 y 5.5
Suscripciones separadas para seguridad, conectividad, producción, desarrollo y pruebas. Log Analytics vive en la suscripción de seguridad. Desarrollo y pruebas usan datos sintéticos o anonimizados	Landing zone, secciones 3 y 5

1.4 Qué queda en otros diseños

Tema	Diseño que lo define
Qué eventos de acceso se auditan (datos de clientes, evidencias y lecturas de temperatura) y cuánto tiempo se guardan los registros	Auditoría, retención y facturación interna
Roles, MFA, identidades de los clientes en el portal y cifrado con Key Vault	Identidades, accesos y cifrado
Cómo opera el equipo las alertas de seguridad y los tableros de operación	Observabilidad
Región de Fabric, espacios de trabajo y qué datos lee o copia	`fabric-workspaces-ingesta-region.md`

Tema	Diseño que lo define
Acceso de calidad, torre y clientes a Fabric	`fabric-acceso-casos-uso-costo.md`

---

2. Datos personales: qué hay, dónde vive y quién lo ve

2.1 Titulares y datos

Los titulares principales son los conductores y los destinatarios. Sus datos exactos no están documentados, así que los de esta tabla salen de lo que la operación necesita para despachar, entregar y responder reclamos. FríoAndes los confirma contra el inventario real de su base (sección 7).

Titular	Datos	De dónde salen	Para qué se usan
Conductor	Nombre, documento de identidad, licencia de conducción, teléfono, camión y viajes asignados	Registro del conductor en la plataforma	Asignar rutas y responder por cada viaje
Conductor	Posición del camión cada 30 segundos durante la jornada, con la hora	Telemetría del camión	Rastreo, hora estimada de llegada, reclamos de cadena de frío
Conductor	Imagen en el video de muelles y de entregas	Cámaras de muelles y de los camiones	Evidencia de cargue y entrega
Destinatario	Nombre, dirección de entrega y teléfono	La guía que crea el cliente corporativo	Entregar la carga
Destinatario	Documento de identidad y firma de quien recibe	Comprobante de entrega	Constancia de la entrega
Destinatario	Imagen en la foto o el video de la entrega	Foto del comprobante y video de entregas	Evidencia de la entrega y de la carga
Usuario de un cliente corporativo	Nombre, correo, cuenta del portal, IP y actividad en el portal	Alta del usuario y uso del portal	Dar acceso a sus guías y detectar abuso
Empleado de FríoAndes	Identidad corporativa, acciones en la torre y en la plataforma, teléfono de la guardia de calidad, acuses de alertas	Entra ID, registros y la tabla de turnos	Operar, auditar quién hizo qué y avisar de noche

Los usuarios de los clientes y los empleados también son titulares, y sus datos pasan por los mismos sistemas. El documento los incluye para que el inventario quede completo.

No hay datos de pago con tarjeta. La plataforma no procesa pagos con tarjeta, y eso deja fuera de alcance las normas de la industria de tarjetas (PCI DSS).

2.2 Datos sensibles: imágenes y firmas

La Ley 1581 define dato personal como cualquier información vinculada o que pueda asociarse a personas determinadas o determinables (artículo 3), y trata los datos biométricos como sensibles (artículo 5). La Superintendencia de Industria y Comercio (SIC) reitera que la biometría implica datos sensibles y exige una autorización previa, expresa, informada y cualificada, que el titular no está obligado a dar.

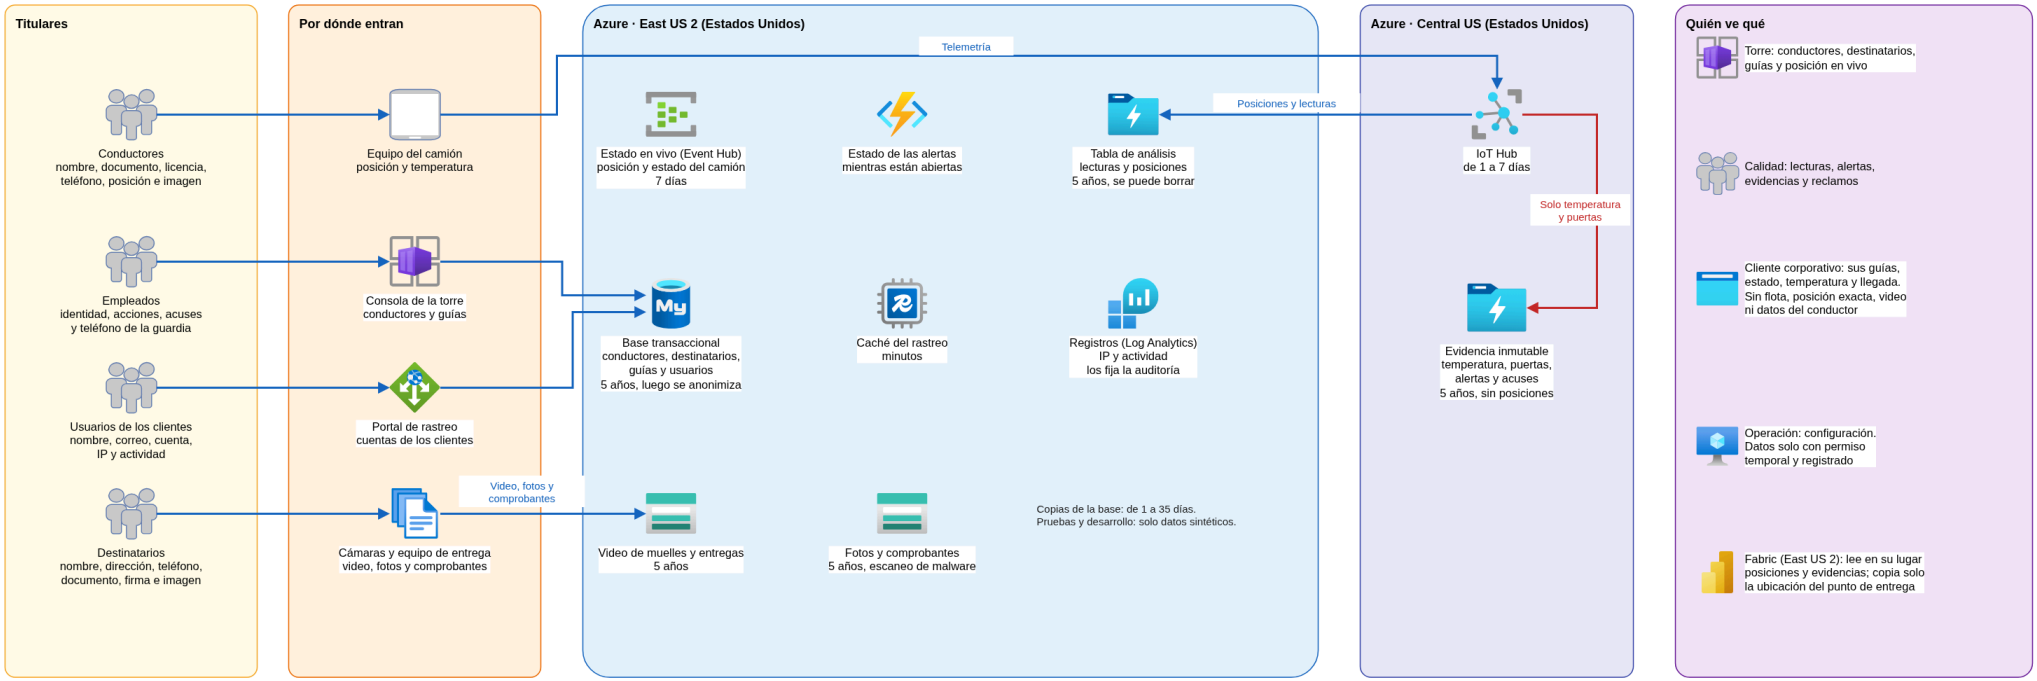
Dato	Es dato personal	Cómo lo trata el diseño
Video de muelles y de entregas donde aparecen conductores, trabajadores o destinatarios	Sí: una persona en la imagen es determinable	Con las protecciones de un dato sensible: acceso restringido a calidad y a quien atiende un reclamo, sin

Dato	Es dato personal	Cómo lo trata el diseño
		acceso del cliente y sin reconocimiento facial
Fotos de entregas y comprobantes con la firma de quien recibe	Sí	Igual que el video, salvo que el cliente pueda ver el comprobante de sus propias entregas, si FríoAndes lo confirma (sección 7)
Posición del camión durante la jornada	Sí: se asocia al conductor del viaje	Dato personal no sensible según el artículo 5, pero revela dónde está una persona. Solo la torre ve la posición exacta

Ningún componente hace reconocimiento facial ni identifica personas por su imagen. El apoyo de Fabric al archivo de evidencias se limita a marcar fotos ilegibles o con carga visiblemente dañada. Si un uso futuro identificara personas por su rostro, los datos pasarían a ser biométricos y necesitarían la autorización especial del artículo 6.

2.3 Dónde vive cada dato

Datos personales: por dónde entran, dónde viven, cuánto duran y quién los ve



Azul: datos que entran. Rojo: lo único que va a la copia inmutable. Todo queda en la geografía de Estados Unidos de Azure; Microsoft trata los datos como encargado. El datacenter de Cali conserva todo hasta su apagado (día 90 a más tardar) y después se borra de forma segura. Al cumplirse cinco años, las evidencias se borran y la base anonimiza los campos personales.

Figura 4: Datos personales: por dónde entran, dónde viven, cuánto duran y quién los ve

Componente	Ubicación	Datos personales	Quién accede	Cuánto se conserva
Base transaccional (MySQL Flexible)	`snet-data`, East US 2	Conductores, destinatarios, guías, usuarios de clientes	Torre, portal (solo las guías del cliente), calidad, operación con permisos temporales	Lo que dure la finalidad (sección 3). Copias automáticas de 1 a 35 días, 7 por defecto
Caché del rastreo (Azure Managed Redis)	`snet-data-pe`, East US 2	Respuestas recientes del rastreo, con el destinatario de la guía	Solo los servicios del portal y de la torre	Minutos, con vencimiento automático de cada entrada
Archivo de evidencias (Blob)	`snet-archive`, East US 2	Video, fotos, comprobantes y PDF	Calidad, quien atiende un reclamo y Fabric, por atajo con la identidad de su espacio de datos (solo fotos y comprobantes nuevos y clips de reclamos)	Cinco años por contrato
Evidencia cruda de telemetría	Central US, copia secundaria en East US 2	Temperatura y puertas de cada camión con su hora, alertas y acuses con la identidad de quien respondió. No guarda posiciones (sección 3.5)	Calidad y quien atiende un reclamo; nadie puede modificarla	Cinco años, inmutable
Tabla de análisis de telemetría	East US 2	Lecturas con guía y cliente, y las posiciones de los camiones	Tableros de calidad y Fabric	Cinco años
Event Hub del estado en vivo	`snet-data-pe`, East US 2	Última posición y estado de cada camión	Torre	Hasta 7 días
IoT Hub	Central US	Mensajes de los camiones en tránsito	Stream Analytics	1 día por defecto, hasta 7
Cuenta de la función notificadora	`snet-data-pe`, East US 2	Estado de cada alerta y quién la reconoció	La función notificadora	Mientras la alerta está abierta; el registro final va a la evidencia
Fabric	East US 2 (capacidad y OneLake); permisos y metadatos en la región principal del tenant	Lee en su lugar las posiciones y las evidencias. Copia solo vistas del libro operativo, con la ubicación del punto de entrega como único dato personal, y guarda el resultado de la revisión de evidencias sin imágenes. Las fotos que revisa con funciones de IA se procesan en el servicio de Azure OpenAI de Fabric en	Torre, calidad y, en la vista insertada, cada cliente sobre sus guías	Lo copiado y los resultados, cinco años con la misma regla de borrado

Componente	Ubicación	Datos personales	Quién accede	Cuánto se conserva
		Estados Unidos, que no las guarda		
Registros (Log Analytics)	Suscripción de seguridad, en la región principal	IP y actividad de los usuarios del portal, rutas consultadas, identidad de los empleados	Seguridad y operación	Lo que fija el diseño de auditoría
Identidades (Entra ID)	Tenant de FríoAndes	Empleados y, si así lo define el diseño de identidades, usuarios de clientes	Administración de identidades	Mientras la cuenta esté activa
Canales de alerta (Teams, correo, SMS)	Microsoft 365 de FríoAndes, Azure Communication Services y el proveedor de SMS	Teléfonos y correos de la guardia. Las alertas llevan solo camión, guía y temperatura	Torre y guardia de calidad	Lo que conserve cada servicio
Cali durante la convivencia	Datacenter de Cali	Todo lo anterior en su versión actual: base MySQL 5.7, NFS y registros de Nginx	Lo que permite hoy el datacenter	Hasta que se apague, como máximo el día 90

Pruebas y desarrollo no tienen datos personales reales. Usan datos sintéticos o anonimizados y sensores simulados, como fijaron la landing zone y el firewall. Por eso no se migra ningún dato de la máquina de pruebas que hoy tiene Cali (MySQL 5.7). No está documentado qué contiene, así que el diseño no depende de eso: al apagar Cali, y después de verificar que la migración llegó completa, se borran de forma segura los discos de todos los servidores que guardaron datos personales (base, archivo NFS, pruebas y registros de Nginx).

2.4 Quién ve qué

Quién	Qué ve	Qué no ve
Despachador en la torre de control	Conductores, destinatarios y guías, posición en vivo de la flota	El video completo del archivo, salvo que atienda un reclamo
Calidad	Lecturas, alertas y acuses, evidencias y comprobantes, posición histórica para reclamos	Datos que no tengan que ver con la cadena de frío o con un reclamo
Cliente corporativo	Sus guías: estado, temperatura, hora estimada de llegada, el destinatario que él mismo registró y, si se confirma, el comprobante de su entrega	La flota, la posición exacta del camión, el video, los datos del conductor y las guías de otros clientes
Operación y administración	La configuración de los servicios. Los datos solo con un permiso temporal y registrado	Datos de negocio por defecto
Analítica en Fabric	Lo que la matriz de acceso de Fabric autorice para cada espacio de trabajo (`fabric-acceso-casos-uso-costo.md`)	Lo que no autorice. Nombres, teléfonos, documentos y direcciones escritas no entran a Fabric
Microsoft, como proveedor de nube	Ningún acceso de rutina: trata los datos por cuenta de FríoAndes (sección 3)	

La vista del cliente es acotada, su acceso sigue el mínimo privilegio y no incluye la flota completa ni el video. Con ese criterio, el cliente tampoco ve los datos del conductor ni la posición exacta del camión: para seguir su carga le bastan el estado, la temperatura y la hora estimada de llegada. Un camión puede llevar carga de varios clientes, así que su posición revela rutas de otros clientes y dónde está el conductor. La torre solo se

usa desde la red corporativa justamente porque muestra la ubicación de la carga. El rol de cada persona y su MFA los define el diseño de identidades.

2.5 Dónde quedan geográficamente

Lugar	Qué datos
Estados Unidos, East US 2	La base, la caché, el archivo de evidencias, la tabla de análisis de telemetría, el Event Hub del estado en vivo, los registros, la copia secundaria de la evidencia de telemetría y la capacidad de Fabric con su OneLake
Estados Unidos, Central US	IoT Hub y la evidencia cruda de telemetría
Colombia, datacenter de Cali	Todo, hasta el apagado del día 90 a más tardar
Por definir	El proveedor de SMS, el tenant de Microsoft 365 y la región principal del tenant de Fabric, donde quedan permisos y metadatos de reportes

Con esta arquitectura, los datos personales de conductores y destinatarios salen de Colombia hacia Estados Unidos. La sección 3 explica qué exige la ley para eso.

---

3. Cumplimiento y retención

3.1 Qué normas aplican

Norma o compromiso	Aplica	Por qué
Ley 1581 de 2012 y Decreto 1377 de 2013 (protección de datos personales en Colombia)	Sí	La plataforma trata datos de personas naturales: conductores, destinatarios, usuarios de los clientes y empleados
Contrato con los clientes de alimentos	Sí	Obliga a conservar cinco años las evidencias y la trazabilidad de temperatura
Normas de la industria de tarjetas (PCI DSS)	No	No hay datos de pago con tarjeta
Registro Nacional de Bases de Datos de la SIC	Si FríoAndes tiene más de 100.000 UVT de activos totales	La SIC lo exige solo a las sociedades por encima de ese umbral (Decreto 090 de 2018). El registro declara, entre otras cosas, las transmisiones al exterior

3.2 Quién responde por cada dato

Datos	Responsable	Encargados	Cómo queda pactado
Conductores, empleados y usuarios de los clientes	FríoAndes	Microsoft (Azure, Microsoft 365, Azure Communication Services) y el proveedor de SMS	Autorización de cada titular y contrato con cada encargado
Destinatarios	FríoAndes	Los mismos	El cliente corporativo garantiza en su contrato con FríoAndes que obtuvo la autorización del destinatario para compartir sus datos con la transportadora

Por qué FríoAndes es responsable también de los datos de los destinatarios. La ley llama responsable a quien decide sobre la base de datos o sobre el tratamiento (artículo 3). FríoAndes produce las evidencias de entrega (fotos, comprobantes y video), las conserva cinco años por su propio contrato con los clientes de alimentos y decide para qué se usan: entregar, probar la entrega, responder reclamos, estimar llegadas y apoyar el archivo de evidencias con Fabric. Lo que viene del cliente es el dato inicial del destinatario en la guía, y por eso la cláusula de la tabla.

3.3 Los datos en Estados Unidos

Con la arquitectura propuesta, los datos personales salen de Colombia hacia Azure en Estados Unidos. Microsoft no decide sobre esos datos: los trata por cuenta de FríoAndes, según su adenda de protección de datos (DPA). Por eso el envío es una **transmisión** a un encargado, que el Decreto 1377 distingue de la transferencia a otro responsable (artículo 3).

La transmisión queda cubierta por dos vías:

Vía	Qué dice la norma	Qué hace FríoAndes
Contrato de transmisión	Una transmisión internacional a un encargado no requiere informar al titular ni pedir su consentimiento si hay un contrato con el alcance del tratamiento, las actividades del encargado y sus obligaciones de seguridad y confidencialidad (Decreto 1377, artículos 24 y 25)	Revisar que la DPA de Microsoft, que acepta al contratar Azure, cubra esos puntos, y firmar un contrato equivalente con el proveedor de SMS
País con nivel adecuado	La SIC lista los países con nivel adecuado de protección y Estados Unidos está en la lista. A esos países también se puede transmitir (Circular Única de la SIC, Título V, numeral 3.2)	Conservar la evidencia de las medidas aplicadas, porque la SIC exige demostrarlas aunque el país esté en la lista

Los datos no salen de Estados Unidos. Cada región de Azure pertenece a una geografía que es una frontera fija de residencia de datos. East US 2 y Central US están en la geografía de Estados Unidos, así que la copia geográfica de la evidencia de telemetría queda dentro del país. Microsoft no accede a los datos por defecto: su soporte solo entra a un caso puntual, con acceso temporal y auditado.

Lo que falta definir fuera de este documento:

- La región principal del tenant de Fabric, donde quedan permisos y metadatos aunque la capacidad esté en East US 2 (`fabric-workspaces-ingesta-region.md`, sección 7.2). Tiene que quedar en un país de la lista de la SIC. En la lista que publica la SIC (versión de 2022) están Estados Unidos y México; Brasil y Chile no están.
- La ubicación del proveedor de SMS y la del tenant de Microsoft 365 de FríoAndes.

Si FríoAndes no acepta Estados Unidos (pregunta 4 de la sesión de aclaraciones), la alternativa es una región de Azure en otro país de la lista, como México. Eso obliga a revisar la latencia medida desde Cali, la disponibilidad de los servicios y la redundancia de IoT Hub en esa región.

3.4 Autorización y aviso

La Ley 1581 pide autorización previa e informada del titular (artículo 9), y el responsable debe conservar la prueba (artículo 17). Ninguna de las excepciones del artículo 10 cubre la operación de FríoAndes.

Titular	Cuándo se obtiene	Qué cubre
Conductor	Al vincularlo a FríoAndes	Sus datos de registro, la posición del camión durante la jornada, su imagen en el video de muelles y entregas, y la transmisión a Estados Unidos
Destinatario	Su dato llega con la guía, autorizado por el cliente corporativo. Al recibir, el comprobante incluye el aviso de privacidad de FríoAndes	Su firma, su documento y la foto de la entrega
Usuario de un cliente corporativo	Al habilitar su cuenta en el portal	Su cuenta y el registro de su actividad, que sirve para detectar abuso (sección 5)
Empleado	Al vincularlo	Su identidad, sus acciones en la plataforma y, si está de guardia, su teléfono

Lo que la plataforma tiene que guardar. Una tabla de autorizaciones en la base transaccional, con el titular, la versión del aviso que aceptó, la fecha y el canal. Así FríoAndes puede probar cada autorización cuando el titular o la SIC la pidan. Es un requisito para el equipo de desarrollo.

3.5 Los cinco años y los derechos del titular

El Decreto 1377 obliga a borrar los datos cuando se cumple su finalidad, pero también dice que se deben conservar cuando lo exija una obligación legal o contractual (artículo 11). El contrato con los clientes de alimentos es esa obligación para las evidencias y la trazabilidad de temperatura. Por eso esos datos se conservan cinco años aunque el titular pida borrarlos, y se borran al cumplirse.

Derecho del titular	Plazo de la ley	Cómo lo atiende la plataforma
Conocer y acceder a sus datos (artículos 8 y 14)	10 días hábiles, prorrogables 5	El mapa de la sección 2 dice dónde buscar. Al conductor se lo encuentra por su documento y por sus viajes; al destinatario, por sus guías
Actualizar y rectificar (artículos 8 y 15)	15 días hábiles, prorrogables 8	Se corrige en la base transaccional. La evidencia inmutable no se modifica: la corrección queda anotada en la base, ligada a la evidencia, para que un reclamo vea las dos. Alterar la evidencia es justo lo que la ley pide impedir (artículo 17)
Suprimir sus datos (artículos 8 y 15)	15 días hábiles, prorrogables 8	Se borra lo que no hace falta para el contrato, por ejemplo una cuenta del portal o el teléfono de un destinatario después de la entrega. Lo que forma parte de la evidencia se conserva los cinco años y se le explica al titular por qué
Reclamo en trámite (artículo 15)	La leyenda se pone en máximo 2 días hábiles	Un campo en la base transaccional marca "reclamo en trámite" en los registros del titular hasta que se resuelva

Las posiciones de los camiones quedan fuera de la copia inmutable. La posición cada 30 segundos es la ubicación del conductor durante su jornada. Si estuviera en la copia inmutable, nadie podría borrarla en cinco años, ni siquiera si la SIC ordenara suprimirla (artículo 8). El contrato con los clientes de alimentos obliga a conservar las evidencias y la trazabilidad de temperatura; la posición no forma parte de esa obligación. Por eso la ruta de IoT Hub hacia la copia inmutable lleva solo los mensajes de temperatura y de puertas: IoT Hub puede filtrar por el tipo de mensaje porque cada mensaje se marca como JSON. Las posiciones quedan en la tabla de análisis, ligadas a la guía y al viaje, también por cinco años para los reclamos. Esa tabla sí se puede corregir y borrar.

Al cumplirse los cinco años:

Dónde	Cómo se borra
Archivo de evidencias y evidencia cruda de telemetría	La política de ciclo de vida de cada cuenta borra los archivos al vencer la retención. Antes, la retención inmutable impide borrarlos
Tabla de análisis de telemetría	Una tarea programada borra las filas de más de cinco años y limpia los archivos viejos de la tabla Delta
Base transaccional	Una tarea programada anonimiza los campos personales de las guías de más de cinco años (nombre, dirección, teléfono, documento del destinatario) y deja los datos de la operación para estadísticas. Los conductores sin viajes dentro de los cinco años se anonimizan igual

Dónde	Cómo se borra
Copias de la base	Vencen solas en máximo 35 días
Fabric	Lo que lee por atajo se borra en el origen. Las vistas copiadas del libro operativo reciben la anonimización de la base. Los resultados de la revisión de evidencias de más de cinco años los borra un cuaderno mensual
Registros	Los borra la retención que fije el diseño de auditoría

3.6 Lo que FríoAndes tiene que tener listo

La ley pide que el responsable pueda demostrar que cumple. Estas piezas las prepara FríoAndes, y la arquitectura depende de ellas:

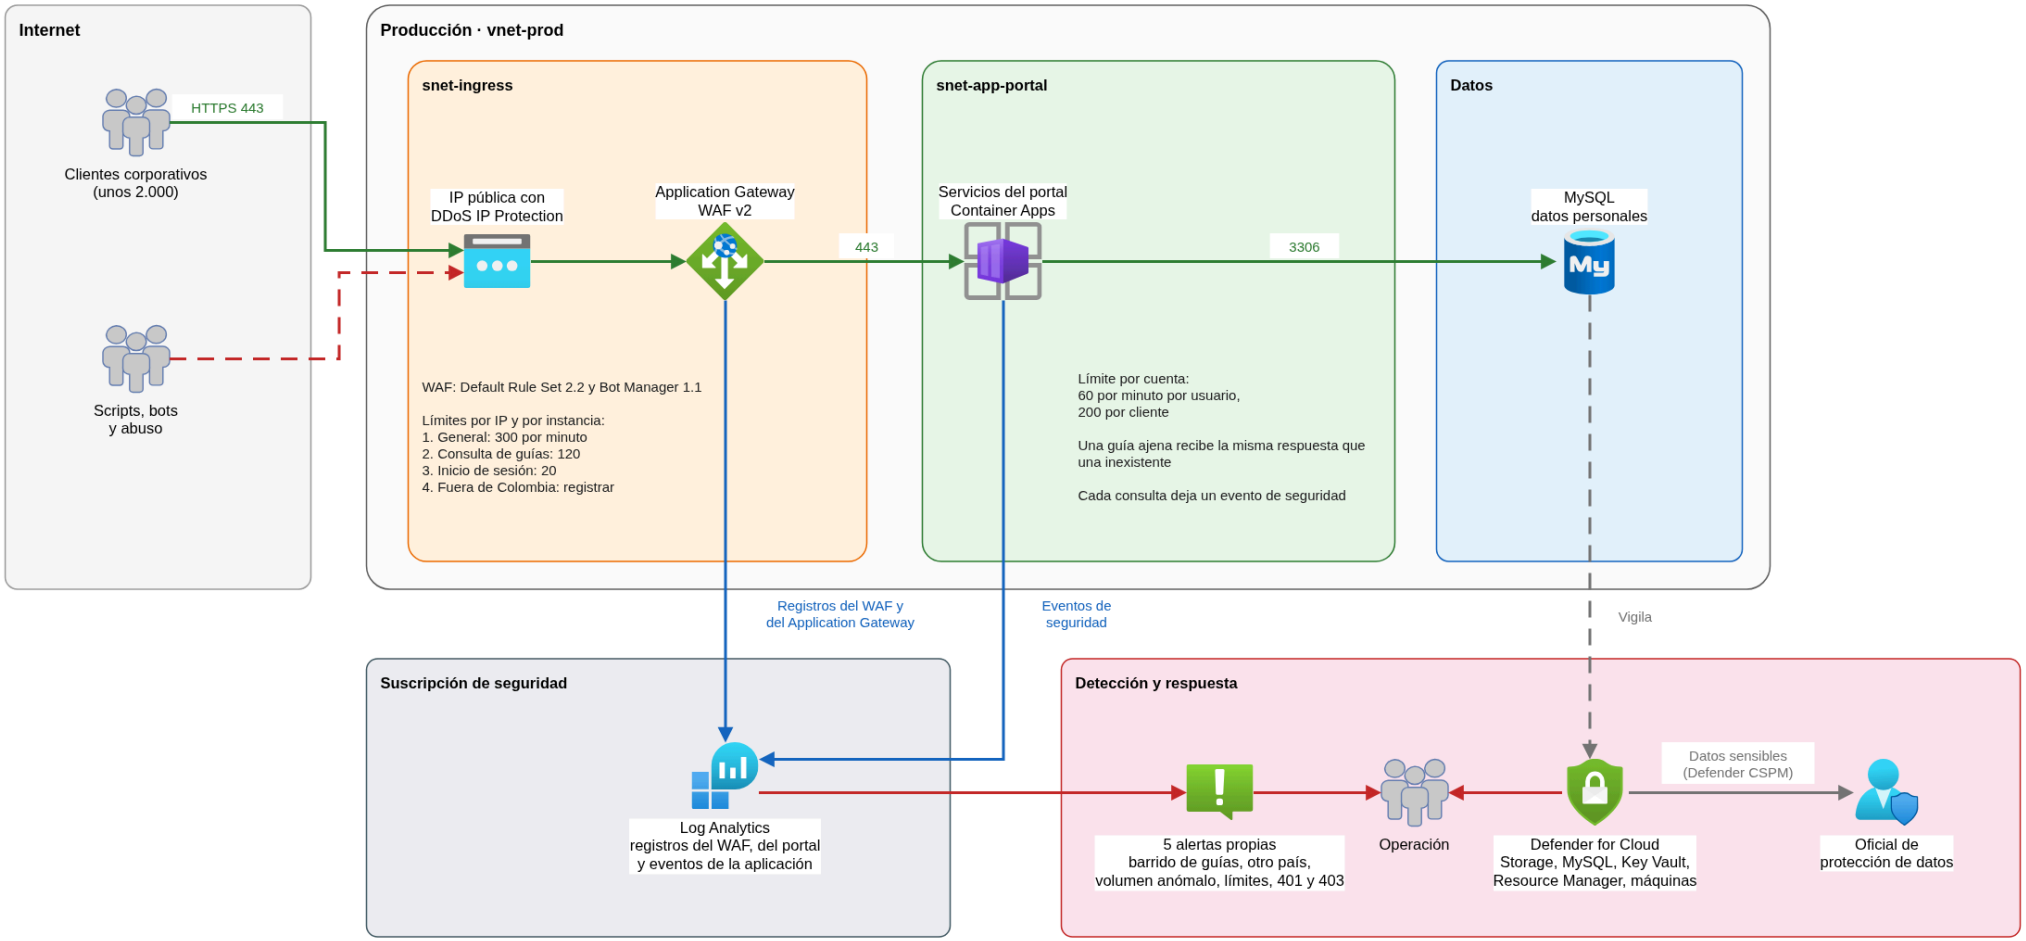
Pieza	Norma
Política de tratamiento de datos y aviso de privacidad, con la finalidad de cada dato y la transmisión a Estados Unidos	Decreto 1377, artículos 13 a 15
Manual interno para atender consultas y reclamos en los plazos de la sección 3.5	Ley 1581, artículo 17
Contratos de transmisión con Microsoft y con el proveedor de SMS	Decreto 1377, artículo 25
Cláusula con los clientes corporativos sobre la autorización de los destinatarios	Sección 3.2
Inscripción o actualización en el Registro Nacional de Bases de Datos, con la transmisión a Estados Unidos, si FríoAndes supera el umbral	Decreto 090 de 2018
Aviso a la SIC cuando haya una violación de seguridad que ponga en riesgo los datos. La detección de la sección 5 es la que dispara ese aviso	Ley 1581, artículo 17

---

4. Perímetro del portal

4.1 Qué protege cada capa

Portal de rastreo: capas de protección y de dónde salen las alertas



Verde: tráfico permitido. Rojo: alertas. Azul: registros. Gris: vigilancia de Defender for Cloud. Si una alerta indica acceso no autorizado a datos personales, operación activa el procedimiento de incidentes y se evalúa el aviso a la SIC (Ley 1581, artículo 17). Sentinel se evalúa con el volumen del primer mes.

Figura 5: Portal de rastreo: capas de protección y de dónde salen las alertas

El portal ya tiene, desde el diseño del firewall, la IP pública con DDoS IP Protection, el Application Gateway con WAF v2 en modo prevención, las reglas administradas Default Rule Set 2.2 contra los ataques web comunes y Bot Manager 1.1 contra los bots maliciosos conocidos. Este documento agrega lo que faltaba: frenar el abuso del rastreo.

Abuso	Ejemplo	Qué lo frena
Inundación desde una IP	Un script que consulta el portal sin parar	Límite por IP en el WAF (regla 1)
Barrido de guías	Probar números de guía en serie para ver cuáles existen	Límite por IP en la consulta de guías (regla 2) y, sobre todo, la autorización de la aplicación: cada cliente solo recibe sus guías
Adivinar contraseñas	Muchos intentos de inicio de sesión	Límite en la ruta de inicio de sesión (regla 3) y la protección del servicio de identidades
Un usuario legítimo que abusa	Una cuenta válida que descarga el rastreo de forma masiva	Límite por cuenta en la aplicación (sección 4.4)
Ataque de red	Inundación de tráfico contra la IP del portal	DDoS IP Protection, ya activa

4.2 Lo que el WAF puede y no puede hacer

El WAF de Application Gateway cuenta las solicitudes por IP del cliente, por país o todas juntas. No conoce la cuenta del usuario. Además, Microsoft advierte dos cosas que el diseño toma en cuenta:

- **Cada instancia lleva su propio contador.** Con dos instancias, las solicitudes de una misma IP se reparten entre ellas, y cada una compara su mitad contra el umbral. El umbral no es un límite exacto del gateway completo.
- **Los umbrales no son exactos.** Sirven para frenar tasas anómalas y mantener el portal disponible. Repartir la capacidad entre clientes con precisión queda fuera de su alcance.

Por eso el diseño tiene dos capas: el WAF frena por IP lo que es claramente anómalo, y la aplicación limita por cuenta, que es lo que el WAF no puede ver.

4.3 Reglas de límite del WAF

El dimensionamiento. En campaña el portal recibe hasta 2.000 solicitudes por minuto, repartidas entre unos 2.000 clientes. Los usuarios de una misma empresa suelen salir a internet por la misma IP. El diseño supone que ningún cliente genera más del 10 % del pico de campaña, es decir 200 solicitudes por minuto desde su IP (sección 7). Producción tiene al menos dos instancias, y si una cae, la otra recibe todo; por eso el umbral se fija para que esas 200 solicitudes pasen aunque lleguen todas a una sola instancia.

Regla	Qué cuenta	Umbral por instancia	Cuándo actúa con dos instancias	Acción
1. Límite general por IP	Todas las solicitudes de una IP	300 por minuto	Cuando una IP supera unas 600 por minuto: el triple del cliente más grande y casi un tercio de todo el pico de campaña	Bloquear
2. Consulta de guías por IP	Las solicitudes a la ruta de consulta de guías	120 por minuto	Cuando una IP supera unas 240 consultas por minuto, más de cuatro por segundo	Bloquear
3. Inicio de sesión por IP	Las solicitudes a la ruta de inicio de sesión del portal, si el	20 por minuto	Cuando una IP supera unos 40 intentos por minuto	Bloquear

Regla	Qué cuenta	Umbral por instancia	Cuándo actúa con dos instancias	Acción
	inicio de sesión pasa por el portal			
4. Tráfico desde fuera de Colombia	Las solicitudes de IP que no son de Colombia ni de país desconocido (código ZZ)	Sin umbral	Siempre	Registrar, sin bloquear

Por qué estas cifras.

- La regla 1 nunca toca el pico de campaña legítimo: las 2.000 solicitudes por minuto de todos los clientes juntos se reparten entre muchas IP, y la más grande, con 200, queda por debajo de 300 aunque una instancia reciba todo.
- La regla 2 apunta al barrido. Una persona consulta unas pocas guías por minuto; cuatro por segundo sostenidas durante un minuto solo las hace un programa.
- La regla 3 depende del diseño de identidades. Si el inicio de sesión de los clientes lo atiende el servicio de identidades de Microsoft, no pasa por el Application Gateway y la regla no hace falta.
- La regla 4 no bloquea, porque no hay certeza de que todos los clientes estén en Colombia. Registra para la detección (sección 5): una cuenta que de repente consulta desde otro país es una señal.

Lo que pasa cuando una regla actúa. El WAF bloquea a esa IP durante el resto del minuto y después la deja pasar hasta el umbral. Un cliente legítimo que excede el límite por un error de su integración se recupera solo al minuto siguiente; un script sostenido queda frenado.

4.4 Límite por cuenta en la aplicación

El WAF no distingue a dos usuarios de la misma empresa ni a un usuario legítimo que abusa. Eso lo hace la aplicación, que sí conoce la cuenta. Es un requisito para el equipo de desarrollo:

Límite	Valor inicial	Respuesta
Por usuario	60 solicitudes por minuto	Código 429 con el tiempo de espera
Por cliente corporativo (todas sus cuentas)	200 solicitudes por minuto, el mismo supuesto de la regla 1	Código 429 con el tiempo de espera
Consulta de guías ajenas	Cada consulta de una guía que no es del cliente	Respuesta igual a la de una guía inexistente, y un evento en el registro de la aplicación para la detección (sección 5)

Responder igual a una guía ajena y a una inexistente evita que el barrido revele qué números existen.

4.5 Cómo se ponen en marcha

1. En pruebas, las reglas arrancan con la acción de registrar mientras corre la prueba de carga de campaña (2.000 solicitudes por minuto, con una distribución de IP parecida a la real).
2. Con esos registros se confirma que ninguna IP legítima se acerca a los umbrales y se pasan a bloquear.
3. Producción arranca con las reglas en bloqueo desde el corte. En el primer mes se revisa la tasa por IP más alta de cada día; si un cliente legítimo se acerca al umbral, se ajusta.
4. Los ajustes se hacen fuera de campaña y en la ventana de 22:00 a 04:00, como cualquier cambio de producción.

Las reglas viven en la misma política del WAF como código, junto con las de la tabla de políticas del firewall. Pruebas y desarrollo usan las mismas reglas.

---

5. Detección de actividad anómala

5.1 Tres fuentes de detección

La parte inferior del diagrama de la sección 4.1 muestra de dónde sale cada alerta.

Fuente	Qué detecta	Quién define la regla
Microsoft Defender for Cloud	Comportamientos anómalos sobre los servicios de Azure: accesos inusuales o exfiltración en el almacenamiento, fuerza bruta contra la base, accesos raros al Key Vault, operaciones sospechosas en Azure Resource Manager	Microsoft, con su inteligencia de amenazas y sus modelos. FríoAndes elige qué planes activa
Registros del WAF, del Application Gateway y del firewall	Abuso del portal por IP: bloqueos por límite, intentos repetidos, tráfico desde fuera de Colombia	FríoAndes, con alertas de búsqueda en Log Analytics
Eventos de la aplicación	Abuso por cuenta: consultas de guías ajenas, volumen anómalo de una cuenta, cambios de país	FríoAndes, con alertas de búsqueda sobre los eventos que emite la aplicación

Las dos últimas son las que miran el portal desde el negocio. Defender for Cloud no sabe qué es una guía ni a qué cliente pertenece, y el WAF no conoce las cuentas. Por eso la aplicación tiene que registrar sus propios eventos de seguridad.

5.2 Planes de Defender for Cloud

Defender for Cloud se activa por suscripción, sobre la estructura de la landing zone:

Plan	Qué protege	Producción	Conectividad	Seguridad	Pruebas y desarrollo
Foundational CSPM (sin costo)	Recomendaciones de configuración y puntuación de seguridad	Sí	Sí	Sí	Sí
Defender CSPM	Rutas de ataque, descubrimiento de datos sensibles en el almacenamiento y la base, cumplimiento normativo	Sí	No	No	No
Defender for Storage	Accesos anómalos y exfiltración en todas las cuentas, datos sensibles en el almacenamiento	Sí	No	Sí (registros)	No
Defender para MySQL	Fuerza bruta y accesos anómalos a la base	Sí	No	No	No
Defender for Key Vault	Accesos inusuales a secretos y llaves	Sí	No	No	No
Defender for Resource Manager	Operaciones sospechosas sobre los recursos (por ejemplo, cambios masivos de permisos)	Sí	Sí	Sí	No
Defender for Servers, plan 1	Las máquinas de administración de `snet-admin`	Sí	No	No	No

Plan	Qué protege	Producción	Conectividad	Seguridad	Pruebas y desarrollo
Defender for Containers	Protección de los contenedores en ejecución. Solo aplica con la variante de Kubernetes	Variante AKS	No	No	No

Por qué pruebas y desarrollo quedan con el plan sin costo. No tienen datos personales reales (sección 2.3). Las recomendaciones de configuración siguen activas para que los errores se vean antes de llegar a producción.

Por qué Defender CSPM solo en producción. Su descubrimiento de datos sensibles muestrea la base y las cuentas de almacenamiento con los tipos de información de Microsoft Purview, y marca dónde hay datos personales. Eso permite comprobar periódicamente que el mapa de la sección 2 sigue siendo cierto: si aparece un nombre o un documento en una cuenta que no debería tenerlos, se ve. Sus rutas de ataque muestran si algún camino desde internet llega a un almacén con datos sensibles.

Container Apps. La protección en ejecución de Defender for Containers cubre solo Kubernetes. Con Container Apps, el escaneo de vulnerabilidades de las imágenes del registro lo hace Defender CSPM. Con la variante de Kubernetes se agrega Defender for Containers.

5.3 Escaneo de malware en el almacenamiento

Defender for Storage puede escanear cada archivo que se sube, pero lo cobra por GB. El archivo crece unos 12 TB al mes, casi todo video, y la siembra inicial es de 1,2 PB:

Qué se sube	Escaneo de malware	Por qué
Fotos, comprobantes y PDF que llegan desde los equipos de los conductores y de los centros	Sí, con un tope mensual por cuenta	Vienen de dispositivos fuera del control de la plataforma y alguien los abre después
Video de muelles y entregas	No	Lo producen las cámaras de FríoAndes. Escanearlo costaría unos USD 1.800 al mes
La siembra de 1,2 PB y la copia desde Cali	No, el escaneo queda apagado durante la migración	Escanear 1,2 PB costaría unos USD 180.000

Todos los archivos tienen igual el análisis por reputación de hash, que viene incluido y compara cada archivo con malware conocido. Para que el escaneo se aplique solo a las fotos y comprobantes, esos archivos tienen que ir en una cuenta separada del video. El diseño del archivo define esa separación.

5.4 Alertas sobre el portal

Alerta	Condición	Fuente	Frecuencia
Barrido de guías	Una cuenta consulta más de 20 guías ajenas o inexistentes en 10 minutos	Eventos de la aplicación	Cada 5 minutos
Cuenta desde otro país	Una cuenta que siempre entra desde Colombia aparece desde otro país	Eventos de la aplicación y regla 4 del WAF	Cada 5 minutos
Volumen anómalo de una cuenta	Una cuenta hace más del triple de consultas que su máximo diario de los últimos 30 días	Eventos de la aplicación	Cada 15 minutos
Límites del WAF activados	Una misma IP activa las reglas de límite en más de 5 minutos distintos dentro de una hora	Registros del WAF	Cada 5 minutos

Alerta	Condición	Fuente	Frecuencia
Intentos de acceso fallidos	Más de 50 respuestas 401 o 403 a una misma IP en 10 minutos	Registros del Application Gateway	Cada 5 minutos

Estas cinco se suman a las del diseño del firewall: destinos maliciosos, rechazos fuera de lo normal, aumento de bloqueos del WAF, ataques de denegación de servicio y cambios en las reglas. Los umbrales son iniciales y se ajustan con el primer mes de datos, igual que los límites de la sección 4.

Lo que la aplicación tiene que registrar. Para estas alertas, cada consulta del portal deja un evento con la cuenta, el cliente, la guía consultada, si era del cliente, el resultado y la IP de origen. Los eventos van al mismo espacio de Log Analytics, y su retención la fija el diseño de auditoría. Es un requisito para el equipo de desarrollo, el mismo que pide el diseño de auditoría para reconstruir quién accedió a datos de clientes.

5.5 Microsoft Sentinel

Sentinel es el sistema de Microsoft para correlacionar señales de seguridad de muchas fuentes, con un equipo de seguridad que investiga incidentes. Para FríoAndes, al inicio, no hace falta:

	Defender for Cloud y alertas de Log Analytics (propuesta)	Sentinel desde el inicio
Qué cubre	Las alertas de Defender y las cinco alertas propias del portal, más las del firewall	Lo mismo, más correlación entre fuentes, análisis de comportamiento de usuarios y casos de investigación
Costo	Las alertas propias, unos pocos dólares al mes	Unos USD 4,76 por GB analizado, sobre todos los registros que se conecten
Quién lo opera	El equipo de operación de la plataforma	Un equipo de seguridad que revise incidentes de forma continua

El volumen de registros se mide en el primer mes, como ya dejó dicho el diseño del firewall. Con ese dato, y si FríoAndes forma un equipo de seguridad, Sentinel se activa sobre el mismo espacio de Log Analytics sin mover nada: las alertas de Defender for Cloud y el registro de actividad de Azure no se cobran en Sentinel, y los primeros 31 días tienen 10 GB diarios sin costo.

5.6 Qué pasa cuando hay una alerta

1. La alerta llega al equipo de operación por el canal que define el diseño de observabilidad (`observabilidad-slo-zabbix.md`, sección 6).
2. Si es abuso del portal, operación bloquea la IP con una regla del WAF o deshabilita la cuenta, y avisa al cliente corporativo dueño de la cuenta.
3. Si hay indicios de que alguien accedió a datos personales sin autorización, se conservan los registros, se activa el procedimiento de incidentes de FríoAndes y se evalúa el aviso a la SIC que exige la Ley 1581 (artículo 17). Si los datos afectados son de clientes de alimentos, el contrato con ellos también puede exigir avisarles.
4. Cada incidente deja su registro para la auditoría.

---

6. Operación y costo

6.1 Costo mensual de producción

Precios de lista en East US 2, con 730 horas al mes. Solo incluye lo que agrega este documento: el WAF, el Application Gateway y los registros del firewall ya están en el costo del diseño del firewall.

Componente	Cálculo	USD al mes
Defender CSPM	10 recursos facturables (2 máquinas de administración, 5 cuentas de	51,10

Componente	Cálculo	USD al mes
	almacenamiento y 3 servidores MySQL) × 5,11	
Defender for Storage	5 cuentas (video del archivo, fotos y comprobantes, evidencia de telemetría, tabla de análisis y cuenta de la función) × 9,78	48,91
Escaneo de malware de fotos y comprobantes	Unos 1.138 GB al mes × 0,15, con un tope de 1.200 GB	De unos 171 a 180
Defender para MySQL	Hasta 3 servidores (el principal y las dos réplicas) × 15	Hasta 45
Defender for Resource Manager	3 suscripciones (producción, conectividad y seguridad) × 5,04	15,11
Defender for Servers, plan 1	2 máquinas de administración × 4,91	9,81
Defender for Key Vault	1 bóveda	0,25
Alertas propias del portal	4 cada 5 minutos × 1,50 + 1 cada 15 minutos × 0,50	6,50
Reglas de límite del WAF	La API de precios no tiene un medidor para ellas	0
Total		**Unos 350, con el escaneo de malware al tope**

Cómo se estimó el escaneo. En el archivo actual hay 110 TB de fotos, comprobantes y PDF y 1,05 PB de video. Si el crecimiento de 12 TB al mes mantiene esa proporción, las fotos y comprobantes son unos 1.138 GB al mes. El tope mensual de 1.200 GB fija el máximo en USD 180; si se alcanza, Defender avisa al 75 % y al 100 % y el resto del mes queda solo el análisis por reputación de hash.

Lo que no está en la tabla:

- Los eventos de seguridad de la aplicación en Log Analytics. Cuestan USD 2,76 por GB, a partir de 5 GB gratuitos al mes, y su volumen depende del uso real del portal. Son los mismos eventos que necesita el diseño de auditoría, así que se cuentan una sola vez, en el costo de la plataforma.
- La copia del archivo durante la migración no suma máquinas en Azure: la hace un agente en Cali (`carga-c-siembra-1-2pb.md`, sección 6).
- El plan de Defender for Containers, que solo aplica con la variante de Kubernetes y se cobra por núcleo de los nodos.
- Pruebas y desarrollo: usan el plan sin costo.

6.2 Operación

Tarea	Frecuencia	Quién
Revisar las alertas de Defender for Cloud y las del portal	Cuando llegan, por el canal del diseño de observabilidad (`observabilidad-slo-zabbix.md`, sección 6)	Operación
Revisar las recomendaciones de Defender for Cloud y la puntuación de seguridad	Semanal	Operación
Revisar la IP con más tráfico de cada día frente a los límites del WAF	Diaria el primer mes, después mensual	Operación
Ajustar umbrales de límites y alertas	Fuera de campaña y en la ventana de 22:00 a 04:00	Operación, con un cambio aprobado
Contrastar el descubrimiento de datos sensibles de Defender CSPM con el mapa de la sección 2	Trimestral	El oficial de protección de datos de FríoAndes

Tarea	Frecuencia	Quién
Atender consultas y reclamos de titulares	En los plazos de la sección 3.5	El área que FríoAndes designe en su manual interno
Revisar la lista de países de la SIC y los contratos con encargados	Anual	Jurídica de FríoAndes

En campaña. Los límites del WAF ya están dimensionados para el pico de 2.000 solicitudes por minuto, así que la campaña no exige cambios. Antes de cada campaña se revisa que ninguna IP legítima del mes anterior se haya acercado a los umbrales.

6.3 Decisiones que bajan o evitan gasto

Decisión	Alternativa descartada	Ahorro
Escanear solo fotos y comprobantes	Escanear también el video	Unos USD 1.800 al mes
Apagar el escaneo durante la migración	Escanear la siembra de 1,2 PB	Unos USD 180.000 una sola vez
Defender for Cloud y alertas de Log Analytics al inicio	Microsoft Sentinel desde el primer día	USD 4,76 por cada GB de registros analizado
Pruebas y desarrollo con el plan sin costo	Los mismos planes que producción	Los planes de pago de esos ambientes
Defender for Servers, plan 1	Plan 2 para las máquinas de administración	USD 19,39 al mes

---

7. Supuestos y confirmaciones pendientes de FríoAndes

7.1 Confirmaciones que necesita el diseño

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
Ubicación de los datos	¿Se acepta que los datos personales de conductores y destinatarios queden en Estados Unidos (East US 2 y Central US)? ¿Los contratos con los clientes de alimentos dicen algo sobre dónde deben guardarse?	Si no se acepta, la plataforma pasa a una región de otro país de la lista de la SIC, como México, y se revisan latencia, servicios y la redundancia de IoT Hub (sección 3.3)
Datos de cada titular	¿Qué campos guarda hoy la base de conductores, destinatarios y usuarios de los clientes?	El inventario de la sección 2.1 es una deducción. Un dato sensible que no está en la lista cambia sus controles
Comprobante de entrega	¿El cliente corporativo ve el comprobante y las fotos de sus propias entregas?	Si no los ve, sale de su vista y los pide a calidad (sección 2.4)
Registro Nacional de Bases de Datos	¿FríoAndes tiene más de 100.000 UVT de activos totales?	Si los tiene, debe inscribir o actualizar sus bases con la transmisión a Estados Unidos (sección 3.6)
Contratos con encargados	¿La adenda de protección de datos de Microsoft cubre lo que pide el artículo 25 del Decreto 1377? ¿Quién es el proveedor de SMS y dónde trata los datos?	Si falta algo, se firma un contrato de transmisión complementario. Si el proveedor de SMS está fuera de la lista de la SIC, se cambia o se revisa la base legal de esa transmisión
Microsoft 365	¿Dónde está el tenant de Microsoft 365 de FríoAndes?	Teams y el correo llevan teléfonos y correos de la guardia; su ubicación entra en el registro de transmisiones

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
Cláusula con los clientes	¿Los contratos con los clientes corporativos incluyen que ellos obtienen la autorización de los destinatarios para compartir sus datos?	Si no la incluyen, se agrega antes de migrar (sección 3.2)
Inicio de sesión de los clientes	¿Los clientes inician sesión en el portal o en el servicio de identidades de Microsoft? Lo define el diseño de identidades	Si es en el portal, aplica la regla 3 del WAF; si no, la protección la da el servicio de identidades (sección 4.3)
Clientes fuera de Colombia	¿Hay clientes corporativos que consulten desde otros países?	Si no los hay, la regla 4 del WAF puede pasar de registrar a limitar (sección 4.3)
Incidentes	¿Los contratos con los clientes de alimentos exigen avisarles de un incidente con datos personales, y en qué plazo?	Se agrega al procedimiento de la sección 5.6

7.2 Supuestos del diseño

Supuesto	Por qué se asume
Ningún cliente corporativo genera más del 10 % del pico de campaña, unas 200 solicitudes por minuto desde su IP	Define los umbrales del WAF. Se confirma con la prueba de carga y con el primer mes de producción (sección 4.5)
Cada usuario del portal hace hasta 60 solicitudes por minuto y cada cliente hasta 200	Valores iniciales del límite por cuenta en la aplicación. Se ajustan con el uso real
Los umbrales de las cinco alertas del portal son iniciales	No hay tráfico real para calibrarlos. Se ajustan con el primer mes de datos
Hay 2 máquinas de administración y 5 cuentas de almacenamiento en producción, con las fotos y comprobantes en una cuenta separada del video	Define el costo de Defender. La separación de cuentas la confirma el diseño del archivo
Defender cobra cada servidor MySQL por separado: el principal y las dos réplicas	No hay una fuente que lo aclare. Se confirma con la primera factura
Las fotos y comprobantes son unos 1.138 GB al mes	Es la proporción actual del archivo (110 TB de fotos frente a 1,05 PB de video) aplicada al crecimiento de 12 TB al mes
El volumen de eventos de seguridad de la aplicación se mide en el primer mes	Depende del uso real del portal. Son los mismos eventos que necesita el diseño de auditoría
Ningún componente identifica personas por su rostro	Si algún uso lo hiciera, las imágenes pasarían a ser datos biométricos y requerirían la autorización especial del artículo 6 de la Ley 1581
Los costos son precios de lista en East US 2, con 730 horas al mes, sin descuentos	Es la base común del cálculo de costos de la plataforma
La plataforma de contenedores es Container Apps con perfiles de carga	Lo mismo que el diseño de red. Con Kubernetes se agrega Defender for Containers (sección 5.2)

3. Red híbrida y preparación para una segunda nube

Red híbrida, subnetting en la nube y verificación de no solapamiento

Este documento describe la red que conecta la sede de Cali, los ocho centros de distribución y la nube de FríoAndes en Azure. Explica cada parte de la solución, por qué se eligió, qué alternativas se descartaron y qué debe confirmar FríoAndes antes de implementarla.

Los diagramas están en `diagramas/` como archivos de draw.io. Cada PNG lleva el diagrama editable incrustado: se abre directamente en draw.io.

Los archivos de apoyo están en la carpeta `red/`, junto a este documento:

Archivo	Qué contiene
`red/data/ip-plan.csv`	El plan de direcciones de la solución con Container Apps: la única fuente de los rangos
`red/data/ip-plan-aks.csv`	El plan de direcciones de la variante con Kubernetes
`red/data/onprem-inventory.csv`	Las 23 subredes on-premises actuales de Cali y los centros
`red/data/azure-subnet-constraints.csv`	Los nombres y tamaños mínimos que exige Azure, con su fuente
`red/data/latency-targets.csv`	Los servidores usados para medir la latencia por región
`red/tools/verify_ip_plan.py`	Verifica el plan contra el inventario on-premises (sección 4.8)
`red/tools/compare_tfplan.py`	Compara el plan de Terraform con `ip-plan.csv` (sección 4.8)
`red/tools/measure_latency.py`	Mide la latencia hacia cada región (sección 3)
`red/tools/build_drawio_diagrams.py`	Genera los diagramas de draw.io a partir del plan
`red/verification/`	Reportes de la verificación de los dos planes y resultados de la medición de latencia

Términos usados

Término	Significado en este documento
Red virtual (VNet)	Red privada dentro de Azure
Subred	Parte de una red virtual con su propio rango de direcciones. Cada servicio de Azure vive en una subred
CIDR	Forma de escribir un rango de direcciones. `10.101.0.0/21` son 2.048 direcciones; `/24` son 256, `/26` son 64, `/27` son 32
Hub y spoke	Topología con una red central (hub) que concentra la conexión con las sedes, el firewall y el acceso administrativo, y redes de ambiente (spokes) conectadas a ella
Peering	Conexión directa y privada entre dos redes virtuales de Azure
VPN sitio a sitio	Túnel cifrado con IPsec, por internet, entre el equipo de red de una sede y Azure
BGP	Protocolo con el que cada lado de una VPN anuncia sus redes al otro. Permite que el tráfico cambie solo de camino cuando un túnel cae
UDR	Ruta definida por el usuario. Se usa para obligar al tráfico a pasar por el firewall
Zona de disponibilidad	Datacenter físicamente separado dentro de una misma región de Azure
Convivencia	Periodo de como máximo 90 días en que el datacenter de Cali y Azure funcionan al mismo tiempo
Estado estable	La operación después del día 90, con la plataforma ya en Azure

1. Contexto y alcance

1.1 Situación actual

FríoAndes opera desde un único datacenter en Cali. Los ocho centros de distribución llegan a Cali por VPN sitio a sitio. Un solo firewall de nueva generación en Cali enruta entre todas las redes, termina las VPN de los centros, publica el portal de rastreo por NAT y aplica las políticas entre subredes. La sede tiene un internet de 400 Mbps simétricos, compartido con el resto de la operación, y no hay enlace dedicado hacia ninguna nube.

El diseño de red tiene que respetar estas condiciones del negocio:

Condición	Consecuencia para la red
Un solo firewall y un solo proveedor de internet en Cali	Son puntos únicos de falla. La sede necesita una ruta redundante hacia la nube
Cada centro llega a Cali por VPN	Hay que decidir si los centros siguen pasando por Cali o se conectan directo a la nube
La torre de control solo se usa desde la red corporativa, porque muestra ubicación de carga y datos de clientes	La consola de despacho no puede tener exposición a internet
Los sensores de los cuartos fríos están en la red local de cada centro, y los de los camiones salen por la red móvil del operador	La telemetría llega por dos caminos distintos
El portal de rastreo se publica por NAT con Nginx y un firewall de aplicaciones	El portal necesita una entrada pública controlada en la nube
Desarrolladores y operadores trabajan parte de la semana fuera de la sede	Se necesita acceso administrativo remoto sin abrir la red de despacho
Hay 23 subredes on-premises en uso (7 en Cali y 2 en cada centro)	Ningún rango de la nube puede repetir esas direcciones

1.2 Qué resuelve este documento

Necesidad	Cómo se cubre aquí
Conectividad entre el datacenter, los ocho centros y la nube, con ruta redundante para Cali	Sección 2: topología, conexión de Cali con dos proveedores y conexión de los centros
Tabla de subnetting de la nube sin solapar el inventario on--premises, con ingreso, aplicación, datos, archivo, ingesta de telemetría, administración, integración con Cali y salida a Fabric, y con desarrollo, pruebas y producción en rangos distintos	Sección 4: plan de direcciones y verificación rango por rango
Confirmar con una medición desde Cali si East US 2 es la región adecuada	Sección 3
Mantener el despacho fuera de internet y publicar el rastreo de forma controlada	Sección 5: subred de la torre sin exposición y una sola entrada pública de aplicación
Acceso administrativo para equipos distribuidos	Sección 5: subred para Azure Bastion y reserva para VPN de usuario
Preparar la interconexión con una segunda nube en 24 meses	Secciones 4 y 5: rango reservado y DNS privado en el hub

Este documento define la red sobre la que se apoyan otros diseños de la plataforma. Las reglas del firewall de nube, el firewall de aplicaciones del portal, el diseño del acceso remoto y la identidad para la segunda nube se detallan en sus propios documentos. Aquí se dejan las subredes, las zonas y los flujos que esos diseños necesitan.

2. Conexión de Cali, los ocho centros y la nube

Esta sección responde tres preguntas:

1. Con qué se conecta la nube a las sedes (la topología).
2. Cómo se evita que Cali quede sin nube si algo falla (la redundancia).
3. Si los centros siguen pasando por Cali o se conectan directo a la nube (la ruta de los centros).

2.1 Topología: hub y spoke con VPN Gateway

La idea

En Azure se crea una red central, el hub (`vnet-hub`), que es la única puerta entre la nube y las sedes. Las redes de los ambientes (producción, pruebas y desarrollo) son los spokes y se conectan al hub por peering. Así, la conexión con las sedes, el firewall y el acceso administrativo existen una sola vez y los usan los tres ambientes. Cada ambiente queda aislado de los otros: para que dos ambientes se hablen, el tráfico tiene que pasar por el firewall del hub.

Qué hay en el hub

Componente	Qué hace
VPN Gateway VpnGw1AZ, activo-activo	Recibe los túneles IPsec de Cali y de los centros. Activo-activo significa que tiene dos instancias, cada una con su IP pública: si una cae o entra en mantenimiento, la otra sigue y la conexión no se corta. El modelo "AZ" reparte esas instancias en zonas de disponibilidad distintas
BGP en el VPN Gateway	Cada sede anuncia sus redes y Azure anuncia las suyas. Cuando un túnel cae, BGP retira esas rutas y el tráfico sigue por los túneles que quedan, sin cambios manuales
Azure Firewall Standard	Todo el tráfico entre las sedes y los ambientes, y toda la salida a internet de los ambientes, pasa por aquí. Registra cada conexión y aplica las reglas del diseño de firewall de nube
Rutas definidas por el usuario (UDR)	Están en la subred del VPN Gateway y en las subredes de los ambientes. Mandan el tráfico al firewall: ningún paquete llega de una sede a un ambiente sin pasar por él
Azure Bastion	Acceso administrativo remoto con Entra ID y MFA (sección 5)
DNS Private Resolver	Permite que las sedes resuelvan los nombres privados de Azure y que Azure resuelva los nombres de Cali (sección 5)

Cómo viaja el tráfico

Un usuario de Cali que abre la consola de despacho:

```
Usuario en Cali
  → firewall de Cali
  → internet (proveedor 1)
  → túnel IPsec cifrado
  → VPN Gateway (hub)
  → Azure Firewall (hub)
  → peering
  → subred de la torre (producción)
```

Un servicio de producción que necesita salir a internet:

```
Servicio en producción → UDR → Azure Firewall → internet
```

En los dos casos el Azure Firewall es el punto de control. Esa es la razón principal del hub: un solo lugar donde se definen, aplican y registran las reglas.

VPN Gateway frente a Virtual WAN

Azure ofrece dos formas de armar este hub. Las dos cumplen el requisito; la diferencia está en el tamaño para el que están pensadas y en el costo.

	VPN Gateway con hub propio (elegido)	Virtual WAN Standard
Quién administra el hub	FríoAndes, con su propia red virtual	Microsoft, como servicio administrado
Para cuántos sitios está pensado	Decenas de túneles. Este modelo admite 30 y el diseño usa 20	Decenas o cientos de sitios, con enrutamiento automático entre ellos
Costo de la red completa	Unos USD 4.300 al mes, incluido el segundo proveedor de Cali	Entre USD 562 y 672 más al mes
Condiciones	Ninguna especial para este caso	Exige un bloque `/22` propio para el hub con firewall, y Bastion y el DNS tienen que salir del hub a otra red

Con diez conexiones, la ventaja de Virtual WAN (enrutar automáticamente entre muchos sitios) no compensa el costo adicional. Si FríoAndes crece a muchas más sedes o a varias regiones, el plan de direcciones ya reserva el bloque `10.100.4.0/22` para pasar a Virtual WAN sin renumerar ninguna red.

Por qué el modelo VpnGw1AZ

Es el modelo más pequeño que reparte sus instancias en zonas de disponibilidad. Soporta unos 650 Mbps en total, por encima de los 400 Mbps del enlace de Cali. Azure ya no permite crear modelos sin zonas. Si el tráfico real se acerca a ese límite (por ejemplo, si la copia del archivo histórico se hace por la red), se sube a VpnGw2AZ por unos USD 241 más al mes, sin cambiar el diseño ni las direcciones.

Qué haría cambiar esta topología

- Agregar un enlace dedicado ExpressRoute para Cali mientras los centros siguen por VPN.
- Tener hubs en más de una región de Azure.
- Conectar la segunda nube con equipos SD-WAN o un appliance de red virtual.
- Superar unos 73.000 a 83.000 GB al mes de tráfico por el firewall.

En cualquiera de esos casos se evalúa Virtual WAN, que ya tiene su rango reservado.

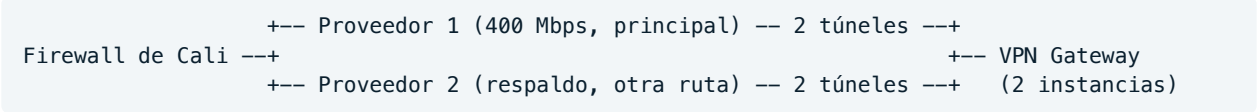
2.2 Redundancia de Cali: dos proveedores de internet

El riesgo

Hoy Cali tiene un solo proveedor de internet. Si ese enlace cae, la sede pierde la conexión con la nube y, con ella, la torre de control.

La solución

Cali contrata un segundo proveedor de internet que llegue por una ruta física distinta: otra fibra, otro ducto y otro nodo del proveedor. Si los dos enlaces comparten el mismo poste o la misma canalización, un solo daño los tumba a la vez y la redundancia deja de existir.



- En Azure se registran dos "local network gateways", uno por cada IP pública de Cali.
- Cada proveedor lleva dos túneles, uno hacia cada instancia del VPN Gateway. En total son cuatro túneles.
- Los cuatro usan BGP.

Activo-pasivo

El proveedor 1 lleva todo el tráfico. El proveedor 2 solo entra si el 1 cae. Para lograrlo, Cali anuncia sus redes por el proveedor 2 con una ruta artificialmente más larga (AS-path prepending): BGP siempre prefiere el camino más corto, así que usa el proveedor 2 solo cuando el 1 desaparece. Cuando el proveedor 1 vuelve, el tráfico regresa solo.

Se eligió activo-pasivo porque los dos enlaces pueden tener capacidades distintas. Si se repartiera el tráfico en paralelo, el enlace menor podría saturarse.

En este diseño hay dos niveles de redundancia que funcionan distinto. El VPN Gateway de Azure trabaja en activo-activo: sus dos instancias están siempre activas. La salida de Cali trabaja en activo-pasivo: un proveedor principal y uno de respaldo. Los dos niveles se combinan: Cali tiene dos túneles activos por el proveedor principal y dos de reserva por el de respaldo.

Lo que esta solución no cubre

El firewall de Cali sigue siendo un solo equipo. Dos proveedores protegen contra la caída de un proveedor. Si el firewall de Cali falla, la sede pierde la conexión igual. Hay tres caminos y la decisión es de FríoAndes:

1. Instalar un segundo firewall y operarlos como par en alta disponibilidad.
2. Usar una VPN de usuario como contingencia, si FríoAndes acepta que una VPN con Entra ID y MFA cuenta como "red corporativa" para usar la torre de control. El plan de direcciones ya reserva el rango para esa VPN.
3. Aceptar el riesgo y dejarlo registrado.

Alternativa descartada: ExpressRoute

Un enlace dedicado ExpressRoute desde Bogotá daría más capacidad y una conexión privada, pero tarda semanas o meses en instalarse, la convivencia dura como máximo 90 días, y cuesta unos USD 1.272 más al mes que la VPN con segundo proveedor. Queda como mejora posterior si FríoAndes necesita un enlace dedicado.

Tampoco sirve poner los dos túneles sobre el mismo proveedor: comparten el punto de falla.

Costo

El segundo proveedor es un supuesto sin cotización: COP 3.000.000 al mes (rango de COP 1,5 a 6 millones), unos USD 906, para 200 Mbps. La cifra final depende de la cotización del proveedor.

2.3 Conexión de los ocho centros

Por qué los centros van directo a la nube

Hoy cada centro llega a Cali por VPN y desde Cali al resto. Si los centros siguieran pasando por Cali después de la migración:

- una caída de Cali dejaría a los ocho centros sin la torre de control, aunque la plataforma ya esté en Azure;
- el enlace de Cali cargaría con el tráfico de todos los centros. Con un supuesto de 300 Kbps por usuario, su uso de entrada pasaría de 17 % a 35 %.

Por eso, cada centro se conecta directamente al VPN Gateway de Azure con dos túneles IPsec (IKEv2) y BGP. Cali deja de ser el punto de paso obligado.

Durante la convivencia: centro por centro, con vuelta atrás

El cambio no se hace a todos los centros a la vez. Cada centro pasa por tres fases:

Fase	Qué pasa	Si algo falla
A	El centro sigue conectado por Cali, como hoy	No aplica
B	Se crea el túnel directo a Azure, pero sin tráfico: el centro sigue prefiriendo la ruta por Cali. Se prueba en la ventana de 22:00 a 04:00	Se borra el túnel y la operación no se entera
C	Se cambia la preferencia y el tráfico pasa por el túnel directo a Azure. La VPN hacia Cali queda como respaldo para lo que todavía viva en Cali	Se devuelve la preferencia a Cali, sin tocar túneles

El orden propuesto es un centro piloto de bajo volumen primero y después uno o dos centros por noche. La VPN de cada centro hacia Cali se apaga a más tardar el día 90.

En estado estable

Cada centro tiene dos túneles directos a Azure, uno hacia cada instancia del VPN Gateway, y anuncia por BGP sus dos redes (usuarios y sensores). Si un centro necesita comunicarse con Cali, el tráfico pasa por Azure: el VPN Gateway hace el tránsito y el Azure Firewall lo controla.

Números de BGP propuestos

Cada sede necesita un número de sistema autónomo (ASN) para BGP:

Sitio	ASN
Azure	65515 (el valor por defecto de Azure)
Cali	65020
Centros	65031 a 65038 (el número imita el segundo octeto de la red de cada centro: Buenaventura 10.31 usa 65031)

Las direcciones BGP de Cali salen de `10.20.10.0/24`, el rango que hoy usa para sus enlaces VPN.

Cuenta de conexiones y túneles

Concepto	Cantidad
Conexiones sitio a sitio	10: Cali cuenta 2 (una por proveedor) y cada centro 1
Túneles	20: 4 de Cali y 2 por cada uno de los 8 centros
Límite del modelo VpnGw1AZ	30 túneles
Segunda nube, cuando llegue	Sería la conexión número 11

Condición

Los equipos de red de los centros tienen que soportar IKEv2, dos túneles simultáneos y BGP. Si alguno no lo soporta, ese centro queda con un túnel activo y otro de respaldo con rutas fijas. La conexión funciona igual, pero el cambio al respaldo es más lento y la fase B se resuelve con métricas fijas.

2.4 Qué pasa con cada función del firewall de Cali

Durante la convivencia el firewall de Cali sigue en pie. Esta tabla dice qué pasa con cada una de sus funciones de red y cuándo. Las reglas de seguridad que se conservan o se trasladan al firewall de nube se detallan en el diseño del firewall de nube (`red-firewall-y-publicacion.md`, sección 5).

Función actual del firewall de Cali	Durante la convivencia	En estado estable
VPN sitio a sitio con los ocho centros	Se mantiene como respaldo y se retira centro por centro (fases A, B y C)	Apagada a más tardar el día 90. Los centros llegan directo a Azure
NAT del portal de rastreo hacia Nginx	Sigue publicando el portal actual	Desde el corte no recibe tráfico, pero queda configurado como camino de vuelta atrás. Se apaga al cerrar ese plazo, como máximo el día 90
Firewall de aplicaciones delante de Nginx	Sigue protegiendo el portal actual	Desde el corte su función la toma el firewall de aplicaciones de Azure (sección 5). Queda configurado y se apaga junto con el NAT
Enrutamiento entre las subredes de Cali	Se mantiene	Se mantiene para lo que queda en la sede: usuarios y torre de control
Políticas entre subredes de servidores de Cali	Se mantienen mientras los servidores sigan encendidos	Se retiran cuando se apaga cada servidor migrado
Salida de Cali hacia la nube	Pasa a dos proveedores con cuatro túneles hacia Azure	Se mantiene

2.5 Diagramas de la conexión

Convivencia (como máximo 90 días)

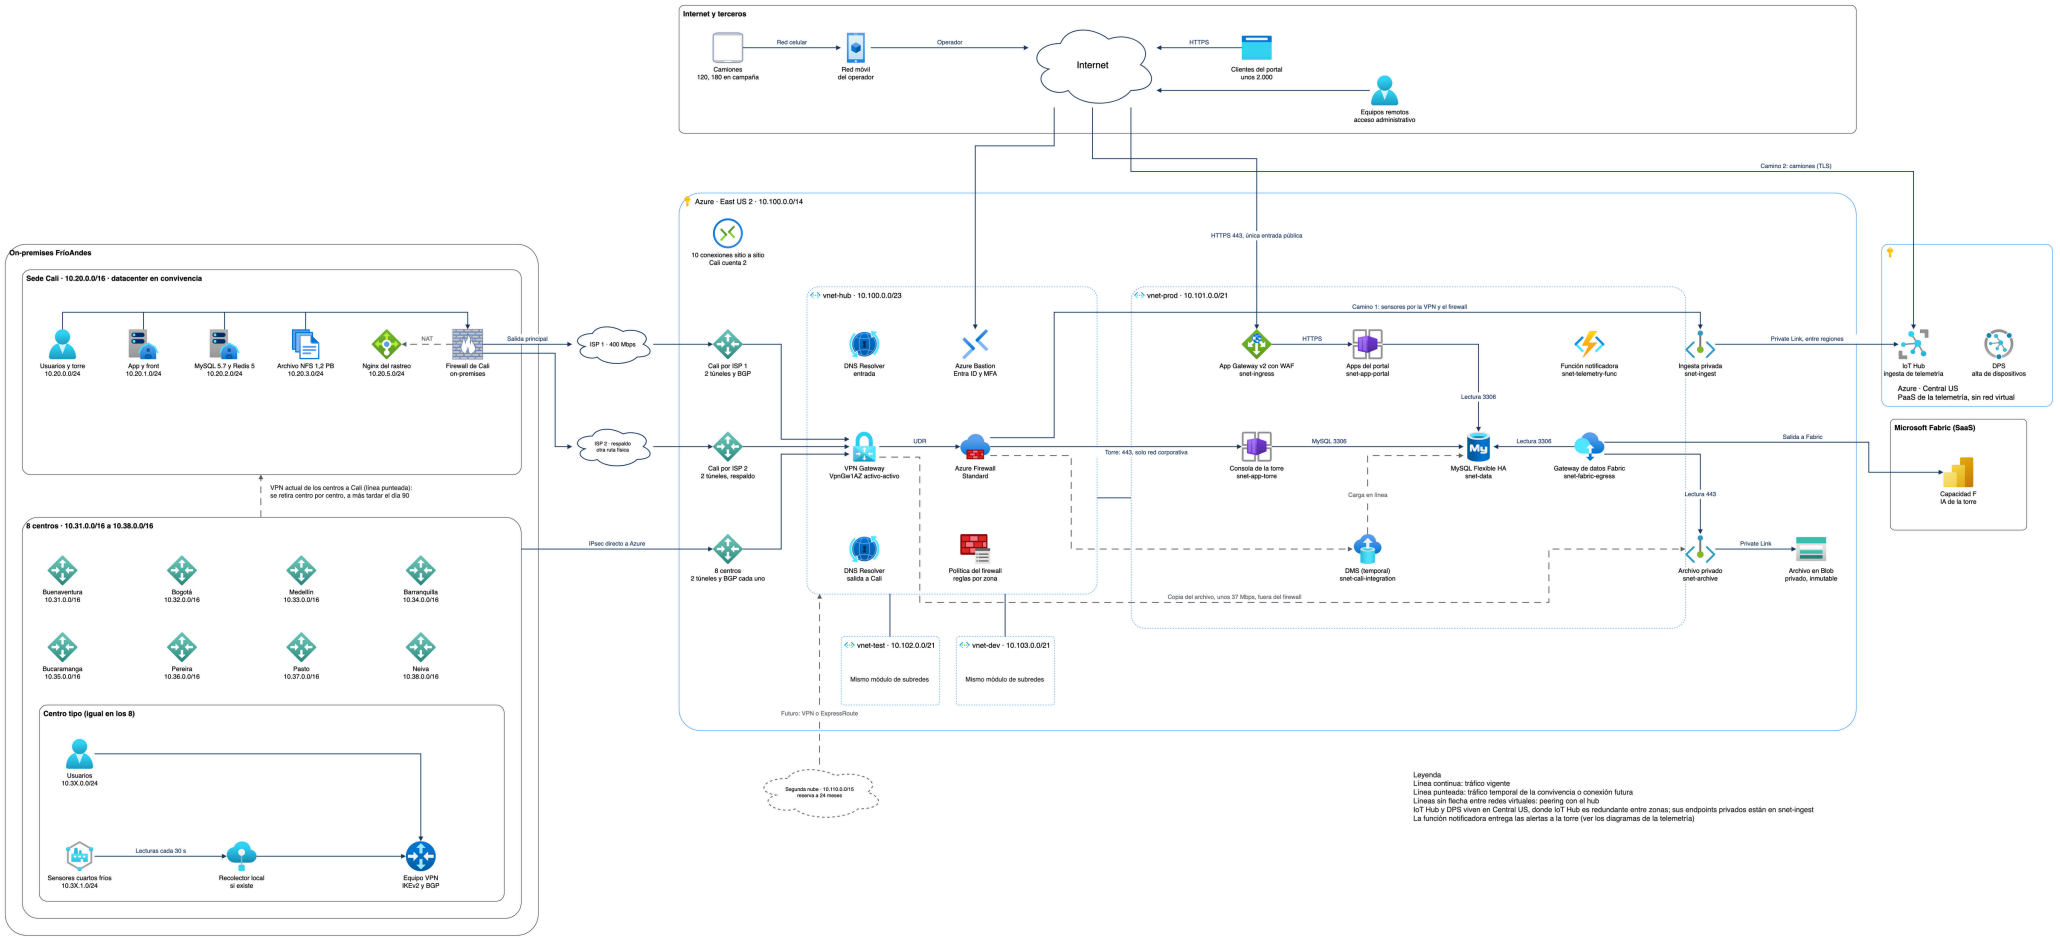


Figura 6: Convivencia: Cali con su datacenter, ocho centros, hub y ambientes de Azure

Qué mirar en este diagrama:

- A la izquierda, Cali todavía con su datacenter (aplicación, bases, archivo y el Nginx del rastreo), con todos los servidores llegando a su firewall.
- La salida de Cali por los dos proveedores, cada uno hacia su local network gateway en Azure.
- La línea punteada entre los centros y Cali es la VPN actual, que se retira centro por centro.
- La línea "IPsec directo a Azure" es la conexión nueva de los centros.
- Las tres entradas al VPN Gateway: proveedor 1, proveedor 2 y los ocho centros.
- Del VPN Gateway al Azure Firewall, y de ahí a la torre de control en producción.

Estado estable (después del día 90)

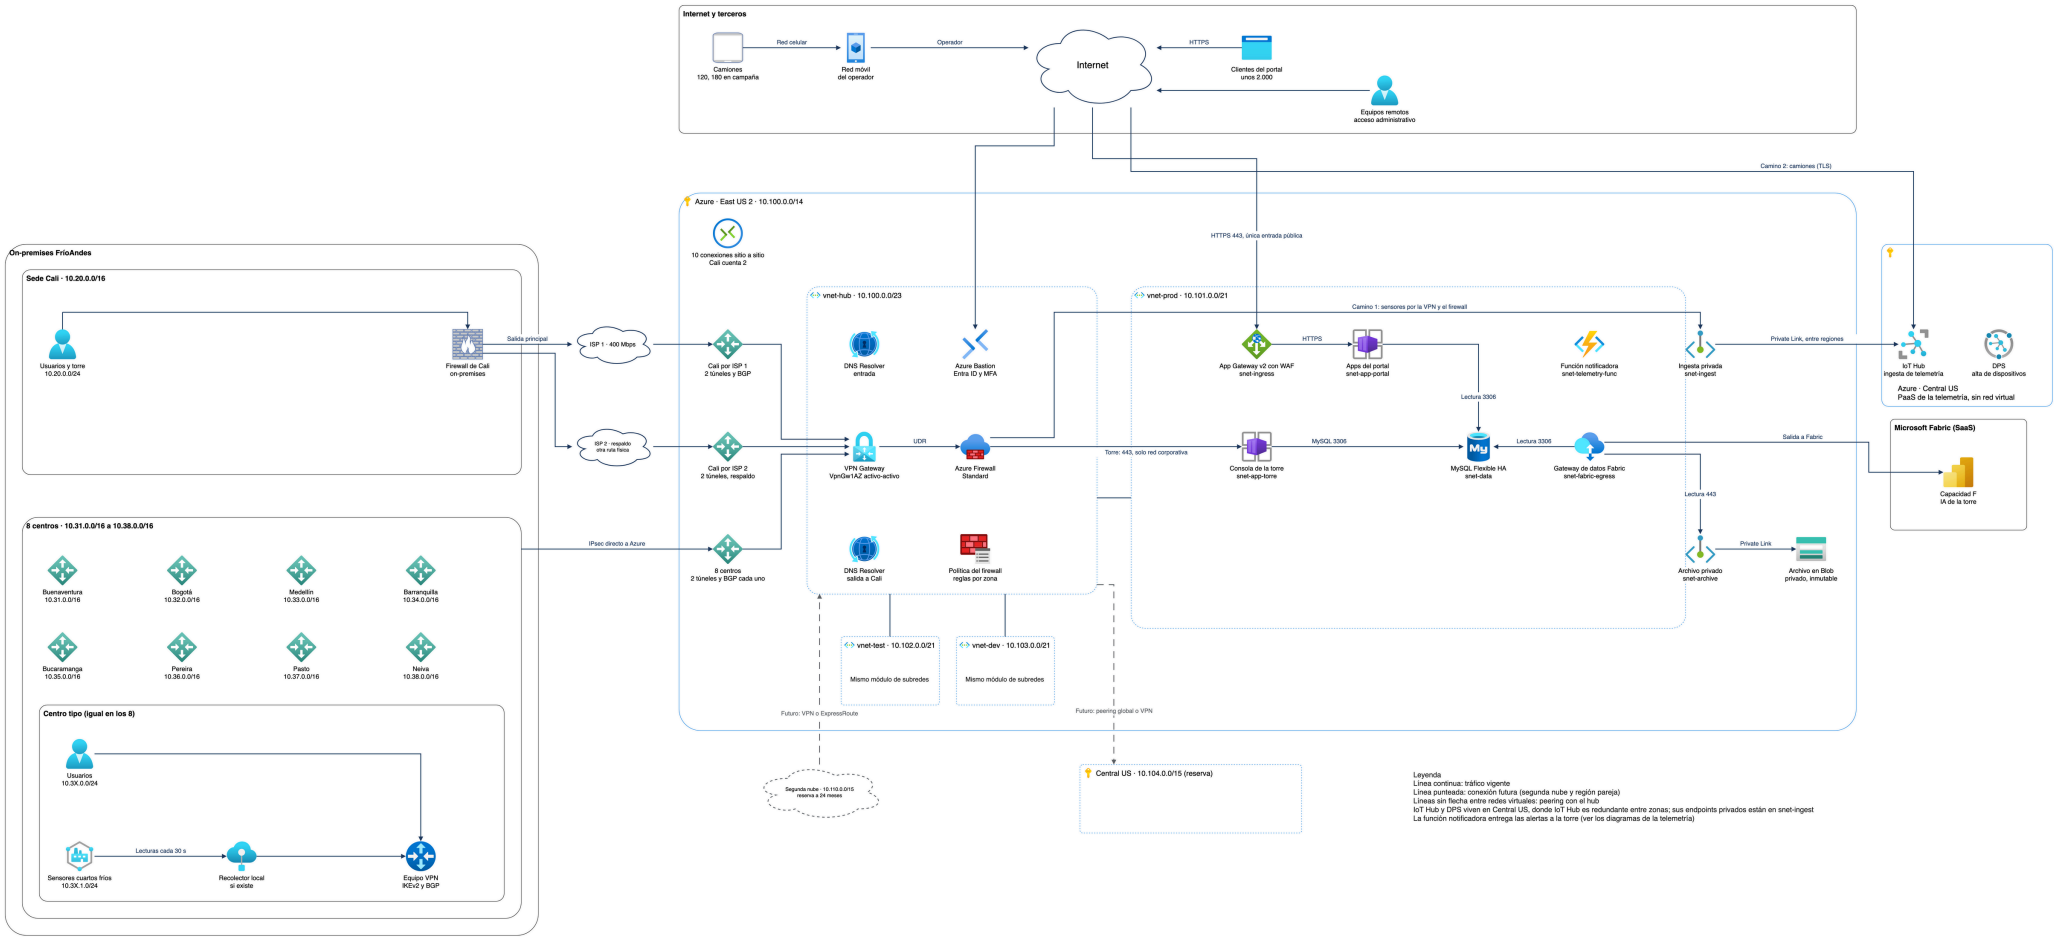


Figura 7: Estado estable: centros directo a Azure, Cali con dos proveedores

Qué cambia frente a la convivencia:

- Cali ya no aloja servidores: quedan los usuarios y su firewall.
- Los centros solo tienen la conexión directa a Azure.
- Aparecen en línea punteada las reservas para el futuro: la región pareja (Central US) y la segunda nube.
- En los dos diagramas, IoT Hub y su servicio de aprovisionamiento (DPS) están en Central US, fuera de las redes virtuales, y la función notificadora de la telemetría está en `snet-telemetry-func` de producción.

---

3. Región de Azure y latencia medida desde Cali

3.1 Qué se decide y por qué importa

La región es el lugar físico donde corre la plataforma. Elegirla afecta cuatro cosas:

Factor	Qué significa para FríoAndes
Latencia	Cuánto tarda cada pedido entre Cali o los centros y la plataforma. Afecta la sensación de rapidez de la torre de control y del portal
Servicios disponibles	No todas las regiones tienen todos los servicios ni todas sus variantes (por ejemplo, redundancia entre zonas)
Costo	El mismo servicio cuesta distinto según la región
Recuperación ante desastres	Cada región de Azure tiene una región pareja. Ahí se reserva espacio para recuperar la plataforma si la región principal falla

La propuesta inicial era East US 2, con Central US como región pareja. Esta sección confirma esa elección con una medición de latencia desde Cali.

3.2 Cómo se midió

Se midió la latencia desde Cali hacia East US 2 y hacia seis alternativas razonables para Colombia: East US, South Central US, Central US, Mexico Central, Brazil South y Chile Central.

- **Qué se mide.** El tiempo que tarda en abrirse una conexión TCP al puerto 443 de un servicio de almacenamiento de Azure ubicado en cada región. Ese tiempo equivale aproximadamente a un viaje de ida y vuelta de un paquete, que es lo que más pesa en la rapidez de una aplicación web.
- **Cuántas veces.** 30 conexiones por región en cada ronda, dos rondas.
- **Qué se reporta.** La mediana, que es el valor del medio: la mitad de las conexiones tardó menos y la otra mitad más. Es más estable que el promedio porque una conexión lenta aislada no la mueve.
- **Desde dónde.** Desde la red cableada de una universidad en Cali. Es una aproximación de la latencia desde la ciudad: la medición no pasa por el enlace de 400 Mbps de la sede de FríoAndes. Antes de implementar conviene repetirla desde la sede con el mismo script; la decisión solo cambia si el resultado cruza la regla de la sección 3.4.
- **Herramienta.** Un script reproducible (`measure_latency.py`), incluido con este documento.

3.3 Resultados

Región	Mediana ronda 1 (ms)	Mediana ronda 2 (ms)	Frente a East US 2
East US 2	96,5	85,5	Referencia
East US	89,0	95,5	8 % menos en la ronda 1, 12 % más en la ronda 2
South Central US	97,2	92,0	1 % y 8 % más
Central US (región pareja)	110,8	105,2	15 % y 23 % más
Mexico Central	114,7	120,3	19 % y 41 % más
Brazil South	157,9	148,7	64 % y 74 % más
Chile Central	159,1	139,6	65 % y 63 % más

Lectura de los resultados:

- East US 2, East US y South Central US quedan prácticamente empatadas: se alternan entre rondas, dentro de la variación normal de una conexión a internet.
- Brazil South y Chile Central, aunque están en Sudamérica, miden entre 60 % y 75 % más. El tráfico de internet desde Colombia sale por los cables submarinos hacia Miami, así que las regiones del este de Estados Unidos quedan más cerca en la práctica que las del sur del continente.
- Mexico Central queda en un punto intermedio.

3.4 Regla de decisión

La regla se fijó antes de medir, para que el resultado no se interpretara a conveniencia:

> Se mantiene East US 2, salvo que otra región tenga una mediana al menos 30 % menor, todos los servicios que necesita la plataforma y un costo comparable.

El umbral es alto a propósito. La plataforma es una consola web, un portal de rastreo y un sistema de alertas con un margen de 60 segundos. Para ese uso, diferencias de 10 a 30 ms no cambian la experiencia de nadie, mientras que cambiar de región sí puede cambiar costos, servicios disponibles y la región pareja.

Resultado: se mantiene East US 2, con Central US como región pareja. Ninguna alternativa baja la latencia un 30 %. La mejor queda 8 % por debajo en una ronda y por encima en la otra.

3.5 Servicios disponibles en la región

East US 2 y su pareja Central US tienen disponibles todos los servicios que usa este diseño:

Grupo	Servicios
Red	VPN Gateway con zonas, Azure Firewall, Application Gateway v2, Azure Bastion, DNS Private Resolver, Virtual WAN (para el futuro)
Aplicación	Container Apps, Azure Kubernetes Service, App Service
Datos	MySQL Flexible Server con alta disponibilidad entre zonas, Azure Managed Redis, Key Vault, almacenamiento Blob
Telemetría	IoT Hub, Event Hubs, Stream Analytics, Functions, Data Explorer
Analítica	Microsoft Fabric

Hay una diferencia que conviene conocer: **IoT Hub tiene redundancia entre zonas en Central US; en East US 2 funciona sin ella.** Por eso el diseño de telemetría ubica IoT Hub y su servicio de aprovisionamiento (DPS) en Central US. La red no cambia: sus endpoints privados quedan en `snet-ingest` de East US 2, porque Azure permite que un endpoint privado esté en otra región que el servicio (`carga-b-telemetria.md`, sección 2.4).

East US 2 tiene tres zonas de disponibilidad en servicio general. El diseño se apoya en esas tres.

3.6 Costo según la región

Los servicios de red (VPN Gateway y Azure Firewall) cuestan lo mismo en las siete regiones medidas. Donde sí hay diferencias es en datos y almacenamiento, según los precios de lista de Azure sin descuentos:

Región	Base de datos MySQL (cómputo)	Almacenamiento Blob
East US 2	Referencia	Referencia
Central US	13 % más	Igual
South Central US	20 % más	Igual
East US	Igual	13 % más
Mexico Central	10 % más	24 % más
Brazil South	35 % más	77 % más
Chile Central	40 % más	40 % más

East US 2 es la más barata o empata en los dos rubros. Con un archivo histórico de 1,2 PB que crece 12 TB al mes, el precio del almacenamiento pesa mucho en la factura.

3.7 Región pareja y recuperación

Central US es la región pareja de East US 2. Azure coordina el mantenimiento de las dos para que no queden fuera de servicio al mismo tiempo, y algunos servicios replican datos entre ellas. La telemetría ya usa Central US como región principal de IoT Hub, DPS y la evidencia de temperatura, porque ahí IoT Hub es redundante entre zonas. Esos servicios no necesitan una red virtual en Central US: sus endpoints privados están en East US 2, así que la reserva `10.104.0.0/15` sigue libre. El plan de direcciones reserva el bloque `10.104.0.0/15` para el hub y la producción de recuperación en Central US (sección 4). El diseño de continuidad de la plataforma define qué se replica y cómo se activa.

3.8 Ubicación de los datos

Con esta decisión, los datos y el procesamiento de la plataforma quedan en Estados Unidos. FríoAndes maneja datos personales de clientes y conductores, así que debe confirmar que esa ubicación es aceptable bajo la Ley 1581 de protección de datos personales y sus políticas internas.

---

4. Plan de direcciones y verificación de no solapamiento

4.1 Qué se resuelve

La nube necesita sus propias direcciones privadas. Si un rango de la nube repite uno que ya usa Cali o un centro, los equipos no saben a cuál de los dos enviar el tráfico y la conexión falla. Por eso el plan de direcciones cumple tres condiciones:

1. Ningún rango de la nube se solapa con las 23 subredes que hoy usa FríoAndes.
2. Desarrollo, pruebas y producción tienen rangos distintos y el mismo patrón de subredes, para que el código de infraestructura se escriba una vez y se use en los tres ambientes.
3. Queda espacio reservado para crecer: más centros, la región pareja, la segunda nube y un posible cambio de topología, sin tener que renumerar nada.

El plan completo vive en un archivo, `ip-plan.csv`, que es la única fuente de las direcciones. Un script lo compara automáticamente con el inventario on-premises (sección 4.8).

4.2 Las redes que ya existen

Estas 23 subredes están en uso y la nube no puede tocarlas:

Sitio	Subredes
Cali	`10.20.0.0/24` usuarios y torre de control, `10.20.1.0/24` aplicación y front, `10.20.2.0/24` bases y caché, `10.20.3.0/24` archivo y Zabbix, `10.20.4.0/24` administración de VMware, `10.20.5.0/24` publicación del rastreo, `10.20.10.0/24` enlaces VPN
Cada uno de los ocho centros	`10.3X.0.0/24` usuarios y `10.3X.1.0/24` sensores de cuartos fríos, donde X va de 1 (Buenaventura) a 8 (Neiva)

Cada sitio usa unas pocas subredes dentro de un bloque `/16` propio: Cali el `10.20.0.0/16` y cada centro su `10.3X.0.0/16`. El plan deja esos `/16` completos para que Cali y los centros puedan crecer sin chocar con la nube.

4.3 Cómo se organizan las direcciones

Toda la nube de la región principal cabe en un solo bloque, `10.100.0.0/14`. Cada función ocupa un `/16` distinto, así que el segundo número de la dirección dice dónde está: 100 es el hub, 101 producción, 102 pruebas y 103 desarrollo.

Bloque	Uso	Contenido
`10.20.0.0/16`	Cali	Las 7 subredes actuales y espacio para crecer

Bloque	Uso	Contenido
`10.31.0.0/16` a `10.38.0.0/16`	Los ocho centros	2 subredes por centro y espacio para crecer
`10.39.0.0/16`	Reserva	Un noveno centro, con el mismo patrón
`10.40.0.0` a `10.99.255.255`	Libre	Preferente para sedes futuras
`10.100.0.0/16`	Hub	Red del hub `10.100.0.0/23`, reserva para Virtual WAN `10.100.4.0/22` y reserva para VPN de usuario `10.100.8.0/22`
`10.101.0.0/16`	Producción	Red `10.101.0.0/21`
`10.102.0.0/16`	Pruebas	Red `10.102.0.0/21`
`10.103.0.0/16`	Desarrollo	Red `10.103.0.0/21`
`10.104.0.0/15`	Reserva	Región pareja (Central US) para recuperación
`10.106.0.0/15` y `10.108.0.0/15`	Libres	Sin asignar
`10.110.0.0/15`	Reserva	Segunda nube

Dentro de cada `/16` la red virtual ocupa solo lo que justifica su cuenta (un `/23` el hub y un `/21` cada ambiente). El resto del `/16` queda libre para crecer.

Decisión: el hub mide `/23` y cada ambiente `/21`.

- **Hub `/23` (512 direcciones).** Sus seis subredes suman 288 direcciones (cuatro `/26` que exige Azure y dos `/28` del DNS). El `/23` deja 224 libres para lo que el hub puede necesitar después: Azure Route Server si se agrega ExpressRoute y un equipo de red virtual para la segunda nube.
- **Cada ambiente `/21` (2.048 direcciones).** Sus once subredes suman 768 direcciones, así que quedan 1.280 libres, un 62,5 %. Ese espacio permite agregar cómputo de telemetría, otro entorno de aplicación o ejecutores privados del pipeline sin renumerar. Un `/22` dejaría solo 288 libres, poco para tres ambientes que van a crecer.
- **Por qué no un `/16` por red virtual.** Serían 65.536 direcciones para unas 750 usadas, sin una necesidad que lo justifique, y se perdería el espacio para reservas.
- **Por qué no ambientes contiguos sin bloques.** Ahorraría espacio, pero se perdería la lectura por el segundo número (100, 101, 102, 103) y el resumen de toda la región en un solo prefijo, `10.100.0.0/14`, que simplifica las rutas y las reglas del firewall de Cali.

4.4 Subredes del hub (`vnet-hub`, `10.100.0.0/23`)

Subred	Rango	Servicio	Reglas de Azure que aplican
`GatewaySubnet`	`10.100.0.0/26`	VPN Gateway	Nombre obligatorio. Sin NSG ni ruta por defecto hacia el firewall
`AzureFirewallSubnet`	`10.100.0.64/26`	Azure Firewall	Nombre obligatorio. Mínimo `/26`
`AzureFirewallManagementSubnet`	`10.100.0.128/26`	Tarjeta de gestión del firewall	Nombre obligatorio. Mínimo `/26`. Se habilita desde el inicio, porque activarla después obliga a detener el firewall
`AzureBastionSubnet`	`10.100.0.192/26`	Azure Bastion	Nombre obligatorio. Mínimo `/26`
`snet-dns-inbound`	`10.100.1.0/28`	DNS Private Resolver, entrada	Exclusiva del resolver. Entre `/28` y `/24`
`snet-dns-outbound`	`10.100.1.16/28`	DNS Private Resolver, salida	Igual que la anterior

Quedan libres en el hub `10.100.1.32/27`, `10.100.1.64/26` (lugar previsto para Azure Route Server si se agrega ExpressRoute) y `10.100.1.128/25` (para un equipo de red virtual de la segunda nube).

Decisión: la `GatewaySubnet` mide `/26`. Azure pide como mínimo `/27`. Si en el futuro FríoAndes agrega ExpressRoute, los dos gateways (VPN y ExpressRoute) tienen que convivir en esa subred, y la arquitectura de referencia de Microsoft recomienda `/26` para ese caso. Una subred con recursos no se puede agrandar: habría que borrar el VPN Gateway y recrearlo, con Cali y los centros sin conexión mientras tanto. Crearla en `/26` desde el inicio cuesta 32 direcciones de un bloque que sobra y evita ese corte.

4.5 Subredes de cada ambiente

Producción, pruebas y desarrollo tienen las mismas once subredes. Solo cambia el segundo número de la dirección (101, 102 o 103).

Subred	Producción	Pruebas	Desarrollo	Servicio
`snet-ingress`	`10.101.0.0/24`	`10.102.0.0/24`	`10.103.0.0/24`	Application Gateway v2 con firewall de aplicaciones (WAF): la entrada pública del portal
`snet-app-torre`	`10.101.1.0/25`	`10.102.1.0/25`	`10.103.1.0/25`	Consola de despacho (torre de control)
`snet-app-portal`	`10.101.1.128/25`	`10.102.1.128/25`	`10.103.1.128/25`	Servicios del portal de rastreo
`snet-data`	`10.101.2.0/27`	`10.102.2.0/27`	`10.103.2.0/27`	MySQL Flexible Server (subred exclusiva)
`snet-data-pe`	`10.101.2.32/27`	`10.102.2.32/27`	`10.103.2.32/27`	Endpoints privados de la caché (Azure Managed Redis), de Key Vault, de los Event Hubs de la telemetría y de la cuenta de la función notificadora
`snet-archive`	`10.101.2.64/27`	`10.102.2.64/27`	`10.103.2.64/27`	Endpoints privados del almacenamiento del archivo histórico, las evidencias y el historial de telemetría
`snet-ingest`	`10.101.2.96/27`	`10.102.2.96/27`	`10.103.2.96/27`	Endpoints privados de IoT Hub y DPS, por donde entran los cuartos fríos
`snet-admin`	`10.101.2.128/27`	`10.102.2.128/27`	`10.103.2.128/27`	Agentes de despliegue y máquinas de operación, administradas por Bastion
`snet-cali-integration`	`10.101.2.160/27`	`10.102.2.160/27`	`10.103.2.160/27`	Herramientas de la migración desde Cali. Queda vacía en estado estable
`snet-fabric-egress`	`10.101.2.192/27`	`10.102.2.192/27`	`10.103.2.192/27`	Gateway de datos que lleva el libro operativo de forma privada hacia Microsoft Fabric
`snet-telemetry-func`	`10.101.3.0/27`	`10.102.3.0/27`	`10.103.3.0/27`	Función notificadora de la telemetría (Azure Functions, plan Flex Consumption), delegada a `Microsoft.App/environments`

Las dos subredes de aplicación (torre y portal) dependen de la plataforma que se elija para correr la consola y el portal. Sus rangos no cambian, pero su configuración sí (sección 7).

Quedan libres en cada ambiente `10.10X.2.224/27`, `10.10X.3.32/27`, `10.10X.3.64/26`, `10.10X.3.128/25` y `10.10X.4.0/22`, para nuevos servicios o ejecutores privados del pipeline. Con la variante Kubernetes, el primero de esos bloques se usa para la API privada del clúster (sección 7).

Las ocho categorías de subred de cada ambiente:

Categoría pedida	Subred
Ingreso	`snet-ingress`
Aplicación	`snet-app-torre` y `snet-app-portal`
Datos	`snet-data` y `snet-data-pe`
Archivo	`snet-archive`
Ingesta de telemetría	`snet-ingest` y `snet-telemetry-func`
Administración	`snet-admin`
Integración con Cali	`snet-cali-integration`
Salida a Fabric	`snet-fabric-egress`

4.6 Reservas para crecer

Reserva	Rango	Para qué
Segunda nube	`10.110.0.0/15`	Dos `/16`: uno para tránsito e interconexión y otro para cargas. Solo reserva las direcciones; la plataforma de la segunda nube se diseña cuando se decida
Región pareja	`10.104.0.0/15`	Hub y producción de recuperación en Central US
Hub de Virtual WAN	`10.100.4.0/22`	Si la topología pasa a Virtual WAN (su hub con firewall exige un `/22`)
VPN de usuario	`10.100.8.0/22`	Direcciones para los equipos que se conecten por VPN de usuario, si se elige esa forma de acceso: unos 450 usuarios internos y unas 60 personas remotas, con margen
Noveno centro	`10.39.0.0/16`	Un centro nuevo con el mismo patrón de los ocho actuales

4.7 Cómo se calcularon los tamaños

Una subred con recursos dentro no se puede agrandar, así que cada tamaño se calcula para el máximo previsto (con la campaña de fin de año incluida) y con margen:

> Direcciones necesarias = las que usa el servicio en su máximo + las que necesita durante actualizaciones + las 5 que Azure reserva en cada subred.

Subred	Cuenta	Tamaño
Subredes de plataforma del hub	Mínimos que exige Azure para cada servicio	`/26` o `/28`
Red del hub	4 subredes de 64 + 2 de 16 = 288 direcciones	`/23` (512)
`snet-ingress`	Application Gateway puede crecer hasta 125 instancias; con su IP privada y las 5 de Azure son 131. Para el portal (unas 2.000 solicitudes por minuto) bastan 4 instancias y se planifican hasta 10	`/24`, el tamaño que recomienda Microsoft
`snet-app-torre` y `snet-app-portal`	Depende de la plataforma (sección 7); el máximo previsto con Container Apps son 97 direcciones	`/25` (128)
`snet-data`	Base principal con alta disponibilidad entre zonas (2) + 2 réplicas de lectura (4) + 1 servidor temporal de migración (2) + 5 de Azure = 13	`/27` (32)
Subredes de endpoints privados	Hasta 10 endpoints cada una	`/27`
`snet-admin`	Hasta 12 máquinas	`/27`
`snet-cali-integration`	Hasta 11 direcciones para las herramientas de migración	`/27`
`snet-fabric-egress`	Hasta 11 miembros del gateway de datos: 5 de Azure + 5 de funcionamiento + 11 + 2 de margen = 23	`/27`
Red de cada ambiente	256 + 2 × 128 + 8 × 32 = 768 direcciones	`/21` (2.048): quedan 1.280 libres, un 62,5 %

4.8 Verificación de no solapamiento

La verificación no se hace a ojo. Un script, `verify_ip_plan.py`, lee el plan de direcciones y el inventario de las 23 subredes on-premises, y comprueba doce condiciones:

Comprobación	Resultado
El inventario tiene las 23 subredes on-premises	Cumple
Todos los rangos del plan están bien escritos	Cumple
Ningún rango de la nube se solapa con las 23 subredes on-premises	Cumple
La nube respeta los `/16` completos de Cali y de cada centro	Cumple
Las redes virtuales no se solapan entre sí (desarrollo, pruebas y producción en rangos distintos)	Cumple
Cada subred está dentro de su red virtual	Cumple
Las subredes no se solapan entre sí	Cumple
Cada ambiente tiene las ocho categorías pedidas	Cumple
Hay un bloque reservado para la segunda nube, libre de solapes	Cumple
Torre, portal, ingesta y analítica tienen subredes propias en cada ambiente	Cumple
La única entrada pública de aplicación es el ingreso del portal	Cumple
Las subredes respetan los nombres y tamaños que exige Azure	Cumple

Conclusión: sin solapamiento. Los 48 rangos de la nube (4 redes virtuales, 39 subredes y 5 reservas) se compararon uno por uno contra las 23 subredes on-premises. La tabla completa, rango por rango, está en el Anexo A.

Cómo comprobarlo. Cualquiera puede repetir la verificación desde la carpeta `red/`:

```
python3 tools/verify_ip_plan.py --plan data/ip-plan.csv --out verification/reporte-ip-plan.md
sha256sum data/ip-plan.csv
# a520eba842e6d7781705613d539fcfd018bfd00481f3842814d07d97036b91a0
```

El hash identifica el archivo verificado. Si alguien cambia una sola dirección, el hash cambia y hay que volver a correr el script.

El script también detecta errores. Se probó con un plan con cinco errores puestos a propósito (una reserva encima de Bogotá y Medellín, dos subredes de desarrollo solapadas, una categoría faltante en pruebas, la torre con entrada pública y una subred de Bastion demasiado pequeña) y los detectó todos.

Verificación contra el código. Cuando la red se escriba en Terraform, un segundo script (`compare_tfplan.py`) compara lo que Terraform va a crear con `ip-plan.csv` y avisa si alguna red o subred difiere. Así la verificación también vale para lo que realmente se despliega (desde la carpeta `red/`):

```
terraform show -json plan.tfplan > plan.json
python3 tools/compare_tfplan.py --tfplan plan.json --plan data/ip-plan.csv --out-csv tf-ip-plan.csv
python3 tools/verify_ip_plan.py --plan tf-ip-plan.csv --out verification/reporte-terraform.md
```

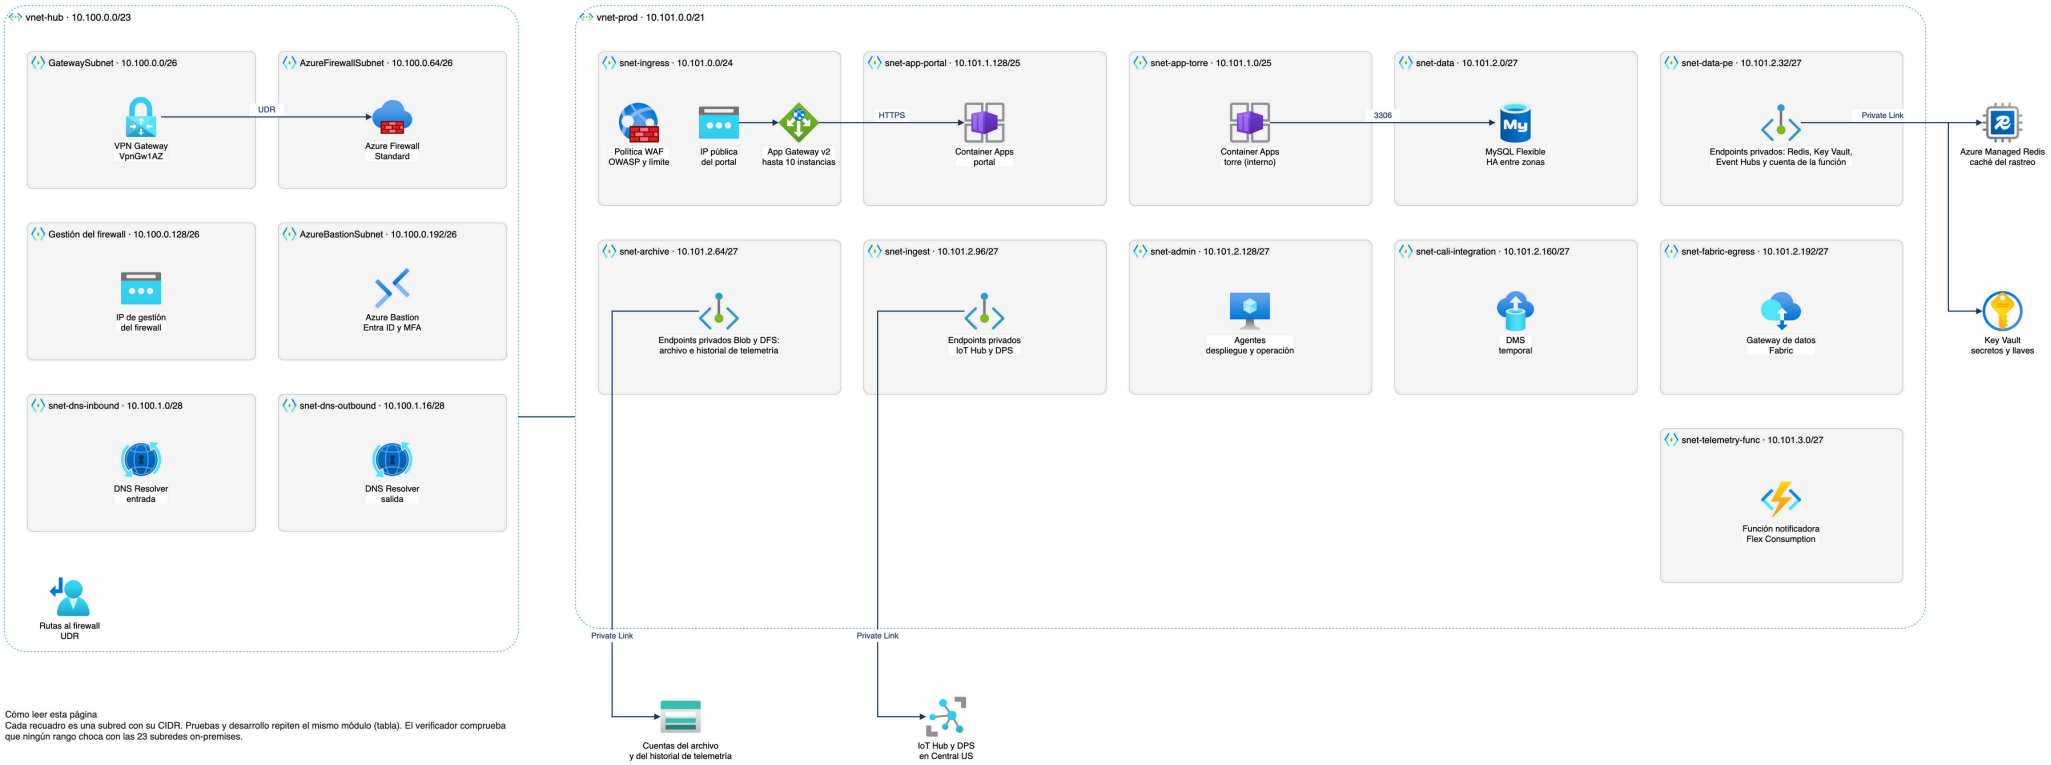
4.9 Cómo se escribe en Terraform

El código de red lee `ip-plan.csv` directamente con `csvdecode(file("ip-plan.csv"))`. Así el código y el plan verificado son siempre iguales y el hash del archivo prueba que no cambió. El módulo de ambiente se escribe una vez y se usa tres veces cambiando solo el rango de la red virtual. Cada subred se calcula con la función `cidrsubnet` de Terraform:

Subred	Bits nuevos	Número	Resultado en producción (`10.101.0.0/21`)
`snet-ingress`	3	0	`10.101.0.0/24`
`snet-app-torre`	4	2	`10.101.1.0/25`
`snet-app-portal`	4	3	`10.101.1.128/25`
`snet-data`	6	16	`10.101.2.0/27`
`snet-data-pe`	6	17	`10.101.2.32/27`

Subred	Bits nuevos	Número	Resultado en producción (`10.101.0.0/21`)
`snet-archive`	6	18	`10.101.2.64/27`
`snet-ingest`	6	19	`10.101.2.96/27`
`snet-admin`	6	20	`10.101.2.128/27`
`snet-cali-integration`	6	21	`10.101.2.160/27`
`snet-fabric-egress`	6	22	`10.101.2.192/27`
`snet-telemetry-func`	6	24	`10.101.3.0/27`

4.10 Diagrama de subredes



Reserva	Rango
segunda-nube	10.110.0.0/15
region-pareja	10.104.0.0/15
hub-vwan	10.100.4.0/22
vpn-usuarios	10.100.8.0/22
centros-nuevos	10.39.0.0/16
on-premises (crecimiento)	10.20 y 10.31 a 10.38 (cada uno /16)

Subred	prod	test	dev
Red virtual	10.101.0.0/21	10.102.0.0/21	10.103.0.0/21
snet-ingress	10.101.0.0/24	10.102.0.0/24	10.103.0.0/24
snet-app-portal	10.101.1.128/25	10.102.1.128/25	10.103.1.128/25
snet-app-torre	10.101.1.0/25	10.102.1.0/25	10.103.1.0/25
snet-data	10.101.2.0/27	10.102.2.0/27	10.103.2.0/27
snet-data-pe	10.101.2.32/27	10.102.2.32/27	10.103.2.32/27
snet-archive	10.101.2.64/27	10.102.2.64/27	10.103.2.64/27
snet-ingest	10.101.2.96/27	10.102.2.96/27	10.103.2.96/27
snet-admin	10.101.2.128/27	10.102.2.128/27	10.103.2.128/27
snet-cali-integration	10.101.2.160/27	10.102.2.160/27	10.103.2.160/27
snet-fabric-egress	10.101.2.192/27	10.102.2.192/27	10.103.2.192/27
snet-telemetry-func	10.101.3.0/27	10.102.3.0/27	10.103.3.0/27

Figura 8: Subredes del hub y de producción con sus rangos, tablas del módulo y de reservas

Cada recuadro es una subred con su rango y el ícono del servicio que aloja, incluida `snet-telemetry-func`. Abajo están la tabla del módulo con los rangos de producción, pruebas y desarrollo, y la tabla de reservas.

---

5. Exposición a internet, acceso administrativo y segunda nube

Esta sección resuelve cinco necesidades: mantener el despacho fuera de internet, publicar el rastreo de forma controlada, dar acceso administrativo a equipos distribuidos sin abrir la red de despacho, preparar un punto de interconexión y DNS para una segunda nube, y separar las cargas en zonas que el firewall pueda controlar.

5.1 Zonas de red

Una zona es un grupo de subredes con el mismo nivel de confianza. Separar las cargas en zonas permite que el firewall y los grupos de seguridad de red (NSG) decidan qué puede hablar con qué. Cada ambiente tiene las mismas zonas:

Zona	Subredes	Quién llega
Torre de control	`snet-app-torre`	Solo usuarios de la red corporativa (Cali y los centros), a través del Azure Firewall
Portal de rastreo	`snet-ingress` y `snet-app-portal`	Clientes desde internet, únicamente a `snet-ingress`. `snet-app-portal` solo recibe tráfico desde `snet-ingress`
Ingesta de telemetría	`snet-ingest` y `snet-telemetry-func`	Sensores de los cuartos fríos, por la VPN de cada centro y el Azure Firewall. La función notificadora no recibe tráfico: lee las alertas de un event hub y avisa a la torre y a los canales
Analítica	`snet-fabric-egress`	Nadie desde afuera. El gateway de datos lee la base de datos y envía la información a Microsoft Fabric
Compartida	`snet-data`, `snet-data-pe`, `snet-archive`, `snet-admin`, `snet-cali-integration`	Las aplicaciones de la plataforma, las herramientas de administración y, durante la convivencia, la migración desde Cali

Cómo se representa la analítica. Microsoft Fabric es un servicio en la nube que no vive dentro de las redes virtuales de FríoAndes. Lo que la red sí tiene que resolver es cómo salen los datos hacia Fabric sin pasar por internet público. Para el libro operativo eso lo hace el gateway de datos de red virtual, alojado en `snet-fabric-egress`, y por eso la zona de analítica es esa subred. La telemetría y el archivo llegan a Fabric por atajos de OneLake con acceso de confianza, que van por la red de Microsoft entre Fabric y cada cuenta, sin pasar por las redes virtuales (`fabric-workspaces-ingesta-region.md`, sección 3).

Torre, portal, ingesta y analítica tienen subredes propias en los tres ambientes. El script de verificación lo comprueba (sección 4.8).

5.2 El despacho fuera de internet

La torre de control muestra ubicación de carga y datos de clientes, así que solo se usa desde la red corporativa. En la nube esto se logra así:

- `snet-app-torre` no tiene ninguna dirección pública ni ninguna entrada desde internet.
- Solo recibe tráfico que llega por las VPN de Cali y de los centros y pasa por el Azure Firewall, por HTTPS (443).
- Ninguna de las entradas públicas de la plataforma (sección 5.4) llega a la torre.

El plan de direcciones declara la exposición de cada subred en la columna `internet` de `ip-plan.csv`. Todas las subredes de la torre tienen el valor `ninguno`, y el script de verificación rechazaría el plan si alguna tuviera otro valor.

5.3 Publicación controlada del rastreo

El portal de rastreo es para unos 2.000 clientes corporativos y tiene que estar en internet. Se publica así:

```
Cliente en internet
  → IP pública del portal
  → Application Gateway v2 con firewall de aplicaciones (WAF), en snet-ingress
  → servicios del portal, en snet-app-portal (sin dirección pública)
  → base de datos y caché, por la red privada
```

- **Una sola puerta.** `snet-ingress` es la única subred con entrada pública de aplicación en cada ambiente.
- **El WAF filtra antes de que el tráfico toque la aplicación.** Aplica las reglas de OWASP contra ataques web comunes y limita la cantidad de solicitudes por origen.
- **Los servicios del portal no tienen dirección pública.** Solo aceptan tráfico que viene del Application Gateway.
- **Pruebas y desarrollo** tienen la misma estructura, pero su entrada se limita a orígenes autorizados (las IP de FríoAndes y del equipo de desarrollo).
- **Durante la convivencia** el portal actual sigue publicado desde Cali por NAT y Nginx. Se apaga en el corte, cuando el portal nuevo queda publicado en Azure (sección 2.4).

La tabla de reglas del WAF y del Azure Firewall se detalla en el diseño del firewall de nube (`red-firewall-y-publicacion.md`).

5.4 Todas las entradas públicas

Esta tabla reúne todo lo que tiene una dirección pública en el diseño, para que nada quede sin control:

Entrada pública	Dónde	Quién la usa	Protección	Vigencia
Portal de rastreo (HTTPS 443)	Application Gateway en `snet-ingress`	Unos 2.000 clientes	WAF	Permanente
Portal de pruebas y desarrollo	`snet-ingress` de pruebas y desarrollo	Equipos autorizados	Solo orígenes autorizados	Permanente
Endpoint público de IoT Hub	Servicio de ingesta	Camiones, por la red móvil del operador	TLS y una credencial por camión	Permanente
Endpoint público del servicio de aprovisionamiento (DPS)	Servicio de ingesta	Camiones, al darse de alta	TLS y certificado del camión	Permanente
Endpoint público de las cuentas del historial de telemetría	Almacenamiento en Central US y East US 2	Solo IoT Hub y Stream Analytics, con su identidad administrada	Reglas de instancia de recurso, sin redes ni IP permitidas	Permanente
IP públicas del VPN Gateway (2)	`GatewaySubnet`	Túneles de Cali y de los centros	IPsec IKEv2	Permanente
IP pública de Azure Bastion	`AzureBastionSubnet`	Equipos de desarrollo y operación	Entra ID y MFA	Permanente
IP de gestión del Azure Firewall	`AzureFirewallManagementSubnet`	Solo la plataforma de Azure	No recibe tráfico de aplicación	Permanente
Salida a internet del firewall	`AzureFirewallSubnet`	Los ambientes, para salir	Solo salida, sin entrada	Permanente
Cuenta de almacenamiento con token de acceso	Servicio de migración de la base (DMS)	Solo DMS, durante la migración	Token SAS con vencimiento	Temporal
Portal actual por NAT y Nginx	Cali, `10.20.5.0/24`	Clientes, hasta el corte. Después queda sin tráfico, como camino de vuelta atrás	NAT y WAF actuales	Temporal

Entrada pública	Dónde	Quién la usa	Protección	Vigencia
VPN de usuario	Hub, si se elige esa forma de acceso	Personas remotas	Entra ID y MFA	Solo reservada

5.5 Acceso administrativo para equipos distribuidos

Desarrolladores y operadores trabajan parte de la semana fuera de la sede. Necesitan administrar la plataforma sin que eso abra la red de despacho.

Solución: Azure Bastion.

```
Persona remota → portal de Azure (Entra ID y MFA) → Azure Bastion (hub)
  → máquina de administración en snet-admin (sin dirección pública)
```

- La persona se autentica con su identidad corporativa y un segundo factor.
- Bastion abre la sesión hacia la máquina desde dentro de la red. Las máquinas no tienen dirección pública y los puertos de administración (SSH y RDP) no se exponen a internet.
- Desde `snet-admin` se opera la plataforma. Esa subred no tiene camino hacia la torre de control salvo lo que permita el firewall.

Opción adicional: VPN de usuario. Si en el futuro se prefiere que las personas remotas se conecten a la red como si estuvieran en la sede, el plan reserva `10.100.8.0/22` para esas conexiones. Esa misma VPN podría servir de contingencia si cae el firewall de Cali (sección 2.2), siempre que FríoAndes acepte que cuenta como red corporativa para usar la torre.

5.6 DNS entre Cali y Azure

Los servicios de Azure se alcanzan por nombres privados (por ejemplo, el de la base de datos o el del almacenamiento). Las sedes tienen que resolver esos nombres a direcciones privadas, y Azure tiene que resolver los nombres internos de Cali. Lo hace el DNS Private Resolver del hub:

Sentido	Cómo funciona
De las sedes hacia Azure	El DNS de Cali reenvía las consultas de los dominios privados de Azure al endpoint de entrada del resolver (`10.100.1.0/28`), que responde con la dirección privada
De Azure hacia Cali	El endpoint de salida (`10.100.1.16/28`) reenvía las consultas de los dominios internos de FríoAndes al DNS de Cali

Las zonas DNS privadas de Azure se enlazan al hub, así que los tres ambientes las comparten.

5.7 Preparación para una segunda nube

FríoAndes prevé sumar otra nube en 24 meses, sin duplicar la plataforma desde el inicio. Para eso la red deja preparados el punto de interconexión, el DNS y la identidad:

Pieza	Qué queda listo
Direcciones	`10.110.0.0/15` reservado: un `/16` para tránsito e interconexión y otro para cargas. La verificación garantiza que nada lo ocupa
Punto de interconexión	El hub. La segunda nube se conecta como una sede más: VPN sitio a sitio con BGP contra el mismo VPN Gateway (sería la conexión 11 de 30) o un enlace dedicado. Si se necesita un equipo de red virtual, tiene espacio reservado en el hub (`10.100.1.128/25`)
DNS	El DNS Private Resolver del hub puede reenviar los dominios de la otra nube a su DNS, igual que hace con Cali
Identidad	Entra ID es la identidad única de la plataforma. El diseño de identidad para varias nubes se detalla en su propio documento
Crecimiento de la topología	Si la interconexión crece a muchas redes, el rango para Virtual WAN (`10.100.4.0/22`) ya está reservado

5.8 Todo pasa por el firewall

El principio del diseño es que todo el tráfico entre las sedes y la nube, y toda la salida a internet de los ambientes, pasa por el Azure Firewall. Eso incluye los sensores de los cuartos fríos y la migración de la base de datos. Algunos flujos se controlan en otro punto, cada uno con su motivo: la copia del archivo histórico durante la migración (sección 6), el acceso de Azure Bastion a las máquinas de administración y el DNS entre Cali y el resolver del hub, que se controlan con NSG; la entrada del portal, que filtra el WAF; y los camiones, que llegan a IoT Hub por internet. La tabla de políticas completa, con el punto de control de cada flujo, está en el diseño del firewall de nube (`red-firewall-y-publicacion.md`, sección 4).

Lista inicial de flujos para el diseño del firewall de nube:

Origen	Destino	Puerto	Vigencia
Usuarios de Cali (`10.20.0.0/24`) y de los centros (`10.3X.0.0/24`)	Torre de control (`snet-app-torre`)	443	Permanente
Sensores de los centros (`10.3X.1.0/24`)	Ingesta privada (`snet-ingest`)	8883, 5671 y 443	Permanente
Internet	Portal (`snet-ingress`)	443	Permanente
`snet-ingress`	Servicios del portal (`snet-app-portal`)	443	Permanente
`snet-app-torre` y `snet-app-portal`	Base de datos (`snet-data`)	3306	Permanente
`snet-app-torre` y `snet-app-portal`	Caché y Key Vault (`snet-data-pe`)	Puertos del servicio	Permanente
Función notificadora (`snet-telemetry-func`)	API de la torre (`snet-app-torre`)	443	Permanente
Función notificadora y torre	Event Hubs de la telemetría (`snet-data-pe`)	5671 y 443	Permanente
Función notificadora	Su cuenta y Key Vault (`snet-data-pe`), evidencia de telemetría (`snet-archive`)	443	Permanente
Gateway de Fabric (`snet-fabric-egress`)	Base de datos (`snet-data`)	3306	Permanente
Azure Bastion	Máquinas de administración (`snet-admin`)	22 y 3389	Permanente, controlado por NSG
DNS de Cali	DNS Private Resolver	53	Permanente, controlado por NSG
Ambientes	Internet, por el Azure Firewall	Según reglas	Permanente
Migración (`snet-cali-integration`), que abre la conexión hacia la base de Cali	Base de datos de Cali (`10.20.2.0/24`)	3306	Temporal
Archivo de Cali (`10.20.3.0/24`)	Archivo en Azure (`snet-archive`)	443	Temporal, fuera del firewall (sección 6)

---

6. Telemetría y convivencia con el datacenter de Cali

6.1 Los dos caminos de la telemetría

La plataforma alerta cuando un camión o un cuarto frío sale del rango de temperatura, con la alerta visible en menos de un minuto. Los sensores están en dos lugares distintos y llegan a la nube por dos caminos distintos:

	Camino 1: cuartos fríos	Camino 2: camiones
Origen	4 cuartos fríos por centro, 32 en total, con una lectura cada 30 segundos las 24 horas. Los sensores están en la red local de cada centro (`10.3X.1.0/24`)	120 camiones en ruta (180 en campaña), con temperatura cada 60 segundos y posición cada 30 segundos
Cómo salen	Por la VPN del centro hacia el hub de Azure	Por la red móvil del operador de flota e internet. Los camiones no tienen subred corporativa
Cómo entran a la nube	VPN Gateway, Azure Firewall y endpoint privado de IoT Hub en `snet-ingest`	Endpoint público de IoT Hub, con conexión cifrada (TLS) y una credencial distinta por camión
Puertos	MQTT 8883, AMQP 5671 y HTTPS 443	Los mismos
Volumen	Unos 8,5 Kbps en total	Unos 48 Kbps, 72 Kbps en campaña. No pasa por el enlace de Cali

```
Camino 1:  sensor del cuarto frío → equipo VPN del centro → túnel IPsec → VPN Gateway
           → Azure Firewall → endpoint privado (snet-ingest) → IoT Hub

Camino 2:  sensor del camión → red móvil del operador → internet → endpoint público de IoT Hub
```

Los dos caminos terminan en el mismo servicio de ingesta. El procesamiento de la alerta, el historial y los tableros están en el diseño de telemetría (`carga-b-telemetria.md`).

Qué deja la red para la telemetría:

- `snet-ingest` en cada ambiente, con los endpoints privados de IoT Hub y del servicio de aprovisionamiento de dispositivos (DPS): 2 de 10. La cantidad de sensores no cambia la cantidad de endpoints. Los Event Hubs y la cuenta de la función van en `snet-data-pe`, y las dos cuentas del historial en `snet-archive`.
- `snet-telemetry-func` (`10.10X.3.0/27`) para la función notificadora que avisa de las alertas, tomada del espacio libre de cada ambiente.
- El volumen de los dos caminos es muy bajo: los 32 cuartos fríos juntos suman unos 8,5 Kbps y los camiones no usan los enlaces de las sedes, así que la telemetría no condiciona el tamaño de la red.

Recolector local. Si cada centro tiene un recolector que agrupe las lecturas antes de enviarlas (por ejemplo, IoT Edge), va en la red de sensores del centro y usa el mismo camino 1. El diseño de telemetría admite las dos formas, según lo que confirme FríoAndes (`carga-b-telemetria.md`, sección 2.8), y ninguna cambia la red.

Resiliencia de IoT Hub. Como se explicó en la sección 3.5, IoT Hub no tiene redundancia entre zonas en East US 2. El diseño de telemetría lo ubica en Central US, y el endpoint privado de `snet-ingest` apunta a ese servicio en la otra región.

6.2 Qué pasa en la red durante la convivencia

Durante los 90 días de convivencia, Cali y Azure funcionan al mismo tiempo y hay tres movimientos de datos temporales:

Movimiento	Desde	Hacia	Cómo	Paso por el firewall
Migración de la base de datos (MySQL 5.7 a MySQL Flexible)	Base de Cali (`10.20.2.0/24`)	Servicio de migración (DMS) en `snet-cali-integration`, que carga en `snet-data`	Migración en línea: copia inicial y replicación continua hasta el corte	Sí
Integración de aplicaciones	Servidores de Cali	`snet-cali-integration`	Lo que necesite el plan de migración mientras conviven los dos sistemas	Sí

Movimiento	Desde	Hacia	Cómo	Paso por el firewall
Copia continua del archivo	Servidor de archivo de Cali (`10.20.3.0/24`)	Endpoint privado del almacenamiento en `snet-archive`	Copia de los archivos nuevos y modificados, unos 37 Mbps de forma sostenida	No (sección 6.3)

`snet-cali-integration` existe solo para la convivencia. En estado estable queda vacía y se puede eliminar o conservar para una migración futura.

La migración de la base también usa, por un tiempo, una cuenta de almacenamiento con un token de acceso temporal. Figura en la tabla de entradas públicas (sección 5.4).

6.3 La copia del archivo, fuera del firewall

El archivo histórico crece unos 12 TB al mes. Mantener la copia de la nube al día significa mover unos 12.154 GB al mes, unos 37 Mbps sostenidos, durante toda la convivencia.

La decisión: esa copia va directo de la VPN al endpoint privado del archivo, sin pasar por el Azure Firewall.

```
Agente de copia en Cali (10.20.3.0/24) → túnel IPsec → VPN Gateway → endpoint privado de Blob
(snet-archive)
                                                                              ↑
                                                                NSG: solo 10.20.3.0/24, puerto 443
```

La copia la hace un agente con AzCopy en la red del archivo de Cali, que lee el NFS local en solo lectura y empuja los archivos por HTTPS con una identidad de Entra ID. El detalle está en el diseño de la siembra (`carga-c-siembra-1-2pb.md`, sección 6).

Por qué:

- El Azure Firewall cobra por cada GB que procesa. Pasar la copia por el firewall costaría unos USD 194 más al mes (12.154 GB por USD 0,016), solo por un tráfico que es temporal, conocido y de un único origen.
- Microsoft contempla este tipo de excepción para copias grandes de datos.

Cómo se controla sin el firewall:

- Un grupo de seguridad de red (NSG) en `snet-archive` solo deja entrar tráfico desde la red del archivo de Cali (`10.20.3.0/24`), y solo por HTTPS (443). Todo lo demás se rechaza.
- Los registros de flujo de la red virtual del hub guardan cada conexión que atraviesa el VPN Gateway, así que la copia queda auditada. Microsoft ya no permite crear registros de flujo de NSG, que se retiran en septiembre de 2027.
- Las cuentas del archivo no usan NFS 3.0: Import/Export no lo admite y tampoco permitiría la inmutabilidad de las evidencias. Cada escritura se autentica con Entra ID, además del NSG.
- La excepción dura lo que dure la copia y se retira al final de la convivencia.

Condición técnica: las rutas tienen que ser simétricas. Ni la tabla de rutas de la `GatewaySubnet` ni la de `snet-archive` pueden mandar ese tráfico al firewall. Si una lo manda y la otra no, la ida y la vuelta toman caminos distintos y el firewall corta la conexión. Para lograrlo, `snet-archive` activa las políticas de red de los endpoints privados solo para el NSG y no para las rutas. Así, la ruta propia del endpoint privado se impone a la ruta del hub hacia el firewall.

Alternativa: pasar la copia por el firewall, con inspección y registro centralizados, por unos USD 194 más al mes. El costo exacto de la opción elegida incluye el procesamiento del endpoint privado, que se ajusta en el cálculo de costos de la plataforma.

6.4 La carga inicial del archivo de 1,2 PB

El corte de la migración dura como máximo 2 horas y no cubre la copia del archivo: los 1,2 PB se tienen que sembrar antes, y el corte solo arrastra lo que cambió.

Esa siembra no puede hacerse por la red:

- A 400 Mbps, usando el 100 % del enlace de Cali, tomaría unos 278 días.
- En los 90 días de convivencia se moverían unos 389 TB, el 32 % del archivo, y la operación se quedaría sin internet todo ese tiempo.

Por eso la siembra tiene que hacerse con discos físicos enviados a Microsoft:

- **Azure Data Box Heavy** está retirado, y los equipos Data Box no se envían a Colombia.
- **Azure Import/Export** permite enviar discos propios a un datacenter de Microsoft, incluso desde otro país. East US 2 y Central US aceptan estos envíos.

El diseño de la siembra (`carga-c-siembra-1-2pb.md`) dimensiona 71 discos en 9 trabajos y su cronograma. Antes de empezar hay que confirmar con Microsoft la capacidad para 1,2 PB, los tiempos de envío y carga, y los trámites de aduana. Si parte de la siembra terminara yendo por la red, habría que subir el VPN Gateway a VpnGw2AZ y ampliar las direcciones de `snet-cali-integration` (ya tiene espacio para hasta 11).

6.5 Diagrama de la convivencia

El diagrama de convivencia de la sección 2.5 muestra estos movimientos:

- La línea "Camino 1: sensores por la VPN y el firewall" sale del Azure Firewall y llega a la ingesta privada.
- La línea "Camino 2: camiones (TLS)" baja desde internet directo a IoT Hub, en Central US.
- La línea punteada del firewall a DMS es la migración de la base. De DMS sale la carga hacia MySQL.
- La línea punteada "Copia del archivo, unos 37 Mbps, fuera del firewall" sale del VPN Gateway sin pasar por el Azure Firewall y llega al endpoint privado del archivo. La copia la empuja un agente desde Cali, sin máquina de copia en Azure.

---

7. Plataforma de aplicación: Container Apps o Kubernetes

7.1 Qué depende de la plataforma

La consola de despacho (torre de control) y los servicios del portal corren sobre una plataforma de contenedores. La plataforma propuesta es **Azure Container Apps**, y se confirma con el diseño de la plataforma logística. Como Kubernetes (Azure Kubernetes Service, AKS) es una alternativa que podría considerarse, esta sección explica también qué cambiaría en la red si se eligiera.

La plataforma solo afecta tres cosas de la red. Todo lo demás de este documento queda igual con cualquiera de las dos:

1. La configuración de `snet-app-torre` y `snet-app-portal` en cada ambiente. Sus rangos no cambian.
2. Una subred adicional por ambiente para la API privada de Kubernetes, solo si se elige AKS.
3. Algunas reglas de salida del Azure Firewall y la forma de publicar la torre.

7.2 Solución con Container Apps

Cómo funciona

Cada ambiente tiene dos entornos de Container Apps con perfiles de carga (workload profiles):

- **Entorno de la torre**, en `snet-app-torre`. Es interno: solo tiene dirección privada y lo alcanzan Cali y los centros a través del Azure Firewall.
- **Entorno del portal**, en `snet-app-portal`. También es interno: recibe tráfico solo desde el Application Gateway de `snet-ingress`, que es la cara pública del portal.

Cada entorno vive en su propia subred, reservada para Container Apps (delegación `Microsoft.App/environments`). Como torre y portal están en entornos y subredes distintos, el NSG y el Azure Firewall pueden filtrar el tráfico entre ellos.

Container Apps escala solo: agrega réplicas cuando sube la demanda, por ejemplo en campaña, y las retira cuando baja. Eso responde al problema de capacidad fija que hoy tiene el datacenter.

Tamaño de las subredes

Concepto	Direcciones
Máximo previsto por entorno: 20 nodos dedicados y 200 réplicas de consumo	40
Durante una actualización, la versión nueva arranca antes de apagar la anterior	80
Direcciones que reserva Container Apps y Azure (peor caso)	17
Total	97, en un `/25` de 128

Hoy producción corre en 4 máquinas de aplicación y front, unas 6 con el 40 % adicional de campaña, así que el máximo previsto deja margen amplio.

Reglas de Container Apps

- Con perfiles de carga, la subred mínima es `/27`. Un entorno solo de consumo exigiría `/23`.
- Container Apps no admite en su subred los rangos `169.254.0.0/16`, `172.30.0.0/16`, `172.31.0.0/16`, `192.0.2.0/24` ni `100.100.0.0/17` a `100.100.192.0/19`. Ningún rango del plan los usa.

7.3 Variante con Kubernetes (AKS): qué cambiaría

Esta variante aplica solo si se elige AKS. Todo lo de las secciones 2 a 6 se mantiene: región, hub, conexión de Cali y de los centros, telemetría, subredes comunes, reservas, zonas y exposición.

Resumen de cambios

Elemento	Container Apps	Kubernetes (AKS)
`snet-app-torre` y `snet-app-portal`	Mismo rango, reservadas para Container Apps	Mismo rango, con los nodos del clúster y sin delegación
Subred adicional por ambiente	Ninguna	`snet-aks-apiserver` en `10.10X.2.224/27`, para la API privada del clúster
Rangos internos	No aplica	Pods `100.64.0.0/16` y servicios `172.20.0.0/20`, reservados en el plan
Separación entre torre y portal	Entornos en subredes distintas	Depende de cuántos clústeres haya por ambiente
Entrada del portal	Application Gateway v2 con WAF	Application Gateway v2 con su controlador para AKS, o Application Gateway for Containers
Entrada de la torre	Entorno interno	Balanceador interno del clúster
Salida a internet	Por el Azure Firewall	Por el Azure Firewall, con reglas adicionales para AKS
Costo propio de la plataforma	Sin costo de plano de control	Entre USD 0 y 73 al mes por clúster
Plan de direcciones	`ip-plan.csv`	`ip-plan-aks.csv`

Modelo de red: Azure CNI Overlay

En Kubernetes, cada aplicación corre en pods dentro de nodos (las máquinas del clúster). Con **Azure CNI Overlay**, el modelo que Microsoft recomienda como opción general, solo los nodos toman direcciones de la subred. Los pods usan un rango privado aparte que no consume direcciones de la red virtual.

Con el mismo máximo de 27 nodos por grupo, los modelos de AKS consumen esto:

Modelo	Direcciones de la red virtual	Subred necesaria
Azure CNI Overlay	27 nodos + 4 balanceadores + 5 de Azure = 36	`/26`
Azure CNI plano, 30 pods por nodo	27 + 27 × 30 = 837	`/22`
Azure CNI plano, 110 pods por nodo	27 + 27 × 110 = 2.997	`/20`

Cada ambiente tiene 1.280 direcciones libres. Con un modelo plano, torre y portal juntos ya pedirían más de eso. Overlay es el único modelo que cabe en el `/21` de cada ambiente sin renumerar.

Subredes de nodos

`snet-app-torre` y `snet-app-portal` conservan su `/25` y alojan los nodos. Se les quita la delegación, porque una subred de nodos de AKS no puede estar delegada.

> Direcciones = nodos + nodos extra durante la actualización (Microsoft recomienda 33 % en producción) + balanceadores internos + 5 de Azure.

Subred	Cuenta	Uso
Torre	3 de sistema + 20 de usuario + 7 extra + 4 balanceadores + 5 = 39	39 de 123
Portal	3 + 20 + 7 + 2 + 5 = 37	37 de 123

Subred para la API privada del clúster

Cada clúster tiene un servidor de API, el punto de control de Kubernetes. Para que sea privado se integra con la red virtual en una subred propia:

- `snet-aks-apiserver` en `10.101.2.224/27`, `10.102.2.224/27` y `10.103.2.224/27`, el bloque que el módulo tenía libre.
- Reservada para AKS (delegación `Microsoft.ContainerService/managedClusters`), con un mínimo de `/28`. Una sola subred sirve para todos los clústeres del ambiente.
- Cada clúster reserva al menos 9 direcciones. Con dos clústeres: 5 de Azure + 9 × 2 = 23. Un `/28` (16) no alcanza; un `/27` (32) sí.
- El NSG permite TCP 443 y 4443 desde las subredes de nodos y TCP 9988 desde el balanceador de Azure.
- Esta integración no es compatible con el cifrado de red virtual (Virtual Network Encryption).

Rangos internos de pods y servicios

Uso	Rango	Nota
Pods	`100.64.0.0/16`	Rango privado admitido por Overlay. Cada nodo toma un `/24`; un `/16` alcanza para 256 nodos
Servicios de Kubernetes	`172.20.0.0/20`	Hasta 4.096 servicios. El DNS interno del clúster queda en `172.20.0.10`

Los dos rangos no se enrutan fuera del clúster, así que se repiten en todos los clústeres y ambientes. No se solapan con las 23 subredes on-premises, con la nube, con las reservas ni con los rangos que AKS no admite. Los valores por defecto de AKS (`10.244.0.0/16` y `10.0.0.0/16`) se descartaron porque caen dentro del espacio `10.x` que usa FríoAndes. En `ip-plan-aks.csv` los dos rangos figuran como reservas, para que nadie los ocupe.

Cuántos clústeres por ambiente

Es la decisión que más pesa en esta variante, por una regla de Azure: dentro de un mismo clúster, el NSG tiene que permitir todo el tráfico entre nodos y pods, y Microsoft indica que bloquear ese tráfico con NSG o firewall no es compatible. Para separar cargas dentro de un clúster se usan políticas de red de Kubernetes.

Opción	Separación entre torre y portal	Plano de control al mes	Operación
Un clúster por ambiente, con dos grupos de nodos	Lógica, con políticas de red de Kubernetes	USD 73 (producción en nivel Standard, pruebas y desarrollo en nivel Free)	La más simple
Dos clústeres en producción, uno en pruebas y uno en desarrollo	De red en producción (firewall y NSG filtran entre torre y portal) y lógica en pruebas y desarrollo	USD 146	El doble de actualizaciones y monitoreo en producción

Opción	Separación entre torre y portal	Plano de control al mes	Operación
Dos clústeres en los tres ambientes	De red en todos	USD 146 con pruebas y desarrollo en Free, USD 438 con todos en Standard	Pruebas valida exactamente lo que va a producción

La opción recomendada es la segunda, con cuatro clústeres en total:

Ambiente	Clústeres	Qué corre en cada uno
Producción	2, nivel Standard	Uno para la torre (nodos en `snet-app-torre`) y otro para el portal (nodos en `snet-app-portal`)
Pruebas	1, nivel Free	Torre y portal juntos, cada uno en su propio grupo de nodos y su propia subred, separados con políticas de red de Kubernetes
Desarrollo	1, nivel Free	Igual que pruebas

Por qué así:

- **Producción con dos clústeres.** La torre no tiene exposición a internet y el portal sí. Con clústeres separados, el tráfico entre los dos cruza el firewall y los NSG, y una falla o una actualización del portal no toca la torre. Es la separación de red que pide el diseño en el ambiente que importa.
- **Pruebas y desarrollo con un clúster cada uno.** Ahí no hay datos reales ni usuarios externos, así que la separación lógica con políticas de red alcanza. Se ahorran dos clústeres que operar y actualizar.
- **Pruebas y desarrollo no pueden compartir un solo clúster.** Un clúster vive dentro de una sola red virtual y cada ambiente tiene la suya. Compartirlo obligaría a unir las redes de pruebas y desarrollo, y se perdería el aislamiento entre ambientes.
- **Se puede subir a dos clústeres en pruebas.** El código de infraestructura recibe el número de clústeres como variable. Si se quiere que pruebas sea una copia exacta de producción, se pone en 2 sin cambiar subredes; con el nivel Free, el plano de control de ese clúster extra no tiene costo.

Las subredes son las mismas con cualquiera de las tres opciones.

Entrada del portal y de la torre

El portal tiene dos caminos, y los dos usan el mismo `/24` de `snet-ingress`:

	Application Gateway v2 con su controlador para AKS	Application Gateway for Containers
Subred	`snet-ingress`, con delegación a `Microsoft.Network/applicationGateways`: Azure CNI Overlay la exige, junto con un tamaño de `/24` o menor y la misma red virtual que los nodos	`snet-ingress` reservada para este servicio, mínimo `/24`
WAF	Sí	Sí
Entrada con IP privada	Admite	No admite
Rutas	Igual que con Container Apps	Necesita su propia tabla de rutas, sin enviar la salida al firewall
Costo fijo con WAF	El mismo que con Container Apps	Unos USD 193 al mes por ambiente, más capacidad

`ip-plan-aks.csv` conserva Application Gateway v2 en `snet-ingress`, con el mismo rango. Con el controlador del Application Gateway, la subred lleva además la delegación indicada en la tabla. Si se elige Application Gateway for Containers, cambia la configuración de esa subred y se vuelve a correr la verificación.

La torre se publica con un balanceador interno del clúster, con IP privada en `snet-app-torre`. Cali y los centros lo alcanzan a través del Azure Firewall. Application Gateway for Containers no sirve para la torre porque no admite IP privada.

Salida a internet

Los nodos necesitan salir a internet para descargar imágenes y recibir actualizaciones. Con este diseño, esa salida pasa por el Azure Firewall:

1. Cada subred de nodos tiene una ruta `0.0.0.0/0` hacia el firewall y el clúster se crea con salida por esa ruta (`userDefinedRouting`), así AKS no crea su propia IP pública.
2. El firewall permite los destinos que AKS necesita con la etiqueta `AzureKubernetesService`, que Microsoft mantiene actualizada, más el DNS y los servicios que se activen (monitoreo, políticas, Key Vault).
3. El tráfico entre los nodos y la API privada va dentro de la red virtual.

Dos efectos a tener en cuenta:

- Microsoft recomienda planear al menos 20 IP públicas de salida en el firewall para producción con AKS, para no agotar los puertos de salida. La alternativa es combinar el firewall con NAT Gateway.
- Hay que definir cómo se llega al registro de imágenes de contenedores: por el firewall o por un endpoint privado en `snet-data-pe`, que tiene espacio.

DNS y despliegue

- El clúster usa una zona DNS privada (`private.eastus2.azmk8s.io`). Se enlaza al hub para que Cali y los agentes de despliegue resuelvan la API.
- Los agentes de despliegue tienen que estar dentro de la red, en `snet-admin`, porque un clúster privado no acepta los agentes alojados por el proveedor del pipeline.

Costo del plano de control

Nivel	USD al mes por clúster	Para qué sirve
Free	0	Sin acuerdo de disponibilidad. Microsoft lo recomienda para menos de 10 nodos
Standard	73	Disponibilidad del 99,95 % del servidor de API con zonas
Premium	438 a 511	Standard con 24 meses de soporte por versión. FríoAndes no lo necesita

El plano de control pesa poco frente al Azure Firewall (USD 912,50 al mes). El costo real de AKS lo marcan los nodos, que se dimensionan con el diseño de la plataforma.

Diagramas de la variante

FríoAndes · Alternativa con Kubernetes (AKS) · Estado estable (después del día 90)

Cambia solo la plataforma de aplicación; la red común es la misma

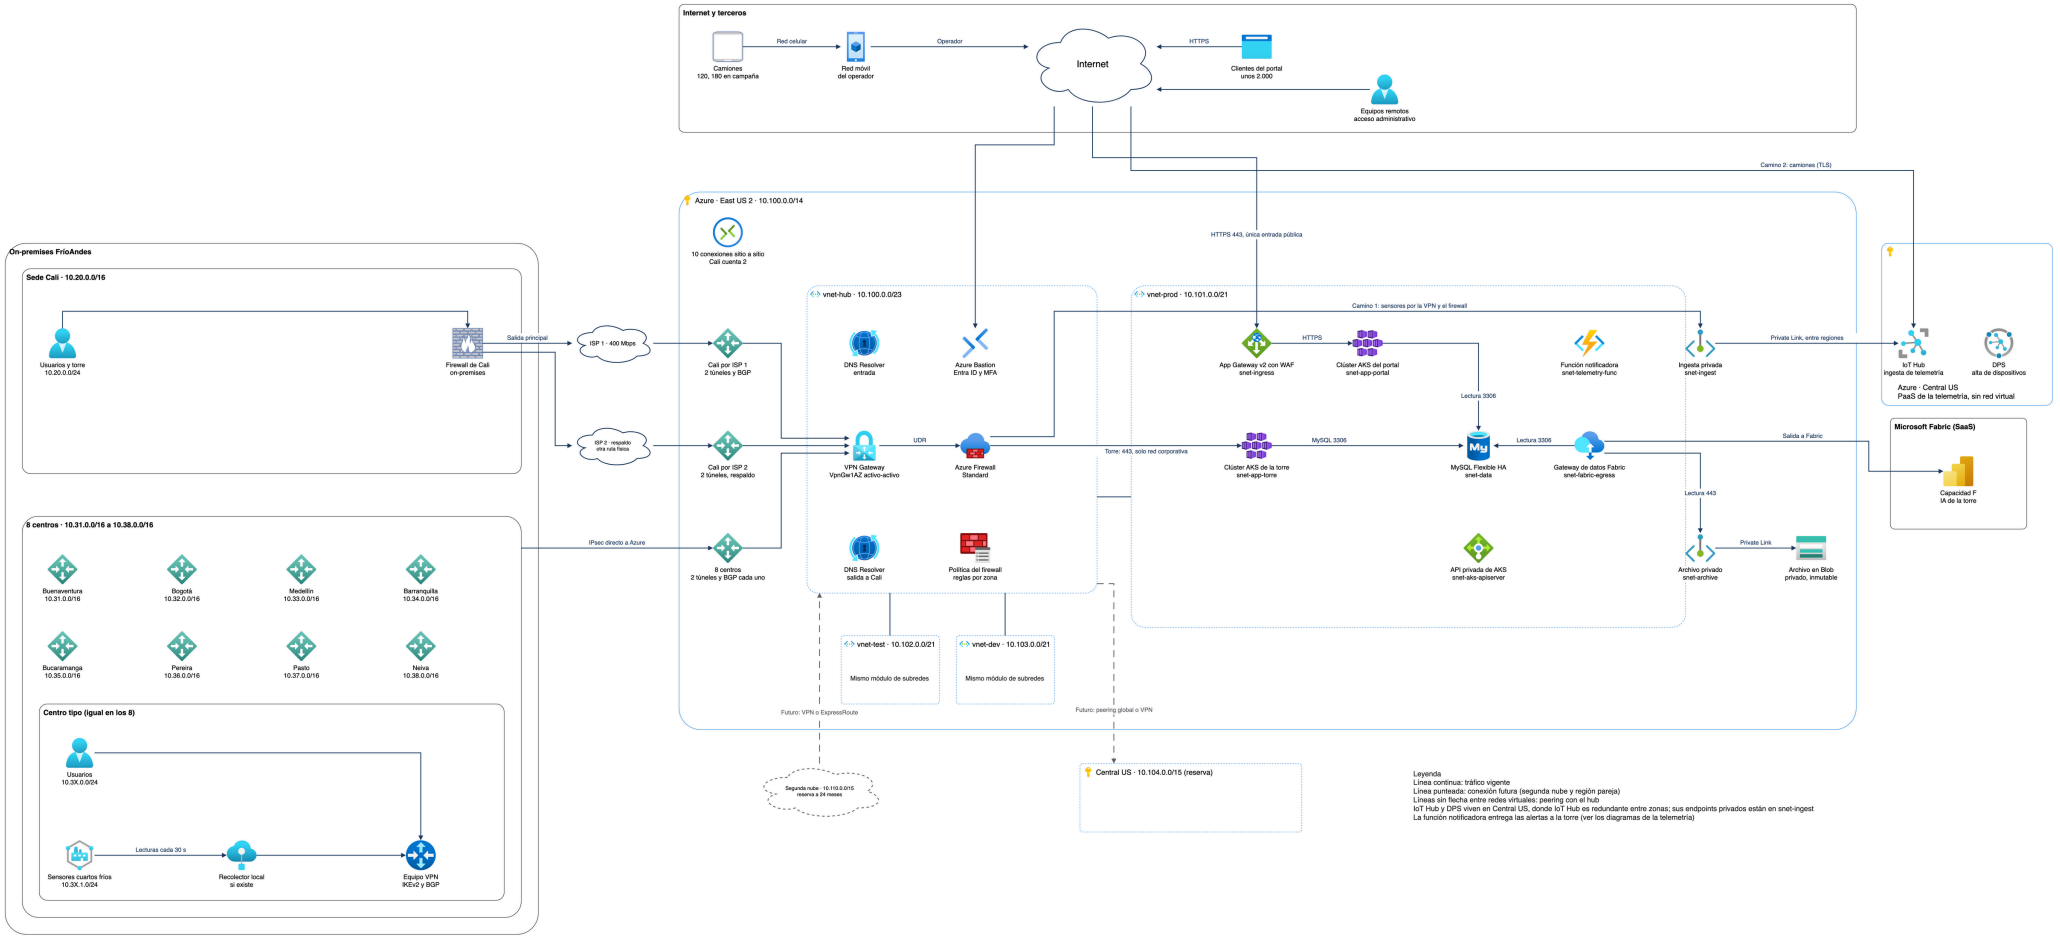
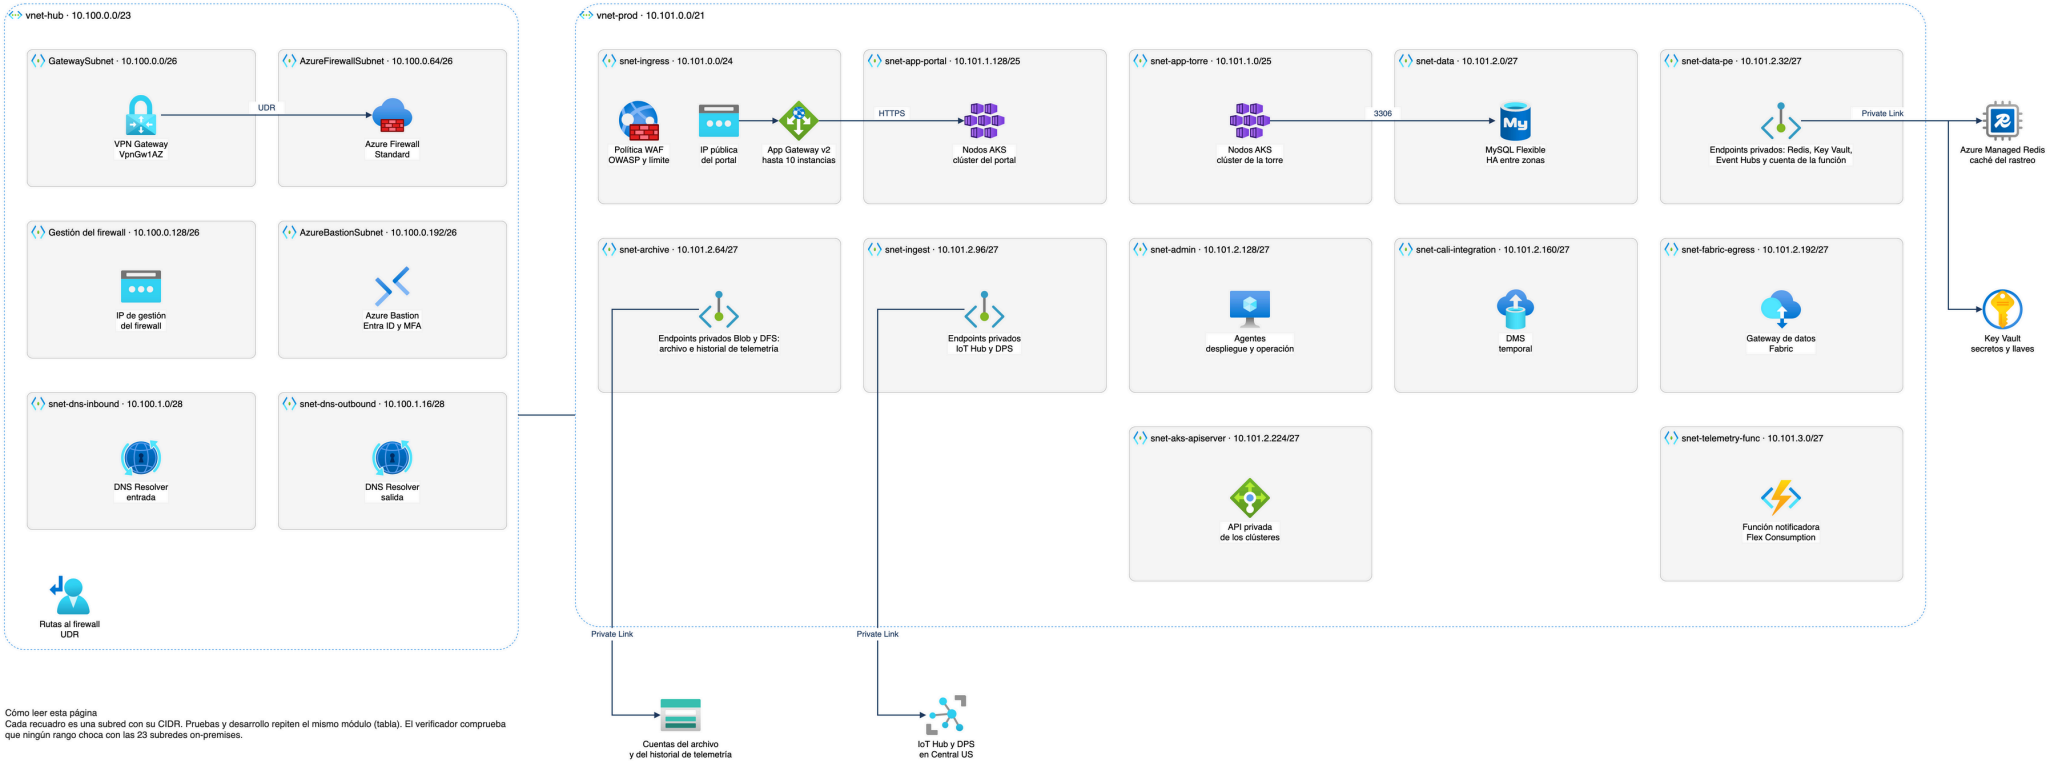


Figura 9: Estado estable con AKS: la red común sin cambios, clústeres de torre y portal en producción y la API privada

La red es la misma del diagrama de estado estable, incluida la telemetría. En producción cambian tres íconos: el clúster de la torre en `snet-app-torre`, el clúster del portal en `snet-app-portal` y la API privada en `snet-aks-apiserver`.

FríoAndes · Alternativa con Kubernetes (AKS) · Hub y prod: subredes, CIDR y servicios

Pruebas y desarrollo repiten el mismo módulo · plan de direcciones verificado sin solapamiento



Cómo leer esta página
Cada recuadro es una subred con su CIDR. Pruebas y desarrollo repiten el mismo módulo (tabla). El verificador comprueba que ningún rango choca con las 23 subredes on-premises.

Reserva	Rango
segunda-nube	10.110.0.0/15
region-pareja	10.104.0.0/15
hub-vwan	10.100.4.0/22
vpn-usuarios	10.100.8.0/22
centros-nuevos	10.39.0.0/16
aks-pods	100.64.0.0/16
aks-servicios	172.20.0.0/20
on-premises (crecimiento)	10.20 y 10.31 a 10.38 (cada uno /16)

Subred	prod	test	dev
Red virtual	10.101.0.0/21	10.102.0.0/21	10.103.0.0/21
snet-ingress	10.101.0.0/24	10.102.0.0/24	10.103.0.0/24
snet-app-portal	10.101.1.128/25	10.102.1.128/25	10.103.1.128/25
snet-app-torre	10.101.1.0/25	10.102.1.0/25	10.103.1.0/25
snet-data	10.101.2.0/27	10.102.2.0/27	10.103.2.0/27
snet-data-pe	10.101.2.32/27	10.102.2.32/27	10.103.2.32/27
snet-archive	10.101.2.64/27	10.102.2.64/27	10.103.2.64/27
snet-ingest	10.101.2.96/27	10.102.2.96/27	10.103.2.96/27
snet-admin	10.101.2.128/27	10.102.2.128/27	10.103.2.128/27
snet-cali-integration	10.101.2.160/27	10.102.2.160/27	10.103.2.160/27
snet-fabric-egress	10.101.2.192/27	10.102.2.192/27	10.103.2.192/27
snet-aks-apiserver	10.101.2.224/27	10.102.2.224/27	10.103.2.224/27
snet-telemetry-func	10.101.3.0/27	10.102.3.0/27	10.103.3.0/27

Figura 10: Subredes del hub y de producción con AKS

Las mismas subredes del diagrama de subredes, incluida `snet-telemetry-func`, con los nodos de AKS, la subred de la API y las reservas de pods y servicios.

Verificación de la variante

`ip-plan-aks.csv` parte de `ip-plan.csv` y suma las tres subredes de la API y las dos reservas de pods y servicios. Tiene 49 filas y pasa las 12 comprobaciones del script, sin solapamiento. Su hash es `06507247ae9683716e832dc2c278535ac16bdeab39a8592fe0f1d4e3c6abe1e3`. Las filas que agrega están al final del Anexo A.

7.4 Si se eligiera otra plataforma

Si la plataforma terminara siendo otra (por ejemplo, App Service), los rangos de `snet-app-torre` y `snet-app-portal` se mantienen y se repite el análisis de tamaño y configuración de esas dos subredes con las reglas de esa plataforma. El resto del documento no cambia.

---

8. Supuestos y confirmaciones pendientes de FríoAndes

Esta lista crece con cada sección del documento.

8.1 Confirmaciones que necesita el diseño

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta es no
Firewall de Cali	¿Es un solo equipo o un par en alta disponibilidad?	Se elige entre un segundo equipo, una VPN de usuario de contingencia o aceptar el riesgo (sección 2.2)
Segundo proveedor	¿Se contrata un segundo proveedor por una ruta física distinta, sin compartir última milla, ducto ni nodo, confirmado por escrito?	Sin él, Cali no tiene ruta redundante y no se cumple el requisito
Equipos de los centros	¿Soportan IKEv2, dos túneles simultáneos y BGP?	El centro queda con túnel activo y de respaldo con rutas fijas (sección 2.3)
Contingencia de la torre	¿Una VPN de usuario con Entra ID y MFA cuenta como red corporativa para usar la torre de control?	Esa opción de contingencia queda descartada
Camiones	¿Se acepta que los camiones envíen a un endpoint público de la nube con una credencial por camión? ¿Envían directo o a través de la plataforma del operador de flota?	Cambia el origen del camino 2, sin cambiar las subredes
Pruebas y desarrollo	¿Pruebas y desarrollo necesitan una entrada pública propia, o basta con limitarla a orígenes autorizados?	Se mantiene limitada a orígenes autorizados
Siembra del archivo	¿Se acepta sembrar el archivo de 1,2 PB con Azure Import/Export (discos propios enviados a Microsoft)?	No hay otra vía práctica: por la red tomaría unos 278 días (sección 6.4)
Video y fotos	¿Dónde se generan el video y las fotos de evidencias después de la migración: en los muelles de Cali, en los centros o en los teléfonos de los conductores?	Define por dónde llegan los unos 12 TB al mes y si cargan la VPN de algún sitio
Ubicación de los datos	¿Es aceptable que los datos y el procesamiento queden en Estados Unidos, según la Ley 1581 y las políticas internas?	Habría que evaluar otra región y repetir la comparación de servicios y costos (sección 3)

8.2 Supuestos del diseño

Supuesto	Por qué se asume
El segundo proveedor cuesta unos COP 3.000.000 al mes por 200 Mbps	No hay cotización; es un valor de referencia del mercado para ese tamaño de enlace
Cada usuario genera unos 300 Kbps de tráfico hacia la plataforma	Se usa para comparar la carga del enlace de Cali con y sin los centros pasando por la sede
Los cambios por centro se hacen en la ventana de 22:00 a 04:00, uno o dos centros por noche, con un piloto primero	El despacho diurno no puede detenerse
Plan de ASN: Azure 65515, Cali 65020, centros 65031 a 65038	Valores privados que no chocan entre sí y se leen fácil
Máximos de capacidad usados para los tamaños: Application Gateway hasta 10 instancias, base de datos con 2 réplicas y 1 servidor temporal, hasta 10 endpoints por subred, hasta 11 miembros del gateway de Fabric	Una subred no se puede agrandar con recursos dentro; se dimensiona para el máximo con margen
Unas 60 personas de desarrollo y operación trabajan fuera de la sede	Define el tamaño de la reserva para VPN de usuario
La plataforma de aplicación es Container Apps con perfiles de carga, con un máximo de 20 nodos dedicados y 200 réplicas por entorno	Se confirma con el diseño de la plataforma logística. Si fuera AKS, aplica la sección 7.3
Cada mensaje de telemetría pesa alrededor de 1 KB	Se usa para estimar el volumen de los dos caminos
La copia continua del archivo mueve unos 12.154 GB al mes (37 Mbps)	Sale del crecimiento actual del archivo, unos 12 TB al mes
El portal se publica con Application Gateway v2 y WAF, el firewall de nube es Azure Firewall Standard y el acceso administrativo es Azure Bastion	El portal y el firewall quedaron confirmados en el diseño del firewall de nube. El acceso administrativo se confirma con el diseño del acceso remoto
La migración en línea de la base usa una cuenta de almacenamiento con token SAS temporal	El servicio de migración no admite una cuenta restringida a la red virtual; se confirma con el diseño de la migración
Una diferencia de latencia menor al 30 % no justifica cambiar de región	La plataforma es una consola web, un portal y alertas con margen de 60 segundos; 10 a 30 ms no cambian la experiencia

---

Anexo A. Rango por rango contra las 23 subredes on-premises

Salida del script de verificación sobre `ip-plan.csv`. Cada rango de la nube se comparó con las 23 subredes on-premises.

Rango de la nube	Red virtual o subred	Resultado
10.100.0.0/23	vnet-hub	sin solapamiento
10.100.0.0/26	vnet-hub/GatewaySubnet	sin solapamiento
10.100.0.64/26	vnet-hub/AzureFirewallSubnet	sin solapamiento
10.100.0.128/26	vnet-hub/AzureFirewallManagementSubnet	sin solapamiento
10.100.0.192/26	vnet-hub/AzureBastionSubnet	sin solapamiento
10.100.1.0/28	vnet-hub/snet-dns-inbound	sin solapamiento
10.100.1.16/28	vnet-hub/snet-dns-outbound	sin solapamiento
10.101.0.0/21	vnet-prod	sin solapamiento
10.101.0.0/24	vnet-prod/snet-ingress	sin solapamiento
10.101.1.0/25	vnet-prod/snet-app-torre	sin solapamiento
10.101.1.128/25	vnet-prod/snet-app-portal	sin solapamiento

Rango de la nube	Red virtual o subred	Resultado
10.101.2.0/27	vnet-prod/snet-data	sin solapamiento
10.101.2.32/27	vnet-prod/snet-data-pe	sin solapamiento
10.101.2.64/27	vnet-prod/snet-archive	sin solapamiento
10.101.2.96/27	vnet-prod/snet-ingest	sin solapamiento
10.101.2.128/27	vnet-prod/snet-admin	sin solapamiento
10.101.2.160/27	vnet-prod/snet-cali-integration	sin solapamiento
10.101.2.192/27	vnet-prod/snet-fabric-egress	sin solapamiento
10.101.3.0/27	vnet-prod/snet-telemetry-func	sin solapamiento
10.102.0.0/21	vnet-test	sin solapamiento
10.102.0.0/24	vnet-test/snet-ingress	sin solapamiento
10.102.1.0/25	vnet-test/snet-app-torre	sin solapamiento
10.102.1.128/25	vnet-test/snet-app-portal	sin solapamiento
10.102.2.0/27	vnet-test/snet-data	sin solapamiento
10.102.2.32/27	vnet-test/snet-data-pe	sin solapamiento
10.102.2.64/27	vnet-test/snet-archive	sin solapamiento
10.102.2.96/27	vnet-test/snet-ingest	sin solapamiento
10.102.2.128/27	vnet-test/snet-admin	sin solapamiento
10.102.2.160/27	vnet-test/snet-cali-integration	sin solapamiento
10.102.2.192/27	vnet-test/snet-fabric-egress	sin solapamiento
10.102.3.0/27	vnet-test/snet-telemetry-func	sin solapamiento
10.103.0.0/21	vnet-dev	sin solapamiento
10.103.0.0/24	vnet-dev/snet-ingress	sin solapamiento
10.103.1.0/25	vnet-dev/snet-app-torre	sin solapamiento
10.103.1.128/25	vnet-dev/snet-app-portal	sin solapamiento
10.103.2.0/27	vnet-dev/snet-data	sin solapamiento
10.103.2.32/27	vnet-dev/snet-data-pe	sin solapamiento
10.103.2.64/27	vnet-dev/snet-archive	sin solapamiento
10.103.2.96/27	vnet-dev/snet-ingest	sin solapamiento
10.103.2.128/27	vnet-dev/snet-admin	sin solapamiento
10.103.2.160/27	vnet-dev/snet-cali-integration	sin solapamiento
10.103.2.192/27	vnet-dev/snet-fabric-egress	sin solapamiento
10.103.3.0/27	vnet-dev/snet-telemetry-func	sin solapamiento
10.110.0.0/15	segunda-nube/reserva-segunda-nube	sin solapamiento
10.104.0.0/15	region-pareja/reserva-region-pareja	sin solapamiento
10.100.4.0/22	hub-vwan/reserva-hub-vwan	sin solapamiento
10.100.8.0/22	vpn-usuarios/reserva-vpn-usuarios	sin solapamiento
10.39.0.0/16	centros-nuevos/reserva-centros-nuevos	sin solapamiento

Filas que agrega la variante con Kubernetes (`ip-plan-aks.csv`):

Rango de la nube	Red virtual o subred	Resultado
10.101.2.224/27	vnet-prod/snet-aks-apiserver	sin solapamiento
10.102.2.224/27	vnet-test/snet-aks-apiserver	sin solapamiento
10.103.2.224/27	vnet-dev/snet-aks-apiserver	sin solapamiento

Rango de la nube	Red virtual o subred	Resultado
100.64.0.0/16	aks-pods/reserva-aks-pods	sin solapamiento
172.20.0.0/20	aks-servicios/reserva-aks-servicios	sin solapamiento

Firewall de nube, transición del firewall de Cali y publicación del portal de rastreo

Este documento define el firewall de la nube de FríoAndes en Azure, la tabla de políticas que aplica, la forma de publicar el portal de rastreo en internet y qué pasa con cada función del firewall actual de Cali durante la convivencia y después de ella. Parte de la red descrita en el documento de red híbrida y subnetting (`red-topologia-subnetting.md`) y usa sus mismos nombres de subredes y rangos.

Los diagramas están en draw.io. Cada imagen PNG de la carpeta `diagramas/` lleva el diagrama incrustado y se abre como diagrama editable en draw.io. Los archivos `.drawio` de la misma carpeta son su fuente.

Los archivos de apoyo están en la carpeta `red/`, junto al plan de direcciones:

Archivo	Qué contiene
`red/data/firewall-policy.csv`	La tabla de políticas completa, regla por regla y ambiente por ambiente: la única fuente para el código de infraestructura
`red/data/firewall-settings.csv`	La configuración general del Azure Firewall
`red/tools/verify_firewall_policy.py`	Verifica la tabla contra el plan de direcciones y las reglas del diseño (sección 4.9)
`red/verification/reporte-firewall-policy.md`	Resultado de la verificación
`red/tools/build_drawio_diagrams.py`	Genera los diagramas de draw.io de este documento

Términos usados

Término	Significado en este documento
Azure Firewall	Firewall administrado de Azure. Vive en el hub y controla el tráfico entre las sedes y la nube, entre ambientes y hacia internet
Política del firewall	Conjunto de reglas del Azure Firewall, organizado en grupos con prioridad. Se administra como código
WAF	Firewall de aplicaciones web. Revisa cada solicitud HTTP o HTTPS y bloquea ataques web conocidos antes de que lleguen a la aplicación
Application Gateway	Balanceador web regional de Azure. Recibe las conexiones del portal, aplica el WAF y las reparte entre los servicios del portal
NSG	Grupo de seguridad de red. Lista de reglas por subred que permite o rechaza tráfico según origen, destino y puerto
UDR	Ruta definida por el usuario. Obliga al tráfico de una subred a pasar por el Azure Firewall
Zona	Grupo de subredes con el mismo nivel de confianza: torre de control, portal, ingesta de telemetría, analítica y compartida
Convivencia	Periodo de como máximo 90 días en que el datacenter de Cali y Azure funcionan al mismo tiempo
Corte	Ventana de hasta 2 horas, en la madrugada de un domingo, en que la base transaccional y el tráfico de despacho y rastreo pasan a Azure
Estado estable	La operación después del día 90, con la plataforma ya en Azure

1. Contexto y alcance

1.1 Situación actual

Hoy un firewall de próxima generación en Cali concentra cinco funciones:

Función	Qué hace hoy
Enrutamiento	Enruta entre las 7 subredes de Cali y las 16 de los centros
VPN sitio a sitio	Mantiene un túnel con cada uno de los ocho centros
NAT del rastreo	Publica el portal de rastreo en internet hacia los servidores Nginx de `10.20.5.0/24`
Políticas entre subredes	Decide qué subred de Cali o de los centros puede hablar con cuál
Firewall de aplicaciones	Delante de Nginx, protege la zona publicada y la zona interna del rastreo

Durante la convivencia este firewall sigue en pie. FríoAndes necesita un firewall de nube adicional, con su tabla de políticas y con el firewall de aplicaciones del rastreo, y saber qué políticas del firewall de Cali se conservan, cuáles se trasladan y cuándo se apaga cada función.

1.2 Qué resuelve este documento

Necesidad	Dónde se responde
Firewall de nube a implementar, además del de Cali	Secciones 2 y 4
Tabla de políticas: origen, destino, puerto, acción y si la regla es temporal de la migración o queda en estado estable	Sección 4
El firewall de aplicaciones del rastreo forma parte del diseño	Secciones 3 y 4
Publicar el rastreo de forma controlada	Sección 3
Mantener el despacho fuera de internet público	Secciones 3 y 4
Qué políticas del firewall de Cali se conservan, cuáles se trasladan y cuándo se apaga cada función	Sección 5
Separación de red entre la torre de control, el portal público, la ingesta de sensores y los datos analíticos	Sección 4
Protección del perímetro público y detección de actividad anómala	Secciones 3 y 6

1.3 Qué toma del diseño de red

El diseño de red ya fijó lo siguiente, y este documento lo usa sin cambios:

- **Topología hub y spoke.** El hub (`vnet-hub`, `10.100.0.0/23`) tiene el VPN Gateway, el Azure Firewall, Azure Bastion y el DNS Private Resolver. Producción, pruebas y desarrollo son spokes conectados por peering (`10.101.0.0/21`, `10.102.0.0/21` y `10.103.0.0/21`).
- **Todo pasa por el firewall.** El tráfico entre las sedes y los ambientes, entre ambientes y hacia internet pasa por el Azure Firewall, obligado por rutas definidas por el usuario. La única excepción es la copia continua del archivo histórico, que va directo al almacenamiento y se controla con un NSG.
- **Las mismas zonas en cada ambiente.** Torre de control (`snet-app-torre`), portal (`snet-ingress` y `snet-app-portal`), ingesta (`snet-ingest`), analítica (`snet-fabric-egress`) y una zona compartida con datos, archivo, administración e integración con Cali.
- **Una sola entrada pública de aplicación por ambiente**, `snet-ingress`, reservada para el portal.
- **Los centros llegan directo a Azure** con su propia VPN, centro por centro durante la convivencia.

---

2. Decisiones de servicio

Esta sección fija tres decisiones de las que depende el resto del documento: cómo se combinan el Azure Firewall y el WAF, qué versión del Azure Firewall se usa y qué servicio publica el portal.

2.1 Cómo se combinan el firewall y el WAF

Azure ofrece dos piezas que se complementan. El Azure Firewall controla cualquier protocolo y es el único que filtra el tráfico de salida. El WAF del Application Gateway revisa el contenido de las solicitudes web de entrada, cosa que el Azure Firewall no hace. Microsoft describe cuatro formas de combinarlos:

Diseño	Cómo viaja la entrada del portal	Cuándo lo recomienda Microsoft
Solo Azure Firewall	Internet, firewall, aplicación	Cuando no hay aplicaciones web publicadas
Firewall y Application Gateway en paralelo (elegido)	Internet, Application Gateway con WAF, aplicación. El firewall controla todo lo demás y toda la salida	Es el diseño común cuando hay cargas web y no web. Es el recomendado para clústeres de Kubernetes
Application Gateway delante del firewall	Internet, Application Gateway con WAF, firewall, aplicación	Cuando el firewall tiene que inspeccionar el tráfico entre el Application Gateway y la aplicación, por ejemplo con detección de intrusiones
Firewall delante del Application Gateway	Internet, firewall, Application Gateway, aplicación	Casos poco comunes. El firewall solo ve tráfico cifrado y la aplicación pierde la IP real del cliente

Por qué en paralelo:

- El portal es la única carga web pública. El WAF la protege y el Azure Firewall se ocupa del resto: torre, sensores, migración, administración y toda la salida a internet.
- El Application Gateway conserva la IP real de cada cliente en el encabezado `X-Forwarded-For`, así que los límites de solicitudes por cliente y la detección de abuso del portal funcionan sin pasar por el firewall.
- La otra opción con sentido, poner el Application Gateway delante del firewall, solo aporta si el firewall inspecciona con detección de intrusiones, que es una función de la versión Premium (sección 2.2). Con la versión Standard ese firewall vería el mismo tráfico que ya filtró el WAF, y cobraría por procesarlo.
- El tráfico del portal no pasa por el firewall, así que no suma a su costo de procesamiento ni compite con el tráfico de las sedes.

Qué exige este diseño en las rutas:

- `snet-ingress` no lleva una ruta `0.0.0.0/0` hacia el firewall. Microsoft solo admite esa ruta en un Application Gateway sin IP pública, y en este diseño la rompería: el Application Gateway necesita salir a internet para que Azure lo administre.
- `snet-app-portal` sí manda su salida a internet al firewall. Las respuestas al Application Gateway viajan dentro de la misma red virtual y no pasan por el firewall.
- En los spokes, las rutas hacia el hub no incluyen el rango de `AzureFirewallSubnet`. Si lo incluyeran, la respuesta podría volver por una instancia del firewall distinta de la que recibió la conexión, y esta se cortaría.

2.2 Versión del Azure Firewall: Standard

El diseño de red supuso Azure Firewall Standard. Esta sección lo confirma frente a las otras dos versiones.

	Basic	Standard (elegida)	Premium
Rendimiento máximo	250 Mbps	30 Gbps	100 Gbps
Filtrado por nombre de dominio en reglas de red	No	Sí	Sí
Proxy DNS	No	Sí	Sí
Inteligencia de amenazas (IP y dominios maliciosos conocidos)	Solo alerta	Alerta y bloqueo	Alerta y bloqueo
Detección y prevención de intrusiones (IDPS)	No	No	Sí
Inspección de TLS de salida y filtrado por URL completa	No	No	Sí
Costo fijo al mes en East US 2	USD 288,35	USD 912,50	USD 1.277,50

	Basic	Standard (elegida)	Premium
Costo por GB procesado	USD 0,065	USD 0,016	USD 0,016

Por qué Standard:

- **Cubre todas las reglas del diseño.** La tabla de políticas usa direcciones, puertos, etiquetas de servicio de Azure y nombres de dominio para la salida a internet. Todo eso está en Standard.
- **Bloquea el tráfico hacia destinos maliciosos conocidos.** La inteligencia de amenazas de Microsoft se configura en modo de alerta y bloqueo. Es la primera capa de detección de actividad anómala en la red (sección 6).
- **Tiene margen de sobra.** El tráfico que procesa el firewall está muy por debajo de su límite: los usuarios internos suman a lo sumo unos 135 Mbps (450 personas a unos 300 Kbps) y la telemetría de los cuartos fríos menos de 1 Mbps.
- **Se puede subir a Premium sin cortar el servicio.** Azure permite cambiar de Standard a Premium con el cambio de versión del recurso, sin tiempo de inactividad, y en el código de infraestructura es un solo atributo (`sku_tier`). No hace falta pagar Premium desde el día uno para tenerlo disponible.

Por qué no Basic: cobra menos de costo fijo y cuatro veces más por GB, así que resulta más barata mientras el firewall procese menos de unos 12.700 GB al mes. El tráfico estimado sin la copia del archivo está por debajo de esa cifra, pero el ahorro sería de menos de USD 200 al mes, y Basic tiene tres límites que el diseño no acepta. Su techo de 250 Mbps queda por debajo del enlace de 400 Mbps de Cali. Solo alerta sobre destinos maliciosos y no los bloquea. Y Azure no permite pasar de Basic a Standard: subir de versión obligaría a reemplazar el firewall.

Por qué no Premium desde el inicio: sus funciones adicionales sirven para inspeccionar tráfico cifrado y detectar intrusiones dentro de la red. Este diseño ya cubre el tráfico web público con el WAF, no maneja datos de tarjetas de pago y deja la detección de comportamientos anómalos en Defender for Cloud (sección 6). Premium cuesta USD 365 más al mes. Si FríoAndes decide inspeccionar el tráfico interno, el cambio se hace sin rediseño: se sube la versión y el Application Gateway pasa a ubicarse delante del firewall (sección 2.1).

2.3 Entrada del portal: Application Gateway con WAF

Azure tiene dos servicios para publicar una aplicación web con WAF:

	Application Gateway WAF v2 (elegido)	Front Door Premium
Alcance	Regional. Vive dentro de la red virtual, en `snet-ingress`	Global. Recibe las conexiones en el punto de presencia de Microsoft más cercano al cliente, que para Colombia es Bogotá
Cómo llega a los servicios del portal	Por la red privada del ambiente	Por un endpoint privado que Front Door crea en su propia red y que FríoAndes aprueba
Separación de zona pública y privada	Por subredes y NSG dentro de la red de FríoAndes	La zona pública queda fuera de la red de FríoAndes
Conmutación entre regiones	Necesita un Application Gateway en la otra región y un cambio de DNS	La hace sola, entre orígenes de distintas regiones
Costo fijo por ambiente	USD 262,80 al mes, más la capacidad usada	USD 330 al mes por perfil, más solicitudes y transferencia

Por qué Application Gateway:

- **El portal es regional.** Unos 2.000 clientes corporativos, casi todos en Colombia, con un pico de 2.000 solicitudes por minuto. No hace falta una red global para ese volumen.
- **Mantiene la separación dentro de la red de FríoAndes.** La zona pública (`snet-ingress`) y la privada (`snet-app-portal`) son subredes con NSG propios, con las reglas a la vista en el mismo código que el resto de la red. El plan de direcciones ya reservó `snet-ingress` para este servicio.

- **Sirve con cualquier plataforma de contenedores.** Funciona igual con Container Apps y con la variante con Kubernetes (sección 2.4).
- **Los cambios no dependen de una distribución global.** En Front Door cada cambio, incluidas las reglas del WAF, se distribuye a todos los puntos de presencia y puede tardar hasta unos 15 minutos en aplicarse, y lo mismo para revertirlo. En una ventana de cambio de 22:00 a 04:00 conviene que aplicar y volver atrás sea lo más directo posible.

Cuándo convendría Front Door Premium: si el diseño de continuidad de la plataforma logística elige un segundo despliegue activo del portal en Central US con conmutación automática, o si FríoAndes quiere absorber ataques de denegación de servicio en el borde de la red de Microsoft. En ese caso Front Door se pone delante del Application Gateway o directo delante de los servicios del portal. Los dos se conectan por endpoint privado y las subredes no cambian.

2.4 La plataforma de contenedores

La plataforma propuesta para la torre y los servicios del portal es Azure Container Apps; Kubernetes (AKS) es la alternativa. Las decisiones de esta sección valen para las dos. La plataforma solo cambia tres puntos de este documento:

Punto	Container Apps	Kubernetes (AKS)
Reglas de salida a internet	Las que necesita Container Apps para descargar imágenes y operar	Las que necesita AKS, con la etiqueta `AzureKubernetesService`, y más direcciones públicas de salida en el firewall
Cómo el Application Gateway llega al portal	Al entorno interno de Container Apps	Al balanceador interno del clúster del portal, o con Application Gateway for Containers
Separación entre torre y portal	Entornos en subredes distintas: el firewall y los NSG filtran entre ellos	En producción, dos clústeres en subredes distintas: igual que con Container Apps. En pruebas y desarrollo, un clúster con políticas de red de Kubernetes

Las secciones 3 y 4 tratan cada punto en su propio apartado. El resto del documento es común a las dos plataformas.

---

3. Publicación del portal de rastreo

El portal de rastreo es la única aplicación de FríoAndes que se publica en internet. Lo usan unos 2.000 clientes corporativos, con un pico ordinario de unas 800 solicitudes por minuto y de 2.000 en campaña, durante unas cuatro horas.

3.1 Recorrido de una solicitud

```
Cliente en internet
  → DNS público del portal: apunta a la IP pública del Application Gateway
  → Application Gateway WAF v2 en snet-ingress (zona pública)
      · termina HTTPS con el certificado del portal
      · el WAF revisa la solicitud y bloquea los ataques conocidos
      · agrega la IP del cliente en el encabezado X-Forwarded-For
  → HTTPS por la red privada del ambiente
  → servicios del portal en snet-app-portal (zona privada, sin dirección pública)
  → base de datos y caché del rastreo, por la red privada
```

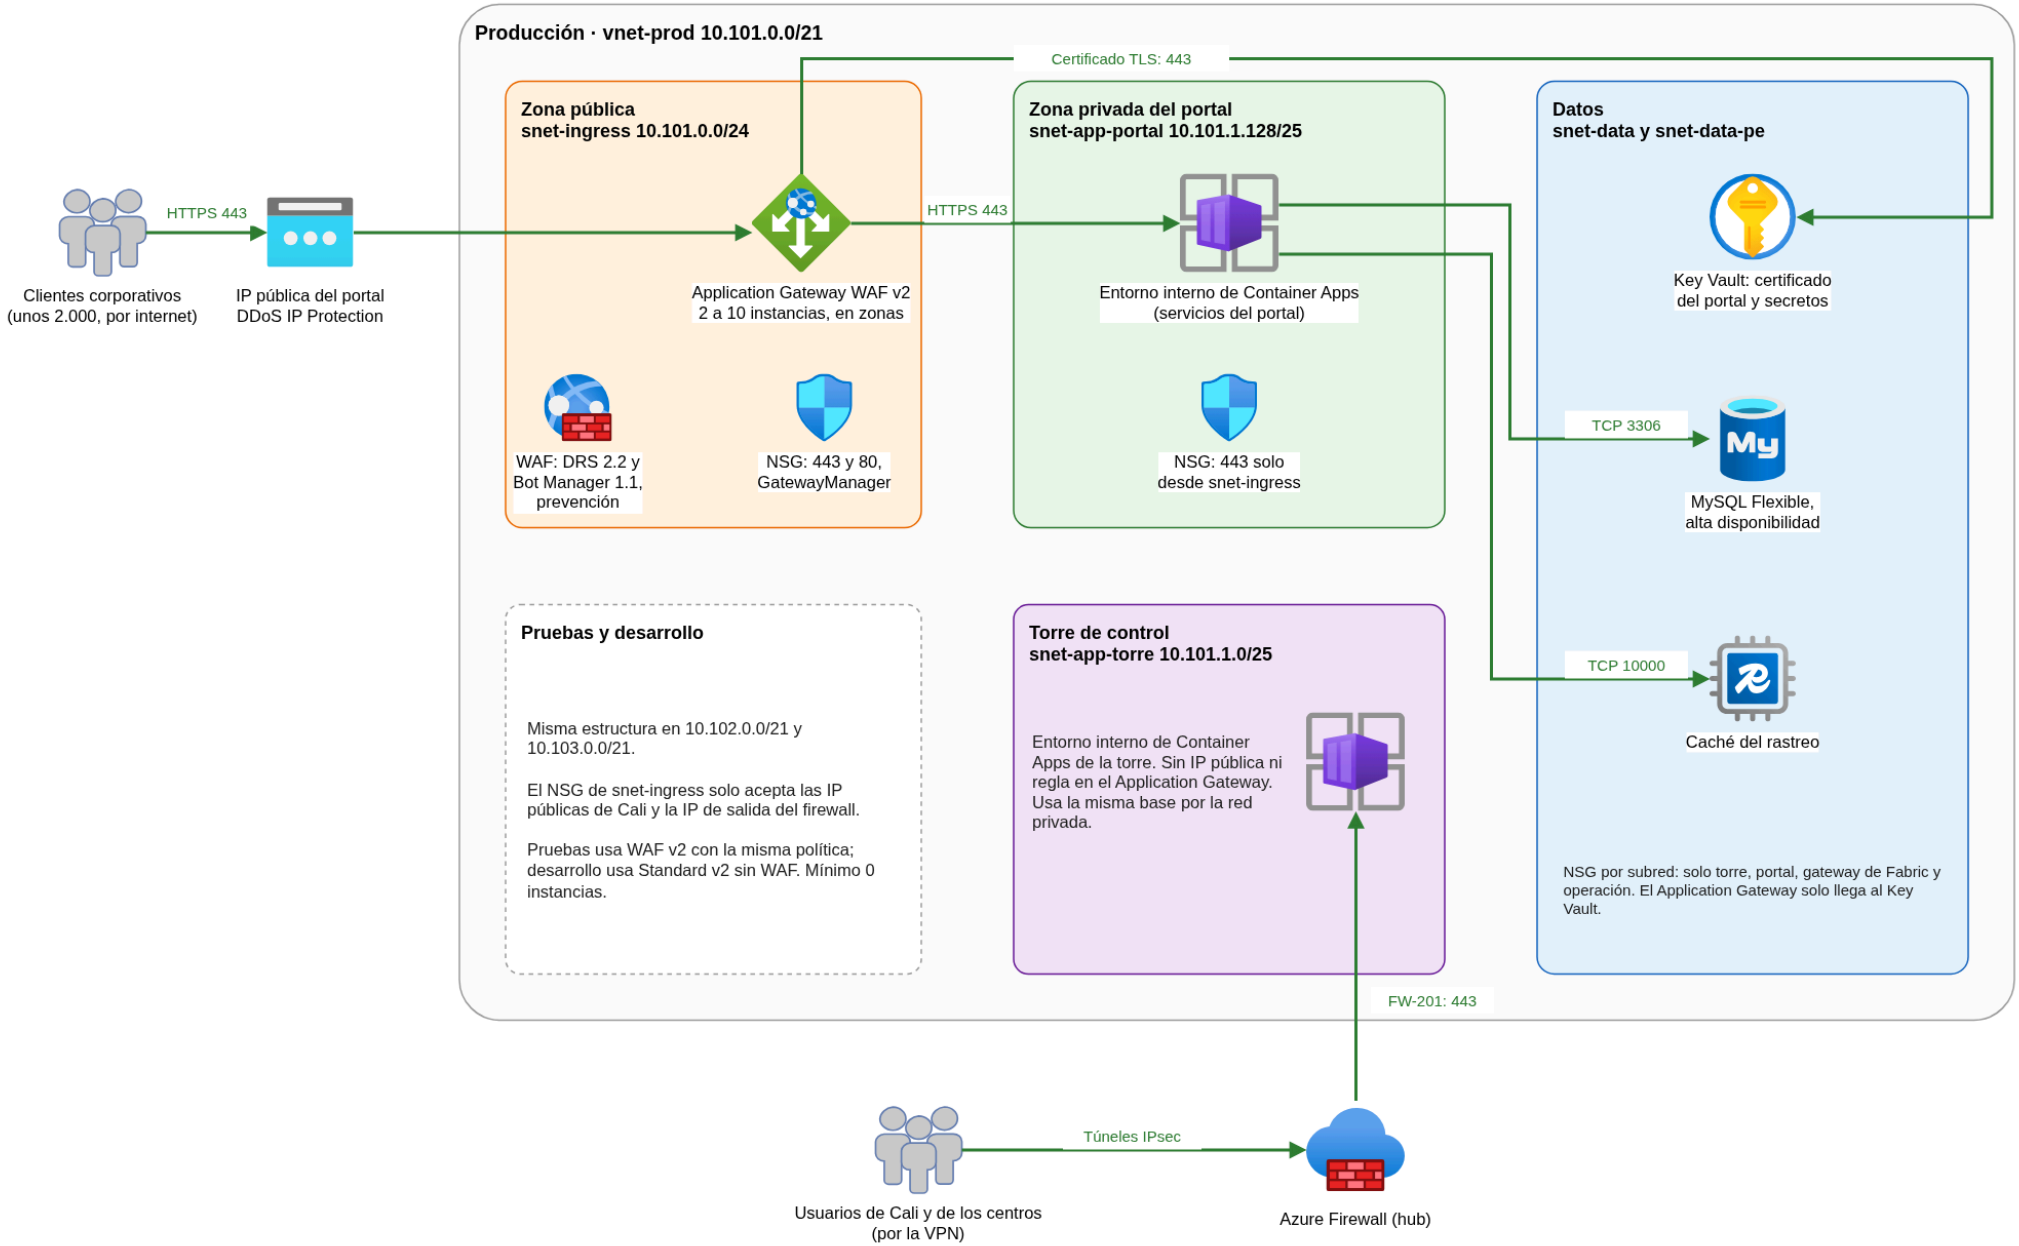


Figura 11: Publicación del portal: zona pública con el Application Gateway y el WAF, zona privada del portal, datos y torre sin camino desde internet

La torre de control no tiene ningún camino desde esta entrada. El Application Gateway solo tiene configurado el portal: no hay regla, nombre ni servidor de la torre en él. La torre se alcanza únicamente desde la red corporativa, a través del Azure Firewall (sección 4).

3.2 Separación entre la zona pública y la privada

La zona pública es `snet-ingress` y la privada es `snet-app-portal`. Cada capa agrega un control independiente:

Capa	Control	Qué impide
Subred `snet-ingress`	Exclusiva del Application Gateway. Azure no permite otros recursos en ella	Que otro servicio quede expuesto por compartir la subred pública
NSG de `snet-ingress`	Entrada permitida solo a 443 y 80 (80 solo redirige a 443), más el tráfico de administración de Azure (etiqueta `GatewayManager`, puertos 65200 a 65535) y las sondas del balanceador de Azure. Todo lo demás se rechaza. La salida a internet no se bloquea, porque Azure la necesita para administrar el servicio	Que se llegue a cualquier otro puerto de la subred pública
Tabla de rutas de `snet-ingress`	`0.0.0.0/0` directo a internet y sin propagar las rutas aprendidas de las sedes	Que una ruta anunciada desde una sede rompa la administración del Application Gateway. Azure no admite enviar la salida de esta subred a un firewall
Servicios del portal	Entorno interno: solo tienen dirección privada	Que se llegue a los servicios del portal sin pasar por el WAF
NSG de `snet-app-portal`	Entrada a 443 solo desde `snet-ingress`. Se rechaza el resto, incluida la torre	Que otra subred del ambiente llegue a los servicios del portal
Tabla de rutas de `snet-app-portal`	La salida a internet y hacia las sedes va al Azure Firewall. El rango de `snet-ingress` queda fuera de esas rutas	Que los servicios del portal salgan a internet sin control. La respuesta al Application Gateway vuelve directo por la red virtual, sin desviarse al firewall

3.3 Capacidad para 800 y 2.000 solicitudes por minuto

El Application Gateway v2 se mide en unidades de capacidad. Una unidad es lo que más se use entre tres medidas: cómputo, conexiones y volumen de datos. Microsoft da estas equivalencias para la versión con WAF:

Medida	Una unidad de capacidad equivale a
Cómputo	Unas 10 solicitudes por segundo revisadas por el WAF
Conexiones	2.500 conexiones persistentes
Volumen	2,22 Mbps

Con un tamaño medio de respuesta de 150 KB (página de rastreo, consulta y mapa; es un supuesto):

	Pico ordinario	Pico de campaña
Solicitudes por segundo	800 / 60 = 13,3	2.000 / 60 = 33,3
Unidades por cómputo	13,3 / 10 = 1,3	33,3 / 10 = 3,3
Volumen	13,3 × 150 KB = 16 Mbps	33,3 × 150 KB = 40 Mbps
Unidades por volumen	16 / 2,22 = 7,2	40 / 2,22 = 18
Unidades necesarias (la mayor)	7,2	18

El volumen de datos manda. Cada instancia del Application Gateway reserva 10 unidades de capacidad.

Configuración de producción:

- **Autoescalado con un mínimo de 2 instancias.** Las 20 unidades reservadas cubren el pico de campaña (18) sin depender del autoescalado, que tarda entre tres y cinco minutos en agregar instancias. Esto importa porque durante una campaña no se hacen cambios en producción: la capacidad tiene que estar lista antes.
- **Máximo de 10 instancias.** Alcanza para más de cinco veces el pico de campaña. La subred `/24` admite hasta 125 instancias, así que el máximo se puede subir sin tocar la red.
- **Zonas de disponibilidad.** El Application Gateway de producción se configura con zonas de disponibilidad, como recomienda Microsoft para producción.

La cifra de 10 solicitudes por segundo por unidad depende del tamaño de las solicitudes y del trabajo del WAF. Se confirma con una prueba de carga en el ambiente de pruebas antes del corte. Después de la salida a producción se revisan las métricas de unidades de capacidad del primer mes y se ajusta el mínimo. Microsoft recomienda alertar cuando el uso supere el 75 % de lo habitual.

3.4 El WAF del portal

Cada ambiente tiene su propia política de WAF, administrada como código:

Elemento	Configuración	Para qué
Reglas administradas	Default Rule Set 2.2, el conjunto que Microsoft recomienda hoy, basado en OWASP Core Rule Set 3.3.4	Bloquear inyección de SQL, scripts entre sitios, inclusión de archivos y los demás ataques web comunes
Protección contra bots	Bot Manager 1.1	Bloquear las IP de bots maliciosos conocidos según la inteligencia de amenazas de Microsoft, que se actualiza varias veces al día
Modo	Prevención: bloquea. El modo detección solo registra y se usa mientras se ajustan las reglas	
Inspección del cuerpo de la solicitud	Activada	Revisar también los datos enviados en formularios y consultas
Exclusiones	Solo las que salgan del ajuste en pruebas, cada una documentada con su motivo	Evitar falsos positivos sin abrir huecos generales

Cómo se llega al modo prevención sin bloquear a clientes legítimos:

1. En pruebas, la política arranca en modo detección mientras se ejecutan las pruebas funcionales y de carga del portal.
2. Se revisan los registros del WAF, se agregan las exclusiones necesarias y se pasa a prevención en pruebas.
3. Producción arranca en modo prevención desde el corte, con la misma política ya ajustada.

Límites de solicitudes y detección de anomalías. El diseño de datos personales y perímetro (`seguridad-datos-personales-perimetro.md`, secciones 4 y 5) agrega a esta misma política cuatro reglas de límite dimensionadas para el pico de 2.000 solicitudes por minuto: límite general por IP, consulta de guías, inicio de sesión y registro del tráfico desde fuera de Colombia (WAF-prod-02 a 05 y WAF-test-02 a 05). También define la detección con Defender for Cloud. Las reglas usan la IP real de cada cliente, que el Application Gateway entrega.

3.5 Certificados y cifrado

- **HTTPS de punta a punta.** El cliente se conecta por HTTPS al Application Gateway, y el Application Gateway se conecta por HTTPS a los servicios del portal. La conexión por el puerto 80 solo redirige a 443.
- **Versión mínima TLS 1.2.** Se usa la política TLS predefinida `AppGwSslPolicy20220101` o una más reciente. Desde agosto de 2025 Azure ya no acepta TLS 1.0 ni 1.1 en el Application Gateway.
- **El certificado público vive en el Key Vault del ambiente.** El Application Gateway lo lee con una identidad administrada que tiene el rol de lectura de secretos (`Key Vault Secrets User`), sin contraseñas en el código.

La referencia al certificado no lleva versión, así que cuando se renueva en Key Vault el Application Gateway toma la nueva versión sola (revisa cada cuatro horas).

- **Acceso privado al Key Vault.** El Key Vault tiene endpoint privado en `snet-data-pe`. Para que el Application Gateway lo encuentre, la zona DNS privada de Key Vault (`privatelink.vaultcore.azure.net`) se enlaza también a la red del ambiente, además de al hub. Si el Application Gateway pierde acceso al certificado, Azure deshabilita el listener; por eso la falta de acceso genera una alerta (sección 6).

3.6 Protección contra denegación de servicio

Opción	Qué da	Costo al mes
Protección de infraestructura (incluida)	Mitigación automática de ataques de red sobre todas las IP públicas de Azure, sin configuración	Sin costo
DDoS IP Protection sobre la IP del portal de producción (propuesta)	Lo anterior, más políticas ajustadas al tráfico del portal, métricas, alertas e informes de cada mitigación	USD 199 por IP
DDoS Network Protection	Lo anterior para todas las IP de la red, más soporte de respuesta rápida, protección del costo durante un ataque y el WAF cobrado a la tarifa sin WAF	Unos USD 2.944 por plan

Propuesta: DDoS IP Protection solo para la IP pública del Application Gateway de producción. Es la única entrada pública de la que dependen los clientes y su disponibilidad es uno de los objetivos de servicio de la plataforma. Con las alertas e informes, el equipo de operación sabe cuándo hubo un ataque y qué se mitigó. Los ataques de aplicación, como el exceso de solicitudes, los detiene el WAF.

Network Protection no se justifica: su costo es unas quince veces el de proteger la IP del portal, y el descuento del WAF que incluye no compensa la diferencia.

3.7 Pruebas y desarrollo

- **Misma estructura que producción**, con su propio Application Gateway en `snet-ingress`.
- **Solo orígenes autorizados.** El NSG de `snet-ingress` acepta 443 únicamente desde:
  - las IP públicas de los dos proveedores de internet de Cali;
  - la IP de salida del Azure Firewall, que usan las pruebas automáticas que corren en `snet-admin`.

  El acceso de las personas que trabajan fuera de la sede sigue el diseño de acceso remoto.
- **Pruebas usa WAF v2** con la misma política que producción, porque ahí se ajusta el WAF antes de cada cambio.
- **Desarrollo usa Application Gateway Standard v2, sin WAF.** No tiene datos reales ni usuarios externos, y las reglas del WAF ya se validan en pruebas. El código es el mismo módulo con otra versión del servicio.
- **Autoescalado con mínimo 0 instancias** en los dos ambientes, porque su tráfico es bajo y no hay campañas.

3.8 Durante la convivencia

Hasta el corte, el portal sigue publicado desde Cali por NAT, Nginx y el firewall de aplicaciones actual. El portal nuevo se publica antes del corte con su propia IP y se prueba sin tráfico de clientes.

- **Unos días antes del corte** se baja el tiempo de vida (TTL) del registro DNS público del portal, para que el cambio y una eventual vuelta atrás se propaguen en minutos.
- **En el corte** el registro DNS pasa de la IP de Cali a la IP del Application Gateway.
- **Para volver atrás**, el registro vuelve a la IP de Cali, que sigue configurada hasta que se cierra el plazo de vuelta atrás.

La sección 5 detalla cuándo se apaga cada pieza de Cali.

3.9 Variante con Kubernetes (AKS): qué cambia en la publicación

Con Container Apps, el Application Gateway envía el tráfico al nombre de la aplicación dentro del entorno interno. Para resolver ese nombre, la zona DNS privada del entorno se enlaza a la red del ambiente y al hub. Con AKS hay dos formas de conectar el Application Gateway con el clúster del portal:

	Application Gateway WAF v2 con su controlador para AKS (propuesta para la variante)	Application Gateway for Containers
WAF	La misma política que con Container Apps (Default Rule Set 2.2 y Bot Manager 1.1)	Solo Default Rule Set 2.1. Sin desafíos de JavaScript ni captcha para bots, sin respuesta de bloqueo personalizada y sin usar `X-Forwarded-For` en reglas personalizadas
Subred	`snet-ingress` igual, con una diferencia: con Azure CNI Overlay debe estar reservada para el Application Gateway (delegación `Microsoft.Network/applicationGateways`), ser `/24` o menor y estar en la misma red virtual que los nodos. El diseño ya cumple las dos últimas condiciones	`snet-ingress` reservada para este servicio, con su propia tabla de rutas
Quién configura las rutas web	El controlador, desde los recursos de Kubernetes. Toma el control de toda la configuración del Application Gateway, así que el código de infraestructura solo crea el recurso y la política del WAF	El controlador, desde los recursos de Kubernetes
Dirección	Microsoft lo mantiene y sugiere evaluar Application Gateway for Containers para soluciones nuevas	Es la evolución que Microsoft propone para Kubernetes

Se propone el controlador del Application Gateway porque conserva el mismo WAF en las dos plataformas, con el conjunto de reglas más reciente. Si se eligiera Application Gateway for Containers, el WAF quedaría con menos funciones y con un conjunto de reglas anterior.

---

4. Tabla de políticas del firewall de nube

Esta sección es la tabla de políticas del firewall de nube: origen, destino, puerto, acción y si cada regla es temporal de la migración o queda en estado estable. La versión completa, regla por regla y ambiente por ambiente, está en `red/data/firewall-policy.csv`. Es la única fuente para el código de infraestructura, y un script la verifica contra el plan de direcciones (sección 4.9).

4.1 Dónde se controla cada flujo

No todo el tráfico pasa por el Azure Firewall. Cada flujo tiene un punto de control, elegido según por dónde viaja:

Punto de control	Qué controla	Por qué ahí
Azure Firewall	Todo lo que va de las sedes a la nube, de la nube a las sedes, entre sedes durante la convivencia, entre ambientes y hacia internet	Es el paso obligado del hub y registra cada conexión en un solo lugar
WAF del Application Gateway	La entrada del portal desde internet	Revisa el contenido de cada solicitud web, que el firewall no lee (sección 2.1)
NSG de cada subred	El tráfico dentro de un mismo ambiente, entre zonas. Es además una segunda capa detrás del firewall	El tráfico entre subredes de una misma red virtual no pasa por el hub

Punto de control	Qué controla	Por qué ahí
IoT Hub y DPS	Los camiones, que llegan desde internet	No están en la red corporativa: la protección es TLS y una credencial por camión

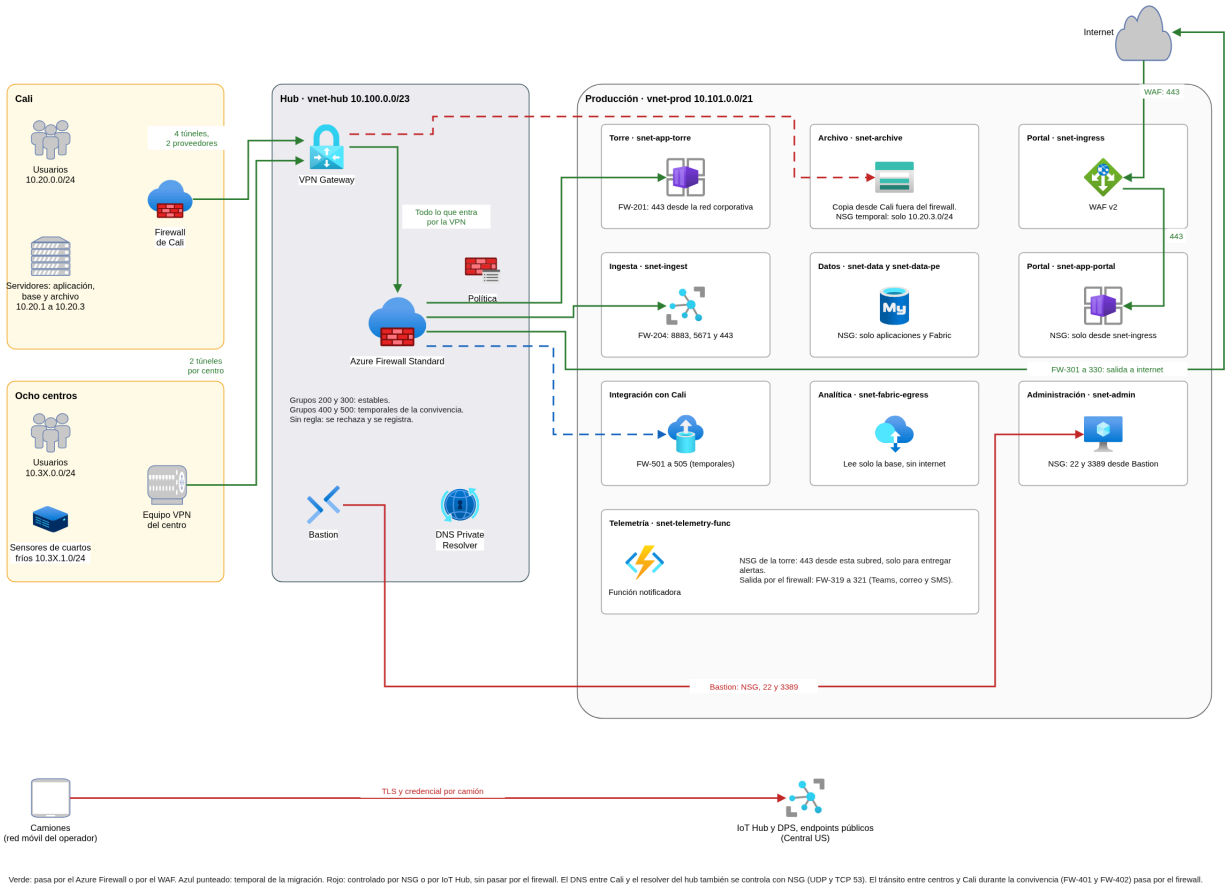


Figura 12: Puntos de control: qué pasa por el Azure Firewall, qué por el WAF y qué por NSG o IoT Hub

En el diagrama, las líneas verdes pasan por el Azure Firewall o por el WAF, las azules punteadas son temporales de la migración y las rojas se controlan con NSG o en IoT Hub, sin pasar por el firewall. La función notificadora de la telemetría (`snet-telemetry-func`) sale a internet por el firewall y llega a la torre por el NSG de la torre.

4.2 Cómo se organiza la política del firewall

- **Una sola política**, administrada como código, con cuatro grupos de reglas por prioridad:

Prioridad	Grupo	Vigencia
200	Sedes a la nube	Estable
300	Salida a internet	Estable
400	Tránsito entre sedes durante la convivencia	Temporal
500	Migración	Temporal

  Las reglas temporales viven solo en los grupos 400 y 500. Al cerrar la convivencia se borran los dos grupos completos, sin revisar regla por regla.

- **Todo lo que no está permitido se rechaza.** Es el comportamiento del Azure Firewall cuando ninguna regla coincide, y cada rechazo queda registrado. Así se bloquea, sin reglas adicionales, el tráfico entre producción, pruebas y desarrollo.

- **Inteligencia de amenazas en modo alerta y bloqueo.** Se rechaza y registra el tráfico hacia y desde IP y dominios maliciosos conocidos, antes de evaluar las reglas.
- **Traducción de origen solo hacia los endpoints privados.** Por defecto, el firewall conserva la IP de origen del tráfico interno. Microsoft exige traducirla cuando el destino es un endpoint privado y la regla es de red: el endpoint privado responde directo al origen y no por el firewall, y la conexión se rompería. Por eso la lista de destinos sin traducción incluye las sedes y las subredes de la nube que no tienen endpoints privados, y deja fuera `snet-ingest`, `snet-data-pe` y `snet-archive`. En la práctica, la torre ve la IP real de cada usuario y la ingesta ve la del firewall. El registro del firewall conserva la IP original del sensor.
- **Sin proxy DNS.** Las reglas de red usan direcciones y etiquetas de servicio, y las de aplicación (nombres de dominio para HTTPS) no lo necesitan.

4.3 Reglas del Azure Firewall

La notación `10.10X` indica que la regla se repite en cada ambiente: `X` es 1 en producción, 2 en pruebas y 3 en desarrollo. Los centros son `10.31` a `10.38`.

Sedes a la nube (estable)

Regla	Origen	Destino	Puerto	Acción	Vigencia
FW-201	Usuarios de Cali (`10.20.0.0/24`) y de los centros (`10.3X.0.0/24`)	Torre de producción (`10.101.1.0/25`)	TCP 443	Permitir	Estable
FW-202 y FW-203	Usuarios de Cali (`10.20.0.0/24`)	Torre de pruebas y de desarrollo (`10.102.1.0/25`, `10.103.1.0/25`)	TCP 443	Permitir	Estable
FW-204	Sensores de los centros (`10.3X.1.0/24`)	Ingesta de producción (`10.101.2.96/27`)	TCP 8883, 5671 y 443	Permitir	Estable

Los sensores reales solo llegan a producción. Pruebas y desarrollo trabajan con datos simulados, como pide el tratamiento de datos personales.

Salida a internet (estable, en cada ambiente)

Reglas	Origen	Destino	Puerto	Acción	Vigencia
FW-301, 307 y 313	Torre y portal (`10.10X.1.0/24`)	Registro de Microsoft y binarios de Container Apps: `mcr.microsoft.com`, `*.data.mcr.microsoft.com`, `packages.aks.azure.com`, `acs-mirror.azureedge.net`	HTTPS 443	Permitir	Estable
FW-302, 308 y 314	Torre, portal y función notificadora de la telemetría (`10.10X.3.0/27`)	Entra ID e identidades administradas: `*.identity.azure.net`, `login.microsoftonline.com`, `*.login.microsoftonline.com`, `login.microsoft.com`, `*.login.microsoft.com`	HTTPS 443	Permitir	Estable
FW-303, 309 y 315	Torre, portal y agentes de despliegue (`10.10X.2.128/27`)	Registro de contenedores de FríoAndes (`<registro>.azurecr.io` y su almacenamiento `*.blob.core.windows.net`)	HTTPS 443	Permitir	Estable

Reglas	Origen	Destino	Puerto	Acción	Vigencia
FW-304, 310 y 316	Torre, portal y función notificadora	Azure Monitor (etiqueta de servicio `AzureMonitor`)	TCP 443	Permitir	Estable
FW-305, 311 y 317	Torre y portal	Servicios externos de la aplicación, como correo y SMS. Cada dominio se agrega con su propio cambio	HTTPS 443	Permitir	Estable
FW-306, 312 y 318	Agentes de despliegue y máquinas de operación (`10.10X.2.128/27`)	Azure Resource Manager, Entra ID, los dominios que GitHub publica para sus ejecutores autoalojados y los repositorios de actualizaciones de Ubuntu y Microsoft	HTTPS 443 y HTTP 80	Permitir	Estable
FW-319, 320 y 321	Función notificadora de la telemetría (`10.10X.3.0/27`)	Canales de las alertas: webhook de Workflows de Teams (`*.api.powerplatform.com` y `*.logic.azure.com`), correo de Azure Communication Services (`<recurso>.communication.azure.com`) y el proveedor de SMS	HTTPS 443	Permitir	Estable
FW-322, 323 y 324	Torre, portal y función notificadora	API de ingesta de registros de Azure Monitor (`*.ingest.monitor.azure.com`), para los eventos de auditoría de negocio y el registro de cada alerta de temperatura. La etiqueta `AzureMonitor` no cubre estos endpoints (`observabilidad-slo-zabbix.md`, sección 2.2)	HTTPS 443	Permitir	Estable
FW-325, 326 y 327	Torre (`10.10X.1.0/25`)	Endpoint SQL de Fabric (etiquetas de servicio `PowerBI` y `Sql`), para leer la hora estimada de llegada con la identidad administrada de la torre. Microsoft pide las etiquetas: el nombre del endpoint solo no alcanza	TCP 1433	Permitir	Estable
FW-328, 329 y 330	Servicios del portal (`10.10X.1.128/25`)	API de Power BI (`api.powerbi.com`), para pedir el token de inserción del reporte del cliente	HTTPS 443	Permitir	Estable

El gateway de Fabric (`snet-fabric-egress`) no tiene ninguna regla de salida a internet. Microsoft devuelve sus resultados a Fabric por un canal interno que no pasa por internet ni por el firewall.

Tránsito entre sedes durante la convivencia (temporal)

Cuando un centro pasa a la conexión directa con Azure, todo lo que todavía vive en Cali le llega a través del hub, y el Azure Firewall lo controla.

Regla	Origen	Destino	Puerto	Acción	Se retira
FW-401	Usuarios de los centros (`10.3X.0.0/24`)	Torre y portal actuales en Cali (`10.20.1.0/24`)	TCP 443	Permitir	Al cerrar el plazo de vuelta atrás del corte
FW-402	Equipos de los centros (`10.3X.0.0/24` y `10.3X.1.0/24`)	Servidor de archivo de Cali (`10.20.3.0/24`), FTP de los históricos de temperatura	TCP 21 y el rango pasivo del servidor FTP	Permitir	Cuando la telemetría en línea reemplaza la carga por lote del centro

Migración (temporal, producción)

Regla	Origen	Destino	Puerto	Acción	Se retira
FW-501	Servicio de migración (`10.101.2.160/27`)	Base de datos de Cali (`10.20.2.0/24`)	TCP 3306	Permitir	En el corte
FW-502	Servicio de migración	Cuenta de almacenamiento de la migración (`<cuenta>.blob.core.windows.net`)	HTTPS 443	Permitir	En el corte, junto con la cuenta y su token
FW-503	Servidores de aplicación de Cali (`10.20.1.0/24`)	Integración con Cali (`10.101.2.160/27`)	TCP 443	Permitir	Al cerrar el plazo de vuelta atrás
FW-504	Integración con Cali	Servidores de aplicación de Cali	TCP 443	Permitir	Al cerrar el plazo de vuelta atrás

En FW-501 el origen es el servicio de migración porque es quien abre la conexión hacia la base de Cali, aunque los datos viajen en el otro sentido. El plazo de vuelta atrás termina, como máximo, el día 90.

No hay regla de replicación de Azure hacia la base de Cali: MySQL no replica de 8.4 hacia 5.7, así que el plan de migración no usa replicación inversa (`carga-c-migracion-y-campana.md`, sección 3.5).

Regla final

Regla	Origen	Destino	Puerto	Acción	Vigencia
FW-999	Cualquiera	Cualquiera	Cualquiera	Denegar y registrar	Estable

4.4 Reglas de los NSG dentro de cada ambiente

Cada subred tiene su NSG. Todas terminan en una regla que rechaza lo que no esté permitido arriba. Esa regla es la que impide, por ejemplo, que el portal llegue a la torre.

Subred de destino	Se permite desde	Puerto	Vigencia
`snet-ingress` (portal)	Producción: internet. Pruebas y desarrollo: las IP públicas de Cali y la IP de salida del firewall	TCP 443 y 80	Estable
`snet-ingress` (portal)	Administración de Azure (etiqueta `GatewayManager`)	TCP 65200 a 65535	Estable
`snet-app-portal`	`snet-ingress`	TCP 443	Estable
`snet-app-torre`	Usuarios de Cali y de los centros (en pruebas y desarrollo, solo Cali), que llegan por el firewall con su IP real	TCP 443	Estable

Subred de destino	Se permite desde	Puerto	Vigencia
`snet-app-torre`	Función notificadora de la telemetría de su ambiente, que entrega las alertas a la consola	TCP 443	Estable
`snet-data` (MySQL)	Torre, portal, gateway de Fabric y máquinas de operación	TCP 3306	Estable
`snet-data-pe` (caché)	Torre, portal y máquinas de operación	TCP 10000	Estable
`snet-data-pe` (Key Vault)	Torre, portal, Application Gateway y máquinas de operación	TCP 443	Estable
`snet-data-pe` (Event Hubs de la telemetría)	Torre	TCP 5671 y 443	Estable
`snet-data-pe` (event hub de alertas, cuenta de la función y Key Vault)	Función notificadora	TCP 5671 y 443	Estable
`snet-archive`	Torre, portal, máquinas de operación y función notificadora. Fabric lee el archivo por atajos con acceso de confianza, sin pasar por la red virtual	TCP 443	Estable
`snet-ingest`	Azure Firewall (`10.100.0.64/26`)	TCP 8883, 5671 y 443	Estable
`snet-admin`	Azure Bastion (`10.100.0.192/26`)	TCP 22 y 3389	Estable
`snet-archive` (producción)	Agente de copia continua en la red del archivo de Cali (`10.20.3.0/24`)	TCP 443	Temporal: al terminar la copia continua
`snet-data` (producción)	Servicio de migración (`10.101.2.160/27`)	TCP 3306	Temporal: en el corte
`snet-cali-integration` (producción)	Servidores de aplicación de Cali, pareja de FW-503	TCP 443	Temporal: al cerrar el plazo de vuelta atrás
Resolver DNS, entrada (hub)	DNS de Cali y redes de los tres ambientes	UDP y TCP 53	Estable
Resolver DNS, salida (hub)	Hacia el DNS de Cali	UDP y TCP 53	Estable
Todas	Cualquier otro origen	Cualquiera	Denegar

4.5 Flujos que no pasan por el Azure Firewall

Flujo	Cómo se controla	Por qué no pasa por el firewall
Clientes hacia el portal	WAF y NSG de `snet-ingress`	Diseño en paralelo (sección 2.1). Azure no admite desviar la salida del Application Gateway al firewall
Camiones hacia IoT Hub y DPS	TLS y una credencial por camión	Llegan desde la red móvil del operador, por internet. Si la plataforma del operador reenvía los datos desde direcciones fijas, el endpoint se limita además a esas direcciones
Copia continua del archivo	NSG temporal de `snet-archive`	Ahorra unos USD 194 al mes de procesamiento por un tráfico temporal,

Flujo	Cómo se controla	Por qué no pasa por el firewall
		conocido y de un solo origen. Decidido en el diseño de red
Azure Bastion hacia las máquinas de operación	NSG de `snet-admin`	Azure no admite rutas definidas por el usuario en la subred de Bastion, y Microsoft indica que no hace falta pasar ese tráfico por el firewall porque es privado
DNS entre Cali y el resolver del hub	NSG de las subredes del resolver	Es tráfico de un servicio compartido del hub, de un solo puerto y con orígenes conocidos

4.6 Rutas que hacen cumplir la tabla

Una regla solo sirve si el tráfico llega al firewall. Estas tablas de rutas lo garantizan:

Subred	Rutas	Efecto
`GatewaySubnet` (hub)	Los tres ambientes (`10.101.0.0/21`, `10.102.0.0/21` y `10.103.0.0/21`) y las redes de las sedes hacia el Azure Firewall	Todo lo que entra por la VPN pasa por el firewall, incluido el tránsito entre un centro y Cali
Subredes de los ambientes, salvo `snet-ingress`	`0.0.0.0/0` hacia el Azure Firewall, sin propagar las rutas aprendidas de la VPN	La salida a internet y hacia las sedes pasa por el firewall. Sin el bloqueo de la propagación, las rutas de las sedes, más específicas, saltarían el firewall
`snet-ingress`	`0.0.0.0/0` hacia internet, sin propagar las rutas de la VPN	Requisito del Application Gateway (sección 3.2)
`AzureBastionSubnet` y subredes del resolver DNS	Sin tabla de rutas	Bastion no la admite; el resolver responde dentro del hub

Los endpoints privados necesitan una configuración adicional. Cada endpoint privado publica una ruta propia, más específica que cualquier ruta del ambiente, que lleva el tráfico directo a él. Azure solo deja que una ruta definida por el usuario la reemplace si la subred del endpoint tiene activadas las políticas de red para rutas. Esa configuración, subred por subred, decide qué pasa por el firewall:

Subred	Políticas de red	Resultado
`snet-ingest`	NSG y rutas	Los sensores que entran por la VPN pasan por el firewall (FW-204) y luego por el NSG
`snet-data-pe`	NSG y rutas	Solo se usa dentro del ambiente. El NSG controla quién llega a la caché, al Key Vault, a los Event Hubs de la telemetría y a la cuenta de la función notificadora
`snet-archive`	Solo NSG	La copia del archivo desde Cali sigue la ruta directa del endpoint y no pasa por el firewall. El NSG la limita al servidor de archivo de Cali

Por lo mismo, la tabla de rutas de la `GatewaySubnet` y la de `snet-archive` quedan coherentes: ninguna de las dos manda la copia al firewall, así que la ida y la vuelta toman el mismo camino.

4.7 Cómo quedan separadas las zonas

La torre de control, el portal público, la ingesta de sensores y los datos analíticos quedan separados en la red así:

Desde \ Hacia	Torre	Portal	Ingesta	Analítica (gateway de Fabric)
Internet	Sin camino: sin IP pública, sin regla	Solo por el WAF	Solo camiones, al endpoint público de IoT Hub	Sin camino

Desde \ Hacia	Torre	Portal	Ingesta	Analítica (gateway de Fabric)
Red corporativa	Firewall (FW-201) y NSG, puerto 443	Por internet, como cualquier cliente	Solo los sensores (FW-204)	Sin camino
Torre		Rechazado por el NSG del portal	Sin regla	Sin regla
Portal	Rechazado por el NSG de la torre		Sin regla	Sin regla
Ingesta (función notificadora)	NSG de la torre, puerto 443, solo para entregar las alertas	Sin regla		Sin regla
Analítica	Sin regla	Sin regla	Sin regla	Solo lee la base y el archivo

La única conexión entre zonas es la de la función notificadora hacia la API de la torre, para entregar las alertas de temperatura. Fuera de ella, ninguna zona puede iniciar una conexión hacia otra: solo comparten la capa de datos, cada una con su regla en el NSG de la base y del archivo.

4.8 Variante con Kubernetes (AKS): qué cambia en la tabla

Elemento	Cambio
FW-301, 307 y 313	Se reemplazan por una regla de aplicación con la etiqueta `AzureKubernetesService`, que Microsoft mantiene con los dominios que necesita AKS
Comunicación de los nodos con el plano de control	Sin reglas en el firewall: el clúster es privado y su API vive dentro de la red (`snet-aks-apiserver`). Los puertos UDP 1194 y TCP 9000 no se necesitan en clústeres privados
NSG de `snet-aks-apiserver`	TCP 443 y 4443 desde las subredes de nodos, y TCP 9988 desde el balanceador de Azure (definido en el diseño de red)
DNS de los nodos	AKS exige UDP y TCP 53 hacia el DNS. El NSG del resolver ya permite los dos
IP de salida del firewall	Microsoft recomienda planear al menos 20 en producción con AKS, para no agotar los puertos de salida
Tráfico dentro de un clúster	No se puede bloquear con NSG ni con el firewall. En producción, torre y portal están en clústeres distintos y la tabla aplica igual. En pruebas y desarrollo, un solo clúster por ambiente, la separación se hace con políticas de red de Kubernetes

4.9 Tabla legible por máquina y verificación

La tabla completa vive en tres archivos de `red/`, junto al plan de direcciones:

Archivo	Contenido
`data/firewall-policy.csv`	Las 100 reglas, ambiente por ambiente: 41 del Azure Firewall, 47 de NSG, 10 del WAF y 2 de IoT Hub y DPS. Cada una con su flujo, punto de control, origen, destino, puerto, acción, vigencia y momento de retiro
`data/firewall-settings.csv`	La configuración general: versión, inteligencia de amenazas, rangos sin traducción de origen, proxy DNS, IP públicas y grupos
`tools/verify_firewall_policy.py`	Comprueba la tabla contra `ip-plan.csv` y el inventario on-premises

El script hace doce comprobaciones. Entre ellas:

- cada rango existe en el plan de direcciones;
- la torre solo recibe tráfico corporativo y, desde la nube, el de la función de alertas de su mismo ambiente;
- ninguna regla une ambientes;
- los sensores reales solo llegan a producción;

- el gateway de Fabric no sale a internet;
- las reglas temporales tienen fecha de retiro y están en los grupos que se borran completos;
- ningún endpoint privado queda en la lista sin traducción de origen.

La tabla actual pasa las doce. Su hash SHA-256 es `3f3e8359f220968fa873ee3fc050c44ac860f7cdb079db5858f9a3a489f7684a` y el reporte está en `verification/reporte-firewall-policy.md`. El código de infraestructura del módulo de seguridad se revisa regla por regla contra este mismo archivo.

Los valores entre <> se completan en la implementación: el nombre del registro de contenedores, los dominios de los proveedores externos, el nombre del recurso de Azure Communication Services y del DPS, las IP públicas de Cali, la IP del DNS de Cali y el rango pasivo del servidor FTP.

---

5. Transición del firewall de Cali

El firewall de Cali sigue en pie durante la convivencia. Esta sección define qué políticas se conservan, cuáles se trasladan y cuándo se apaga cada función, en tres partes: las funciones del equipo, las políticas que hoy aplica y el orden en que se apagan.

5.1 Los hitos que marcan cada cambio

Los cambios del firewall de Cali se atan a hitos de la migración, no a fechas fijas. Así, si el plan de migración mueve una fecha, la transición del firewall se mueve con ella.

Hito	Qué pasa en la red
Inicio de la convivencia (día 0)	Cali ya tiene sus cuatro túneles hacia Azure por los dos proveedores. Se activan las reglas temporales de los dos lados
Paso de cada centro a la conexión directa	El centro deja de entrar por Cali. Lo que todavía vive en Cali le llega a través del hub de Azure
Corte	La base de datos y el tráfico de despacho y rastreo pasan a Azure. El portal empieza a publicarse desde el Application Gateway
Cierre del plazo de vuelta atrás	Ya no se puede volver a Cali. Se retiran las reglas temporales y los caminos de respaldo
Día 90	Límite de la convivencia: se apaga la carga de Cali. Ningún paso de esta tabla puede quedar después

El plazo de vuelta atrás empieza en el corte y termina, como máximo, el día 90. Su duración exacta la fija el plan de migración y la confirma FríoAndes.

Todos los cambios en el firewall de Cali y en el de Azure se hacen en la ventana de 22:00 a 04:00, fuera de campaña, como cualquier cambio de infraestructura.

5.2 Qué pasa con cada función del firewall de Cali

Función	Durante la convivencia	Qué la reemplaza	Cuándo se apaga
Enrutamiento entre las subredes de Cali	Se mantiene	Nada: Cali sigue siendo una sede	No se apaga. Al final solo enruta lo que queda en la sede: usuarios y enlaces
VPN sitio a sitio con los ocho centros	Se mantiene como respaldo de cada centro que pasa a la conexión directa	La VPN de cada centro con el VPN Gateway de Azure	Centro por centro, al cerrar el plazo de vuelta atrás y como máximo el día 90
NAT del portal de rastreo hacia Nginx	Publica el portal actual hasta el corte. Después del corte no recibe tráfico, pero queda configurado como camino de vuelta atrás	La IP pública del Application Gateway (sección 3)	Al cerrar el plazo de vuelta atrás

Función	Durante la convivencia	Qué la reemplaza	Cuándo se apaga
Firewall de aplicaciones delante de Nginx	Protege el portal actual hasta el corte. Después, igual que el NAT	El WAF del Application Gateway	Junto con el NAT
Políticas entre subredes	Se mantienen mientras los servidores sigan encendidos (sección 5.3)	El Azure Firewall y los NSG para todo lo que se mudó	Cada política se retira cuando se apaga el servidor que protegía
Salida de Cali hacia Azure (función nueva)	Se agrega al inicio: dos proveedores, cuatro túneles, BGP	No aplica	No se apaga: es la conexión permanente de la sede

Al final de la convivencia, el firewall de Cali queda como firewall de sede: protege la red de usuarios, da salida a internet a la sede y mantiene los túneles hacia Azure. Deja de publicar servicios y de proteger servidores, porque ya no quedan servidores en Cali.

5.3 Qué políticas se conservan, cuáles se trasladan y cuáles se retiran

Las reglas actuales del firewall de Cali no están documentadas. Esta tabla las deduce del inventario de redes y de las cargas de la sede. FríoAndes debe exportar la política real para conciliarla regla por regla antes del día 0 (sección 8).

Política de hoy (deducida)	Destino	Dónde queda	Cuándo se retira en Cali
Usuarios de Cali (`10.20.0.0/24`) hacia la torre (`10.20.1.0/24`), HTTPS	Se traslada	FW-201 y el NSG de `snet-app-torre`	Al cerrar el plazo de vuelta atrás
Usuarios de los centros hacia la torre, por la VPN de cada centro	Se traslada	FW-201. Mientras la torre siga en Cali, FW-401	Al cerrar el plazo de vuelta atrás
Internet hacia Nginx (`10.20.5.0/24`) por NAT, con firewall de aplicaciones	Se traslada	WAF y NSG de `snet-ingress` (sección 3)	Al cerrar el plazo de vuelta atrás
Nginx hacia los servidores de aplicación	Se traslada	NSG de `snet-app-portal`: solo desde el Application Gateway	Al apagar los servidores Nginx
Servidores de aplicación hacia bases y caché (`10.20.2.0/24`)	Se traslada	NSG de `snet-data` y `snet-data-pe`	Al apagar la base de Cali
Servidores de aplicación hacia el archivo (`10.20.3.0/24`), NFS y FTP	Se traslada	NSG de `snet-archive`, por HTTPS	Al apagar el servidor de archivo
Centros hacia el archivo de Cali, carga de los históricos de temperatura	Se conserva temporalmente	FW-402 para los centros que ya pasaron a la conexión directa	Cuando la telemetría en línea reemplaza la carga por lote
Zabbix (`10.20.3.0/24`) hacia los servidores y equipos de Cali	Se conserva	Sin cambios: Zabbix vigila lo que queda en Cali	El día 61, cuando se apaga Zabbix (`observabilidad-slo-zabbix.md`, sección 8)
Administración de VMware (`10.20.4.0/24`)	Se conserva	Sin cambios	Al apagar los clústeres de VMware
Usuarios de Cali hacia internet	Se conserva	Sin cambios	No se retira
Entre ambientes del mismo clúster (desarrollo, pruebas y producción comparten hoy el clúster)	Se reemplaza por un aislamiento más estricto	Cada ambiente en su propia red, sin reglas entre ellos (FW-999)	Al apagar el clúster de aplicación

5.4 Reglas que se agregan en el firewall de Cali

Para que la convivencia funcione, el firewall de Cali también necesita reglas nuevas. Son la contraparte de las reglas de Azure: si un lado permite y el otro no, la conexión no se establece.

Origen	Destino	Puerto	Vigencia	Contraparte en Azure
Usuarios de Cali (`10.20.0.0/24`)	Torre en Azure (`10.101.1.0/25`, `10.102.1.0/25` y `10.103.1.0/25`)	TCP 443	Estable	FW-201 a FW-203
DNS de Cali	Resolver DNS del hub (`10.100.1.0/28`)	UDP y TCP 53	Estable	NSG del resolver
Resolver DNS del hub (`10.100.1.16/28`)	DNS de Cali	UDP y TCP 53	Estable	NSG del resolver
Servicio de migración (`10.101.2.160/27`)	Base de datos de Cali (`10.20.2.0/24`)	TCP 3306	Temporal, hasta el corte	FW-501
Servidores de aplicación de Cali (`10.20.1.0/24`)	Integración con Cali (`10.101.2.160/27`), y en sentido contrario	TCP 443	Temporal, hasta el cierre del plazo de vuelta atrás	FW-503 y FW-504
Agente de copia continua en la red del archivo de Cali (`10.20.3.0/24`)	Archivo en Azure (`10.101.2.64/27`)	TCP 443	Temporal, hasta terminar la copia continua	NSG de `snet-archive`
Centros que todavía entran por Cali	Torre en Azure	TCP 443	Temporal, hasta que cada centro pasa a la conexión directa	FW-201

5.5 Orden de apagado

Orden	Momento	Qué se apaga o se retira	Dónde
1	En el corte	Replicación de la base hacia Azure: FW-501, FW-502 y su pareja en el NSG de `snet-data`. La cuenta de almacenamiento y su token	Azure y Cali
2	En el corte	El portal deja de publicarse desde Cali: el DNS público apunta al Application Gateway. El NAT y el firewall de aplicaciones quedan configurados, sin tráfico	Cali
3	Cuando cada centro deja la carga por lote	La regla de FTP de ese centro (FW-402)	Azure
4	Al terminar la copia continua del archivo	La regla temporal del NSG de `snet-archive`	Azure y Cali
5	Al cerrar el plazo de vuelta atrás	El NAT del portal y el firewall de aplicaciones. Los grupos temporales del Azure Firewall (400 y 500) completos. Las reglas temporales de los NSG. Las VPN de los centros hacia Cali	Azure y Cali
6	Al apagar cada servidor de Cali	Las políticas que lo protegían	Cali
7	Día 90 a más tardar	Revisión final: se quitan de `firewall-policy.csv` las reglas temporales, se vuelve a correr el verificador y su reporte no debe listar ninguna. `snet-cali-integration` se elimina o queda vacía	Azure

Después del paso 7, la tabla de políticas tiene solo reglas estables, y el firewall de Cali solo protege la red de la sede.

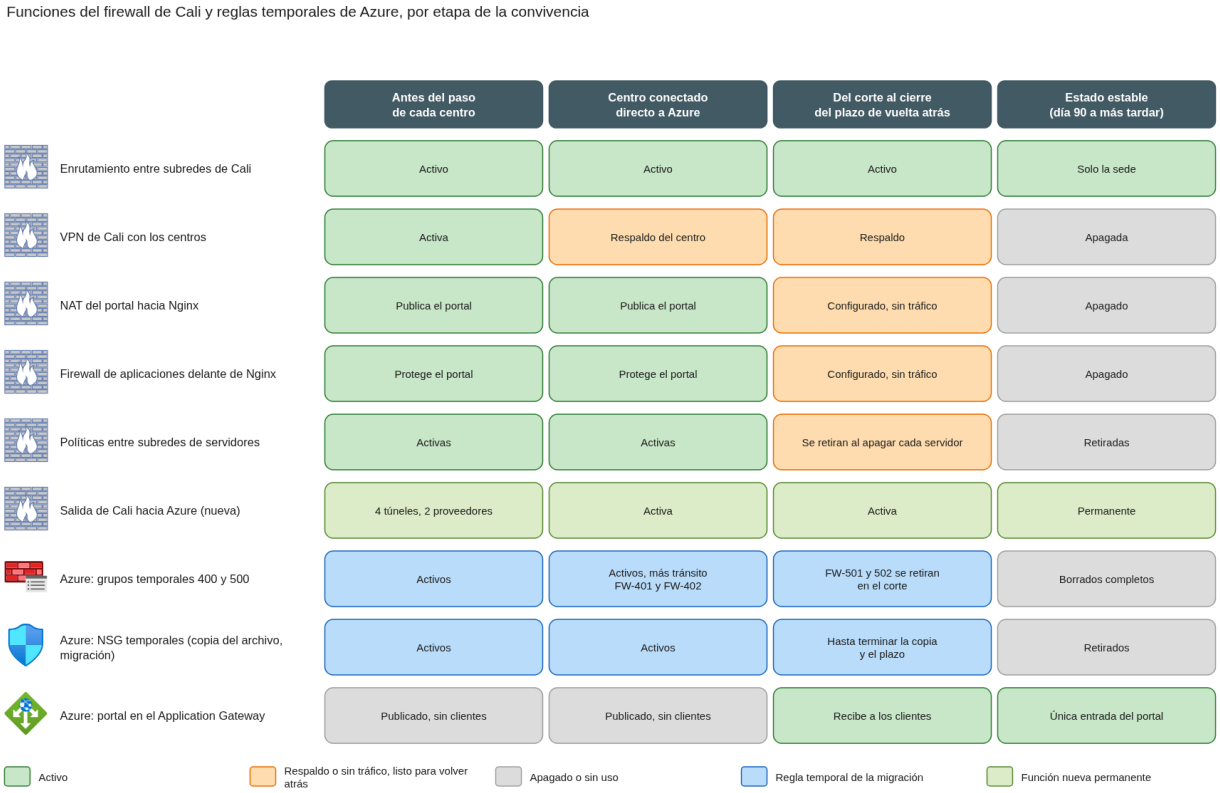


Figura 13: Estado de cada función del firewall de Cali y de las reglas temporales de Azure en cada etapa de la convivencia

---

6. Registro y detección de actividad anómala

El perímetro público tiene que estar protegido y la actividad anómala, detectada. Esta sección define qué registra cada pieza del diseño, qué alertas se generan y a dónde van. La retención de los registros la fija el diseño de auditoría y retención, y la operación diaria de las alertas, el diseño de observabilidad (`observabilidad-slo-zabbix.md`, sección 6).

6.1 Qué se registra

Todos los registros van al espacio de Log Analytics de la plataforma, en tablas propias de cada servicio (modo de recurso específico). Microsoft recomienda ese modo porque las consultas son más simples, se pueden dar permisos por tabla y, en el caso del firewall, el costo de registro puede bajar hasta un 80 %.

Fuente	Qué guarda	Para qué sirve
Azure Firewall: reglas de red y de aplicación	Cada conexión permitida o rechazada, con origen, destino, puerto y la regla que decidió	Reconstruir quién habló con quién entre las sedes, los ambientes e internet
Azure Firewall: inteligencia de amenazas	Cada conexión hacia o desde una IP o dominio malicioso conocido, y la acción tomada	Detectar equipos comprometidos o intentos de contacto con infraestructura maliciosa
Application Gateway: acceso	Cada solicitud al portal, con la IP del cliente, la ruta, el código de respuesta y el tiempo	Disponibilidad del portal y análisis del abuso
Application Gateway: WAF	Cada solicitud que activó una regla del WAF, con la IP del cliente, la regla y la acción	Ver qué ataques se bloquearon y ajustar falsos positivos

Fuente	Qué guarda	Para qué sirve
DDoS IP Protection	Métricas, alertas e informes de cada mitigación sobre la IP del portal	Saber cuándo hubo un ataque de red y qué se mitigó
Registros de flujo de red virtual	Cada flujo que atraviesa la red del hub y la de producción, con la decisión del NSG que lo evaluó	Auditar los flujos controlados por NSG, incluida la copia del archivo
Registro de actividad de Azure	Cada cambio en la política del firewall, los NSG, las rutas y el WAF, con quién lo hizo	Saber quién cambió una regla y cuándo

Registros de flujo de red virtual. Microsoft ya no permite crear registros de flujo de NSG (se retiran en septiembre de 2027) y los reemplaza por registros de flujo de red virtual. Se activan en la red del hub y en la de producción. Tienen dos límites que el diseño considera:

- No registran el tráfico en el endpoint privado, solo en el origen. Para la copia del archivo, el origen está en Cali. El registro queda en la red del hub, porque los registros de flujo incluyen el tráfico que atraviesa el VPN Gateway. A eso se suman los registros del firewall de Cali.
- No cubren Container Apps, MySQL ni el resolver DNS. Para esos servicios, el registro de la conexión lo dan el Azure Firewall (cuando cruza el hub) y los registros propios de cada servicio.

6.2 Alertas

Alerta	Condición	Por qué importa
Destino malicioso	Cualquier evento de inteligencia de amenazas en el firewall	Un equipo de la red intenta hablar con infraestructura maliciosa conocida
Rechazos fuera de lo normal	Aumento de conexiones rechazadas por el firewall desde un mismo origen	Barrido de puertos, equipo mal configurado o intento de moverse entre zonas
Ataques al portal	Aumento de solicitudes bloqueadas por el WAF	Ataque en curso contra el portal
Ataque de denegación de servicio	Inicio de una mitigación de DDoS IP Protection	El portal está bajo ataque de red
Capacidad del portal	Unidades de capacidad del Application Gateway por encima del 75 % de lo habitual	El portal se acerca a su límite reservado
Certificado del portal	Pérdida de acceso del Application Gateway al Key Vault	Azure deshabilita el listener y el portal deja de responder
Salud del firewall	Estado degradado o no disponible, o métricas que dejan de llegar	Sin firewall, las sedes pierden la plataforma y los ambientes, la salida a internet
Cambio en reglas	Cualquier cambio en la política del firewall, los NSG o el WAF. Operación lo contrasta con los cambios aprobados	Detectar un cambio no autorizado en la seguridad de la red

Las alertas de seguridad van al equipo de operación, con los niveles y canales del diseño de observabilidad (`observabilidad-slo-zabbix.md`, sección 6.4). La detección de comportamientos anómalos en el uso del portal (por ejemplo, un cliente que consulta guías ajenas) y los planes de Defender for Cloud están en el diseño de datos personales y perímetro (`seguridad-datos-personales-perimetro.md`, sección 5), sobre estos mismos registros.

6.3 Costo de los registros

Concepto	Precio en East US 2
Ingesta en Log Analytics, plan Analytics	Primeros 5 GB al mes sin costo, luego USD 2,76 por GB

Concepto	Precio en East US 2
Registros de flujo de red virtual	Primeros 5 GB al mes por suscripción sin costo, luego USD 0,50 por GB, más el almacenamiento

El volumen depende del tráfico real y se mide en el primer mes. Para bajar el costo, las tablas del firewall de mayor volumen (reglas de red y de aplicación permitidas) pueden pasar al plan Basic de Log Analytics, que Microsoft estima hasta 80 % más barato. A cambio, esas tablas quedan fuera del análisis de políticas del firewall. Las tablas de inteligencia de amenazas y del WAF se quedan en el plan Analytics porque alimentan las alertas. Azure permite cambiar el plan de una tabla una vez cada siete días. Traffic Analytics, el análisis visual de los registros de flujo (de USD 2,30 a 3,50 por GB procesado), no se activa al inicio: los registros quedan guardados y se puede activar después si operación lo necesita.

---

7. Costo

Precios de lista en East US 2, en dólares, con 730 horas al mes. El Azure Firewall y su procesamiento ya están en el costo de la red y no se suman de nuevo.

7.1 Costo mensual de este diseño

Componente	Cálculo	USD al mes	Ya incluido en el costo de la red
Azure Firewall Standard	1,25 × 730	912,50	Sí
Procesamiento del firewall	USD 0,016 por GB	Según tráfico	Sí
Application Gateway WAF v2, producción	0,36 × 730 fijo + 20 unidades reservadas × 0,0144 × 730	473,04	No
Application Gateway WAF v2, pruebas	0,36 × 730 fijo + unas 1 unidad de uso	273,31	No
Application Gateway Standard v2, desarrollo	0,20 × 730 fijo + unas 1 unidad × 0,008 × 730	151,84	No
IP públicas de los tres Application Gateway	3 × 0,005 × 730	10,95	No
DDoS IP Protection, IP del portal de producción	0,2726 × 730	199,00	No
Registros (sección 6.3)	Según volumen	Se mide en el primer mes	No
Total nuevo de este diseño		**1.108,14 más los registros**	

Mes de campaña. El pico de campaña necesita unas 18 unidades de capacidad y producción tiene 20 reservadas, así que el Application Gateway no cuesta más en campaña. El mayor tráfico del portal se paga como transferencia de salida a internet, que está en el costo de la red.

7.2 Decisiones que bajan o evitan gasto

Decisión	Alternativa descartada	Ahorro al mes
DDoS IP Protection solo para la IP del portal	DDoS Network Protection	USD 2.744,55 (2.943,55 - 199,00)
Azure Firewall Standard, con subida a Premium sin corte si se necesita	Premium desde el inicio	USD 365,00
Application Gateway como única entrada del portal	Front Door Premium delante del Application Gateway	Al menos USD 330, la tarifa base de Front Door, más sus cargos por solicitud y transferencia

Decisión	Alternativa descartada	Ahorro al mes
Pruebas y desarrollo con autoescalado desde 0 instancias	Una instancia reservada en cada uno	USD 210,24 (2 × 10 unidades × 0,0144 × 730, a tarifa WAF)
Desarrollo sin WAF	WAF v2 en desarrollo	USD 116,80 en el costo fijo (0,16 × 730)
Firewall y Application Gateway en paralelo	Application Gateway delante del firewall	USD 16 por cada 1.000 GB de tráfico del portal que el firewall no procesa

A esto se suma la decisión del diseño de red de llevar la copia del archivo fuera del firewall, que evita unos USD 194 al mes durante la convivencia.

---

8. Supuestos y confirmaciones pendientes de FríoAndes

8.1 Confirmaciones que necesita el diseño

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
Plazo de vuelta atrás	¿Cuánto tiempo después del corte debe ser posible volver a Cali?	El diseño lo limita al día 90. Un plazo más corto adelanta el retiro de las reglas temporales, del NAT del portal y de la VPN de los centros hacia Cali (sección 5)
Política actual del firewall de Cali	¿Pueden exportar la política real del firewall de Cali antes del inicio de la convivencia?	Las políticas de la sección 5.3 son deducidas del inventario. La exportación permite conciliarlas regla por regla y agregar a la tabla lo que falte
Carga de los históricos de temperatura	¿Qué equipo de cada centro envía los archivos de cada hora, por qué protocolo y con qué rango de puertos pasivos?	Cambian el origen y los puertos de FW-402
Integración entre Cali y Azure durante la convivencia	¿Qué puertos necesita la integración entre los servidores de Cali y la plataforma nueva, además de HTTPS?	Se agregan reglas temporales a los grupos 400 y 500
Direcciones fijas	¿Cuáles son las IP públicas de los dos proveedores de Cali y la IP de los servidores DNS de Cali?	Se completan el NSG de entrada de pruebas y desarrollo, y los NSG del resolver DNS
Servicios externos	¿Qué servicios externos usa la aplicación (correo, SMS u otros) y con qué dominios?	Cada dominio se agrega a FW-305, 311 y 317 con su propio cambio
Envío de los camiones	¿Los camiones envían directo a la nube o la plataforma del operador de flota reenvía los datos desde direcciones fijas?	Si es la plataforma del operador, el endpoint público de IoT Hub se limita a sus direcciones

8.2 Supuestos del diseño

Supuesto	Por qué se asume
La respuesta media del portal pesa unos 150 KB (página de rastreo, consulta y mapa)	Define la capacidad del Application Gateway, que en este caso se mide por volumen de datos. Se confirma con la prueba de carga antes del corte

Supuesto	Por qué se asume
Cada unidad de cómputo del WAF atiende unas 10 solicitudes por segundo	Es la referencia de Microsoft para WAF v2. Depende del tamaño de las solicitudes y se confirma con la prueba de carga
Cada usuario interno genera unos 300 Kbps hacia la plataforma	El mismo valor del diseño de red. Se usa para comparar el tráfico del firewall con los límites de cada versión
El equipo que prueba la torre en pruebas y desarrollo trabaja desde Cali o con el acceso remoto definido para FríoAndes	Por eso solo los usuarios de Cali llegan a la torre de esos ambientes
Pruebas y desarrollo usan datos de sensores simulados	No se llevan datos reales a ambientes con menos controles
Los centros envían los históricos de temperatura por FTP pasivo al servidor de archivo de Cali	Hoy se cargan por lote cada hora, y ese servidor ofrece FTP y NFS
Las políticas actuales del firewall de Cali son las deducidas en la sección 5.3	La política real no está documentada
El portal se dimensiona sin campañas de más de 2.000 solicitudes por minuto	Es el pico de campaña previsto. Con más tráfico, el autoescalado agrega instancias hasta 10 sin cambiar la red
Los costos son precios de lista en East US 2, con 730 horas al mes, sin descuentos ni reservas	Es la base común del cálculo de costos de la plataforma
El volumen de registros se mide en el primer mes de operación	No hay tráfico real para estimarlo. El plan de cada tabla se ajusta con ese dato
La plataforma de contenedores es Container Apps con perfiles de carga	Lo mismo que el diseño de red. Si fuera AKS, aplican las secciones 3.9 y 4.8

Acceso remoto administrativo y preparación para una segunda nube

1. Decisión y alcance

Se adopta **Azure Bastion Standard en el hub de conectividad**, con autenticación corporativa de Microsoft Entra ID, MFA, acceso condicional y permisos sobre máquinas de administración específicas. Las personas remotas administran la infraestructura que les corresponde sin incorporar sus equipos domésticos a la red de despacho.

La torre de control conserva su acceso desde las redes corporativas autorizadas de Cali y los centros, con los roles funcionales definidos para la aplicación. Tener un rol de administrador de infraestructura, acceso a Bastion o una sesión en una máquina de operación no autoriza a utilizar la consola de despacho.

Para la segunda nube se reutilizarán el hub, la estrategia de Azure DNS Private Resolver y el tenant corporativo de Entra ID. Se conserva la reserva de direcciones de #8. El proveedor y las cargas que se llevarán a esa nube se decidirán cuando exista una necesidad aprobada.

1.1 Relación con las decisiones existentes

Referencia	Base que aporta	Decisión de este documento
#5 — Landing zone, documento	Tenant corporativo; suscripciones de conectividad, seguridad, producción, pruebas y desarrollo; grupos y etiquetas	Bastion y DNS pertenecen a `sub-fa-connectivity`; las máquinas administrativas a su ambiente; los registros se centralizan en `sub-fa-security`
#8 — Red híbrida, documento, secciones 4 y 5	Hub y spokes, Bastion, subredes administrativas, DNS y reservas	Confirma Bastion como mecanismo inicial y conserva los rangos de `red/data/ip-plan.csv`
#7 — IAM, documento	Grupos, mínimo privilegio, MFA, separación de roles de aplicación y Azure RBAC	Aplica esos controles al acceso remoto y a la futura federación

Referencia	Base que aporta	Decisión de este documento
#9 — Firewall, documento	Reglas de Bastion, DNS, torre y salida de administración	Conserva sus puntos de control y concreta los bloqueos de movimiento lateral
#6 — Auditoría, documento	Registro central, responsabilidades y retención	Añade las fuentes y evidencias del acceso remoto sin crear otro destino de auditoría

Las dependencias directas de #11 son #5 y #8; las demás referencias coordinan identidad, controles y auditoría.

2. Acceso remoto administrativo

2.1 Por qué Bastion

Alternativa	Evaluación para FríoAndes
Azure Bastion	Elegida: ya está prevista en #8 y permite sesiones SSH/RDP a máquinas privadas concretas. El equipo remoto no obtiene una conexión general a las redes de los ambientes
VPN punto a sitio con Entra ID	Se conserva como alternativa futura si hacen falta herramientas locales con conectividad IP privada. Exigiría definir grupos, rutas, DNS y reglas adicionales; la VPN por sí sola no separa administración y despacho

Se propone Standard para disponer de escalado y opciones de cliente nativo cuando sean necesarias. El camino inicial preferente es SSH desde el navegador a una máquina Linux de administración compatible con inicio de sesión Entra. Bastion no es un escritorio ni administra directamente MySQL, Container Apps o Key Vault: proporciona acceso a la máquina desde la que se ejecutan herramientas autorizadas. La gestión por Azure Portal o API de Azure Resource Manager utiliza su propio control de acceso. [T1][T2]

No se activa VPN punto a sitio el día uno. El bloque `10.100.8.0/22` continúa reservado. Una eventual VPN de contingencia para despacho requiere una decisión expresa sobre qué considera FríoAndes red corporativa y una revisión de #7, #8 y #9; no queda autorizada por este documento.

2.2 Ubicación y direcciones

Los rangos siguientes proceden de `red/data/ip-plan.csv`; no se asignan bloques nuevos.

Elemento	Ubicación	Rango
Hub compartido	`sub-fa-connectivity`, East US 2, `vnet-hub`	`10.100.0.0/23`
Bastion	`AzureBastionSubnet` del hub	`10.100.0.192/26`
Administración de producción	`sub-fa-prod`, `snet-admin`	`10.101.2.128/27`
Administración de pruebas	`sub-fa-test`, `snet-admin`	`10.102.2.128/27`
Administración de desarrollo	`sub-fa-dev`, `snet-admin`	`10.103.2.128/27`
Torre de producción	`snet-app-torre`	`10.101.1.0/25`
Torre de pruebas y desarrollo	`snet-app-torre` de cada ambiente	`10.102.1.0/25` y `10.103.1.0/25`

Bastion se conecta a las máquinas de los spokes mediante el peering previsto en #8. Las máquinas no reciben IP pública. Las sesiones de usuarios entran a Bastion por HTTPS; SSH/RDP se habilita únicamente entre Bastion y los destinos administrativos autorizados. Se preservan además las comunicaciones de plataforma que requiere el servicio. [T1][T3]

2.3 Secuencia de acceso y Zero Trust

1. La persona usa una cuenta corporativa individual desde un equipo gestionado. Entra ID evalúa MFA y la política de acceso condicional: grupo autorizado y dispositivo conforme. Seguridad valida las licencias y la integración de gestión de dispositivos antes de habilitar el acceso.

2. El usuario accede al recurso permitido en Azure. Los roles se asignan por máquina o grupo de recursos administrativo, sin conceder lectura ni administración de toda producción para poder usar Bastion.
3. Para la sesión en el sistema operativo se configura también el inicio de sesión Entra de la VM. Iniciar sesión en Azure Portal no sustituye la autenticación en la máquina.
4. La persona recibe acceso de usuario normal. Si necesita privilegios, solicita elevación temporal con PIM, justificación y aprobación para producción, conforme a #7.
5. Ejecuta únicamente las acciones y conexiones permitidas. La red restringe destinos y puertos; el servicio de destino vuelve a comprobar la identidad y sus permisos.
6. El cierre de sesión, la baja del usuario o un incidente activan la retirada de accesos. Ante un incidente también se terminan las sesiones activas: retirar un grupo no garantiza cortar inmediatamente una sesión ya abierta.

Zero Trust se concreta en comprobar identidad, equipo, privilegio y destino, sin confiar en una conexión solo porque procede de una máquina interna.

Para las VM se asignan los roles `Virtual Machine User Login` o, temporalmente, `Virtual Machine Administrator Login`, más las lecturas de VM, NIC, Bastion y VNet que requiera la conexión. Las extensiones de inicio de sesión y el sistema operativo deben ser compatibles. El acceso RDP con Entra desde el navegador figura en vista previa en la documentación consultada; no es una dependencia de la solución inicial. Si se necesitan máquinas Windows, se valida el camino de cliente nativo compatible con MFA antes de incorporarlas. [T2]

La configuración inicial mantiene deshabilitados los enlaces compartibles, la conexión por IP arbitraria y el soporte de cliente nativo mientras no exista una necesidad aprobada. Las sesiones SSH no permiten reenvío de puertos ni de agente. Una futura habilitación del cliente nativo no amplía destinos ni permisos.

2.4 Quién puede entrar

Perfil de #5 y #7	Acceso administrativo remoto	Límite
`grp-fa-dev`	Máquina de administración de desarrollo y recursos de sus RG autorizados	Sin acceso a máquinas o datos de producción
`grp-fa-qa`	Máquina de pruebas cuando la función lo requiera	Datos sintéticos o anonimizados; sin acceso a producción
`grp-fa-ops-prod`	Máquinas de operación de producción aprobadas	Elevación temporal para acciones privilegiadas; sin uso de la torre por este permiso
`grp-fa-network`	Administración de conectividad según sus roles; sesión en VM solo si se asigna expresamente	No adquiere permisos sobre bases, secretos o funciones de despacho
Seguridad y auditoría	Lectura de registros según #6 y #7	Sin sesión administrativa en VM por defecto
Despachadores y clientes	Ninguno por su rol funcional	El despacho usa el acceso corporativo existente; el cliente utiliza su portal

Las máquinas interactivas y los ejecutores de despliegue deben ser recursos distintos, aunque compartan `snet-admin`. No se entrega una sesión humana en un ejecutor que pueda obtener credenciales del pipeline. Una identidad administrada con privilegios en una VM sería utilizable por procesos de esa VM; por eso las máquinas interactivas no llevan una identidad de despliegue privilegiada.

3. Cómo se mantiene aislada la torre

3.1 Controles por recorrido

Recorrido	Decisión	Control
Equipo remoto → Bastion	Permitir la sesión autorizada por HTTPS	Entra, MFA, acceso condicional y Azure RBAC

Recorrido	Decisión	Control
Bastion → VM de `snet-admin`	Permitir SSH 22 o RDP 3389 según la VM	NSG y permisos de inicio de sesión; reglas `NSG-prod-08`, `NSG-test-08` y `NSG-dev-08` de #9
Bastion → torre u otras VM no administrativas	Denegar	Destinos restringidos en red y ausencia de permisos de sesión
Máquina administrativa → torre, en cualquier ambiente	Denegar	NSG de origen y destino; firewall cuando el recorrido atraviese el hub
Máquina administrativa → otro ambiente o redes de usuarios de Cali y centros	Denegar por defecto	NSG y reglas del firewall; sin proxy ni salto por una máquina corporativa
Máquina administrativa → herramientas de gestión, repositorios y actualizaciones	Permitir únicamente destinos aprobados	Salida por Azure Firewall; base en `FW-306`, `FW-312` y `FW-318`
Máquina administrativa → datos del mismo ambiente	Solo una operación autorizada y con identidad propia	NSG del servicio y permisos del motor; no equivale a acceso general a datos
Usuario corporativo autorizado → torre	Mantener el flujo de #8 y #9	VPN sitio a sitio, firewall, NSG y autorización de aplicación

En #9, `NSG-*-03` ya contempla acceso desde administración a MySQL del mismo ambiente. La existencia de ese permiso de red no concede una cuenta de base de datos. Los accesos humanos a datos productivos necesitan una autorización específica y auditoría; los desarrolladores no heredan credenciales de producción.

3.2 Reglas que deben comprobarse en la implementación

- Mantener la denegación final de entrada de `NSG-*-99` con prioridad anterior a las reglas predeterminadas permisivas. No se añade `snet-admin` a los orígenes permitidos de la torre.
- Añadir a los NSG administrativos una denegación de salida explícita hacia los tres rangos de la torre y las redes corporativas de usuarios. Enumerar las excepciones administrativas antes del cierre general, con destino y puerto concretos.
- No asumir que el firewall del hub ve todo el tráfico de una VNet. Una ruta entre subredes del mismo ambiente puede ser directa; el NSG y la autorización del destino son necesarios.
- Restringir Bastion a las VM administrativas, preservando las reglas de funcionamiento del servicio. El flujo Bastion–VM se controla con NSG y no se fuerza a atravesar el firewall del hub. [T3]
- Deshabilitar reenvío IP, proxies y túneles en las máquinas interactivas. No otorgar a sus usuarios permisos para modificar NSG, rutas, NIC o la identidad de esas máquinas.
- Separar administración de infraestructura y roles de despacho. También se restringen operaciones como ejecución remota de comandos, acceso a consolas de contenedores o recuperación de credenciales cuando permitan saltarse la separación funcional.

Un administrador con capacidad para cambiar la red puede alterar sus controles. Ese privilegio debe ser excepcional, temporal, aprobado y auditado; no se presenta como una garantía absoluta frente al administrador más privilegiado.

Las denegaciones de salida y el endurecimiento anterior son requisitos de #11 que deben incorporarse a la implementación y conciliarse con `red/data/firewall-policy.csv`. Este documento no afirma que esas filas adicionales ya existan en la tabla de #9.

3.3 Registros y continuidad

Se envían los diagnósticos de Bastion y los eventos de administración al espacio Log Analytics central de `sub-fa-security`, el mismo destino lógico de #6 y #9. Se correlacionan con inicios de sesión de Entra, activaciones PIM, eventos del sistema operativo, cambios de red y accesos al servicio de destino. La retención sigue #6; no se crea otra política independiente.

Los registros de conexión no equivalen a una grabación completa de pantalla o de todos los comandos. Si se exige grabación de sesiones, se evaluarán las capacidades, compatibilidades y costos de Bastion Premium antes de comprometer esa evidencia.

Ante la indisponibilidad de Bastion no se abren SSH/RDP públicos ni la torre. Se recupera el servicio; el trabajo de despacho continúa por sus conexiones corporativas existentes mientras estas estén disponibles. Bastion no sustituye el plan de continuidad regional ni resuelve una caída del firewall de Cali.

4. Punto de interconexión con la segunda nube

El punto único **lógico** será `vnet-hub` en `sub-fa-connectivity`. La segunda nube se conectará al hub, sin crear túneles individuales a cada ambiente ni usar la sede de Cali como tránsito obligatorio.

Como opción inicial para ese momento se propone VPN sitio a sitio con IPsec/IKEv2 y BGP sobre el VPN Gateway de #8, con enlaces redundantes compatibles en ambos extremos. La redundancia física no contradice un punto lógico común. Un enlace dedicado, una NVA o Virtual WAN se evaluarán si el tráfico, la latencia o las restricciones del proveedor lo justifican.

Reserva de #8	Uso futuro
`10.110.0.0/15`	Bloque de segunda nube: `10.110.0.0/16` para tránsito y `10.111.0.0/16` para cargas; subdivisión detallada cuando se elija proveedor
`10.100.1.128/25`	Espacio disponible del hub para una NVA, si resulta necesaria
`10.100.4.0/22`	Reserva para una futura topología Virtual WAN
`10.104.0.0/15`	Recuperación en otra región de Azure; es una reserva distinta de la segunda nube

La interconexión exigirá validar los prefijos reales de ambas nubes, filtrar anuncios BGP, evitar rutas por defecto no aprobadas y verificar el retorno simétrico a través de los controles previstos. El tráfico de las cargas entre nubes deberá pasar por el firewall del hub con permisos específicos; el DNS tendrá su recorrido controlado según la sección siguiente. No se habilita tránsito libre hacia Cali, los centros o todos los ambientes.

La capacidad disponible se revisará contando conexiones, túneles, ancho de banda y fallos simultáneos según el SKU vigente. Que el diseño de #8 contemple una conexión adicional no prueba por sí solo que tenga capacidad para cualquier segunda nube. Antes de incorporarla se medirán latencia y transferencia con sus cargas reales.

5. DNS híbrido reutilizable

Se utiliza Azure DNS Private Resolver en el hub, con las subredes exclusivas de #8, delegadas a `Microsoft.Network/dnsResolvers`. Los prefijos identifican subredes; en los reenviadores se configurará la IP privada concreta del endpoint, no el CIDR. [T4]

Elemento	Rango	Función
`snet-dns-inbound`	`10.100.1.0/28`	Recibir consultas de redes autorizadas sobre nombres privados de Azure
`snet-dns-outbound`	`10.100.1.16/28`	Reenviar consultas de dominios externos a Azure hacia sus servidores DNS

Las zonas privadas de Azure se vinculan al hub. Para esta propuesta, las VNet de los ambientes usan como DNS personalizado la IP del endpoint inbound. El conjunto de reglas de reenvío se vincula al hub para resolver los dominios de Cali y, en el futuro, los de la segunda nube. La IP asignada al inbound se registra en IaC; su recreación exige comprobar los clientes y reenviadores que la utilizan. [T4][T5]

Consulta	Recorrido previsto
Cali o centros → nombre privado de Azure	DNS corporativo autorizado → VPN → endpoint inbound → zona privada vinculada al hub
Ambiente de Azure → nombre privado de Azure	DNS configurado en la VNet → endpoint inbound → zona privada

Consulta	Recorrido previsto
Ambiente de Azure → dominio interno de Cali	Resolver del hub → regla para el dominio de Cali → endpoint outbound → DNS corporativo
Segunda nube → nombre privado de Azure, cuando se incorpore	Reenviador DNS de la segunda nube → interconexión privada → endpoint inbound
Azure → nombre privado de la segunda nube, cuando se incorpore	Regla específica del dominio de esa nube → endpoint outbound → endpoint DNS remoto

Se permiten UDP y TCP 53 únicamente para los servidores y orígenes acordados. La base actual son `NSG-hub-01` y `NSG-hub-02`; se completan las IP de los DNS de Cali y se agregan los futuros endpoints remotos cuando existan. Los centros usan el DNS corporativo autorizado; un DNS propio de un centro necesitará una entrada expresa en esa lista.

Cada dominio mantiene una autoridad definida. No se crean reglas que reenvíen una consulta de vuelta al resolver que la originó, ni se vincula al hub una regla para sus propias zonas apuntando a su mismo inbound. Se prueba tanto la resolución correcta como la ausencia de bucles. Resolver un nombre no concede permiso de conexión al servicio. [T5]

6. Identidad federada para la segunda nube

El tenant corporativo de Microsoft Entra ID de #5 sigue siendo la fuente de identidad de las personas. Al seleccionar otra nube se configura su integración de federación admitida —por ejemplo, SAML u OIDC según el servicio— y se mapean grupos corporativos a roles locales de esa nube. Entra autentica; el proveedor de destino autoriza las acciones con su propio modelo de IAM. [T6]

No se presume que Azure RBAC o PIM administren automáticamente los permisos de otro proveedor. Se deberá diseñar el equivalente de roles, duración de sesión, elevación, revocación y cuentas de emergencia en la nube elegida. La desactivación de una persona debe retirar el acceso federado y los permisos o sesiones locales que correspondan.

Las identidades de aplicaciones se mantienen separadas por carga y ambiente. Para automatizaciones se evaluará federación de identidad de cargas de trabajo con tokens de corta duración donde exista soporte. No se copiarán secretos de producción ni se supondrá que una identidad administrada de Azure tiene permisos automáticos fuera de Azure.

7. Qué existe el día uno y qué se difiere

Día uno de la solución	Incorporación futura, sujeta a diseño y aprobación
Un tenant corporativo y grupos con permisos por ambiente	Federación con el IAM de la nube seleccionada y mapeo de roles
Un Bastion compartido y máquinas administrativas necesarias por ambiente	Otro mecanismo remoto solo si lo exige una necesidad validada
Hub, VPN de las sedes y firewall definidos en #8 y #9	Enlaces redundantes hacia la segunda nube y reglas por flujo
DNS Private Resolver para las necesidades actuales de Cali y Azure	Endpoints DNS y reglas para los dominios privados de la segunda nube
Reservas IP y convenciones comunes	Subredes concretas del proveedor elegido y su verificación de no solapamiento
Auditoría y etiquetas integradas con #5 y #6	Exportación de los eventos de la nueva nube y clasificación de sus costos

No se duplican el día uno las aplicaciones de despacho o rastreo, las bases de datos, Redis, el archivo de 1,2 PB, la ingesta de telemetría ni las capacidades de Fabric en otra nube. Tampoco se contratan enlaces a un proveedor todavía no seleccionado, se crea un segundo directorio corporativo ni se despliegan anticipadamente una NVA o Virtual WAN. Reservar direcciones no crea recursos ni replica datos.

La segunda nube no se presenta como recuperación ante desastres automática. La continuidad entre regiones de Azure tiene su propio alcance; si una carga exige recuperación entre proveedores, deberá definir replicación, RPO, RTO y pruebas adicionales.

7.1 Capacidad y costos que deben presupuestarse

La estimación consolidada debe contar Bastion Standard, sus unidades y horas, las VM administrativas y discos, transferencia, DNS Private Resolver, registros y las licencias necesarias para acceso condicional, gestión de dispositivos y PIM. Se reutilizan los componentes ya presupuestados en #8 para evitar cobrarlos dos veces.

No se presenta un precio mensual sin el número de administradores simultáneos, tamaños y horarios de VM, volumen de registros y licencias disponibles. La segunda nube agregará en su momento enlaces, transferencia de salida, DNS y recursos del proveedor. Esos conceptos quedan identificados, pero no como gasto contratado ni como una plataforma duplicada desde el inicio.

8. Verificación de aceptación

La revisión documental contrasta los rangos y las reglas citadas con #8 y #9. Los escenarios siguientes son pruebas de implementación pendientes, no resultados obtenidos en Azure.

Prueba	Resultado esperado	Evidencia
Desarrollador autorizado desde equipo conforme y con MFA	Sesión en su VM de desarrollo	Inicio de sesión Entra, evento Bastion y evento de VM
Usuario sin MFA, fuera del grupo o con equipo no conforme	Acceso rechazado	Resultado de acceso condicional y autorización
Desarrollador intenta acceder a VM de producción	Acceso rechazado	Permisos efectivos y registro del intento
Usuario tiene lectura del recurso, pero no permiso de inicio de sesión en VM	No obtiene sesión en el sistema operativo	Prueba de autorización de VM
Desde la VM administrativa se intenta HTTPS a la torre y un salto por una máquina corporativa	Ambos caminos bloqueados	Pruebas de conectividad y reglas efectivas de NSG; firewall si atraviesa el hub
Usuario con rol de despacho intenta usar la torre desde fuera de las redes corporativas	Bloqueado por red aunque su rol funcional sea válido	Prueba externa y control de origen
Despachador autorizado desde una sede corporativa	Torre accesible sin alteración de su recorrido	Prueba funcional desde Cali o centro
Operador solicita elevación y termina su intervención	Activación aprobada, limitada y registrada	Eventos PIM y de la operación
Máquina administrativa intenta usar identidad de despliegue o secretos ajenos	Acceso rechazado	Inventario de identidades y permisos del servicio
Consultas DNS entre Cali y Azure, incluida una inexistente	Respuestas privadas correctas o error esperado, sin bucles	Consultas a DNS y configuración de reenvío
Retirada de un usuario o incidente	Nuevos accesos denegados y sesiones terminadas según procedimiento	Prueba de baja y cierre de sesión
Revisión del alcance de segunda nube	Reservas conservadas y ausencia de duplicación anticipada	Inventario y plan IaC

Antes de activar la segunda nube se añadirán pruebas de no solapamiento, filtrado BGP, caída de cada túnel, retorno por el firewall, DNS bidireccional, SSO, revocación y aislamiento entre ambientes.

Criterio de #11	Evidencia de diseño
Mecanismo remoto identificado y justificado, con protección de despacho	Secciones 2 y 3: Bastion, Entra, mínimo privilegio y bloqueos explícitos; pruebas en sección 8
Interconexión, DNS e identidad reutilizables, sin duplicación el día uno	Secciones 4, 5, 6 y 7

9. Datos que se confirman antes del despliegue

Dato pendiente	Responsable propuesto	Qué condiciona
Administradores simultáneos, herramientas y sistemas operativos	Plataforma y operaciones	Tamaño de Bastion y VM; necesidad de cliente nativo o Windows
Licencias de Entra/PIM y dispositivos gestionados	Identidad y seguridad	Aplicación efectiva de MFA, acceso condicional y elevación
Inventario de máquinas administrativas y ejecutores	Plataforma	Separación de sesiones humanas, identidades y destinos
IP y dominios del DNS corporativo, incluida su continuidad tras migrar Cali	Redes	Reenvío DNS y reglas concretas
Nombre o ID exacto del Log Analytics central	Seguridad	Configuración de diagnósticos al mismo destino de #6 y #9
Orígenes y acciones permitidas de operación	Seguridad, redes y responsables de cargas	Reglas concretas y permisos en datos, sin abrir despacho
Proveedor, región, cargas y residencia de datos de segunda nube	Arquitectura y cliente	Diseño de la futura interconexión y federación

Estos pendientes no cambian la decisión inicial de acceso mediante Bastion. Hasta resolverlos no se habilitan accesos amplios para compensar datos faltantes.

10. Referencias técnicas

Las fuentes describen capacidades de Azure. Los rangos y las restricciones de negocio proceden de los documentos de FríoAndes enlazados en la sección 1.1.

- **[T1]** Microsoft Learn: Planificación del acceso remoto a VM con Azure Bastion y configuración de Bastion.
- **[T2]** Microsoft Learn: Autenticación de Entra ID en Bastion y conexión SSH a Linux.
- **[T3]** Microsoft Learn: Reglas NSG de Bastion.
- **[T4]** Microsoft Learn: Azure DNS Private Resolver.
- **[T5]** Microsoft Learn: Endpoints y conjuntos de reglas del resolver.
- **[T6]** Microsoft Learn: Autenticación de aplicaciones y usuarios con Entra ID.

4. Automatización y DevOps

Automatización y DevOps: ambientes, pipeline, secretos y cambio

Este documento resume cómo se construye y se cambia la plataforma: qué ambientes hay, cómo se escribe la infraestructura como código, cómo el pipeline lleva un cambio de desarrollo a producción, dónde viven los secretos y cómo se respeta la ventana de cambios de FríoAndes. El código está en el repositorio `frioandes-platform/iac` (Fase 2, issues #20 a #24) y las plantillas de release notes en la Fase 4 (#29 a #31). Aquí está el diseño que ese código implementa, con los nombres de la red, la seguridad y el gobierno ya definidos.

1. Ambientes

Ambiente	Suscripción	Red	Datos	Quién cambia
Desarrollo	`sub-fa-dev`	`10.103.0.0/21`	Sintéticos; sin sensores reales	Desarrolladores en sus grupos de recursos y el pipeline
Pruebas	`sub-fa-test`	`10.102.0.0/21`	Sintéticos o anonimizados; sensores simulados	Solo el pipeline; QA ejecuta pruebas
Producción	`sub-fa-prod`	`10.101.0.0/21`	Reales	Solo el pipeline, con aprobación; personas solo con PIM y por incidente
Hub	`sub-fa-connectivity`	`10.100.0.0/23`	—	Solo el pipeline, con aprobación del equipo de redes

Los tres ambientes de aplicación tienen la misma estructura (las once subredes de `red-topologia-subnetting.md`, sección 4) y salen del mismo módulo. Cambian el rango, los tamaños y la cantidad de réplicas, no la forma. Así lo que se prueba en pruebas es lo que llega a producción, y lo que dejó de compartir clúster en Cali queda separado por suscripción, identidad y red.

Ambientes y promoción: el mismo código y la misma imagen, de desarrollo a producción

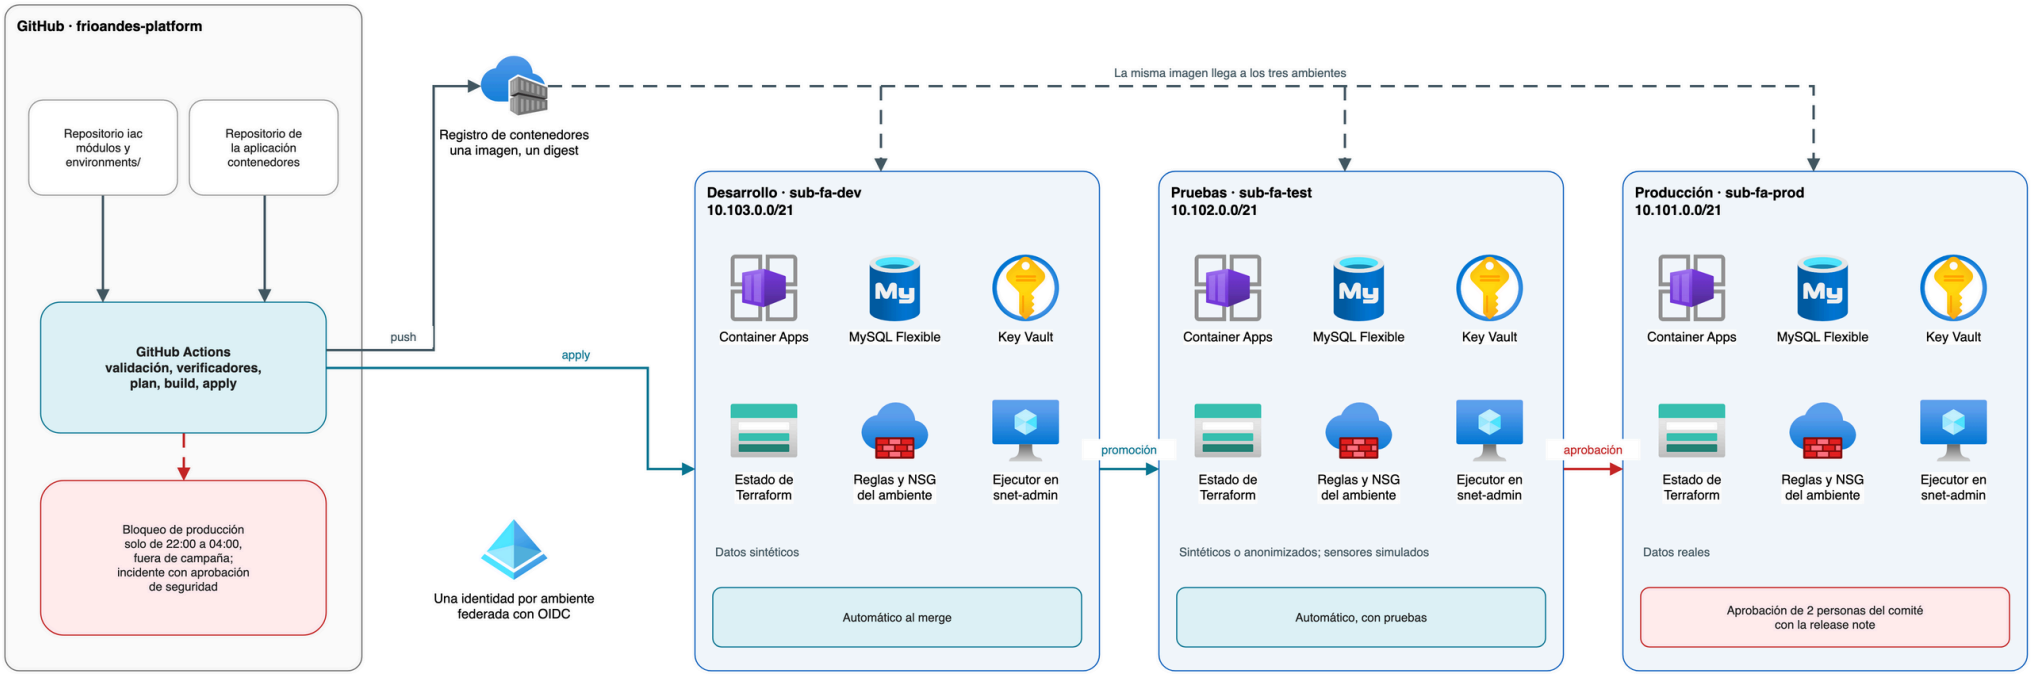


Figura 14: Ambientes y promoción: el mismo código y la misma imagen pasan de desarrollo a pruebas y a producción

2. Infraestructura como código

Pieza	Qué hace	Fuente que no se copia a mano
`modules/network`	Red virtual, subredes, NSG y tablas de rutas de un ambiente	`ip-plan.csv`, leído con `csvdecode` (`red-topologia-subnetting.md`, sección 4.9)
`modules/security`	Azure Firewall, su política y los grupos de reglas, marcando las temporales de la migración	`firewall-policy.csv` (`red-firewall-y-publicacion.md`, sección 4)
`modules/compute` o `modules/ingest`	Un componente de cómputo (Container Apps) o de ingesta (IoT Hub), conectado a la red y la seguridad por referencia	—
`environments/dev`, `test` y `prod`	Llaman a los módulos con los valores de cada ambiente	—

- **Estado remoto, uno por ambiente,** en una cuenta de almacenamiento de su suscripción, con bloqueo y versiones. Un error en el estado de desarrollo no toca producción, y la identidad de desarrollo no puede leer el estado de producción.
- **Etiquetas en el código.** Terraform pone las cinco etiquetas obligatorias (`ambiente`, `carga`, `costo`, `criticidad` y `responsable`) y Azure Policy rechaza lo que llegue sin ellas (`gobierno-landing-zone.md`, sección 5).
- **Continuidad desde el mismo código.** Los entornos de Central US se crean con el mismo módulo cambiando la región (`carga-a-plataforma-logistica.md`, sección 6).
- **El código va en inglés** y la documentación en español, como el resto de la plataforma.

3. Pipeline y promoción

GitHub Actions, con un GitHub Environment por ambiente:

```
pull request
  → validación: formato, terraform validate, verificadores del plan de direcciones y del
firewall
  → terraform plan contra desarrollo, publicado en el pull request
merge a main
  → build y push de las imágenes al registro de contenedores (una vez, con su digest)
  → apply en desarrollo → apply en pruebas, con pruebas automáticas
  → plan de producción → aprobación en el Environment de producción → apply en producción
```

Regla	Cómo se cumple
Promoción controlada	La misma imagen, por su digest, y el mismo código pasan de desarrollo a pruebas y a producción. Nada se construye dos veces
Aprobación para producción	El Environment de producción exige la aprobación de dos personas del comité de cambios, con la release note diligenciada
Sin despliegue productivo fuera de la ventana	Un paso del pipeline rechaza el apply de producción entre las 04:00 y las 22:00 hora de Colombia y en las fechas de campaña, que lee de un archivo del repositorio. La excepción por incidente exige una etiqueta de incidente y la aprobación de seguridad
Ejecutores dentro de la red	Los recursos privados (base, Key Vault, Container Apps internos) se despliegan desde ejecutores autoalojados en `snet-admin` de cada ambiente, separados de las máquinas de operación (`red-acceso-remoto-segunda-nube.md`, sección 2). El build de imágenes puede usar los ejecutores de GitHub

Regla	Cómo se cumple
Salida controlada de los ejecutores	Solo hacia Azure Resource Manager, Entra ID, GitHub y el registro de contenedores, por el Azure Firewall (reglas FW-303, 306, 309, 312, 315 y 318 de `red-firewall-y-publicacion.md`, sección 4)

---

4. Secretos e identidades del pipeline

- **Sin credenciales duraderas.** Cada ambiente tiene su propia identidad de despliegue en Entra ID, federada con GitHub por OIDC y limitada a su Environment. El repositorio no guarda contraseñas ni claves (`seguridad-iam-cifrado.md`, sección 4).
- **Permisos mínimos.** La identidad de desarrollo solo actúa en `sub-fa-dev`; la de producción solo en `sub-fa-prod` y solo desde el Environment aprobado. Ninguna puede asignar roles fuera de lo que el código declara.
- **Secretos de la aplicación en Key Vault.** Un Key Vault por ambiente (`kv-fa-dev`, `kv-fa-test` y `kv-fa-prod`). Las aplicaciones leen sus secretos con identidad administrada; el pipeline solo escribe los que una herramienta no puede reemplazar por identidad.
- **Auditoría.** Las lecturas y cambios de secretos y los despliegues quedan en el Log Analytics central (`gobierno-auditoria-facturacion.md`).

---

5. Estrategia de cambio

Regla de FríoAndes	Cómo la aplica la plataforma
Ningún cambio productivo de 04:00 a 22:00	Los cambios a producción se aplican de 22:00 a 04:00; el pipeline los bloquea fuera de ese horario
Ningún cambio durante una campaña, salvo incidente	El calendario de campañas está en el repositorio y el pipeline lo lee
Cada cambio se aprueba, se avisa y se puede deshacer	Release note de aplicación o de infraestructura con qué cambia, la ventana, el impacto, la aprobación, el aviso a despacho y a calidad, y cómo se vuelve atrás (#29 y #30)

Cómo se vuelve atrás:

- **Aplicación.** Container Apps conserva la revisión anterior: volver atrás es mover el tráfico a ella, en minutos y sin desplegar de nuevo. Los cambios de esquema son compatibles hacia atrás, en dos pasos: primero se agrega lo nuevo, y lo viejo se quita en una ventana posterior.
- **Infraestructura.** Se revierte el commit y se aplica de nuevo, por el mismo pipeline y con la misma aprobación. Lo que no se puede deshacer con un apply (borrar datos, retirar una regla de la que depende Cali) se marca así en la release note y necesita una aprobación adicional.
- **Durante la convivencia** la base no admite cambios de esquema: lo que la aplicación necesite para la migración y para Fabric se termina antes del día 0 (`carga-c-migracion-y-campana.md`, sección 3).

---

6. Verificación

Comprobación	Herramienta	Cuándo
Las direcciones no se solapan con Cali ni entre ambientes	`red/tools/verify_ip_plan.py`	En cada pull request que toque la red
Las reglas del firewall respetan el plan y el diseño	`red/tools/verify_firewall_policy.py`	En cada pull request que toque el firewall

Comprobación	Herramienta	Cuándo
Lo que Terraform va a crear coincide con el plan de direcciones	`red/tools/compare_tfplan.py` sobre el `plan`	Antes de cada apply
El código coincide con la tabla de políticas, regla por regla	Revisión documentada (#21)	Al cerrar el módulo de seguridad
El `plan` corre limpio sobre los tres módulos	Evidencia fechada y con el commit (#24)	Al cerrar la Fase 2

---

7. Supuestos

Supuesto	Por qué se asume
El repositorio de código y el pipeline viven en GitHub	Es donde está el proyecto; los issues #20 a #24 ya lo fijan
El estado de Terraform va en una cuenta de almacenamiento por ambiente, en su propia suscripción	Aísla el estado igual que los ambientes
La aprobación de producción la dan dos personas del comité de cambios	Separa quien escribe el cambio de quien lo autoriza
El calendario de campañas se mantiene en un archivo del repositorio	El pipeline necesita leerlo para bloquear despliegues; las fechas salen de `carga-c-migracion-y-campana.md`, sección 4.1

5. Cargas de trabajo

Arquitectura de la plataforma de operación logística (Carga A)

Este documento diseña el front, los servicios de negocio, los datos, la seguridad y la continuidad de la consola de despacho y el portal de rastreo, que reemplazan el núcleo actual sobre virtualización local. Parte de la red ya diseñada (`red-topologia-subnetting.md` y `red-firewall-y-publicacion.md`), de la gobernanza (`gobierno-landing-zone.md`) y de los límites de datos personales (`seguridad-datos-personales-perimetro.md`), y usa sus mismos nombres y decisiones.

1. Contexto y alcance

Hoy la consola de despacho y el portal de rastreo corren sobre virtualización local, con desarrollo, pruebas y producción compartiendo el mismo clúster de aplicación. La operación tiene 450 usuarios internos y unos 2.000 clientes corporativos habilitados en el portal, con un pico ordinario de 800 solicitudes por minuto y de 2.000 en campaña. El negocio exige un RPO de 15 minutos y un RTO de 4 horas.

Este documento cubre la arquitectura de esa plataforma: front, los cuatro servicios de negocio que hoy corren en el núcleo, los datos que necesita y cómo se recupera ante una falla regional. No cubre la ingesta de telemetría (`carga-b-telemetria.md`, issue #13, ya resuelta), ni la migración desde Cali ni el escenario completo de campaña (issue #14), ni la estrategia de Fabric (issues #17 y #18), que dependen de las decisiones de este documento.

2. Front: consola de despacho y portal

Se confirma **Azure Container Apps** como plataforma de contenedores, la propuesta de la red (`red-topologia-subnetting.md`, sección 7.2). Cada ambiente tiene dos entornos de Container Apps con perfiles de carga, cada uno en su propia subred:

- **Entorno de la torre**, en `snet-app-torre`. Interno: solo lo alcanzan Cali y los centros a través del Azure Firewall (issue #9). Aquí corre la consola de despacho que usan los 450 usuarios internos.
- **Entorno del portal**, en `snet-app-portal`. Interno también: recibe tráfico únicamente desde el Application Gateway v2 con WAF de `snet-ingress` (issue #9), que es la cara pública para los clientes corporativos.

El tamaño de cada entorno (hasta 20 nodos dedicados y 200 réplicas de consumo) ya está dimensionado en la red con margen para la campaña. Cómo se reparte el +40 % de cómputo de campaña entre torre y portal lo detalla `carga-c-migracion-y-campana.md` (issue #14), sección 7, sin tocar los rangos de red.

3. Servicios de negocio

Los cuatro servicios corren como aplicaciones separadas dentro de los mismos dos entornos de Container Apps de la sección anterior; no tienen subred propia.

Servicio	Qué hace	Quién lo usa
Guías	Crea y da seguimiento a las guías de despacho	Escribe la torre. El portal expone de forma exclusiva las guías del cliente corporativo que consulta, identificado, como ya definió `seguridad-datos-personales-perimetro.md`
Inventario	Capacidad y estado de cuartos fríos y camiones	Solo la torre. No se expone en el portal
Asignación de muelle y ruta	Decide qué camión sale por qué muelle y con qué ruta	Solo la torre. Cuando exista, la ETA de IA del issue #18 es una entrada adicional, no un reemplazo de esta decisión

Servicio	Qué hace	Quién lo usa
Facturación corporativa	Genera y consulta la facturación de cada cliente	Escribe la torre. El portal expone solo la facturación del cliente que consulta. No hay datos de pago con tarjeta, como ya fijó `seguridad-datos-personales-perimetro.md`

4. Datos

Base relacional. Azure Database for MySQL Flexible Server, siguiendo el motor actual. La versión propuesta es **MySQL 8.4 (LTS)**: la versión 8.0 ya no tiene soporte de la comunidad desde octubre de 2023, y 8.4 es la serie de soporte extendido vigente que ofrece Azure Database for MySQL Flexible Server. Alta disponibilidad zonal, con 2 réplicas y 1 servidor temporal, ya reservada en `snet-data` por la red (`red-topologia-subnetting.md`, sección 5.1).

Caché. Azure Managed Redis, en `snet-data-pe`, puerto 10000 con TLS, como ya la nombra la tabla de políticas del firewall (issue #9). No se usa el nombre anterior "Azure Cache for Redis": ese servicio tiene retiro anunciado por Microsoft, y la red y el firewall ya se diseñaron sobre Azure Managed Redis.

Secretos y certificados. Azure Key Vault, con endpoint privado en `snet-data-pe`, igual que lo reservó la red.

5. Seguridad

Autenticación interna. Los 450 usuarios internos se autentican con Microsoft Entra ID, con los grupos ya definidos en la gobernanza (`gobierno-landing-zone.md`): `grp-fa-ops-prod` para operación de producción, `grp-fa-dev` y `grp-fa-qa` para desarrollo y pruebas. MFA y elevación temporal por PIM para administradores, como ya decidió ese documento.

Portal. Protegido por el Application Gateway v2 con WAF del issue #9, y por los límites de solicitudes del issue #10: 300 por minuto por IP en el WAF, dimensionado para el pico de 2.000, más el límite por cuenta y por cliente de la aplicación.

Secretos. Cada servicio lee sus credenciales de Key Vault con identidad administrada; ninguna credencial queda en el código ni en variables de entorno sin cifrar.

La matriz detallada de roles por aplicación, con el principio de mínimo privilegio, es responsabilidad del issue #7 y no se repite aquí: esta sección usa los grupos generales que ya existen.

6. Continuidad: RPO y RTO

El negocio exige un RPO de 15 minutos y un RTO de 4 horas. La región pareja de East US 2 es Central US, y la red ya reservó `10.104.0.0/15` para el hub y la producción de recuperación de esta continuidad (`red-topologia-subnetting.md`, sección 4, fila de reservas).

Base de datos. MySQL Flexible Server replica de forma continua hacia una réplica de solo lectura en Central US. El RPO de 15 minutos se cumple con esa réplica: el retraso de replicación se monitorea (issue #16) y genera alerta si supera el umbral. El RTO de 4 horas es el tiempo del runbook de continuidad, que promueve la réplica a primaria; no es una conmutación automática.

Front. Los entornos de Container Apps de Central US se activan con el mismo módulo de Terraform que produce los de East US 2 (issues #20 a #24), cambiando solo la región. No quedan encendidos todo el tiempo: se activan como parte del runbook, lo que pesa en el RTO de 4 horas y se detalla en el costo de campaña (issue #26).

Caché. Azure Managed Redis no se replica entre regiones. Al activar Central US, la caché arranca vacía y se llena con el primer tráfico; no afecta el RPO porque no guarda datos que no estén también en la base.

Fuera de alcance de este documento. Cómo se redirige el tráfico del portal durante el failover (DNS, Front Door o Traffic Manager) y quién ejecuta el runbook no están decididos todavía; quedan como confirmación pendiente en la sección 8.

7. Diagrama

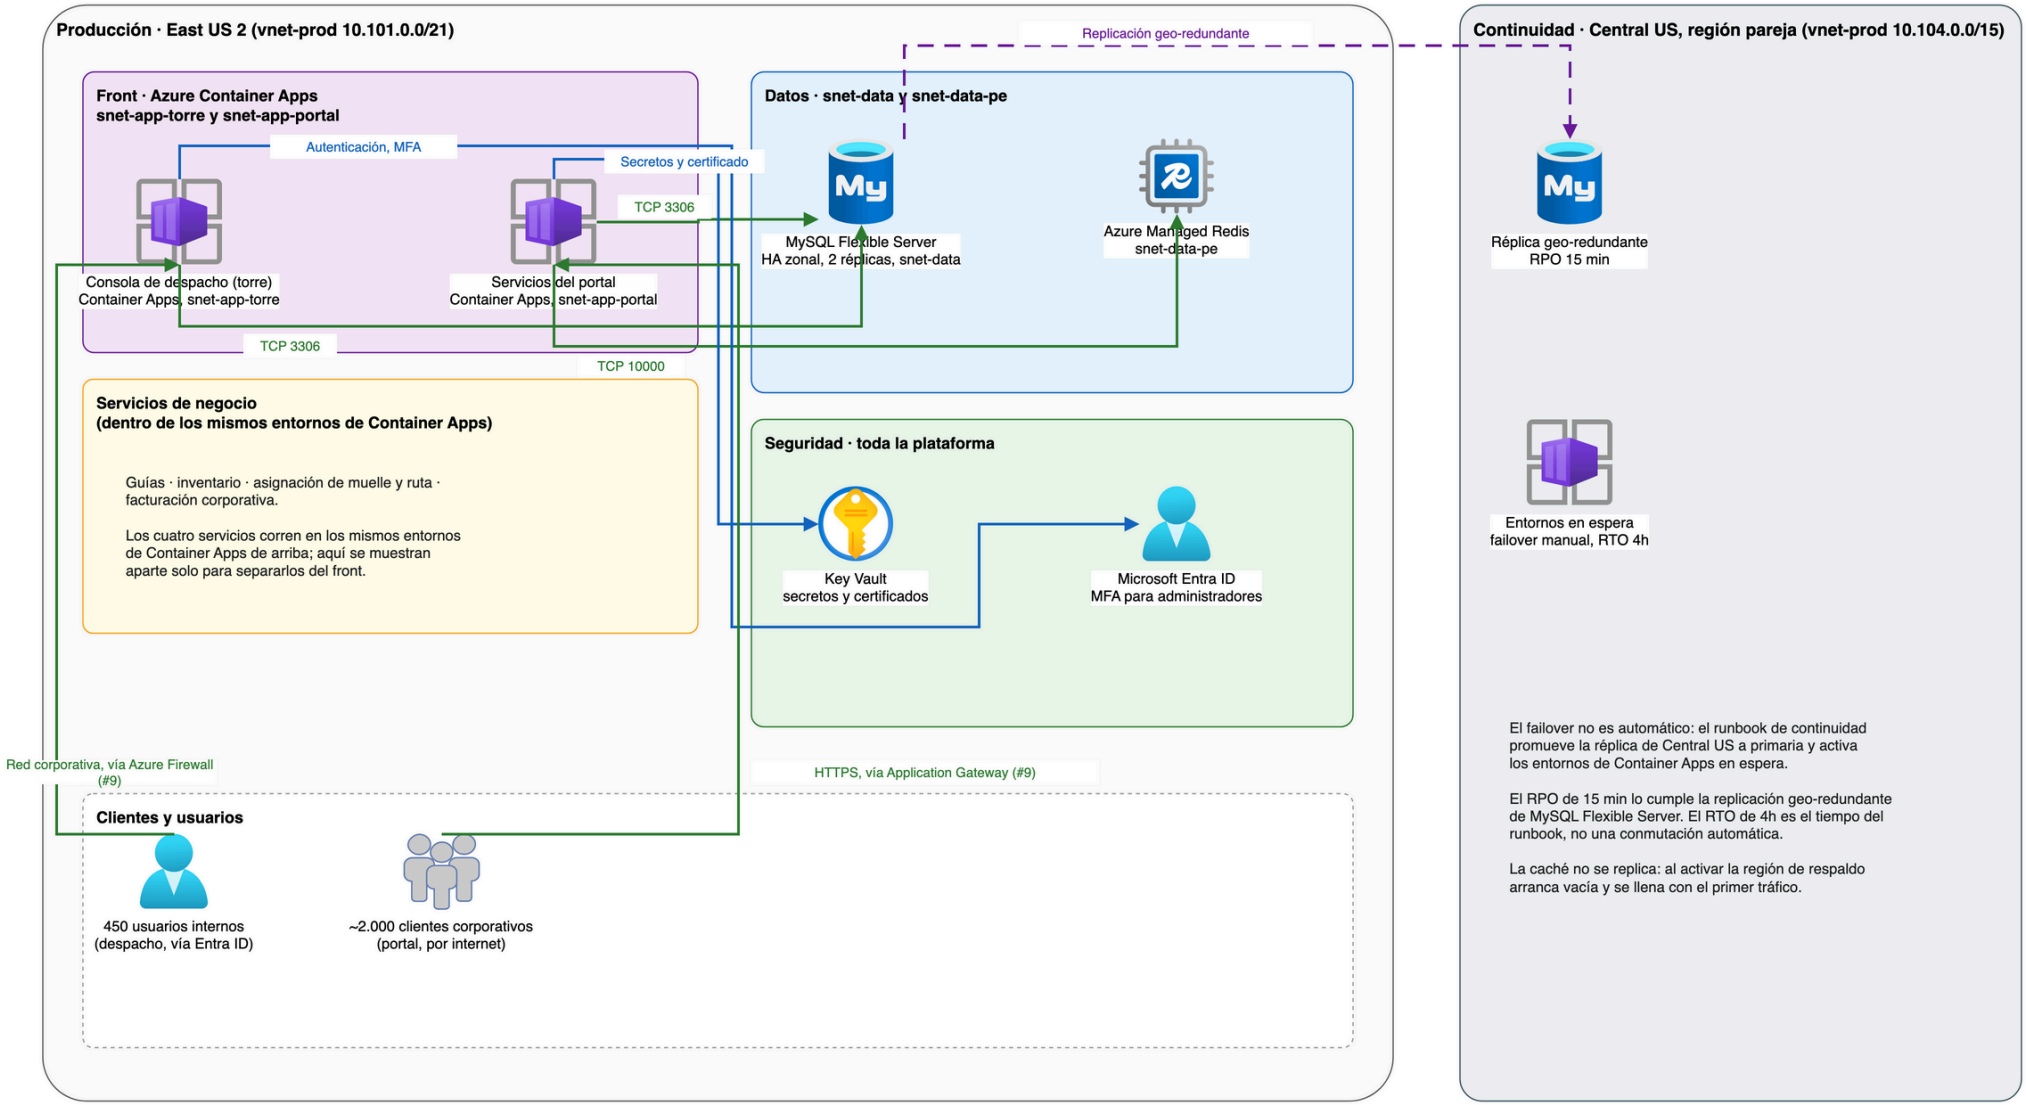


Figura 15: Front, servicios, datos, seguridad y continuidad de la plataforma logística, en producción y en la región pareja

El diagrama muestra dos zonas: producción en East US 2, con el front (torre y portal en Container Apps), los servicios de negocio, los datos (MySQL Flexible Server y Azure Managed Redis) y la seguridad (Key Vault y Entra ID); y la continuidad en Central US, con la réplica de la base y los entornos de Container Apps en espera.

8. Supuestos y confirmaciones pendientes de FríoAndes

8.1 Confirmaciones que necesita el diseño

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
Redirección del tráfico en el failover	¿FríoAndes usa o quiere Azure Front Door o Traffic Manager, o prefiere un cambio manual de DNS?	Cambia cómo se cumple el RTO de 4 horas y si hace falta un servicio adicional en la red
Responsable del runbook	¿Quién ejecuta la promoción de la réplica y la activación de Central US: la torre, un equipo de guardia de DevOps?	Define a quién capacitar y a quién alertar cuando falle la región principal
Costo de la réplica en espera	¿Los entornos de Central US se mantienen apagados hasta el runbook, o encendidos en el mínimo para bajar el RTO?	Cambia el costo mensual de continuidad (issue #26) y el tiempo real del RTO

8.2 Supuestos del diseño

Supuesto	Por qué se asume
MySQL 8.4 (LTS) es la versión de la base relacional	Es la serie con soporte extendido vigente de Azure Database for MySQL Flexible Server; MySQL 8.0 ya no tiene soporte de la comunidad
El +40 % de cómputo de campaña se aplica solo a los entornos de Container Apps de torre y portal	Es lo que define el issue #14; los datos y la seguridad ya están dimensionados con margen para ese pico
La asignación de muelle y ruta sigue siendo una decisión de la torre, no de un modelo de IA	Es la misma decisión que ya fija el issue #18 para toda la plataforma: ningún modelo de IA decide el despacho por sí solo

9. Validación y cierre

Criterio de aceptación	Evidencia en este documento
El diagrama separa explícitamente front, servicios, datos, seguridad y continuidad	Diagrama de la sección 7, con las cinco zonas marcadas
La base relacional se diseña con alta disponibilidad que permita cumplir RPO 15 min, y el failover indica cómo se cumple el RTO de 4h	Sección 6: réplica geo-redundante de MySQL Flexible Server para el RPO, runbook de continuidad para el RTO

Telemetría de cadena de frío: ingesta, alerta e historial

Este documento define cómo llegan a la nube las lecturas de los cuartos fríos y de los camiones de FríoAndes, cómo se genera la alerta de temperatura en menos de un minuto, a quién le llega según la hora, dónde se guarda el historial para reclamos y qué tableros ven calidad, la torre de control y el cliente corporativo. Parte de la red y del firewall ya diseñados (`red-topologia-subnetting.md` y `red-firewall-y-publicacion.md`) y usa sus mismos nombres.

Términos usados

Término	Significado en este documento
Lectura	Un mensaje de un sensor: temperatura, posición o apertura de puerta, con la hora en que se midió
Excursión de temperatura	Una lectura fuera del rango permitido para la carga o el cuarto frío
Sensor sin señal	Un sensor del que dejan de llegar lecturas en el tiempo esperado
IoT Hub	Servicio de Azure que recibe los mensajes de los dispositivos, con una identidad por dispositivo
Servicio de aprovisionamiento (DPS)	Servicio de Azure que registra cada dispositivo en IoT Hub la primera vez que se conecta, sin configurarlo a mano
Unidad de IoT Hub	Bloque de capacidad que se compra por mes. Cada unidad del nivel 1 recibe hasta 400.000 mensajes al día
Camino 1	Cuartos fríos: red local del centro, VPN, Azure Firewall y endpoint privado de IoT Hub
Camino 2	Camiones: red móvil del operador de flota, internet y endpoint público de IoT Hub
Turno de guardia de calidad	Quien recibe las alertas de 22:00 a 04:00, cuando la torre de control no opera

---

1. Contexto y alcance

1.1 Qué resuelve la telemetría

La telemetría tiene que alertar cuando un camión o un cuarto frío sale del rango de temperatura y conservar el historial para reclamos. Son cuatro piezas:

Pieza	Qué necesita FríoAndes	Dónde se responde
Ingesta	Temperatura, apertura de puerta y posición de la flota	Sección 2
Procesamiento de baja latencia	Alerta visible en menos de un minuto desde el evento, en condiciones normales de red. De 04:00 a 22:00 la recibe la torre; de noche, el turno de guardia de calidad	Sección 3
Almacenamiento analítico	Historial, reclamos y reportes a clientes, con la trazabilidad de temperatura guardada cinco años	Sección 4
Tableros	Para calidad y una vista reducida para el cliente corporativo, que no ve la flota completa	Sección 5

1.2 Qué toma del diseño de red y del firewall

Ya definido	Dónde
Los cuartos fríos llegan por la VPN de su centro, pasan por el Azure Firewall (regla FW-204: MQTT 8883, AMQP 5671 y HTTPS 443) y entran por un endpoint privado en `snet-ingest`	Red, sección 6.1; firewall, sección 4.3
Los camiones llegan por internet al endpoint público de IoT Hub, con TLS y una credencial por camión	Red, sección 6.1; firewall, sección 4.5
`snet-ingest` tiene espacio para 10 endpoints privados, y `10.10X.3.0/24` queda libre para el cómputo de la telemetría	Red, sección 6.1
Pruebas y desarrollo no reciben sensores reales: usan datos simulados	Firewall, sección 4.3
La regla temporal FW-402 (envío por FTP de los históricos de cada hora a Cali) se retira cuando la telemetría en línea reemplaza esa carga	Firewall, sección 5.5

1.3 Volumen

Fuente	Cantidad	Frecuencia	Mensajes por segundo	Mensajes por día
Temperatura de los camiones	120	Una cada 60 s, jornada de 18 h	2,0	129.600
Posición de los camiones	120	Una cada 30 s, jornada de 18 h	4,0	259.200
Cuartos fríos	32 (8 centros × 4)	Una cada 30 s, 24 h	1,07	92.160
Aperturas de puerta (supuesto)	Cuartos fríos y camiones	Al abrir y al cerrar	Menos de 0,1	Unas 5.500
Total normal			**7,2**	**unos 486.000**
Total en campaña (180 camiones)			**10,2**	**unos 682.000**

No hay una cifra de aperturas de puerta. Se suponen dos aperturas por hora en cada cuarto frío y diez paradas al día por camión, con un mensaje al abrir y otro al cerrar. Aunque la cifra real fuera diez veces mayor, seguiría siendo una parte menor del total.

Con mensajes de 1 KB, el volumen es de unos 0,5 GB al día, unos 15 GB al mes y menos de 1 TB en cinco años. El volumen es bajo. Lo que exige diseño es la latencia de la alerta, los dos caminos de entrada, el destinatario según la hora y la detección de sensores sin señal.

---

2. Ingesta

2.1 Los dos caminos

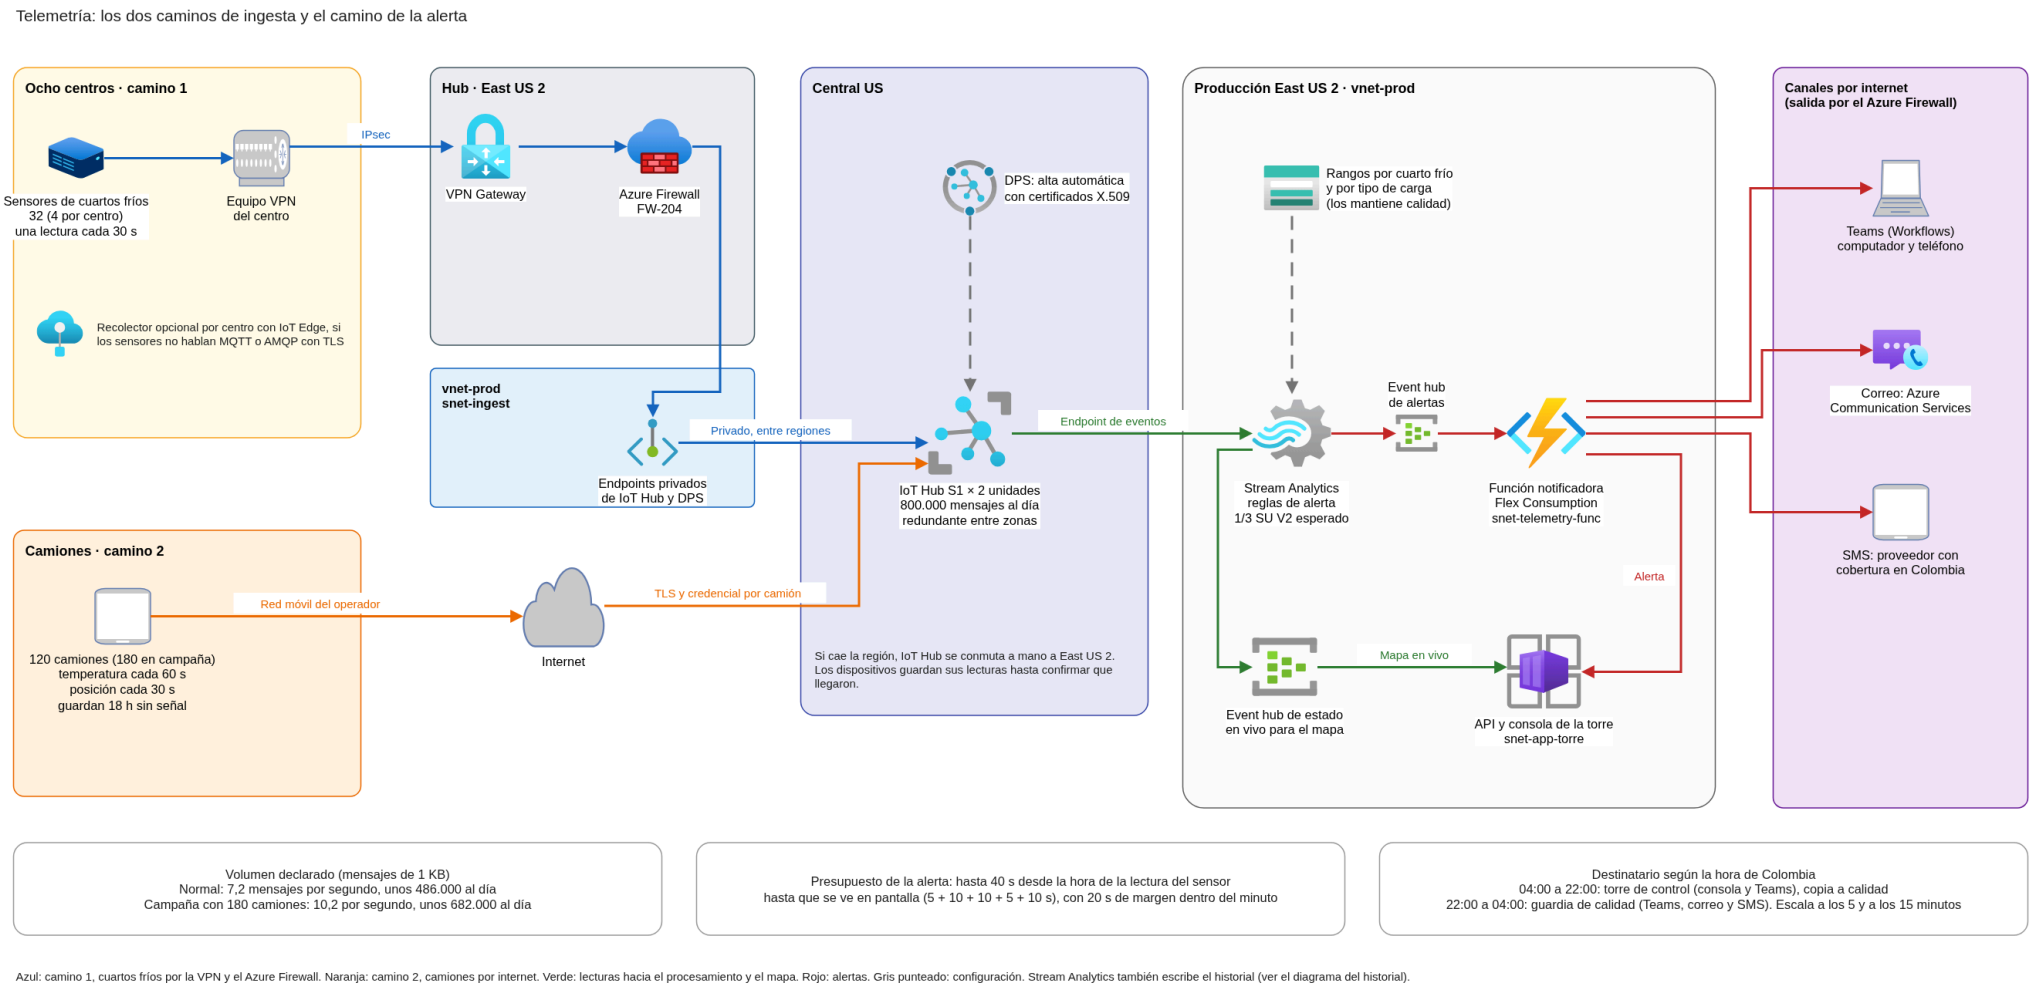


Figura 16: Los dos caminos de ingesta y el camino de la alerta

- **Camino 1, cuartos fríos:** sensor, recolector del centro si existe, VPN del centro, VPN Gateway, Azure Firewall (regla FW-204), endpoint privado en `snet-ingest` e IoT Hub.
- **Camino 2, camiones:** equipo del camión, red móvil del operador, internet y endpoint público de IoT Hub.

Los dos caminos terminan en el mismo IoT Hub. Desde ahí, el procesamiento no distingue de dónde vino cada lectura: cada dispositivo tiene su identidad, y esa identidad dice si es un cuarto frío o un camión.

IoT Hub admite al mismo tiempo el endpoint privado y el público. Microsoft desaconseja cerrar el acceso público cuando los dispositivos están en una red amplia, como la red móvil de los camiones. Por eso el endpoint público queda abierto, protegido con TLS y con la identidad de cada camión. Si los datos de los camiones terminan llegando desde la plataforma del operador de flota, con direcciones fijas, el endpoint público se limita a esas direcciones con el filtro de IP de IoT Hub (sección 2.9).

2.2 Servicio de ingesta: IoT Hub

	IoT Hub (elegido)	Event Hubs	Broker MQTT de Event Grid
Identidad por dispositivo	Sí, con registro de dispositivos	No: identifica aplicaciones, no dispositivos	Sí, con registro de clientes
Alta automática de dispositivos	Sí, con el servicio de aprovisionamiento (DPS)	No	No hay un servicio equivalente
Configuración remota de cada dispositivo	Sí (gemelos de dispositivo, nivel Standard)	No	Por mensajes entre clientes
Recolector local en los centros	Sí, con IoT Edge (nivel Standard)	No	Con Azure IoT Operations, que corre sobre Kubernetes en el borde
Endpoint privado	Sí, ya previsto en `snet-ingest`	Sí	No se evaluó
Costo base para este volumen	USD 50 al mes (2 unidades S1)	USD 21,90 al mes (una unidad de rendimiento) más ingresos	USD 29,20 al mes (una unidad de rendimiento) más operaciones

Por qué IoT Hub: es el único de los tres que da a la vez identidad por dispositivo, alta automática y configuración remota, y el diseño de red ya lo dejó previsto con su endpoint privado. Event Hubs sirve para recibir datos de aplicaciones, no de dispositivos, y solo conviene si la plataforma del operador de flota es la que envía los datos de los camiones (sección 2.9). El broker MQTT de Event Grid es una buena opción para comunicación entre dispositivos y la nube en los dos sentidos, pero el caso no la necesita.

2.3 Nivel y unidades

Nivel	Qué incluye	Costo por unidad al mes
B1 (básico)	Telemetría desde el dispositivo, identidad por dispositivo, enrutamiento, DPS	USD 10
S1 (estándar, elegido)	Lo anterior, más mensajes de la nube al dispositivo, gemelos de dispositivo para configuración remota e IoT Edge	USD 25

Cada unidad del nivel 1 (B1 o S1) recibe hasta 400.000 mensajes al día, contados en bloques de 4 KB: un mensaje de 1 KB cuenta como uno.

	Mensajes al día	Unidades S1 necesarias
Día normal	Unos 486.000	2 (capacidad de 800.000)
Día de campaña	Unos 682.000	2 (capacidad de 800.000)

Producción usa dos unidades S1, USD 50 al mes. Cubren la campaña con un 15 % de margen sin tocar la configuración, lo que importa porque durante una campaña no se hacen cambios. Si la flota crece, se agrega una unidad sin interrumpir el servicio. El límite de envíos por segundo (al menos 100 con S1) está muy por encima de los 10 por segundo del caso.

Por qué S1 y no B1: el nivel estándar permite cambiar el rango de temperatura de un dispositivo o su frecuencia de lectura desde la nube, y es el que admite un recolector con IoT Edge en los centros (sección 2.8). La diferencia es de USD 30 al mes. Azure permite pasar de B1 a S1 sin interrumpir el servicio, pero no al revés.

2.4 Región y resiliencia

Microsoft publica en qué regiones IoT Hub tiene redundancia entre zonas de disponibilidad. **East US 2 no está en la lista. Central US, la región pareja, sí, para datos y para cómputo.** En una región sin esa redundancia, una falla de zona puede dejar sin ingesta, y por lo tanto sin alertas, hasta que Microsoft la resuelva.

	IoT Hub en Central US (propuesta)	IoT Hub en East US 2
Falla de una zona	Sin pérdida de datos ni interrupción: IoT Hub cambia de zona solo	La ingesta puede detenerse hasta que la zona se recupere
Falla de la región	Conmutación manual a East US 2, la región pareja, entre 10 minutos y 2 horas	Conmutación manual a Central US, entre 10 minutos y 2 horas
Latencia desde Cali (medición del diseño de red)	Mediana de 105 a 111 ms	Mediana de 86 a 97 ms
Endpoint privado de los cuartos fríos	En `snet-ingest` de East US 2: Azure permite que el endpoint esté en otra región que el servicio	En `snet-ingest`, misma región
Costo adicional	Transferencia entre regiones: unos 15 GB al mes a USD 0,02, unos USD 0,30	Ninguno
Ubicación de los datos	Estados Unidos, igual que el resto de la plataforma	Estados Unidos

Propuesta: IoT Hub en Central US. La alerta es una de las dos capacidades críticas de la plataforma y depende de que la ingesta no se detenga. La diferencia de latencia (unos 15 ms) es despreciable frente al minuto de la alerta, y el costo extra es de centavos. El procesamiento de la alerta y el historial quedan en East US 2, junto al resto de la plataforma, y leen de IoT Hub entre regiones.

En los dos casos, la conmutación a la región pareja hace perder los mensajes que IoT Hub todavía no había entregado. Por eso los dispositivos guardan sus lecturas hasta confirmar que llegaron (sección 2.7).

2.5 Identidad de cada dispositivo

Cada sensor de cuarto frío y cada equipo de camión tiene su propia identidad en IoT Hub. Así se puede bloquear un dispositivo robado o dañado sin afectar a los demás, y cada lectura queda atribuida a su origen.

	Certificados X.509 con DPS (propuesta)	Claves simétricas con DPS
Cómo se identifica el dispositivo	Con un certificado propio, firmado por una autoridad de certificación de FríoAndes	Con una clave derivada de una clave de grupo
Si se compromete un dispositivo	Se revoca su certificado; los demás siguen	Se cambia su clave; si se filtra la clave del grupo, quedan expuestos todos
Requisito en el equipo	Soportar certificados; Microsoft recomienda guardar el secreto en un módulo de hardware seguro	Ninguno especial
Alta	Automática: el dispositivo se presenta a DPS y queda registrado en IoT Hub	Automática

Propuesta: certificados X.509 con grupos de inscripción en DPS, uno para los cuartos fríos y otro para los camiones. Si los equipos que FríoAndes tiene o compre no soportan certificados, se usan claves simétricas con un grupo por centro y uno para la flota, para limitar el alcance de una clave filtrada.

DPS va en Central US, junto a IoT Hub. Los cuartos fríos se dan de alta por un endpoint privado de DPS en `snet-ingest`, al lado del de IoT Hub: Azure permite que el endpoint esté en otra región que el servicio. Para eso, los equipos de los cuartos fríos se configuran con el endpoint propio del DPS de FríoAndes y no con el endpoint global de Microsoft. Los camiones usan el endpoint público.

DPS cobra USD 0,10 por cada 1.000 operaciones. Con unos 150 dispositivos que se registran una vez y se vuelven a registrar de vez en cuando, el costo es de centavos al mes. Microsoft recomienda usar DPS desde el inicio aunque la flota sea pequeña, para que crecer no obligue a cambiar el firmware de los equipos.

2.6 Qué lleva cada mensaje

Todos los dispositivos envían el mismo formato, en JSON:

Campo	Contenido
Identidad	La del dispositivo en IoT Hub (la agrega IoT Hub, no la envía el dispositivo)
Tipo	Temperatura, posición o puerta
Hora de la medición	La hora del sensor en UTC, sincronizada por GPS en los camiones y por la red del centro en los cuartos fríos
Número de secuencia	Correlativo por dispositivo, para detectar lecturas perdidas o repetidas
Valor	Grados Celsius, coordenadas, o puerta abierta o cerrada
Guía o viaje	En los camiones, la guía o el viaje en curso, para cruzar la lectura con la carga y con el cliente

Cada mensaje se marca como JSON en UTF-8 (propiedades `contentType` y `contentEncoding` del mensaje). Sin esa marca, IoT Hub guarda el contenido codificado en base64 al enviarlo al almacenamiento (sección 4).

La hora de la medición es la que cuenta para la alerta y para los reclamos, no la hora de llegada. Así, una lectura que llega tarde porque el camión estuvo sin señal queda en su lugar correcto del historial.

2.7 Camiones sin señal

La alerta tiene que verse en menos de un minuto en condiciones normales de red. Cuando un camión pierde la señal celular:

- El equipo del camión guarda las lecturas con su hora y su número de secuencia, al menos durante una jornada completa (18 horas).
- Al recuperar la señal, las envía en orden. IoT Hub las recibe como cualquier otra lectura.
- El procesamiento usa la hora de la medición: si una lectura atrasada muestra una excursión, genera una alerta marcada como tardía, con la hora real del evento, para que calidad sepa que el problema ocurrió mientras no había señal (sección 3).
- La falta de lecturas de un camión en ruta dispara la alerta de sensor sin señal (sección 3).

Esto es un requisito para los equipos de los camiones, que FríoAndes debe confirmar con su proveedor.

2.8 Recolector en los centros

Todavía no está definido si los sensores de los cuartos fríos se conectan uno por uno o a través de un equipo del centro. El diseño admite las dos formas:

	Sensores directos	Recolector por centro con IoT Edge
Qué se conecta a IoT Hub	Cada sensor, con su identidad	Un equipo por centro, que reúne las lecturas de sus cuatro cuartos fríos
Si cae la VPN del centro	Cada sensor guarda sus lecturas, si puede	El recolector guarda las lecturas y las envía al volver la conexión
Requisito	Que el sensor hable MQTT o AMQP con TLS y soporte su identidad	Un equipo por centro y el nivel S1 de IoT Hub

	Sensores directos	Recolector por centro con IoT Edge
Cuándo conviene	Sensores modernos con conexión IP	Sensores antiguos o que solo hablan protocolos industriales locales

En los dos casos la red es la misma: el tráfico sale por la red de sensores del centro y usa el camino 1.

2.9 Si la plataforma del operador de flota reenvía los datos

Si los equipos de los camiones no envían directo a la nube y es la plataforma del operador de flota la que reenvía los datos, el camino 2 cambia:

- La plataforma del operador envía a un Event Hub (nivel Standard) con su propia identidad de aplicación, desde direcciones fijas permitidas con filtro de IP.
- Cada mensaje trae la identidad del camión en el contenido, porque Event Hubs no identifica dispositivos.
- El procesamiento de la alerta lee de IoT Hub (cuartos fríos) y del Event Hub (camiones) con la misma lógica.

Es la pregunta 3 de la sesión de aclaraciones. Hasta tener la respuesta, el diseño supone que los camiones envían directo.

2.10 Pruebas y desarrollo

Ambiente	IoT Hub	Qué recibe
Producción	S1, 2 unidades	Los sensores reales
Pruebas	S1, 1 unidad (USD 25 al mes)	Un simulador que reproduce el volumen normal, y durante las pruebas de carga el de campaña con una unidad extra temporal
Desarrollo	Gratuito (8.000 mensajes al día)	Un simulador con pocos dispositivos

Los ambientes que no son de producción nunca reciben sensores reales: el firewall solo permite los sensores de los centros hacia la ingesta de producción.

---

3. Alerta en menos de un minuto

3.1 Qué cuenta como "un minuto"

La alerta debe poder verse en menos de un minuto desde el evento, en condiciones normales de red. Un camión mide la temperatura cada 60 segundos: si el evento fuera el momento exacto en que la temperatura real cruza el límite, la espera hasta la siguiente lectura podría consumir el minuto entero y ninguna arquitectura lo cumpliría.

El diseño mide el minuto desde la hora de la lectura que marca el sensor hasta que la alerta se ve en la pantalla de quien la recibe. Es un supuesto que se confirma en la sesión de aclaraciones (sección 7). Con esa definición, el presupuesto de tiempo queda así:

Tramo	Presupuesto	Cómo se cumple
Del sensor a IoT Hub	Hasta 5 s	Conexión persistente con MQTT o AMQP sobre TLS; el dispositivo envía en cuanto mide
De IoT Hub al procesamiento	Hasta 10 s	Stream Analytics lee continuamente el endpoint de eventos de IoT Hub
Procesamiento de la regla	Hasta 10 s	Reglas por lectura, sin esperar ventanas de tiempo; orden por hora de llegada (sección 3.3)
Del procesamiento al notificador	Hasta 5 s	Stream Analytics escribe la alerta en un event hub que la función lee por la red privada (sección 3.2)
Del notificador a la pantalla y al teléfono	Hasta 10 s	Aviso a la consola de la torre y a Teams (sección 3.6)
Total	**Hasta 40 s**	Deja 20 s de margen dentro del minuto

Los valores de cada tramo son el presupuesto del diseño, no una garantía de Azure. Microsoft indica que IoT Hub no garantiza una latencia máxima, por eso el objetivo de servicio de la alerta se mide de punta a punta en producción (sección 6) y el presupuesto se valida con la prueba de carga antes de salir.

3.2 Cómo se procesa

```
IoT Hub (Central US)
  → Stream Analytics (East US 2): reglas de excursión, puerta abierta y sensor sin señal
      → event hub de alertas → función notificadora (East US 2): destinatario según la hora,
canales y escalamiento
          → consola de la torre, Teams, correo, SMS
      → event hub de estado en vivo → mapa de la torre (sección 5.2)
      → historial (sección 4)
```

Componente	Qué hace	Por qué este servicio
Stream Analytics	Evalúa cada lectura contra el rango de su cuarto frío o de su carga, detecta puertas abiertas demasiado tiempo y sensores sin señal	Reglas en un lenguaje parecido a SQL, cruce con datos de referencia (los rangos), procesamiento exactamente una vez, SLA del 99,9 % y redundancia de zonas automática en East US 2. Sin servidores que mantener
Función notificadora (Azure Functions, plan Flex Consumption)	Recibe solo las alertas, descarta las repetidas, decide a quién avisar según la hora, envía por cada canal, registra el acuse y escala si nadie responde	La lógica de destinatarios y canales es código de negocio que cambia; una función la aísla del motor de reglas. Se integra con la red del ambiente para llegar a la torre

La alerta vive en Azure, junto a la plataforma. Fabric lee las mismas lecturas para el aviso temprano predictivo y los análisis de la torre, pero no está en el camino de la alerta: así la alerta no depende de que una capacidad de Fabric esté encendida de noche.

Por qué las alertas pasan por un event hub. Microsoft indica que Stream Analytics, en su clúster compartido, no puede llamar a una función que está dentro de una red virtual, y la función notificadora lo está para llegar a la torre. Por eso Stream Analytics escribe cada alerta en un event hub del mismo namespace que alimenta el mapa de la torre (sección 5.2), y la función la lee por el endpoint privado. Así la función no tiene ninguna entrada pública, y si se detiene un momento las alertas esperan en el event hub, que las guarda hasta 7 días, en vez de perderse. El namespace Standard admite hasta 10 event hubs, así que el de alertas no suma un costo fijo.

Alternativa descartada: todo en funciones. Una función podría leer cada lectura y evaluar las reglas. Es más barata en cómputo, pero obliga a programar a mano lo que Stream Analytics ya resuelve: el estado de cada sensor, las lecturas repetidas, la detección de silencio y la recuperación sin perder alertas.

3.3 Reglas de alerta

Alerta	Cuándo se dispara	Severidad
Posible excursión	La primera lectura fuera del rango del cuarto frío o de la carga	Alta: se avisa de inmediato
Excursión confirmada	La segunda lectura seguida fuera de rango	Crítica: se escala si nadie respondió
Vuelta al rango	La primera lectura dentro del rango después de una excursión	Informativa: cierra la alerta y registra la duración
Puerta abierta	Una puerta lleva abierta más del tiempo permitido (supuesto: 5 minutos en cuartos fríos, 15 en camiones)	Alta
Sensor sin señal	No llega ninguna lectura de un sensor en el tiempo de tres lecturas: 90 s en los cuartos	Alta

Alerta	Cuándo se dispara	Severidad
	fríos y en los camiones con viaje activo (por la posición, que llega cada 30 s)	
Excursión tardía	Una lectura atrasada (por falta de señal) muestra una excursión que ya ocurrió	Alta, marcada con la hora real del evento

Por qué se avisa con la primera lectura. Esperar una segunda lectura para descartar ruido del sensor costaría 60 segundos en los camiones y rompería el minuto. Por eso la primera lectura fuera de rango ya avisa, como posible excursión, y la segunda la confirma y la escala. Calidad puede ajustar esta regla por tipo de carga si un sensor resulta ruidoso.

Rangos por cuarto frío y por carga. Los rangos permitidos viven en una tabla de referencia que mantiene el equipo de calidad: un rango por cuarto frío y uno por tipo de carga, que se asigna al camión con la guía o el viaje. Cada rango tiene además un margen de aviso: con él, Stream Analytics calcula los umbrales que usa el aviso temprano de Fabric. Stream Analytics recarga esa tabla sin detenerse.

Orden por hora de llegada. Stream Analytics solo emite resultados cuando avanza su reloj interno. Si ordenara las lecturas por la hora del sensor, tendría que esperar la tolerancia a lecturas tardías antes de emitir; Microsoft sugiere empezar con 5 minutos para dispositivos de campo, lo que rompería el minuto. Por eso las reglas ordenan por la hora en que IoT Hub recibió la lectura, y usan la hora del sensor como dato: la alerta muestra cuándo ocurrió el evento, y si la diferencia entre las dos horas es grande, la marca como tardía. Los cuartos fríos envían las 24 horas, así que el reloj del procesamiento siempre avanza, también de noche.

3.4 Destinatario según la hora

Hora de Colombia	Quién recibe	Por qué canal	Si nadie responde
04:00 a 22:00	La torre de control	Consola de la torre y canal de Teams de la torre. Copia al canal de calidad	A los 5 minutos, al supervisor de turno de la torre y al responsable de calidad
22:00 a 04:00	El turno de guardia de calidad	Teams en el teléfono, correo y SMS	A los 5 minutos, al responsable de calidad. A los 15, al gerente de operaciones

- La hora de corte se calcula en el código con la hora de Colombia (UTC-5, sin horario de verano). El plan Flex Consumption no admite configurar la zona horaria del sistema, así que no se depende de ella.
- El turno de guardia y sus teléfonos viven en una tabla que mantiene calidad, para cambiar quién está de guardia sin tocar el código.
- Cada alerta tiene un estado: abierta, reconocida, cerrada. El acuse se registra desde la consola de la torre o desde la tarjeta de Teams, con la identidad de quien respondió. Ese registro sirve para los reclamos y para auditar quién vio qué.

3.5 Canales

Canal	Para qué	Cómo se envía	Nota
Consola de la torre	Ver la alerta en la pantalla de despacho, sobre el mapa	La función notificadora llama a la API interna de la torre, que la muestra en vivo a los usuarios conectados	Mostrar la alerta en pantalla es parte de la aplicación de la torre
Microsoft Teams	Aviso en el computador y en el teléfono, con notificación	Webhook de Workflows de Teams hacia el canal o el chat del turno	Los conectores de Office 365 en Teams se retiraron en mayo de 2026; Workflows es su reemplazo. Requiere que FríoAndes use Microsoft 365
Correo	Constancia y respaldo	Azure Communication Services, servicio de correo	

Canal	Para qué	Cómo se envía	Nota
SMS	Respaldo para el turno de noche si el teléfono no tiene datos	Un proveedor de SMS con cobertura en Colombia	Azure Communication Services no envía SMS directo a Colombia: sus números gratuitos solo llegan a Estados Unidos, Canadá y Puerto Rico, y para otros países Microsoft remite a proveedores asociados (Messaging Connect). El proveedor lo confirma FríoAndes

El cliente corporativo no recibe alertas en tiempo real: ve el estado de sus cargas en su vista del portal (sección 5).

3.6 Dónde corre la función notificadora

- **Plan Flex Consumption con dos instancias siempre listas**, de 512 MB, asignadas a la función que lee el event hub de alertas. Las instancias siempre listas evitan el arranque en frío, que podría sumar segundos a la primera alerta de la noche. Con dos instancias, Azure permite repartirlas entre zonas de disponibilidad.
- **El primer aviso sale apenas llega la alerta**, desde esa misma función. El estado de cada alerta (abierta, reconocida, cerrada) y el escalamiento a los 5 y a los 15 minutos los lleva una orquestación de Durable Functions, que espera con temporizadores y se cierra cuando alguien reconoce la alerta. La orquestación usa el identificador de la alerta como nombre: antes de abrir una, la función revisa si ya existe, y así descarta las alertas repetidas que Stream Analytics puede entregar más de una vez.
- **Cuenta de almacenamiento propia.** Toda función necesita una, y Durable Functions guarda ahí el estado y los temporizadores. Es ZRS, porque con redundancia de zonas Azure solo admite cuentas ZRS, y tiene el acceso público desactivado, con endpoints privados de blob, queue y table en `snet-data-pe`.
- **Integrada a la red del ambiente**, para llamar a la API interna de la torre y leer el event hub sin salir a internet. Necesita una subred propia: Microsoft pide al menos un `/27`, reservada para el plan (delegación `Microsoft.App/environments`), y no permite compartirla con un entorno de Container Apps ni poner en ella endpoints privados. Se crea `snet-telemetry-func` en `10.10X.3.0/27` de cada ambiente, dentro del espacio que el plan de direcciones dejó libre para el cómputo de la telemetría.
- **Salida a internet por el Azure Firewall**, solo hacia los canales y los servicios que la función necesita:

Destino	Dominios	Regla del firewall
Webhook de Workflows de Teams	`*.api.powerplatform.com` y `*.logic.azure.com`, los que Microsoft indica para el disparador HTTP de Workflows	FW-319, FW-320 y FW-321 (uno por ambiente)
Correo de Azure Communication Services	`<recurso>.communication.azure.com`	Las mismas
Proveedor de SMS	Los que indique el proveedor que elija FríoAndes	Las mismas
Entra ID e identidades administradas	Los mismos de las demás aplicaciones	FW-302, FW-308 y FW-314
Azure Monitor	Etiqueta de servicio `AzureMonitor`	FW-304, FW-310 y FW-316

3.7 Capacidad y campaña

- **Stream Analytics: se espera 1/3 de unidad de streaming (V2) en producción.** Microsoft recomienda empezar con 1 unidad y ajustar con la métrica de uso, e indica que 1/3 suele bastar para entradas pequeñas; el caso tiene unos 10 mensajes por segundo en campaña. La memoria que usa el estado de las reglas depende de la cantidad de sensores (unos 210 en campaña), no del volumen. La prueba de carga de campaña en pruebas arranca con 1 unidad, mide el uso y fija el tamaño de producción. Se alerta si el uso pasa del 80 %, y el tamaño se puede cambiar sin detener el trabajo.

- **IoT Hub con dos unidades** cubre la campaña (sección 2.3).
- **La función notificadora** solo procesa alertas, no lecturas: decenas al día en operación normal.

Ninguna pieza del camino de la alerta necesita un cambio para la campaña. Eso importa porque durante una campaña no se hacen cambios en producción.

3.8 Pruebas y desarrollo

El mismo trabajo de Stream Analytics y la misma función se despliegan en pruebas y desarrollo, conectados al simulador de cada ambiente. En pruebas se valida el presupuesto de la sección 3.1 con la prueba de carga de campaña. Los trabajos de Stream Analytics de pruebas y desarrollo se detienen cuando no se usan, y un trabajo detenido no se cobra.

---

4. Historial y reclamos

4.1 Qué se guarda y para qué

Uso	Qué necesita	Por cuánto tiempo
Reclamo de un cliente	Todas las lecturas de la carga o del cuarto frío en el período del reclamo, las alertas que se generaron y quién las reconoció, sin posibilidad de alteración	Cinco años, por contrato con los clientes de alimentos
Reportes a clientes y tableros de calidad	Lecturas con el contexto de negocio: cuarto frío, camión, guía y cliente	Cinco años
Aviso temprano y estimación de llegada en Fabric	Historial de lecturas y posiciones para los modelos	Los mismos cinco años: Fabric los lee con un atajo, sin copiarlos (`fabric-workspaces-ingesta-region.md`, sección 5)

Con unos 15 GB al mes, el historial completo de cinco años es de unos 900 GB. El tamaño es pequeño. Lo que importa es que la evidencia no se pueda alterar, que no se pague dos veces por guardarla y analizarla, y que Fabric la lea sin copiarla.

4.2 Dónde se guarda: el historial vive en el lago de datos de Azure

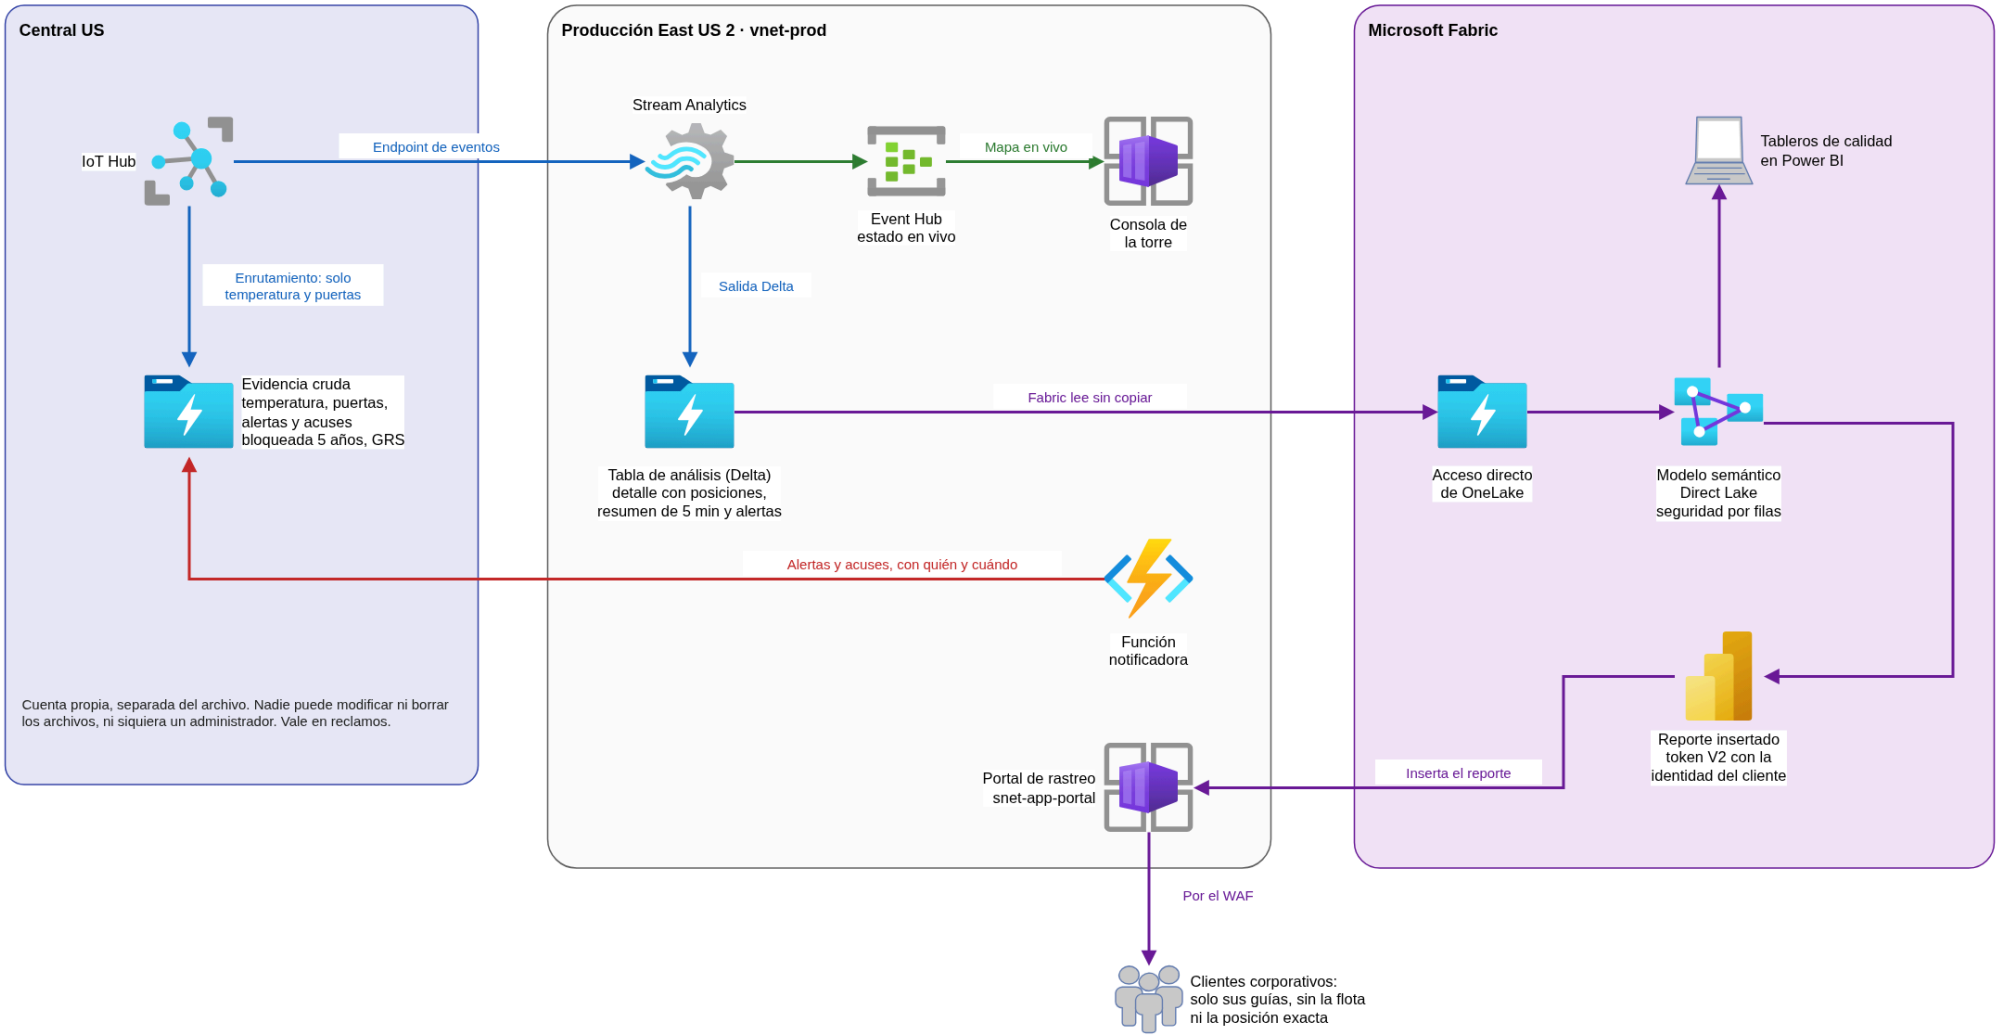
	Lago de datos en Azure (propuesta)	Azure Data Explorer	Eventhouse de Fabric con los cinco años
Qué es	Archivos en Azure Data Lake Storage Gen2: una copia de evidencia inmutable y una tabla Delta para análisis	Un clúster de base de datos de series de tiempo en Azure	La base de series de tiempo de Fabric, con el mismo motor de consultas que Data Explorer
Costo de guardar 5 años	Menos de USD 40 al mes al final del quinto año, sumando las dos copias	El clúster de producción más pequeño tiene al menos dos nodos: solo el recargo del motor son unos USD 321 al mes, más las máquinas	El consumo de la capacidad de Fabric, que debe quedar encendida para recibir datos día y noche
Evidencia inalterable	Sí: contenedor con retención bloqueada por cinco años	No es su función	No es su función
Cómo lo usa Fabric	Lo lee en su lugar, con un acceso directo de OneLake, sin copiar	Con un acceso directo de base de datos	Es Fabric
Pagar dos veces	No: Fabric lee lo que ya está en Azure	Sí, si Fabric también guarda la telemetría	No, pero la evidencia queda dentro de la capacidad de Fabric

Por qué el lago. Guardar cinco años de telemetría en archivos cuesta centavos por GB y no exige un motor encendido. La consulta rápida y los tableros los hace Fabric, que la plataforma usa de todos modos para la inteligencia artificial de la torre, leyendo los mismos archivos. Así hay un solo lugar donde vive el historial y un solo motor que lo analiza.

La opción "Synapse" de la tarjeta ya no aplica. Microsoft retiró Synapse Data Explorer el 7 de octubre de 2025 y remite a Eventhouse de Fabric.

4.3 Las dos copias del lago

Telemetría: historial de cinco años y tableros



Azul: lecturas. Verde: estado en vivo. Rojo: alertas. Morado: lectura de Fabric. Cinco años de detalle son unos 890 millones de filas; el resumen de 5 minutos, unos 64 millones, queda bajo el tope de Direct Lake de las capacidades pequeñas (300 millones de filas por tabla en F2 a F32). Los tableros usan el resumen.

Figura 17: Historial de cinco años y tableros

	Evidencia cruda	Tabla de análisis
Qué contiene	Cada mensaje de temperatura y de puerta tal como llegó a IoT Hub, con la identidad del dispositivo y la hora de llegada. Además, cada alerta y cada acuse con quién y cuándo. Las posiciones de los camiones no van aquí	Cada lectura con su contexto: cuarto frío o camión, guía, cliente, rango aplicado y si generó alerta. También las posiciones de los camiones, ligadas a la guía y al viaje
Quién la escribe	IoT Hub, con su enrutamiento a almacenamiento, en JSON. La ruta filtra por el tipo de mensaje (`$body.tipo`), que IoT Hub puede leer porque cada mensaje va marcado como JSON. La función notificadora agrega las alertas y los acuses	Stream Analytics, con su salida nativa a tablas Delta. Las tablas se crean antes de arrancar el trabajo, sin la propiedad de solo agregar y sin deletion vectors: si las crea Stream Analytics quedan de solo agregar y no se podrían borrar las posiciones
Formato	Archivos JSON por lote, con la ruta de IoT Hub (hub, partición, año, mes, día, hora y minuto)	Tabla Delta (archivos Parquet con su registro de transacciones), que Fabric reconoce como tabla
Protección	Contenedor con política de retención por tiempo, bloqueada, de cinco años: nadie puede modificar ni borrar los archivos, ni siquiera un administrador	Contenedor normal: la tabla necesita mantenimiento periódico (compactar archivos y limpiar los viejos), que no se puede hacer en un contenedor inmutable
Región	Central US, junto a IoT Hub. Con redundancia geográfica, la copia secundaria queda en East US 2	East US 2, junto al resto de la plataforma
Uso	Reclamos y auditoría. Es la fuente que vale si hay disputa	Tableros, reportes y Fabric

Por qué la evidencia la escribe IoT Hub y no Stream Analytics. Si el procesamiento de la alerta falla o tiene un error de lógica, la evidencia igual queda completa, porque la escribe el servicio de ingesta sin transformar nada. Al crear esa ruta se crea también una ruta al endpoint de eventos de IoT Hub: Microsoft indica que, en cuanto existe una ruta, los mensajes dejan de llegar al endpoint de eventos si no hay una ruta hacia él, y de ese endpoint lee Stream Analytics.

Por qué dos copias no es pagar dos veces. Las dos son archivos en almacenamiento de bajo costo y suman menos de USD 40 al mes al final de los cinco años. Lo que se evita es mantener un segundo motor de base de datos encendido.

4.4 Retención y borrado

- **Política bloqueada.** El contenedor de evidencia usa una política de retención por tiempo a nivel de contenedor, que es la que Azure admite en cuentas de Data Lake. Se prueba sin bloquear (incluido que el enrutamiento de IoT Hub escriba sin errores en el contenedor protegido) y se bloquea antes de recibir datos reales; Microsoft recomienda bloquearla en menos de 24 horas. Una política bloqueada se puede alargar, pero no acortar ni borrar.
- **Cuenta separada del archivo.** La evidencia de telemetría vive en Central US, con espacio de nombres jerárquico y su propia política, y la escribe IoT Hub. Las cuentas del archivo histórico están en East US 2, sin espacio de nombres jerárquico, porque las siembra Import/Export (`carga-c-siembra-1-2pb.md`). Por eso la telemetría tiene su propia cuenta.
- **Niveles de acceso.** Los archivos pasan de Hot a Cool a los 30 días y a Cold a los 180, con la política de ciclo de vida de la cuenta. Azure permite cambiar el nivel de acceso de archivos inmutables.
- **Borrado.** Al vencer los cinco años, el ciclo de vida borra los archivos. Antes de eso, nadie puede borrarlos.
- **Datos personales.** La posición de un camión identifica al conductor. Si estuviera en la copia inmutable, nadie podría borrarla en cinco años, ni siquiera por orden de la SIC. Por eso las posiciones van solo a la tabla de análisis, que se puede corregir y borrar, y la copia inmutable guarda la temperatura, las puertas, las alertas y los acuses. El contrato con los clientes de alimentos obliga a conservar las evidencias y la trazabilidad de temperatura; la posición no forma parte de esa obligación. El diseño de datos personales y perímetro (`seguridad-datos-personales-perimetro.md`, sección 3.5) concilia la retención contractual con los derechos del titular bajo la Ley 1581.

4.5 Acceso privado

- **Solo dos servicios escriben por el endpoint público.** El acceso público de las dos cuentas queda "habilitado desde redes seleccionadas", sin redes ni direcciones IP permitidas, con una regla de instancia para el IoT Hub (cuenta de evidencia) y otra para el trabajo de Stream Analytics (cuenta de análisis). Los dos escriben con su identidad administrada: Microsoft los incluye entre los servicios que pueden entrar así. Azure no admite estas reglas si el acceso público se desactiva del todo: en ese caso solo entra tráfico por endpoint privado, y ni IoT Hub ni Stream Analytics podrían escribir.
- **Todo lo demás entra por endpoints privados** (blob y dfs) en `snet-archive` de producción: la función notificadora, que agrega alertas y acuses a la evidencia, y los equipos de operación. Son 4 endpoints que se suman a los del archivo y las evidencias, dentro de los 10 de la subred. Azure permite que el endpoint privado esté en otra región que la cuenta, como ocurre con la evidencia en Central US.
- La tabla de rangos que lee Stream Analytics (sección 3.3) vive en la cuenta de análisis, con el mismo acceso.
- Microsoft Fabric entra a la cuenta de análisis con una regla de instancia que nombra solo su espacio de datos, con acceso de confianza (`fabric-workspaces-ingesta-region.md`, sección 3). La cuenta de evidencia no tiene regla para Fabric: Fabric no la lee.

4.6 Los 40 TB de históricos de temperatura

Hoy los centros envían archivos de temperatura cada hora a Cali, y el archivo guarda 40 TB de esos históricos. La telemetría en línea no llega a 1 TB en cinco años, así que esos 40 TB deben tener otro contenido o formato. Es la pregunta 8 de la sesión de aclaraciones.

- **Viajan con el resto del archivo** en la siembra del archivo histórico. No se copian a la tabla de análisis por defecto.
- **Si un reclamo o un reporte necesita los años anteriores**, se convierte una sola vez la parte que siga dentro de los cinco años de retención al formato de la tabla de análisis. Lo que tenga más de cinco años depende de lo que FríoAndes responda sobre la retención (pregunta 1).
- **El envío por FTP de cada centro se apaga** cuando sus cuartos fríos ya envían en línea a IoT Hub. Ese es el momento de retirar la regla temporal FW-402 de ese centro.

4.7 Costo del historial

Copia	Cálculo al final del quinto año (unos 900 GB cada una)	USD al mes
Evidencia (Central US, redundancia geográfica)	900 GB en Cool GRS a USD 0,02 (la mayor parte estará en Cold, a 0,008)	Hasta 18
Tabla de análisis (East US 2, redundancia local)	900 GB en Hot LRS a USD 0,0184	Hasta 17
Total		**Hasta unos 35**

El primer año cuesta mucho menos, porque el historial crece de a 15 GB por mes. Las operaciones de escritura y lectura se suman en el cálculo de costos de la plataforma.

---

5. Tableros

5.1 Quién ve qué

Quién	Qué necesita	Dónde lo ve	Frescura
Torre de control	Alertas en el momento y mapa de la flota en ruta	En la consola de la torre	Segundos
Equipo de calidad	Estado de cuartos fríos y camiones, excursiones y su duración, alertas y tiempos de respuesta, sensores sin señal, reportes por cliente y material para reclamos	Tableros de Power BI en Fabric	Unos minutos

Quién	Qué necesita	Dónde lo ve	Frescura
Cliente corporativo	El estado y la temperatura de sus propias guías, sin ver la flota	Vista dentro del portal de rastreo	Unos minutos

La alerta en el momento no depende de ningún tablero: llega por la consola y por Teams (sección 3). Los tableros sirven para seguir, analizar y responder reclamos.

5.2 La torre: alertas y mapa en vivo

La consola de la torre es parte de la plataforma logística. La telemetría le entrega dos cosas:

- **Las alertas**, por la API interna de la torre, desde la función notificadora (sección 3.5).
- **El estado en vivo de la flota y de los cuartos fríos** (última posición, última temperatura y estado de cada sensor), por un Event Hub que alimenta Stream Analytics y que el servicio de la torre lee para actualizar el mapa. Un Event Hub Standard con una unidad de rendimiento cuesta USD 21,90 al mes, más unos USD 0,40 por los unos 14,6 millones de eventos mensuales. El namespace tiene el acceso público desactivado: Stream Analytics escribe como servicio de confianza, con su identidad administrada, y la torre y la función notificadora leen por un endpoint privado en `snet-data-pe`. El mismo namespace tiene el event hub de alertas (sección 3.2). Cada evento del estado lleva además los dos umbrales de aviso del sensor, que alimentan el aviso temprano de Fabric: un Eventstream lo lee con su propio grupo de consumidores (`fabric`) por un endpoint privado administrado que el namespace aprueba (`fabric-acceso-casos-uso-costo.md`, sección 3).

El mapa de la torre no se construye sobre un reporte de Fabric: necesita frescura de segundos y no debe depender de que una capacidad de Fabric esté encendida. La estimación de hora de llegada que la torre muestre la define `fabric-acceso-casos-uso-costo.md`.

5.3 Los datos de los tableros: una tabla resumida

Los tableros de Fabric leen la tabla de análisis con Direct Lake, que toma los archivos del lago sin copiarlos y se actualiza solo cuando llegan datos nuevos. Pero Microsoft fija topes por tabla según el tamaño de la capacidad:

Capacidad de Fabric	Filas por tabla	Archivos Parquet por tabla
F2 a F32	300 millones	1.000
F64	1.500 millones	5.000

Cinco años de lecturas son unos 890 millones de filas, por encima del tope de las capacidades pequeñas. Por eso Stream Analytics escribe, además del detalle, una **tabla resumida**:

Tabla	Qué contiene	Filas en cinco años	Quién la usa
Detalle	Cada lectura con su contexto (sección 4.3)	Unos 890 millones	Reclamos y análisis puntual, consultados por guía o por cuarto frío y por fecha, con el endpoint SQL de Fabric
Resumen de 5 minutos	Por sensor y por intervalo de 5 minutos: temperatura mínima, máxima y promedio, minutos fuera de rango, puertas abiertas y lecturas recibidas	Unos 64 millones	Todos los tableros
Alertas	Cada alerta con su ciclo: cuándo se abrió, quién la reconoció, cuándo se cerró	Miles	Tableros de calidad y reportes de tiempos de respuesta

El resumen queda muy por debajo del tope incluso en la capacidad más pequeña. Stream Analytics escribe archivos pequeños con frecuencia, así que las tablas necesitan una compactación diaria para no pasar el tope de archivos. Esa tarea, con el VACUUM y el borrado a los cinco años, la hace cada noche un cuaderno de Fabric a través del atajo (`fabric-workspaces-ingesta-region.md`, sección 5.3).

5.4 Tableros de calidad

Tablero	Contenido
Estado actual	Cada cuarto frío y cada camión en ruta con su última temperatura, su rango y su estado (normal, advertencia, excursión, sin señal), con los colores de estado del sistema de diseño
Excursiones	Excursiones por centro, por cliente y por tipo de carga, con su duración y temperatura máxima
Respuesta a alertas	Tiempo hasta el reconocimiento por turno (torre de día, guardia de noche), alertas escaladas y alertas sin reconocer
Salud de los sensores	Sensores sin señal, lecturas perdidas por número de secuencia y lecturas tardías por falta de señal
Reportes por cliente	El historial de temperatura de las guías de un cliente en un período, listo para enviar o para un reclamo

Licencias. Los usuarios internos que ven reportes de Power BI necesitan licencia Pro si la capacidad de Fabric es menor que F64; con F64 o más, basta la licencia gratuita con rol de lector. El tamaño de la capacidad lo decide `fabric-acceso-casos-uso-costo.md` con esta regla a la vista.

5.5 Vista del cliente corporativo

- **Qué ve.** Solo sus guías: estado, temperatura a lo largo del viaje o de la permanencia en bodega, excursiones y cuándo se resolvieron. No ve la flota, otros clientes, ni la posición exacta del camión; el avance del viaje se muestra con la hora estimada de llegada que calcula Fabric (`fabric-acceso-casos-uso-costo.md`).
- **Dónde lo ve.** Dentro del portal de rastreo, con un reporte de Power BI insertado en modo "la aplicación es dueña de los datos": el portal autentica al cliente con su propio inicio de sesión y pide a Power BI un token de inserción. Los clientes no necesitan licencia de Power BI.
- **Cómo se limita a sus datos.** El modelo semántico tiene seguridad por filas por cliente, y el portal pone la identidad del cliente en el token de inserción. Así, aunque los 2.000 clientes usan el mismo reporte, cada uno solo ve sus filas. Con Direct Lake, Microsoft pide un token de inserción V2 y una conexión con identidad fija. El modelo lee solo `cliente_guias`, una tabla curada por guía, sin posición, camión, conductor ni video (`fabric-acceso-casos-uso-costo.md`, sección 2.3).
- **Disponibilidad.** Los reportes insertados funcionan mientras la capacidad de Fabric está encendida. Si `fabric-acceso-casos-uso-costo.md` apaga o reduce la capacidad de noche, la vista del cliente se ve afectada en esas horas; esa decisión se toma allí con este efecto a la vista.

---

6. Operación, objetivo de servicio y costo

6.1 Cómo se mide el objetivo de la alerta

La plataforma tiene dos objetivos de servicio, y uno es la oportunidad de la alerta de temperatura. El diseño de observabilidad fija el objetivo (`observabilidad-slo-zabbix.md`, sección 5.3); esta sección define cómo se mide.

Elemento	Definición
Indicador	Porcentaje de alertas de excursión cuya diferencia entre la hora de la lectura del sensor y la hora en que la alerta queda visible es de 60 segundos o menos
"Visible"	La API de la torre confirma que recibió la alerta (de día) o Teams acepta el mensaje (de noche). La función notificadora registra esa hora
Exclusiones	Las alertas tardías: lecturas que llegaron atrasadas por falta de señal, porque el minuto aplica en condiciones normales de red. Se identifican por la diferencia entre la hora del sensor y la hora de llegada a IoT Hub: más de 25 segundos, porque el resto del camino tiene un presupuesto de 35
Objetivo	99 % de las alertas en 28 días, contando las reales y las sintéticas

Cada alerta guarda cinco marcas de tiempo: lectura en el sensor, llegada a IoT Hub, salida de Stream Analytics, envío del notificador y confirmación del canal. Así, si el objetivo se incumple, se sabe en qué tramo del presupuesto (sección 3.1) se perdió el tiempo.

Alerta sintética. Las excursiones reales deberían ser pocas, y un objetivo medido solo con ellas puede pasar semanas sin datos. Por eso un sensor de prueba, registrado en IoT Hub de producción como un dispositivo más, envía cada 15 minutos una lectura fuera de rango marcada como sintética. Recorre el mismo camino que una alerta real, pero el notificador la envía a un canal de monitoreo y no a la torre ni a la guardia. Si una alerta sintética no llega en un minuto, operación recibe un aviso. Son 96 mensajes al día, sin costo apreciable.

6.2 Señales de salud del camino de la alerta

Componente	Señal	Por qué
IoT Hub	Dispositivos conectados, errores por límite de envío, salud y latencia de las rutas	Una caída de dispositivos conectados es el primer síntoma de un problema de red en un centro o en el operador de flota
Stream Analytics	Retraso de la marca de agua, eventos acumulados sin procesar y uso de la unidad de streaming	El retraso de la marca de agua es el retraso del procesamiento: si sube, la alerta llega tarde
Event hub de alertas	Alertas acumuladas sin leer	Si crece, la función no está leyendo y las alertas no salen
Función notificadora	Ejecuciones fallidas y fallas de envío por canal	Una alerta que no sale por ningún canal es una alerta perdida
Alerta sintética	Llegada en menos de un minuto	Mide el camino completo, de punta a punta

Estas señales se integran al diseño de observabilidad de la plataforma (`observabilidad-slo-zabbix.md`, secciones 4.4 y 6), que define dónde se ven y a quién avisan.

6.3 Campaña

Elemento	Operación normal	Campaña (180 camiones)	Cambio necesario
Mensajes al día	Unos 486.000	Unos 682.000	Ninguno: dos unidades S1 reciben 800.000
Stream Analytics	1/3 de unidad (a confirmar con la prueba de carga)	El mismo tamaño, validado en la prueba de carga de campaña	Ninguno
Función notificadora	Decenas de alertas al día	Proporcional a la flota	Ninguno: escala sola
Historial	Unos 15 GB al mes	Unos 20 GB al mes durante la campaña	Ninguno

La telemetría de campaña se dimensiona con los 180 camiones; el 40 % adicional aplica solo a la capa de aplicación. Ningún componente de la telemetría cambia de tamaño en campaña, así que el mes de campaña cuesta prácticamente lo mismo que uno normal. Esto importa porque durante una campaña no se hacen cambios en producción.

6.4 Costo mensual de producción

Precios de lista en East US 2 y Central US, con 730 horas al mes.

Componente	Cálculo	USD al mes
IoT Hub S1, 2 unidades (Central US)	2 × 25	50,00
Servicio de aprovisionamiento de dispositivos	USD 0,10 por 1.000 operaciones, unos cientos al mes	Menos de 0,10
Stream Analytics, 1/3 de unidad V2	243,3 horas-unidad × 0,33	80,30
Función notificadora, 2 instancias siempre listas de 512 MB	2 × 0,5 GB × 2.628.000 s × 0,000004	10,51

Componente	Cálculo	USD al mes
Event Hub del estado en vivo y de las alertas	21,90 + 14,6 millones de eventos × 0,028 por millón (las alertas son decenas al día)	22,31
Cuenta de almacenamiento de la función (ZRS)	Pocos GB a USD 0,023; operaciones de Durable Functions a USD 0,004 por 10.000 en queue y USD 0,0625 por 10.000 escrituras en blob	Se mide en pruebas
Transferencia entre Central US y East US 2	Unos 15 GB × 0,02	0,30
Historial (las dos copias)	Sección 4.7	De unos 3,50 el primer año hasta unos 35 al quinto
Total		**De unos 167 a unos 199, más la cuenta de la función**

No incluye la capacidad de Fabric ni las licencias de Power BI, que van aparte en el costo de Fabric, ni el proveedor de SMS, que depende de la cotización. Correo y Teams tienen costo despreciable para este volumen.

Pruebas y desarrollo. IoT Hub S1 de una unidad en pruebas (USD 25) y gratuito en desarrollo. Stream Analytics y la función se pagan solo mientras corren las pruebas.

6.5 Decisiones que bajan o evitan gasto

Decisión	Alternativa descartada	Ahorro al mes
Historial en el lago de datos, leído por Fabric sin copiar	Un clúster de Azure Data Explorer de producción	Más de USD 321 (solo el recargo del motor, sin contar las máquinas)
Stream Analytics de 1/3 de unidad, validado con la prueba de carga	Una unidad completa fija	USD 160,60
Tabla resumida para los tableros	Tableros sobre el detalle completo, que en menos de dos años exigiría una capacidad de Fabric F64 por los topes de Direct Lake	La diferencia entre una capacidad pequeña y una F64, que calcula el costo de Fabric
IoT Hub gratuito en desarrollo y Stream Analytics detenido fuera de las pruebas	Los mismos recursos encendidos todo el mes	USD 25 de IoT Hub y el costo de Stream Analytics fuera de las horas de prueba

---

7. Supuestos y confirmaciones pendientes de FríoAndes

7.1 Confirmaciones que necesita el diseño

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
El minuto de la alerta	¿El minuto se cuenta desde que el sensor mide o desde que la temperatura real pasa el límite?	El diseño lo cuenta desde la hora de la lectura (sección 3.1). Si fuera desde el cruce real del límite, con lecturas cada 60 s en los camiones ninguna arquitectura lo cumple, y habría que medir más seguido
Envío de los camiones	¿Los equipos de los camiones envían directo a la nube o la plataforma del operador de flota reenvía los datos?	Si reenvía el operador, los camiones entran por un Event Hub con las direcciones del operador (sección 2.9)
Equipos de los camiones	¿Los equipos hablan MQTT o AMQP con TLS, soportan certificados y pueden guardar al menos 18 horas de lecturas sin señal?	Sin certificados se usan claves simétricas por grupo (sección 2.5). Sin memoria

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
		suficiente, las lecturas de un corte largo se pierden
Equipos de los centros	¿Los sensores de los cuartos fríos se conectan uno por uno o hay un equipo que los reúne? ¿Cómo se reportan las aperturas de puerta?	Con sensores antiguos se agrega un recolector con IoT Edge por centro (sección 2.8). El volumen de puertas cambia poco el total
Tiempos de puerta abierta	¿Cuánto tiempo puede estar abierta una puerta antes de alertar?	El diseño usa 5 minutos en cuartos fríos y 15 en camiones. Calidad lo cambia en la tabla de referencia, sin tocar el código
Cadena de escalamiento	¿Quién es el supervisor de turno de la torre, el responsable de calidad y el gerente de operaciones que reciben las alertas escaladas?	Cambian los destinatarios de la sección 3.4, que viven en una tabla que mantiene calidad
Microsoft 365	¿FríoAndes usa Microsoft 365 y Teams?	Sin Teams, el aviso de noche se apoya en correo y SMS, y la torre en su consola
Proveedor de SMS	¿Qué proveedor de SMS con cobertura en Colombia usará FríoAndes y con qué dominios?	Sus dominios completan FW-319, FW-320 y FW-321
Históricos de temperatura	¿Qué contienen los 40 TB de históricos, si la telemetría en línea no llega a 1 TB en cinco años? ¿Se conserva lo que pasa de cinco años?	Define si una parte se convierte al formato de la tabla de análisis (sección 4.6)
Ubicación de los datos	¿Se acepta que la telemetría, incluida la posición de los camiones, quede en Estados Unidos (Central US y East US 2)?	Si no, cambian la región de IoT Hub y del historial

7.2 Supuestos del diseño

Supuesto	Por qué se asume
Cada cuarto frío registra unas dos aperturas de puerta por hora y cada camión unas diez paradas al día, con un mensaje al abrir y otro al cerrar	No hay una cifra conocida. Aunque fuera diez veces mayor, seguiría siendo una parte menor del total (sección 1.3)
Cada mensaje pesa alrededor de 1 KB	El mismo valor del diseño de red. Un mensaje de hasta 4 KB cuenta como uno en IoT Hub
Los camiones operan una jornada de 18 horas	Define el volumen de los camiones y el tiempo mínimo que el equipo guarda lecturas sin señal
Un equipo por camión envía temperatura, posición y puerta	Una identidad por camión en IoT Hub. Si hubiera un equipo por sensor, aumenta la cantidad de identidades pero no el volumen
La torre de control opera de 04:00 a 22:00, hora de Colombia (UTC-5, sin horario de verano), y de noche recibe la guardia de calidad	Es el horario de operación de la torre. La función calcula la hora en su código
El objetivo de la alerta es el 99 % de las alertas visibles en 60 segundos o menos, medido en 28 días	Lo fija el diseño de observabilidad (`observabilidad-slo-zabbix.md`, sección 5.3). Se confirma con FríoAndes junto con la meta del portal
Stream Analytics trabaja con 1/3 de unidad de streaming en producción	Lo confirma la prueba de carga de campaña en pruebas, que arranca con 1 unidad (sección 3.7)
Las operaciones de la cuenta de la función se miden en pruebas	Dependen de cómo trabaja Durable Functions con el volumen real de alertas. Con el dato se completa el costo de la sección 6.4
Pruebas y desarrollo usan sensores simulados	No se llevan datos reales a ambientes con menos controles

Supuesto	Por qué se asume
Los costos son precios de lista en East US 2 y Central US, con 730 horas al mes, sin descuentos ni reservas	Es la base común del cálculo de costos de la plataforma
La plataforma de contenedores es Container Apps con perfiles de carga	Lo mismo que el diseño de red. La función notificadora no puede compartir subred con un entorno de Container Apps, por eso tiene la suya

Estrategia de migración del núcleo y escenario de campaña (Carga C)

Este documento define cómo se pasa del núcleo que hoy corre en el datacenter de Cali a la plataforma logística nueva (`carga-a-plataforma-logistica.md`): qué se mueve tal como está, qué se rehace, cómo se migra la base de datos, en qué fechas conviven los dos sistemas, cómo es el corte de dos horas y cuándo se apaga Cali. También dimensiona el escenario de campaña con las tres reglas del enunciado. Usa la red, el firewall, la telemetría y los datos personales ya diseñados, con sus mismos nombres y reglas.

Términos usados

Término	Qué significa aquí
Convivencia	El periodo en que Cali y Azure funcionan al mismo tiempo. Empieza el día 0 y dura como máximo 90 días
DMS	Azure Database Migration Service, el servicio que copia la base de Cali a MySQL Flexible Server y la mantiene al día hasta el corte
Carga inicial	La primera copia completa de la base. Después de ella, DMS solo aplica los cambios que van ocurriendo en Cali (replicación continua)
Corte	La ventana de hasta dos horas, en la madrugada de un domingo, en la que la base y el tráfico de despacho y rastreo pasan de Cali a Azure
Punto de no retorno	El momento del corte después del cual Azure recibe escrituras reales. Desde ahí, volver a Cali ya no es limpio
Plazo de vuelta atrás	Los días después del corte en que Cali se mantiene intacta, sin tráfico, como contingencia. Lo nombran también `red-firewall-y-publicacion.md` y la tabla de políticas
Congelamiento de esquema	Periodo en que no se cambia la estructura de la base de Cali (tablas, columnas, índices)
Rehost, replatform, reemplazar, reconstruir, retirar	Las cinco formas de migrar una pieza: moverla tal cual, moverla con ajustes de plataforma, cambiarla por un servicio administrado, rehacerla o apagarla

1. Contexto y alcance

1.1 Lo que hay hoy en Cali

El núcleo corre en 14 máquinas virtuales sobre VMware, en tres clústeres de dos servidores cada uno:

Clúster	Qué corre	Soporte
Datos	MySQL 5.7 en CentOS 7: producción (sin réplica, con un volcado nocturno a la 01:00 en el mismo clúster), desarrollo y pruebas. Redis 5 en CentOS 7	Fuera de soporte
Aplicación	4 máquinas Ubuntu 20.04 con Docker (2 de producción, 1 de desarrollo y 1 de pruebas), con los contenedores despacho, inventario, facturación corporativa, rastreo y evidencias. 2 máquinas con Nginx y 2 con el front, en Ubuntu 22.04	Ubuntu 20.04 solo con soporte extendido de pago

Clúster	Qué corre	Soporte
Transversal	FTP y NFS con el archivo de 1,2 PB, en CentOS 7. Zabbix en Ubuntu 20.04	Fuera de soporte, y el archivo no tiene copia fuera de ese servidor

1.2 Qué resuelve este documento

- La decisión de cada componente: qué se mueve tal cual durante la convivencia y qué se rehace en la plataforma nueva, sin pagar dos diseños más allá de los 90 días.
- La migración de la base de MySQL 5.7 a MySQL 8.4, con lo que exige del origen y de la aplicación.
- El calendario de la convivencia, con fecha de apagado de Cali, y cómo se acomoda a las campañas.
- El guion del corte de dos horas, que solo arrastra el diferencial transaccional y no los 1,2 PB.
- Qué significa volver atrás antes y después del corte.
- El dimensionamiento de campaña: +40 % solo en la capa de aplicación, el portal por 2.000 solicitudes por minuto y la telemetría por 180 camiones.

1.3 Qué toma de los otros diseños

Viene de	Qué se usa aquí
`carga-a-plataforma-logistica.md` (#12)	Container Apps con dos entornos por ambiente (torre y portal), MySQL Flexible Server 8.4 con alta disponibilidad zonal y réplica en Central US, Azure Managed Redis, Key Vault y Entra ID
`red-topologia-subnetting.md` (#8)	`snet-cali-integration` (`10.101.2.160/27`) para DMS y las máquinas de copia; la copia continua del archivo fuera del firewall (sección 6.3); el paso de cada centro a la conexión directa; la latencia medida desde Cali (sección 3)
`red-firewall-y-publicacion.md` (#9)	Los hitos de la convivencia (sección 5.1), las reglas temporales FW-401 a FW-504, el cambio de DNS del portal (sección 3.8) y el orden de apagado (sección 5.5)
`carga-b-telemetria.md` (#13)	IoT Hub, la alerta que no depende de Cali ni de Fabric, el retiro de la carga por lote de cada centro (sección 4.6) y la telemetría de campaña (sección 6.3)
`seguridad-datos-personales-perimetro.md` (#10)	Pruebas y desarrollo sin datos personales reales; el cliente ve sus guías, comprobantes y fotos, nunca la flota

1.4 Qué queda en otros diseños

- La siembra de los 1,2 PB y la copia continua del archivo, con sus cálculos: #15 (`carga-c-siembra-1-2pb.md`). Este documento solo fija cuándo deben estar listas.
- Las cifras de costo de la migración y del mes de campaña: #25 y #26. Aquí se dice qué se paga dos veces y por cuánto tiempo.
- El detalle de lo que vigila Azure Monitor y el apagado de Zabbix: #16. Aquí se fija la fecha.
- La plantilla de cambio de infraestructura, que usa este corte como ejemplo: #30.

2. Qué se mueve tal cual y qué se rehace

2.1 El criterio

El enunciado pide que los módulos actuales no queden como un segundo sistema permanente. La regla que sigue este documento es:

- **Lo que se mueve tal cual** a Azure es lo que ya está empaquetado de forma portátil: los contenedores. Llegan con la misma lógica y solo cambian su configuración.
- **Lo que se queda tal cual en Cali** durante la convivencia tiene una fecha de retiro dentro de los 90 días, escrita en la sección 6.
- **Lo que se rehace** se construye una sola vez, directamente en su forma final, para no pagar primero una copia de Cali y después el diseño definitivo. Es el caso de la base, la caché, el proxy, el monitoreo y la carga de temperatura.

2.2 Los cinco componentes de la aplicación

Los nombres son los del enunciado. La plataforma nueva organiza los servicios como los define la Carga A (guías, inventario, asignación de muelle y ruta, facturación corporativa), así que la tabla dice también dónde queda cada contenedor de hoy.

Contenedor de hoy	Decisión	Dónde queda en Azure	Por qué
despacho	**Se mueve tal cual** (replatform mínimo)	Entorno de la torre. Se separa en dos aplicaciones, guías y asignación de muelle y ruta, solo como despliegue: misma imagen y mismo código	Ya es un contenedor. Rehacerlo no aporta nada a la migración y alargaría el plan
inventario	**Se mueve tal cual**	Entorno de la torre	Ídem. No se expone en el portal
facturación corporativa	**Se mueve tal cual**	Entorno de la torre. El portal muestra solo la facturación del cliente que consulta, a través del servicio de rastreo	Ídem
rastreo	**Se mueve tal cual**	Entorno del portal, detrás del Application Gateway con WAF	Ídem. Su capacidad de campaña se calcula aparte (sección 7.3)
evidencias	**Se rehace la forma de leer y escribir archivos**; el resto del contenedor se mueve tal cual	Entorno de la torre. Lee y escribe en el almacenamiento de Azure con su identidad administrada, sin NFS	Container Apps solo monta recursos compartidos de Azure Files y no monta Blob Storage, donde vive el archivo (sección 2.4). Sin este ajuste, evidencias no puede correr en la plataforma nueva

Los cinco contenedores cambian juntos, en el corte. No se mueve módulo por módulo, por tres razones:

1. Los cinco comparten la misma base. Si un módulo pasara a Azure antes que la base, cada consulta cruzaría la VPN hasta Cali. La latencia medida desde Cali hasta East US 2 tiene una mediana de 85 a 97 ms por viaje de ida y vuelta (`red-topologia-subnetting.md`, sección 3.3): una pantalla que hace 20 consultas seguidas tardaría casi dos segundos solo en la red.
2. Una escritura en dos bases a la vez (Cali y Azure) exigiría una sincronización en los dos sentidos, que MySQL no ofrece entre 5.7 y 8.4 (sección 3.5).
3. Un solo corte es una sola ventana de riesgo, ensayada de punta a punta, en vez de cinco.

Antes del corte los cinco ya están desplegados en Azure, probados contra la base replicada y sin usuarios.

2.3 Las piezas de apoyo

Pieza de hoy	Decisión	Destino	Cuándo
2 máquinas con el front (Ubuntu 22.04)	**Se rehace el empaquetado**: el front pasa a un contenedor	Una aplicación de front en cada entorno de Container Apps	Desplegado antes del día 0; recibe usuarios en el corte
2 máquinas con Nginx	**Se reemplaza** por un servicio administrado	Application Gateway v2 con WAF (#9)	Recibe a los clientes en el corte; Nginx se apaga al cerrar el plazo de vuelta atrás
MySQL 5.7 de producción	**Se rehace** sobre MySQL Flexible Server 8.4, migrando los datos en línea con DMS	`snet-data` de producción	Replicación desde el día 5; cambia en el corte (sección 3)
MySQL 5.7 de desarrollo y de pruebas	**Se rehacen vacías**, con datos inventados	`snet-data` de desarrollo y de pruebas	Antes del día 0. No se migran: pruebas y

Pieza de hoy	Decisión	Destino	Cuándo
			desarrollo no llevan datos personales reales (#10)
Redis 5	**Se reemplaza** por Azure Managed Redis	`snet-data-pe`	No hay datos que mudar: es una caché y se llena sola con el primer tráfico
Servidor FTP y NFS con 1,2 PB	**Se retira**. Los datos se siembran antes y se mantienen al día con la copia continua (#15)	Cuentas de documentos y de video, con endpoint privado en `snet-archive`	La siembra por discos queda conciliada antes del ensayo (31 de enero); la copia continua corre desde el día 0 hasta la noche después del corte
Carga por lote de temperatura (FTP cada hora)	**Se queda tal cual en Cali** hasta que cada centro envía en línea, y después **se retira**	La reemplaza IoT Hub (#13)	Centro por centro, entre los días 8 y 19 (sección 4.3)
Zabbix	**Se queda tal cual en Cali** vigilando lo que sigue allí, y después **se retira**	Azure Monitor (#16)	Se apaga el día 61, con Cali
VMware (3 clústeres, 6 servidores)	**Se retira**	—	Día 62 (14 de marzo de 2027)

2.4 Ajustes que se piden al equipo de desarrollo

El enunciado permite pedir adaptaciones a la aplicación, justificadas y sin implementarlas en este reto. Todas tienen que estar terminadas y probadas en el ambiente de pruebas antes del día 0, porque durante la convivencia la base de Cali no admite cambios de esquema (sección 3.3).

Ajuste	Contenedores	Por qué lo exige la plataforma
Leer y escribir archivos con la API de Blob Storage y la identidad administrada, en vez de un montaje NFS	evidencias	Container Apps no monta Blob Storage. El nombre de cada archivo en Azure es su ruta relativa de hoy, así que la base no cambia
Funcionar con MySQL 8.4	Los cinco	La base pasa de 5.7 a 8.4 (sección 3.3)
Leer la configuración y los secretos de variables y de Key Vault, sin archivos locales	Los cinco	Las réplicas de Container Apps se crean y se destruyen solas
No guardar sesión ni archivos en el disco del contenedor	Los cinco	Ídem; una réplica nueva no tiene el disco de la anterior
Exponer un chequeo de salud por HTTP	Los cinco	Container Apps y el Application Gateway lo usan para sacar de servicio una réplica que falla
Emitir métricas, registros y trazas con OpenTelemetry	Los cinco	Lo usa la observabilidad (#16) y la validación del corte
Iniciar sesión con Entra ID en la consola	despacho, inventario, facturación corporativa, evidencias	MFA y acceso condicional para los 450 usuarios internos (#12, #7)
Filtrar por cliente todo lo que expone el portal	rastreo	Cada cliente ve solo sus guías, comprobantes, fotos y facturas (#10)
Un modo de mantenimiento que deje la aplicación de Cali en solo lectura y muestre un aviso en el portal	despacho, rastreo	Lo usa el corte para detener las escrituras sin apagar el servicio (sección 5.3)

Ajuste	Contenedores	Por qué lo exige la plataforma
Una exportación de las guías, movimientos de inventario y facturas creados después de una fecha	despacho, inventario, facturación corporativa	Es la única forma de volver a Cali después del punto de no retorno (sección 6.2)

3. La base de datos: de MySQL 5.7 a MySQL 8.4

3.1 Migración en línea con DMS

La base de producción se migra con **DMS en modo en línea**: una carga inicial y después la replicación continua de los cambios, leyendo el registro binario (binlog) de Cali, hasta el corte. Así, el corte no copia la base: solo espera a que la réplica alcance al origen y cambia el destino de la aplicación.

- **Nivel:** DMS Premium de 4 vCores, que es el que exige la migración en línea. Microsoft no lo cobra durante los primeros 183 días desde su creación, y la convivencia completa cabe en ese plazo.
- **Dónde corre:** en `snet-cali-integration` de producción, como ya lo reservó la red.
- **Por dónde pasa:** del servicio de migración a la base de Cali por el Azure Firewall y la VPN (FW-501, TCP 3306), y a la cuenta de almacenamiento temporal de la migración (FW-502). Las dos reglas se retiran en el corte.
- **Destino:** MySQL Flexible Server 8.4 de producción, en `snet-data`. Microsoft recomienda subirlo de tamaño mientras dura la carga inicial y bajarlo después. Ese cambio se hace en ventanas y no toca a Cali.

DMS admite como destino las versiones 5.7, 8.0 y 8.4, y migrar desde una versión menor a una mayor.

3.2 Lo que exige la base de Cali

Requisito de DMS	Qué se hace en Cali	Cuándo
Registro binario activo, en formato ROW	`log_bin` y `binlog_format=ROW` en el servidor de producción. Activar `log_bin` exige reiniciar MySQL	Ventana del día 1, en un reinicio de pocos minutos. Es la única intervención en la base de Cali antes del corte
Que el binlog no se borre antes de que DMS lo lea	`expire_logs_days=3`: tres días, para cubrir un fin de semana sin revisión	Día 1
Usuario de migración	Usuario con `REPLICATION CLIENT`, `REPLICATION SLAVE` y `SELECT`, solo desde `10.101.2.160/27`	Día 1
Sin bases con mayúsculas y minúsculas mezcladas en el nombre	Se revisa el inventario de bases. Flexible Server no las admite	Antes del día 0
Espacio en disco para tres días de binlog	Se mide el volumen diario del binlog en la primera semana	Días 1 a 5

El volcado nocturno de la 01:00 se mantiene hasta el corte, como respaldo de Cali.

3.3 El salto de 5.7 a 8.4

MySQL no permite actualizar un servidor directamente de 5.7 a 8.4: obliga a pasar por 8.0. DMS no actualiza el servidor; copia los datos de forma lógica a un servidor 8.4 nuevo, y por eso sí admite ese salto. Aun así, la aplicación tiene que funcionar con 8.4, y hay tres consecuencias:

1. **La compatibilidad se prueba antes del día 0.** Se corre la verificación de actualización de MySQL Shell (`util.checkForServerUpgrade` con versión de destino 8.4) contra una copia de la base de Cali en un ambiente aislado, y se corrigen los hallazgos en la aplicación. Los casos típicos de este salto son: palabras que pasaron a ser reservadas, el juego de caracteres por defecto (`utf8mb4` con su nueva intercalación), consultas que dependían de la caché de consultas (eliminada en 8.0) y la autenticación (8.4 usa `caching_sha2_password` por defecto, así que el conector de la aplicación tiene que soportarlo).
2. **Los parámetros del servidor nuevo copian los de Cali.** Microsoft pide igualar `sql_mode`, la versión de TLS y todo parámetro que en Cali no tenga su valor por defecto. Se agrega `time_zone`, para que las horas guardadas no cambien.

3. **Congelamiento de esquema desde que arranca DMS hasta el corte.** DMS replica cambios de esquema solo hacia destinos 5.7 y 8.0. Con destino 8.4, una tabla o columna creada en Cali durante la convivencia no llega a Azure. Por eso, entre el día 5 y el corte, la aplicación de Cali solo recibe correcciones sin cambios de esquema. Los cambios de esquema se hacen en Azure, después del corte.

Además, DMS no copia la cláusula `DEFINER` de vistas, rutinas y disparadores: los crea con el usuario de la migración. El equipo de desarrollo revisa ese inventario antes del ensayo.

3.4 Carga inicial

El enunciado no da el tamaño de la base, así que en vez de suponerlo se calcula hasta qué tamaño la carga inicial cabe en una ventana de 22:00 a 04:00 (6 horas, 21.600 segundos):

Ancho de banda disponible en la noche	Tamaño máximo que cabe en una ventana
300 Mbps (el enlace de 400 Mbps, menos la copia continua del archivo, unos 37 Mbps, y margen)	300 Mbps × 21.600 s / 8 = 810 GB
150 Mbps (la mitad del enlace)	405 GB

Basta con confirmar que la base de producción pesa menos de unos 400 GB para que la carga inicial quepa en una noche incluso con la mitad del enlace. La carga inicial arranca un sábado a las 22:00 (día 5), para tener el domingo de margen. Si la base pesa más, se arranca un sábado y se deja correr hasta la noche del domingo, porque la carga inicial no detiene la base de Cali.

3.5 Por qué no hay replicación de vuelta

MySQL solo replica de una versión menor a una igual o mayor. De 8.4 hacia 5.7 no hay replicación ni bajada de versión posible. Por lo tanto:

- **Volver atrás limpio solo es posible durante el corte**, antes del punto de no retorno, mientras Azure no haya recibido escrituras reales (sección 5.5).
- **La regla FW-505 y su pareja en el NSG de `snet-data` no se crean.** El diseño del firewall las dejó condicionadas a esta decisión. Se retiran de `firewall-policy.csv` en este mismo cambio.
- Después del corte, volver a Cali exige la exportación de lo creado en Azure (sección 6.2).

3.6 Alta disponibilidad y réplica de Central US

La Carga A fija alta disponibilidad zonal y una réplica de lectura en Central US para cumplir el RPO de 15 minutos. Las dos se activan **antes del corte**, en la ventana del día 13, cuando la carga inicial ya terminó y DMS está solo replicando cambios. Así, desde el primer minuto en Azure la base ya cumple el RPO.

El ensayo del día 20 mide si la alta disponibilidad o la réplica atrasan a DMS. Si lo hacen, se desactivan en la ventana siguiente al ensayo y se activan en la primera ventana después del corte. Mientras tanto, el respaldo automático de Flexible Server permite restaurar a cualquier momento de los últimos días. Esa decisión se anota en el reporte del ensayo.

4. Calendario de la convivencia

4.1 Las campañas

El enunciado nombra tres campañas sin dar fechas. Este calendario las supone así, y durante ellas no hay cambios productivos salvo incidente:

Campaña	Fechas supuestas	Cómo se fija
Fin de año	15 de noviembre de 2026 al 10 de enero de 2027	Despachos de fin de año y regreso de vacaciones
Semana Santa	15 al 28 de marzo de 2027	La semana anterior al Domingo de Ramos (21 de marzo) hasta el Domingo de Resurrección (28 de marzo)
Mitad de año	15 de junio al 15 de julio de 2027	Vacaciones de mitad de año y prima de servicios

Hoy es 13 de octubre de 2026. Empezar la convivencia antes del 15 de noviembre dejaría menos de cinco semanas para tener la plataforma, la siembra y las adaptaciones listas, y la campaña de fin de año partiría la convivencia en dos. Por eso **el día 0 es el lunes 11 de enero de 2027**, el primer día después de la campaña.

Con ese inicio, el **día 90 es el domingo 11 de abril de 2027**. La campaña de Semana Santa cae dentro de la convivencia, así que el plan termina todo cambio antes del 15 de marzo y deja Semana Santa solo para operar.

4.2 Las ventanas

Los cambios productivos van de 22:00 a 04:00, fuera de campaña. Entre el 11 de enero y el 14 de marzo hay 63 noches útiles. Este plan usa unas 30. Las demás quedan de reserva para repetir un paso que falle.

4.3 Fases y fechas

Fase	Días	Fechas	Qué pasa
Preparación	Antes del día 0	Hasta el 10 de enero de 2027	Plataforma desplegada en los tres ambientes con el código de infraestructura y el pipeline (#20 a #24). Producción en Azure queda encendida al mínimo y sin usuarios: no es un cambio productivo, porque nadie la usa. Adaptaciones de la aplicación probadas en pruebas. Siembra del archivo por discos en curso desde el 2 de noviembre; la copia a los discos solo lee el servidor y puede seguir durante la campaña (#15). Prueba de carga de campaña en pruebas (sección 7.6)
Inicio de la convivencia	0	Lunes 11 de enero	Túneles de Cali hacia Azure por los dos proveedores. Reglas temporales de los dos lados (grupos 400 y 500, `red-firewall-y-publicacion.md`, sección 5.4). Reenvío de DNS entre Cali y el hub
Binlog y piloto de centro	1	Martes 12 de enero	Reinicio de MySQL de Cali con binlog (sección 3.2). Primer centro conectado directo a Azure, como piloto
Centros	3 a 12	14 al 23 de enero	Los otros siete centros, uno o dos por noche. Los sensores de cuartos fríos de cada centro empiezan a enviar en línea a IoT Hub apenas el centro queda conectado
Carga inicial de la base	5	Sábado 16 de enero	Arranca DMS. Desde aquí rige el congelamiento de esquema en Cali
Camiones	1 a 19	12 al 30 de enero	Alta de los camiones en IoT Hub, en grupos de unos 30. No dependen de Cali ni de los centros
Fin de la carga por lote	8 a 19	19 al 30 de enero	Cada centro envía en línea y por FTP en paralelo durante 7 días.

Fase	Días	Fechas	Qué pasa
			Si los dos coinciden, se retira la regla FW-402 de ese centro
Alta disponibilidad de la base	13	Domingo 24 de enero	Alta disponibilidad zonal y réplica en Central US (sección 3.6)
Copia continua del archivo	0 a 35	11 de enero al 15 de febrero	Empieza con los túneles del día 0 y queda al día hacia el 15 de enero (#15)
Pruebas en Azure con datos replicados	6 a 19	17 al 30 de enero	Pruebas de solo lectura de los cinco contenedores contra la base replicada, con usuarios clave de despacho y facturación
Siembra conciliada	14 a 18	25 al 29 de enero	Último envío de discos cargado y conciliación completa del archivo (#15)
Ensayo del corte	20	**Domingo 31 de enero**, 01:00 a 03:00	El corte completo sobre un servidor temporal (sección 5.2)
Reserva para un segundo ensayo	27	Domingo 7 de febrero	Solo si el primero no cumple los criterios
Aviso a clientes corporativos	27	Domingo 7 de febrero	Aviso de la ventana de mantenimiento del portal, siete días antes
Corte	34	**Domingo 14 de febrero**, 01:00 a 03:00	Sección 5
Cierre de la copia del archivo	35	Lunes 15 de febrero	Última sincronización, verificación y fin de la copia continua. Se retira la regla temporal del NSG de `snet-archive`
Plazo de vuelta atrás	34 a 55	14 de febrero al 7 de marzo	Cali intacta y sin tráfico (sección 6.1). Incluye el primer cierre de facturación mensual en Azure, el 1 de marzo
Cierre del plazo	56	Lunes 8 de marzo	Se retiran el NAT y el firewall de aplicaciones de Cali, los grupos temporales 400 y 500, las reglas temporales de los NSG y las VPN de los centros hacia Cali
Apagado de Cali	56 a 62	8 al 14 de marzo	Servidores de Cali, Zabbix y VMware, en el orden de la sección 6.3. **Cali queda apagada el domingo 14 de marzo (día 62)**
Margen	63 a 90	15 de marzo al 11 de abril	Semana Santa sin cambios. Lo que haya quedado pendiente se cierra entre el 29 de marzo y el 11 de abril

4.4 Si se mueve una fecha

Si pasa esto	Qué se hace
El ensayo no cumple los criterios	Se repite el 7 de febrero y el corte pasa al 21 de febrero. El resto del calendario se corre una semana y Cali se apaga el 21 de marzo, dentro

Si pasa esto	Qué se hace
	de Semana Santa, así que ese apagado pasa al 29 de marzo. Sigue dentro del día 90
El corte se suspende el mismo día (sección 5.4)	Fechas de reserva: domingo 21 y domingo 28 de febrero
La preparación se atrasa	El día 0 se puede correr. **El corte no puede pasar del domingo 7 de marzo**: con el plazo de vuelta atrás de 21 días se cierra el 28 de marzo, el apagado va del 29 de marzo al 4 de abril y el día 90 sigue cumpliéndose. Un día 0 posterior al 1 de febrero obliga a acortar el plazo de vuelta atrás o a pasar la convivencia completa después de Semana Santa

5. El corte

5.1 Qué cubre y qué no

El corte cubre el cambio de la base transaccional y del tráfico de despacho y de rastreo. **No cubre la copia del archivo de 1,2 PB.** Ese volumen se siembra con discos y queda conciliado antes del ensayo (#15), y la copia continua lo mantiene al día desde el día 0: unos 12 TB al mes, es decir, unos 400 GB al día.

En el corte solo queda por copiar lo que llegó al archivo de Cali desde la última pasada de la copia continua. Si la copia pasa cada hora, son unos 17 GB (12 TB / 30 días / 24 horas). A 200 Mbps eso toma unos 11 minutos y corre en paralelo con la validación de la base.

La base tampoco se copia en el corte. DMS la mantiene al día desde el día 5, y en el corte solo se espera a que el retraso de la réplica llegue a cero.

La telemetría no participa del corte. Ya funciona en Azure desde antes del día 0 y la alerta a la guardia de calidad sigue llegando durante la madrugada del corte.

5.2 El ensayo

El ensayo del día 20 repite el corte completo, con los mismos tiempos, sin tocar el tráfico real:

- Una segunda actividad de DMS replica la base de Cali hacia el **servidor temporal** que la red ya reservó en `snet-data` de producción. El ensayo se hace en producción y no en pruebas porque usa datos personales reales, y pruebas no los lleva.
- Se ejecuta el guion de la sección 5.3, con el portal en un nombre de prueba en lugar del nombre público. La base de Cali no se pone en solo lectura: se toma el retraso de la réplica en un momento dado.
- Se mide cuánto toma cada paso y se ajusta el guion. Si un paso pasa de su tiempo, el ensayo falla.
- Al terminar, el servidor temporal y su actividad de DMS se eliminan.

5.3 Guion

Domingo 14 de febrero de 2027. Hora de Colombia. El servicio queda en mantenimiento de 01:00 a 03:00 como máximo, y la hora de 03:00 a 04:00 queda libre para atender cualquier problema antes de que empiece el despacho.

Hora	Paso	Responsable	Tiempo
Días antes	TTL del registro público del portal y del registro interno de la torre a 5 minutos (`red-firewall-y-publicacion.md`, sección 3.8). Comité de cambios aprobado. Avisos enviados (sección 5.6)	Líder del corte	—
Sábado 22:00	Congelamiento de cambios en Cali y en Azure. Revisión de que DMS va con retraso cercano a cero y de que la réplica de Central US está al día	Líder del corte, base de datos	—
00:30	Volcado completo de la base de Cali, en lugar del volcado de la 01:00. Es el respaldo de vuelta atrás	Base de datos	30 min
00:55	Primera decisión: seguir o suspender. Se suspende si falta alguien o algún criterio previo	Líder del corte	5 min

Hora	Paso	Responsable	Tiempo
01:00	La aplicación de Cali entra en modo de mantenimiento: torre en solo lectura y aviso en el portal. La base de Cali queda en `read_only` y `super_read_only`	Aplicación, base de datos	5 min
01:05	Se espera a que DMS marque cero segundos de retraso. Se anota la posición final del binlog	Base de datos	5 min
01:10	Se inicia el corte en DMS y se confirma que terminó	Base de datos	10 min
01:20	Validación de datos: conteo de filas de todas las tablas y una suma de verificación por columnas clave de guías, inventario y facturas, con la misma consulta en Cali y en Azure. En paralelo, última sincronización del archivo (sección 5.1)	Base de datos, archivo	20 min
01:40	Las ocho aplicaciones de producción (los cinco contenedores de hoy: seis aplicaciones en el entorno de la torre y dos en el del portal, sección 7) pasan a su número normal de réplicas y abren escrituras contra Flexible Server	Aplicación	10 min
01:50	DNS: el registro público del portal pasa a la IP del Application Gateway y el registro interno de la torre al entorno de la torre en Azure	Red	5 min
01:55	Pruebas de humo con un cliente de prueba: inicio de sesión en la torre con Entra ID y MFA desde Cali y desde un centro; creación de una guía de prueba; consulta de esa guía en el portal; carga y consulta de una evidencia; consulta de una factura	Usuarios clave, pruebas	30 min
02:25	**Segunda decisión: seguir o volver atrás** (sección 5.4)	Líder del corte con despacho y calidad	5 min
02:30	Si se sigue: se quitan los datos del cliente de prueba y se abre el servicio. Este es el **punto de no retorno**. Si se vuelve atrás: sección 5.5	Aplicación	30 min
03:00	Fin del mantenimiento. Monitoreo reforzado hasta las 06:00, con el equipo del corte disponible	Todos	—
04:00	Empieza el despacho sobre Azure. La torre de control confirma la operación a las 04:30	Despacho	—

5.4 Criterios para seguir

Se sigue si se cumplen todos estos criterios. Si falla uno, se vuelve atrás sin discutir:

Criterio	Cómo se comprueba
DMS terminó el corte sin errores	Estado de la actividad en DMS
Conteos y sumas de verificación iguales en Cali y en Azure	El reporte de la validación de las 01:20
Las pruebas de humo pasan completas	La lista firmada por los usuarios clave
Las ocho aplicaciones responden sus chequeos de salud y no hay errores 5xx en el Application Gateway	Azure Monitor (#16)
La réplica de Central US está al día	Métrica de retraso de la réplica
Son las 02:30 o antes	Reloj. Si a las 02:30 no hay decisión, se vuelve atrás

5.5 Volver atrás durante el corte

Hasta las 02:30 Azure solo recibió los datos del cliente de prueba, así que volver atrás es limpio y no pierde nada:

1. El registro público del portal y el registro interno de la torre vuelven a las direcciones de Cali. Con el TTL de 5 minutos, el cambio llega en minutos.
2. La base de Cali sale de `read_only`. No recibió ninguna escritura desde las 01:00.
3. La aplicación de Cali sale del modo de mantenimiento.
4. En Azure, los contenedores vuelven a su mínimo y la base de Azure se descarta. Para otro intento se crea una nueva actividad de DMS desde el principio, porque la del corte ya terminó.

Toma menos de 30 minutos y termina antes de las 03:00. Las reglas temporales del firewall no cambian, porque todavía no se ha retirado ninguna.

5.6 Aprobación y avisos

La aprobación y los avisos quedan en la plantilla de infraestructura (#30), que usa este corte como ejemplo. Lo mínimo es:

A quién	Qué se le dice	Cuándo
Comité de cambios: gerencia de operaciones, responsable de calidad y líder técnico	Pide la aprobación con el guion, el reporte del ensayo y los criterios para seguir	Lunes 8 de febrero
Torre de control (despacho)	La torre queda en solo lectura de 01:00 a 03:00. A las 04:00 abre en Azure, con la misma dirección y el mismo inicio de sesión de Entra ID	Siete días antes y el sábado
Guardia de calidad	La alerta de temperatura no cambia y sigue llegando por los mismos canales. Tendrá un contacto directo con el equipo del corte	Siete días antes y a las 00:55
Clientes corporativos	El portal queda en mantenimiento de 01:00 a 03:00	Correo siete días antes y aviso en el portal
Equipo del corte: base de datos, red, aplicación, pruebas y usuarios clave	Guion, turnos y canal del corte	Después del ensayo

6. Después del corte: plazo de vuelta atrás y apagado de Cali

6.1 El plazo de vuelta atrás

El plazo dura **21 días**, del 14 de febrero al 7 de marzo de 2027. Se elige así por dos razones:

- Cubre tres semanas completas de despacho y el primer cierre de facturación mensual en Azure (1 de marzo). Es lo que más probablemente muestre un error que las pruebas no vieron.
- Termina una semana antes de Semana Santa, lo que deja la semana del 8 al 14 de marzo para apagar Cali con ventanas normales.

Durante el plazo, Cali queda intacta y sin tráfico: la base de Cali en solo lectura, el NAT y el firewall de aplicaciones configurados, la VPN de cada centro hacia Cali como respaldo y Zabbix vigilando.

6.2 Qué significa volver atrás después del corte

Volver atrás después del punto de no retorno **no es limpio**, porque los datos creados en Azure no pueden replicarse a 5.7 (sección 3.5). Las salidas ante una falla grave son, en este orden:

1. **Corregir en Azure.** Es lo normal ante cualquier falla de la aplicación o de la configuración.
2. **Pasar a Central US** con el procedimiento de continuidad de la Carga A, si lo que falla es la región.
3. **Volver a Cali**, solo si las dos anteriores no resuelven una falla que impida despachar. Lo decide el comité de cambios. Se hace en tres pasos: la base de Cali sale de solo lectura; se cargan en Cali, con la exportación pedida al equipo de desarrollo (sección 2.4), las guías, los movimientos de inventario y las facturas creados en Azure desde el corte; y se vuelven los registros de DNS. Lo que la exportación no cubra se vuelve a digitar.

La tercera salida existe para no quedar sin camino ante algo imprevisto. No se espera usarla, y por eso no justifica mantener Cali más allá de los 21 días.

6.3 Orden de apagado

Sigue el orden de `red-firewall-y-publicacion.md`, sección 5.5, con fechas:

Orden	Fecha	Qué se apaga o se retira
1	Domingo 14 de febrero, en el corte	FW-501, FW-502 y su pareja en el NSG de `snet-data`. La cuenta de almacenamiento de la migración y su token. El servicio DMS se elimina el día siguiente, cuando la validación queda firmada
2	Domingo 14 de febrero, en el corte	El portal deja de publicarse desde Cali. El NAT y el firewall de aplicaciones quedan configurados, sin tráfico
3	19 al 30 de enero, centro por centro	FW-402 de cada centro, cuando su carga por lote queda reemplazada
4	Lunes 15 de febrero	La regla temporal del NSG de `snet-archive`, al terminar la copia continua del archivo
5	Lunes 8 de marzo, al cerrar el plazo	El NAT del portal y el firewall de aplicaciones de Cali. Los grupos temporales 400 y 500 completos (incluidas FW-401, FW-503 y FW-504). Las reglas temporales de los NSG. Las VPN de los centros hacia Cali
6	8 al 12 de marzo	Servidores de Cali, en este orden: las 4 máquinas de aplicación y las 2 de front; las 2 de Nginx; Redis; las 3 bases MySQL, con un último volcado de producción guardado en el archivo de Azure; el servidor FTP y NFS, cuando #15 confirma que el archivo en Azure está completo. Con cada servidor se retiran las políticas del firewall de Cali que lo protegían
7	Sábado 13 de marzo	Zabbix, cuando #16 confirma que todo lo que vigilaba ya está cubierto por Azure Monitor o dejó de existir
8	Domingo 14 de marzo (día 62)	Los tres clústeres de VMware. Revisión final de `firewall-policy.csv`: se quitan las reglas temporales y el verificador no debe listar ninguna. `snet-cali-integration` queda vacía

Después del día 62 el firewall de Cali queda solo como firewall de sede: usuarios, salida a internet y túneles hacia Azure.

6.4 Monitoreo durante la convivencia

Zabbix sigue vigilando todo lo que está en Cali hasta que se apaga: servidores, la base de Cali y su replicación, el firewall y los túneles. Azure Monitor vigila la plataforma nueva desde el día 0. El detalle de qué se mide y de los dos objetivos de servicio está en #16. Este documento le pide dos señales propias de la migración:

- El retraso de la replicación de DMS, con alerta si pasa de 5 minutos fuera de la carga inicial.
- El atraso de la copia continua del archivo, con alerta si pasa de un día de crecimiento (unos 400 GB).

7. Escenario de campaña

7.1 Las tres reglas

El enunciado da tres reglas distintas que no se mezclan:

Parte	Regla	Dónde se aplica
Capa de aplicación	+40 % de cómputo, la hipótesis del negocio	Entorno de la torre: los servicios internos y su front
Portal	Se dimensiona con el pico de 2.000 solicitudes por minuto durante unas 4 horas, no con el 40 %	Entorno del portal y Application Gateway
Telemetría	Se dimensiona con 180 camiones	IoT Hub y Stream Analytics

La base, la caché, el firewall y la red no son capa de aplicación: el 40 % no se les aplica. Se validan con la prueba de carga (sección 7.6).

7.2 Capa de aplicación: +40 %

En operación normal, cada servicio tiene al menos 2 réplicas, en zonas distintas, para que la caída de una zona no lo detenga. Guías tiene 3 porque concentra el trabajo de los 450 usuarios internos. Cada réplica tiene 1 vCPU y 2 GiB.

Servicio, en el entorno de la torre	Réplicas normales	Réplicas de campaña (+40 %, redondeado hacia arriba)
Front de la torre	2	3 (2,8)
Guías	3	5 (4,2)
Asignación de muelle y ruta	2	3 (2,8)
Inventario	2	3 (2,8)
Facturación corporativa	2	3 (2,8)
Evidencias	2	3 (2,8)
Total	**13 vCPU**	**20 vCPU** (13 × 1,4 = 18,2; el redondeo por servicio suma 20)
Nodos D4 del perfil dedicado (4 vCPU, 16 GiB)	4	6 (4 × 1,4 = 5,6)

Encaje con la red. Los 6 nodos de campaña coinciden con las "unas 6 máquinas con el 40 %" que usó la red para dimensionar `snet-app-torre`, y quedan muy por debajo del techo de 20 nodos.

Solo en el horario de despacho. El 40 % se aplica de 04:00 a 22:00 durante los días de campaña. De noche la torre no se usa, y las réplicas vuelven al mínimo normal.

7.3 Portal: 2.000 solicitudes por minuto

	Pico ordinario	Pico de campaña
Solicitudes por segundo	800 / 60 = 13,3	2.000 / 60 = 33,3
Réplicas de rastreo necesarias, a 15 solicitudes por segundo por réplica (supuesto)	13,3 / 15 = 0,9, es decir 1	33,3 / 15 = 2,2, es decir 3
Más una réplica para tolerar la caída de una zona	2	4
Front del portal (contenido casi estático)	2	3
Application Gateway	20 unidades reservadas (2 instancias)	Las mismas 20 unidades cubren las 18 que pide la campaña (`red-firewall-y-publicacion.md`, sección 3.3)

Por la ley de Little, con 0,3 segundos por respuesta, el pico de campaña tiene unas 10 solicitudes en curso al mismo tiempo (33,3 × 0,3). La carga es pequeña: el tamaño lo manda la disponibilidad, no la potencia.

El portal corre en el perfil de consumo del entorno, que cobra por réplica activa. Su escalado sigue la concurrencia HTTP: mínimo 2 réplicas y máximo 10. Así, las réplicas extra solo existen durante las horas del pico, unas 4 por día de campaña.

7.4 Telemetría: 180 camiones

	Normal (120 camiones)	Campaña (180 camiones)
Temperatura de camiones	2,0 mensajes por segundo	3,0
Posición de camiones	4,0	6,0
Cuartos fríos (32, sin cambio)	1,07	1,07
Total	**Unos 7,1 por segundo**	**Unos 10,1 por segundo**

El diseño de telemetría ya comprobó que ninguna pieza cambia de tamaño con los 180 camiones: dos unidades S1 de IoT Hub reciben 800.000 mensajes al día frente a unos 682.000 en campaña, y Stream Analytics se valida en la prueba de carga (`carga-b-telemetria.md`, sección 6.3).

7.5 Lo que no cambia en campaña

Componente	Por qué no cambia
MySQL Flexible Server	No es capa de aplicación. Se valida en la prueba de carga que el uso de CPU quede por debajo del 70 % con la carga de campaña. Si no, se sube de tamaño en una ventana antes de la campaña, como cambio de datos y no como parte del 40 %
Azure Managed Redis	Ídem. El rastreo es casi todo lectura y la caché absorbe las consultas repetidas
Application Gateway	Ya reserva la capacidad de campaña (sección 7.3)
Azure Firewall, VPN Gateway	El portal no pasa por el enlace de Cali. Los 450 usuarios internos son los mismos en campaña

7.6 Cómo se aplica sin hacer cambios en campaña

Durante una campaña no se hacen cambios en producción, así que la capacidad de campaña tiene que estar lista antes y activarse sola:

- **Torre:** una regla de escalado por calendario (el escalador cron de KEDA que admite Container Apps) sube el mínimo de réplicas a los valores de campaña de 04:00 a 22:00, hora de Colombia, en las fechas de la sección 4.1. La regla se configura en una ventana normal antes de cada campaña, como cambio de infraestructura con su plantilla, y se retira después. La escala por concurrencia sigue activa encima de ese mínimo.
- **Portal:** no necesita regla de calendario. Escala solo con la concurrencia.
- **Prueba de carga:** en el ambiente de pruebas, antes del día 0 y antes de cada campaña, con 2.000 solicitudes por minuto sostenidas durante 4 horas en el portal, la carga de la torre aumentada en 40 % y el tráfico simulado de 180 camiones. La prueba confirma los supuestos de las secciones 7.2 y 7.3 (15 solicitudes por segundo por réplica y el uso de la base) y ajusta los números antes de producción.

7.7 Si la convivencia cruzara una campaña

El calendario de la sección 4 evita que la convivencia corte una campaña antes del apagado: Semana Santa queda en el margen. Si un atraso obligara a convivir durante una campaña:

- No se hace ningún paso de la sección 4.3 durante la campaña. El calendario se detiene y retoma al terminar.
- Si la campaña cae antes del corte, la operación sigue en Cali, con el 40 % de hoy sin resolver. La capacidad fija de Cali es justamente el problema que motiva el proyecto.
- Si cae después del corte, la operación ya corre en Azure con las reglas de la sección 7.6, y Cali espera apagada o en su plazo de vuelta atrás.

8. Diagramas

De Cali a Azure: decisión, destino y momento de cada pieza

Pieza en Cali	Decisión	Destino en Azure	Cuándo
despacho, inventario, facturación corporativa	**Se mueve tal cual**	Entorno de la torre (Container Apps)	Cambian juntos en el corte
rastreo	**Se mueve tal cual**	Entorno del portal, detrás del Application Gateway con WAF	En el corte
evidencias	**Se rehace**	Entorno de la torre; lee y escribe en Blob Storage, sin NFS	Ajuste probado antes del día 0; cambia en el corte
Front (2 máquinas)	**Se rehace**	Un contenedor de front por entorno	En el corte
Nginx (2 máquinas)	**Se reemplaza**	Application Gateway v2 con WAF	En el corte; Nginx se apaga al cerrar el plazo
MySQL 5.7 de producción	**Se rehace**	MySQL Flexible Server 8.4, migrado en línea con DMS	Replicación desde el día 5; cambia en el corte
MySQL 5.7 de desarrollo y pruebas	**Se rehace**	Bases nuevas vacías, con datos inventados	Antes del día 0
Redis 5	**Se reemplaza**	Azure Managed Redis	En el corte; arranca vacía
FTP y NFS con 1,2 PB	**Se retira**	Cuentas de archivo y evidencias (siembra y copia continua, #15)	Siembra conciliada antes del ensayo; copia continua del día 0 al 35
Carga de temperatura por lote	**Se retira**	IoT Hub (#13)	Centro por centro, días 8 a 19
Zabbix	**Se retira**	Azure Monitor (#16)	Día 61
VMware (3 clústeres)	**Se retira**	—	Día 62: Cali apagada

Se mueve tal cual (misma imagen, otra configuración) · Se rehace en su forma final · Se reemplaza por un servicio administrado · Se retira

Figura 18: Decisión y destino en Azure de cada pieza del datacenter de Cali

El primer diagrama muestra, para cada pieza de Cali, qué decisión se toma (moverla tal cual, rehacerla, reemplazarla o retirarla), adónde va en Azure y cuándo.

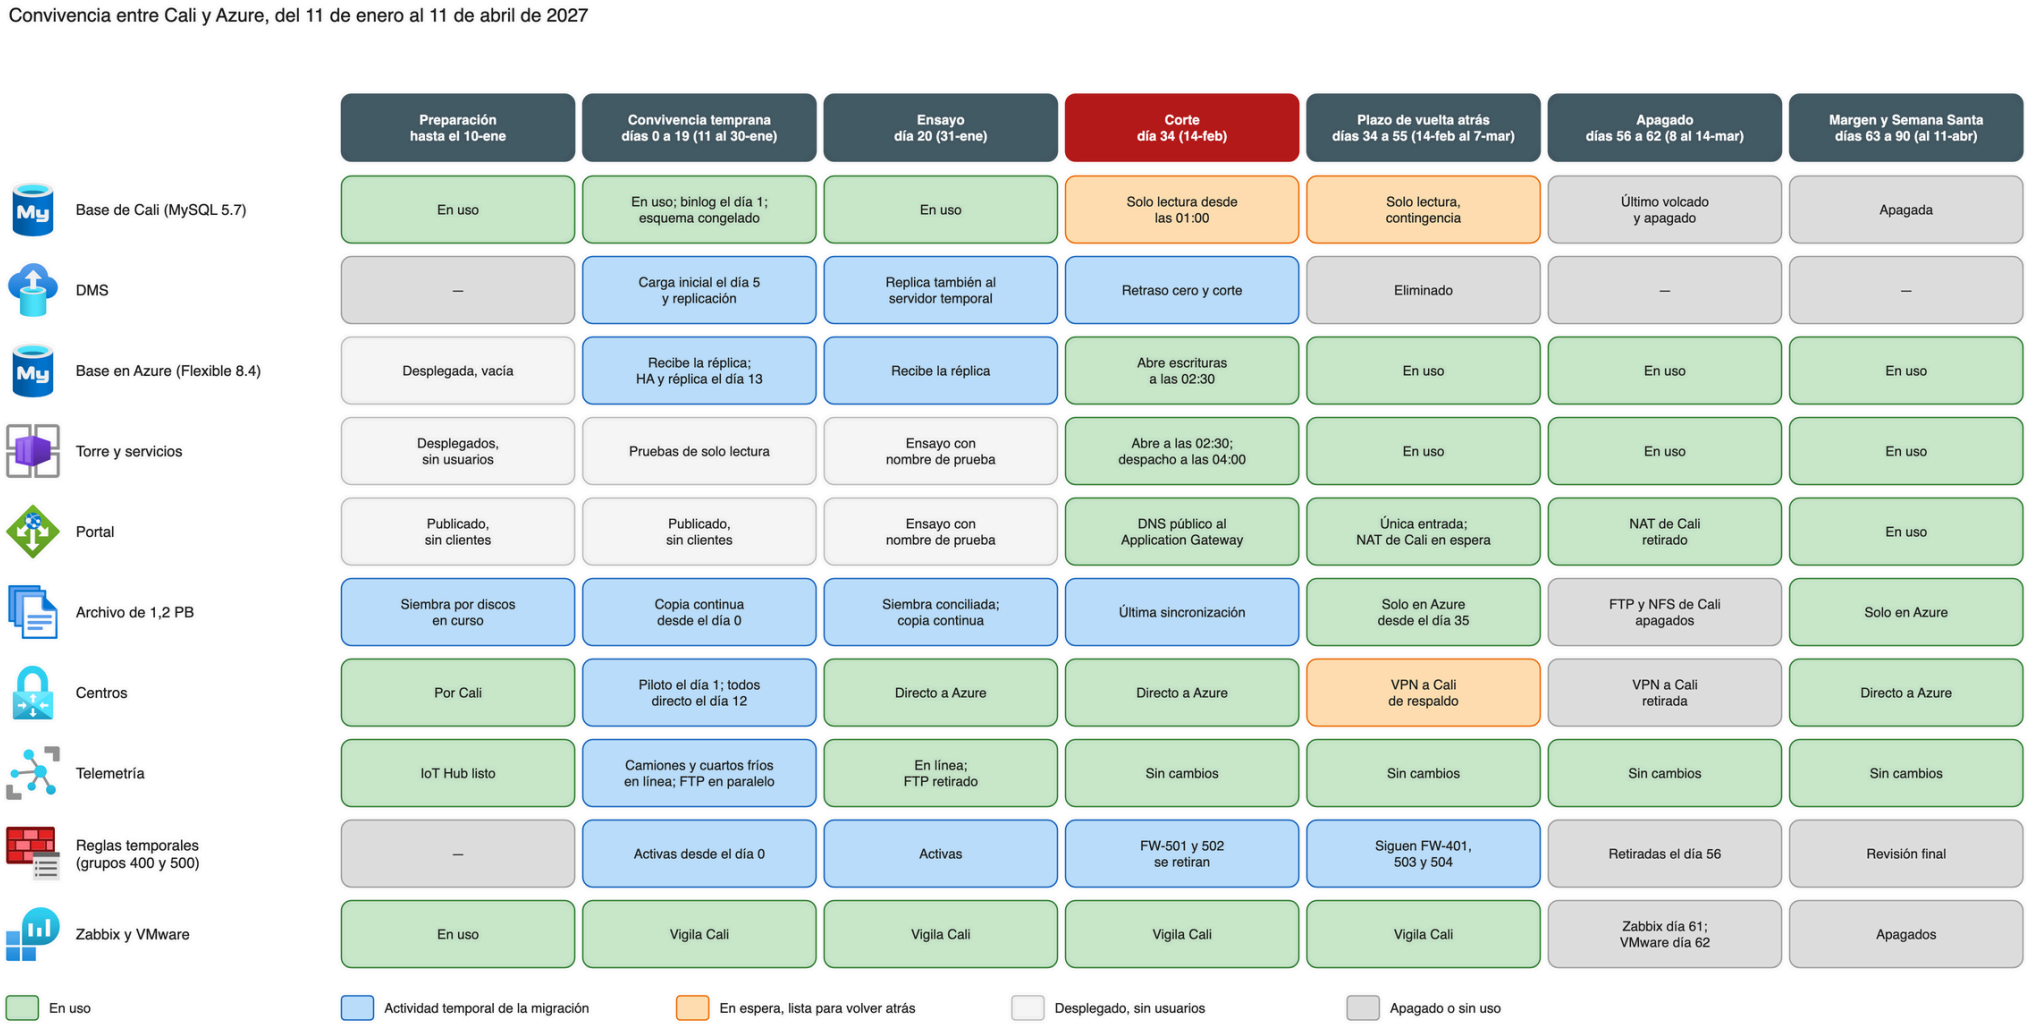


Figura 19: Estado de cada pieza en cada fase de la convivencia, del 11 de enero al 11 de abril de 2027

El segundo diagrama recorre las fases de la convivencia, con las fechas de la sección 4.3, y el estado de cada pieza en cada una: en Cali, en Azure, en paralelo o apagada.

Los dos se generan con `tools/build_carga_c_diagrams.py`.

9. Costo: qué se paga dos veces y por cuánto tiempo

Las cifras van en #25 (costo único de la migración) y #26 (mes estable y campaña). Este documento fija lo que esas estimaciones deben contar:

Concepto	Duración	Qué cuenta
Producción en Azure sin usuarios	Desde que se despliega (antes del 11 de enero) hasta el corte (14 de febrero)	Container Apps al mínimo, Flexible Server, Managed Redis, Application Gateway y firewall. La base se sube de tamaño solo durante la carga inicial
Servidor temporal del ensayo	Unos días alrededor del 31 de enero	Un Flexible Server del mismo tamaño que producción
DMS Premium de 4 vCores	Del 16 de enero al 15 de febrero	Sin costo: entra en los 183 días que Microsoft no cobra
Cali y Azure a la vez	Hasta el 14 de marzo (día 62)	Lo que FríoAndes siga pagando por Cali (energía, soporte de VMware, soporte extendido de Ubuntu). El enunciado no da esos costos
Horas del equipo	Ensayo, corte y apagado	Unas 2 noches de ensayo y corte con 6 a 8 personas, y unas 15 noches de cambios durante la convivencia

Decisiones que bajan o evitan gasto

Decisión	Alternativa descartada	Qué se evita
Cali se apaga el día 62	Esperar hasta el día 90	28 días de pagar dos plataformas
Bases de desarrollo y pruebas creadas vacías	Migrar también esas dos bases	Dos migraciones más y llevar datos personales a ambientes con menos controles
Ensayo en el servidor temporal, que se borra al terminar	Un ambiente de preproducción permanente con datos reales	Un servidor de base de datos encendido todo el año
Sin replicación de vuelta a Cali	Mantener una segunda migración de Azure a Cali durante el plazo	Un servidor de replicación inversa que además MySQL no admite de 8.4 a 5.7
Producción en Azure al mínimo hasta el corte	Producción a tamaño completo desde el despliegue	Las réplicas y los nodos que no se usan mientras no hay usuarios
El portal escala por concurrencia y la torre por calendario	La capacidad de campaña encendida toda la campaña, las 24 horas	Las horas de cómputo fuera del pico del portal y fuera del horario de despacho

10. Supuestos y confirmaciones pendientes de FríoAndes

10.1 Confirmaciones que necesita el diseño

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
Fechas de campaña	¿Cuáles son las fechas reales de las tres campañas?	Mueve el día 0, el corte y el apagado. El corte no puede pasar del 7 de marzo de 2027 con las fechas supuestas
Fecha de inicio	¿Se acepta empezar la convivencia el 11 de enero de 2027?	Ídem

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
Plazo de vuelta atrás	¿Se aceptan 21 días, sabiendo que después del corte volver a Cali no es limpio?	Un plazo más largo retrasa el apagado de Cali; no puede pasar del día 90
Tamaño de la base	¿La base de producción pesa menos de unos 400 GB? ¿Cuánto binlog genera al día?	Si pesa más, la carga inicial usa el fin de semana completo (sección 3.4). El binlog define el espacio de disco en Cali
Binlog en Cali	¿La base de producción ya tiene `log_bin`?	Si ya lo tiene, se evita el reinicio del día 1
Evidencias que llegan por FTP	¿Alguien sube evidencias directamente al servidor FTP, sin pasar por el contenedor evidencias?	Si sí, ese flujo también tiene que cambiar de destino en el corte
Usuarios clave en el corte	¿Despacho y facturación pueden poner usuarios clave en el ensayo y en el corte, de madrugada?	Sin ellos, las pruebas de humo no validan el negocio
Último volcado de Cali	¿Cuánto tiempo hay que conservar el último volcado de la base de Cali después del apagado?	Define su retención en el archivo de Azure

10.2 Supuestos del diseño

Supuesto	Por qué se asume
Campañas del 15 de noviembre al 10 de enero, del 15 al 28 de marzo de 2027 y del 15 de junio al 15 de julio	El enunciado nombra las campañas sin fechas
El día 0 es el lunes 11 de enero de 2027, el corte el domingo 14 de febrero y el apagado de Cali el domingo 14 de marzo (día 62)	Es la primera fecha libre de campaña con tiempo para preparar, y termina antes de Semana Santa
Una réplica de rastreo de 1 vCPU atiende 15 solicitudes por segundo	Se confirma con la prueba de carga de campaña
La copia continua del archivo pasa al menos una vez por hora	Deja unos 17 GB por copiar en el corte. Lo fija #15
El plazo de vuelta atrás dura 21 días	Cubre el primer cierre de facturación en Azure y termina antes de Semana Santa
Los contenedores de hoy no tienen dependencias entre sí fuera de la base y del archivo	Permite moverlos tal cual con solo ajustes de configuración
La aplicación puede quedar en solo lectura con un modo de mantenimiento	Es una de las adaptaciones pedidas. Sin ella, el corte tendría que apagar la aplicación de Cali

11. Validación y cierre

Criterio de aceptación	Evidencia en este documento
Cada uno de los 5 componentes actuales tiene una decisión explícita (se mueve tal cual o se rehace) con justificación, y el plan de convivencia respeta el límite de 90 días con fecha de apagado de Cali	Sección 2.2 (los cinco contenedores, con los nombres del enunciado) y 2.3 (las piezas de apoyo). Sección 4.3: Cali se apaga el 14 de marzo de 2027, día 62, con margen hasta el día 90 (11 de abril)
El plan de corte detalla que solo arrastra el diferencial transaccional, no los 1,2 PB	Sección 5.1: la base llega al corte replicada por DMS y el archivo sembrado y al día. El corte solo espera el retraso cero de la réplica y copia unos 17 GB de archivo en paralelo. Guion en la sección 5.3
El dimensionamiento de campaña aplica el +40 % únicamente a la capa de aplicación, sin extenderlo al portal ni a la telemetría	Sección 7: +40 % solo en el entorno de la torre (7.2), el portal por 2.000 solicitudes por minuto (7.3) y la telemetría por 180 camiones (7.4). La base, la caché y la red quedan fuera (7.5)

Siembra y transferencia del archivo de 1,2 PB (Carga C)

Este documento define cómo llega a Azure el archivo histórico de Cali sin usar el enlace operativo de 400 Mbps: por qué no puede ir por la red, con qué medio físico se envía, cuántos discos hacen falta, en qué fechas, en qué cuentas de almacenamiento queda y cómo se mantiene al día hasta el corte. Completa el plan de migración (`carga-c-migracion-y-campana.md`), que solo fija cuándo tiene que estar listo.

Términos usados

Término	Qué significa aquí
Siembra	La carga inicial del archivo en Azure por un camino distinto de la red, antes de la convivencia
Import/Export	Servicio de Azure que recibe discos propios del cliente en un datacenter de Microsoft y copia su contenido a una cuenta de almacenamiento
Trabajo de importación	Un envío de hasta 10 discos hacia una sola cuenta de almacenamiento
WAImportExport	La herramienta de Microsoft que prepara los discos: copia los archivos, los cifra con BitLocker y genera el diario que Azure usa para importarlos
Copia continua	La copia por la red de lo que llega al archivo de Cali después de la siembra, hasta el corte
T0 y T1	Las dos fechas de corte de la siembra: T0 separa lo que va en los discos principales y T1 lo que va en el envío del diferencial
Inmutabilidad	Una política de Azure que impide modificar o borrar un archivo hasta una fecha, ni siquiera un administrador

1. Contexto y alcance

1.1 Lo que hay hoy

El archivo vive en una sola máquina CentOS 7 con FTP y NFS, en el clúster transversal de Cali (`10.20.3.0/24`). No tiene copia fuera de ese servidor.

Contenido	Volumen	Cómo es
Video de muelles y de entregas	1,05 PB	Objetos grandes
Fotos, comprobantes y PDF	110 TB	La mayoría pesa menos de 2 MB. Si promedian 1 MB, son unos 110 millones de archivos
Históricos de temperatura que hoy se cargan por lote	40 TB	Archivos que envían los centros cada hora
Total	**1,2 PB**	Crece unos 12 TB al mes, sobre todo video y fotos. Retención contractual de 5 años

1.2 Qué resuelve este documento

- El cálculo del tiempo por la red y la conclusión de que no es viable.
- El medio físico, sabiendo que Azure Data Box Heavy ya no existe.
- Las cuentas de Azure que reciben el archivo: cuántas, en qué nivel de acceso, con qué redundancia e inmutabilidad.
- Cuántos discos y trabajos hacen falta, y el cronograma hasta el ensayo del corte.
- Cómo se cierra el diferencial de unos 12 TB al mes entre la copia a los discos y el corte.
- Cómo se verifica que no falta nada.

1.3 Qué toma de los otros diseños

Viene de	Qué se usa aquí
`carga-c-migracion-y-campana.md` (#14)	El calendario: día 0 el 11 de enero de 2027, ensayo el 31 de enero, corte el 14 de febrero. evidencias lee y escribe por la API de Blob con el nombre de cada archivo igual a su ruta relativa de hoy, sin NFS

Viene de	Qué se usa aquí
`red-topologia-subnetting.md` (#8)	`snet-archive` para los endpoints privados del archivo; la copia continua va de la VPN al endpoint privado sin pasar por el Azure Firewall (sección 6.3); el descarte de Data Box (sección 6.4)
`red-firewall-y-publicacion.md` (#9)	La regla temporal NSG-prod-11 de `snet-archive` y su retiro al terminar la copia continua
`seguridad-datos-personales-perimetro.md` (#10)	El escaneo de malware apagado durante la migración, y fotos y comprobantes en una cuenta separada del video para escanear solo esa cuenta después
`gobierno-auditoria-facturacion.md` (#6)	Evidencias con retención inmutable de cinco años, bloqueada

1.4 Qué queda en otros diseños

- Las cifras de costo de la migración y del mes estable: #25 y #26. Aquí se dan las cantidades y los precios de lista de cada línea.
- Qué parte del archivo lee Fabric y cómo: #17 y #18.
- El paso del video a niveles más baratos después de la migración: #26, con lo que decida #17 sobre la muestra de video.

2. Por qué no puede ir por la red

1,2 PB son $1{,}2 \times 10^{15}$ bytes, es decir $9{,}6 \times 10^{15}$ bits.

Escenario	Cálculo	Tiempo
Usando el enlace completo de 400 Mbps	$9{,}6 \times 10^{15} / 400 \times 10^{6} = 24 \times 10^{6}$ segundos	**278 días**, unos 9 meses
Usando la mitad del enlace, porque la operación necesita el resto	$9{,}6 \times 10^{15} / 200 \times 10^{6} = 48 \times 10^{6}$ segundos	**556 días**, unos 18 meses
Usando el enlace completo solo durante los 90 días de convivencia	$400 \times 10^{6} \times 90 \times 86.400 / 8$	389 TB, el 32 % del archivo

Además, mientras se copia, el archivo sigue creciendo: en 278 días suma unos 111 TB más (278 / 30 × 12 TB).

No es viable por la red. El enlace es compartido y no hay enlace dedicado hacia la nube: aun usándolo completo, sin dejar nada para la operación, la copia tomaría tres veces lo que dura la convivencia. La red solo alcanza para seguir el crecimiento, unos 37 Mbps sostenidos (sección 6).

3. El medio: Azure Import/Export con discos propios

3.1 Opciones

Opción	Capacidad	¿Sirve desde Colombia?	Por qué
Azure Data Box Heavy	Unos 770 TB útiles; harían falta 2	**No**	Microsoft lo retiró y ya no se puede pedir
Azure Data Box (120 TB o 525 TB)	3 equipos de 525 TB	**No**	El equipo no cruza fronteras comerciales: Microsoft lo envía y lo recibe en un datacenter de Azure del mismo país, y Colombia no tiene región de Azure
Azure Data Box Disk	40 TB por pedido; harían falta 30 pedidos	**No**	La misma restricción de país, y 30 pedidos no son manejables
Azure Import/Export	Discos propios, sin límite de trabajos	**Sí**	Se envían discos propios a un datacenter de Microsoft desde otro país, con un transportador internacional.

Opción	Capacidad	¿Sirve desde Colombia?	Por qué
			East US 2 y Central US reciben envíos
Por la red	—	No	Sección 2

El issue pedía dimensionar dispositivos Data Box Heavy. Con ese equipo habrían hecho falta 2 (1.200 / 770, redondeado hacia arriba), pero no se puede pedir. El dimensionamiento de este documento es el del medio que sí está disponible: Import/Export.

3.2 Cómo funciona

1. Se prepara cada disco con WAImportExport: copia los archivos, los cifra con BitLocker (AES de 256 bits) y genera un diario por disco.
2. Se crea un trabajo de importación en Azure, uno por cada grupo de hasta 10 discos, apuntando a una sola cuenta de almacenamiento, y se sube el diario de cada disco.
3. Se envían los discos al datacenter de East US 2 con un transportador internacional y se registra el número de guía en el trabajo.
4. Microsoft recibe los discos, copia su contenido a la cuenta y los devuelve con la cuenta del transportador que dio FríoAndes.

3.3 Requisitos que condicionan el diseño

Requisito de Import/Export	Consecuencia
No admite cuentas con NFS 3.0	Las cuentas del archivo no pueden tener NFS 3.0, como suponía la red. Ya no hace falta: evidencias pasa a la API de Blob (#14) y la copia continua usa HTTPS (sección 6). Esto también permite la inmutabilidad, que Azure no admite en cuentas con NFS 3.0 (sección 4.3)
Hasta 10 discos por trabajo, y cada trabajo va a una sola cuenta	Los trabajos se arman por cuenta: uno para documentos y seis para video (sección 5)
Discos SATA: HDD de 2,5" o 3,5" con sectores lógicos de 512 bytes, o SSD de 2,5". No sirven discos USB ni discos externos con su caja	Se usan HDD de 3,5" SATA III de 20 TB con formato 512e, que reportan sectores lógicos de 512 bytes. Sirven adaptadores USB a SATA para prepararlos, si reportan 512 bytes
Una sola partición NTFS por disco	WAImportExport la crea al preparar el disco
WAImportExport corre en Windows de 64 bits con BitLocker. La lista oficial nombra Windows 10 y Windows Server 2012 R2	Las estaciones de copia usan Windows. En la primera semana se prueba la herramienta en Windows Server 2022; si no funciona, se usa Windows 10 Enterprise en una máquina aislada que solo hace la copia
Cargo de USD 80 por disco procesado, más el envío de ida (lo paga FríoAndes) y el de vuelta (a la cuenta de su transportador)	Sección 9

3.4 Seguridad del envío

- **Cifrado.** Cada disco viaja cifrado con BitLocker. La llave la protege una llave de FríoAndes en Key Vault (llave administrada por el cliente), no queda escrita en el paquete y Microsoft la usa solo para la importación.
- **Cadena de custodia.** Se lleva un inventario con el serial de cada disco y el trabajo al que pertenece. Los discos se empacan entre dos personas, en cajas selladas, y se envían con seguimiento.
- **Datos personales.** El archivo tiene fotos, firmas y video de destinatarios y conductores. El envío a Estados Unidos es la misma transmisión a Microsoft como encargado que ya aceptó #10. Los discos no se pueden leer sin la llave.
- **Al volver.** Los discos regresan a FríoAndes. Se borran de forma segura antes de reutilizarlos o desecharlos, y su destino queda anotado en el inventario.

4. Dónde queda el archivo en Azure

4.1 Dos cuentas

#10 pidió separar fotos y comprobantes del video, para escanear malware solo donde hace falta. Este diseño lo resuelve con dos cuentas en producción, en East US 2, ambas con endpoint privado de Blob en `snet-archive`, sin llave compartida (solo Entra ID) y **sin NFS 3.0 ni espacio de nombres jerárquico**:

	Cuenta de documentos	Cuenta de video
Contenido	Fotos, comprobantes y PDF (110 TB) e históricos de temperatura (40 TB), en contenedores separados	Video de muelles y de entregas (1,05 PB)
Volumen inicial	150 TB	1.050 TB
Crecimiento	Unos 1,1 TB al mes (fotos y comprobantes)	Unos 10,9 TB al mes
Nivel por defecto	Cool	**Cold**: la importación queda directamente en Cold, sin pasar un mes en un nivel más caro
Redundancia	GRS, con copia en Central US	LRS, como punto de partida
Escaneo de malware	Apagado durante la siembra y la copia continua. Se enciende al cerrar la conciliación (sección 7), para lo que suban los conductores y los centros	No
Quién lee	evidencias y, a través de rastreo, el cliente sus propios comprobantes y fotos	evidencias, para quien atiende un reclamo

Los históricos de temperatura van con los documentos y no con el video porque son trazabilidad contractual, como los comprobantes: van en la cuenta con copia geográfica. Como los centros dejan de enviarlos cuando cada uno pasa a IoT Hub (#14), el escaneo de malware de esa cuenta no los alcanza.

Acceso público durante la siembra. Import/Export escribe en la cuenta por la excepción de servicios de confianza de Microsoft, y Azure no admite esa excepción si el acceso público está desactivado del todo. Por eso, mientras dura la siembra, las dos cuentas tienen el acceso público "habilitado desde redes seleccionadas", sin ninguna red ni dirección IP permitida y con esa excepción, igual que las cuentas de telemetría (#13). Todo lo demás entra por el endpoint privado. Cuando se carga el último trabajo, el acceso público se desactiva del todo.

Por qué el video queda en LRS. El video es el 88 % del volumen. En Cold, LRS cuesta USD 0,0036 por GB al mes y GRS 0,00803: para 1.050 TB, unos USD 3.780 frente a 8.430 al mes. LRS ya guarda tres copias dentro del datacenter, que es más de lo que tiene hoy el archivo. Si FríoAndes exige copia geográfica también para el video, #26 cuantifica la diferencia.

4.2 Nombres

El nombre de cada archivo en Azure es su ruta relativa en el servidor de Cali. Así, evidencias encuentra cada archivo con la misma ruta que tiene guardada en la base, sin cambiar datos (#14, sección 2.4). Cada carpeta de primer nivel del servidor se vuelve un contenedor.

4.3 Inmutabilidad y borrado a los cinco años

#6 pide evidencias con retención inmutable de cinco años, bloqueada. Como las cuentas no tienen NFS 3.0, Azure lo permite. Hay un detalle propio de la siembra: **un archivo importado tiene como fecha de creación el día de la importación, no la de hace años**. Una política de cinco años contados desde la creación guardaría una foto de 2023 hasta 2031, más de lo que permite el contrato y la Ley 1581.

Por eso:

- Se usa **inmutabilidad por versión**, que permite fijar la fecha de vencimiento de cada archivo.
- Después de cada importación, un proceso toma la fecha original de cada archivo del listado de Cali, la guarda como etiqueta del archivo y fija su inmutabilidad hasta esa fecha más cinco años.

- Los archivos nuevos que llegan después del corte toman la política por defecto del contenedor: cinco años desde su creación, que en ese caso sí es su fecha real.
- **El borrado al vencer** lo hace un proceso mensual que lee la etiqueta de fecha original. No se puede usar el ciclo de vida de Azure contando días desde la creación, porque para los archivos importados esa fecha es la de la importación.
- **Los archivos con más de cinco años al momento de la siembra** se importan, pero no se bloquean. Quedan marcados para borrarlos cuando FríoAndes confirme si se pueden eliminar (es la pregunta 1 de la sesión de aclaraciones). Si lo confirma antes de preparar los discos, ni siquiera se envían (sección 9.2).

El primer envío, un disco de prueba (sección 5.3), comprueba que la importación funciona en un contenedor con inmutabilidad por versión.

5. Discos, trabajos y cronograma

5.1 Cuántos discos

Cada disco de 20 TB se llena hasta 18 TB, dejando un 10 % para el sistema de archivos, el diario y el margen de la herramienta.

Cuenta	Volumen	Discos (volumen / 18 TB, redondeado hacia arriba)	Trabajos (hasta 10 discos)
Documentos	150 TB	9	1 (D1)
Video	1.050 TB	59	6 (V1 a V5 de 10 discos, V6 de 9)
Diferencial, documentos	Unos 2,4 TB	1	1
Diferencial, video	Unos 22,8 TB	2	1
Total	**Unos 1.225 TB**	**71**	**9**

Se compran 74 discos: los 71 y 3 de repuesto por si alguno falla en la preparación.

5.2 Estaciones de copia y velocidad

Dos estaciones Windows con WAImportExport, en la red del archivo de Cali (`10.20.3.0/24`), conectadas al servidor de archivo por 10 GbE y con el recurso NFS montado en solo lectura. Cada estación prepara hasta 5 discos a la vez, así que entre las dos llenan un trabajo completo de 10 discos.

El límite no son los discos, que escriben a más de 150 MB/s cada uno. El límite es cuánto puede leer el servidor de archivo sin degradar a evidencias, que lo sigue usando todos los días:

Horario	Lectura máxima del servidor	Por qué
04:00 a 22:00 (despacho)	250 MB/s	evidencias sigue leyendo y escribiendo en el servidor
22:00 a 04:00	500 MB/s	Uso mínimo del archivo
Promedio del día	**312,5 MB/s, unos 27 TB al día**	(18 × 250 + 6 × 500) / 24

Estos valores son un supuesto. La primera semana se mide la latencia de evidencias con la copia corriendo y se ajustan. La copia solo lee el servidor, así que no es un cambio productivo y puede correr durante la campaña de fin de año. Si en campaña la lectura degrada a evidencias, se baja el tope diurno y el cronograma usa el margen de la sección 5.4.

Por qué no se lee el NFS a través de la VPN desde Azure. Con unos 90 ms de viaje de ida y vuelta, cada archivo pequeño cuesta varias idas y vueltas de NFS. Para 110 millones de archivos, eso domina el tiempo. Las estaciones de copia y el agente de la copia continua (sección 6) leen el NFS dentro de la red de Cali.

5.3 Cronograma

Fechas de 2026 y 2027. El tránsito supuesto es de 7 días puerta a puerta, incluida la aduana, y la carga en Azure toma 10 días desde que llegan los discos. Ambos se confirman con la prueba.

Paso	Volumen	Copia a discos	Envío	Llega a East US 2	En Azure
Preparación: confirmaciones con Microsoft y el transportador, compra de discos, estaciones, cuentas de Azure	—	13 al 23 de octubre	—	—	—
Prueba: 1 disco con unos 2 TB de fotos	2 TB	20 y 21 de octubre	22 de octubre	29 de octubre	8 de noviembre
T0: listado del archivo de Cali. Todo lo que exista antes de T0 va en D1 y V1 a V6	—	Lunes 2 de noviembre	—	—	—
D1: documentos	150 TB	2 al 7 de noviembre	9 de noviembre	16 de noviembre	26 de noviembre
V1: video más reciente	180 TB	7 al 14 de noviembre	16 de noviembre	23 de noviembre	3 de diciembre
V2	180 TB	14 al 20 de noviembre	23 de noviembre	30 de noviembre	10 de diciembre
V3	180 TB	20 al 27 de noviembre	30 de noviembre	7 de diciembre	17 de diciembre
V4	180 TB	27 de noviembre al 4 de diciembre	7 de diciembre	14 de diciembre	24 de diciembre
V5	180 TB	4 al 10 de diciembre	11 de diciembre	18 de diciembre	28 de diciembre
V6: video más antiguo	150 TB	10 al 16 de diciembre	17 de diciembre	24 de diciembre	3 de enero
T1: listado del archivo. Lo creado entre T0 y T1 va en el envío del diferencial	—	Lunes 4 de enero	—	—	—
Diferencial: documentos y video	Unos 25 TB	4 y 5 de enero	6 de enero	13 de enero	23 de enero
Copia continua por la red, de lo creado desde T1	Unos 400 GB al día	Desde el día 0, 11 de enero (sección 6)	—	—	Al día hacia el 15 de enero
Conciliación (sección 7)	—	25 al 29 de enero	—	—	—
Ensayo del corte con el archivo completo	—	Domingo 31 de enero	—	—	—

La prueba sale antes de que empiece la copia grande y vuelve antes de que se envíe V1. Así, el tránsito, la aduana, la carga y la inmutabilidad por versión se comprueban con un disco y no con diez.

Orden. Primero los documentos, que son los que más consulta evidencias y los que ve el cliente en el portal. Después el video, del más reciente al más antiguo, porque los reclamos casi siempre son sobre entregas recientes.

5.4 Margen y qué pasa si algo se atrasa

El límite real no es el día 0: es el **corte del 14 de febrero**. Hasta el corte, evidencias sigue corriendo en Cali y leyendo el servidor de Cali, así que nada de lo que se siembra se usa antes. Además, la carga de V5 y V6 cae en la semana de Navidad, cuando el tránsito y la carga pueden tardar más que lo supuesto.

Si pasa esto	Qué se hace
La prueba muestra un tránsito o una carga más lentos	Se recalcula el cronograma antes de enviar V1. Hay unas 4 semanas de margen entre la conciliación y el corte
La lectura en campaña tiene que bajar	Cada 50 MB/s menos de lectura diurna alarga la copia unos 6 días. El margen absorbe hasta unos 150 MB/s menos
Se rechaza o se pierde un disco	Se vuelve a copiar con un disco de repuesto y va en el envío siguiente
V6 (el video más antiguo) no está cargado para el corte	El corte sigue. Mientras llega, si un reclamo necesita uno de esos videos, operación lo copia a mano desde el servidor de Cali, que sigue encendido hasta el 12 de marzo (#14, sección 6.3)
Los documentos (D1) o el diferencial no están cargados para el corte	El corte no se hace: es un criterio para seguir del guion (#14, sección 5.4)

6. El diferencial: lo que llega al archivo después de copiar los discos

El archivo crece unos 12 TB al mes, unos 400 GB al día. Ese crecimiento se cierra en tres tramos, sin que el corte tenga que copiar volumen:

Tramo	Qué cubre	Cómo llega
Antes de T0 (2 de noviembre)	Todo el archivo existente, 1,2 PB	Discos D1 y V1 a V6
Entre T0 y T1 (2 de noviembre al 4 de enero)	63 días × 400 GB, unos 25 TB	Un envío más de discos: el diferencial
Desde T1	Unos 400 GB al día	La copia continua por la red, desde el día 0

El tramo del medio va en discos y no por la red por dos razones: los túneles de Cali hacia Azure se activan el día 0 (#14), y aunque existieran antes, 25 TB más el crecimiento diario tardarían más de un mes en ponerse al día por la red.

6.1 La copia continua

	Cómo es
Quién copia	Un agente en una máquina Linux nueva en Cali, en la red del archivo (`10.20.3.0/24`), con el recurso NFS montado en solo lectura. Empuja los archivos a Azure con AzCopy
Por dónde	Por la VPN hasta el endpoint privado de Blob de cada cuenta en `snet-archive`, sin pasar por el Azure Firewall, como ya decidió la red (sección 6.3 de `red-topologia-subnetting.md`). El DNS de Cali resuelve los nombres privados con el resolver del hub
Puerto	Solo HTTPS (443). Las cuentas ya no tienen NFS, así que la regla NSG-prod-11 deja de permitir los puertos 111 y 2048
Identidad	Una entidad de servicio con certificado, con permiso de escritura solo en las dos cuentas del archivo. Vence el día 90. Sin token SAS ni llave de la cuenta
Qué copia	Cada hora, los archivos creados o modificados desde la pasada anterior, más una pasada completa los domingos. Si el archivo está organizado por carpetas de fecha, la pasada de cada hora recorre solo las carpetas del mes en curso y del anterior

	Cómo es
Topes de ancho de banda	50 Mbps de 04:00 a 22:00 y 250 Mbps de 22:00 a 04:00: hasta 405 + 675 = 1.080 GB al día, frente a unos 400 GB de crecimiento
Ponerse al día	Entre T1 (4 de enero) y el día 0 (11 de enero) se acumulan unos 2,8 TB. Con 680 GB al día por encima del crecimiento, la copia queda al día en unos 4 días, hacia el 15 de enero
Después	El promedio queda en los unos 37 Mbps que ya usó la red para dimensionar el VPN Gateway

Una pasada por hora deja, en el peor momento, unos 17 GB por copiar. Es lo que el corte sincroniza en paralelo con la validación de la base (#14, sección 5.1).

Por qué no AzCopy `sync`. `sync` compara el origen completo con el destino completo en cada pasada. Con más de 110 millones de archivos, cada pasada tardaría horas solo en listar. La copia por fecha de modificación solo toca lo nuevo.

6.2 Cuándo termina

La noche después del corte (lunes 15 de febrero) se hace la última pasada y una conciliación final (sección 7). Desde ahí, evidencias escribe directamente en Azure. Se apaga el agente y se retira la regla NSG-prod-11, como ya fija #14.

7. Verificación

Momento	Qué se verifica	Cómo
Cada trabajo	Que Azure copió todo lo que tenía cada disco	El registro de errores de cada disco que entrega el trabajo de importación. Un archivo con error se vuelve a enviar por la copia continua
Cada trabajo	Fechas originales e inmutabilidad	El proceso de la sección 4.3, con su propio registro
Conciliación (25 al 29 de enero)	Que están todos los archivos	Se compara el listado completo de Cali (ruta, tamaño y fecha) con el inventario de Blob de las dos cuentas. Toda diferencia se copia por la red
Conciliación	Que el contenido es el mismo	Se calcula el MD5 de una muestra del 1 % de los archivos en Cali y en Azure, desde una máquina de `snet-admin`, dentro de la región
Conciliación	Que la llave compartida sigue desactivada y que el acceso público queda desactivado del todo, ya sin la excepción de Import/Export	Azure Policy de la landing zone (#5)
Noche del 15 de febrero	Lo mismo, después de la última pasada	Ídem

Criterio para el ensayo: el 100 % de los archivos del listado de T1 está en Azure con el mismo tamaño, la muestra de MD5 coincide completa y no hay errores pendientes. Al cerrar la conciliación se enciende el escaneo de malware de la cuenta de documentos (#10).

El atraso de la copia continua tiene su alerta en el monitoreo de la migración: avisa si pasa de un día de crecimiento, unos 400 GB (#14, sección 6.4).

8. Diagramas

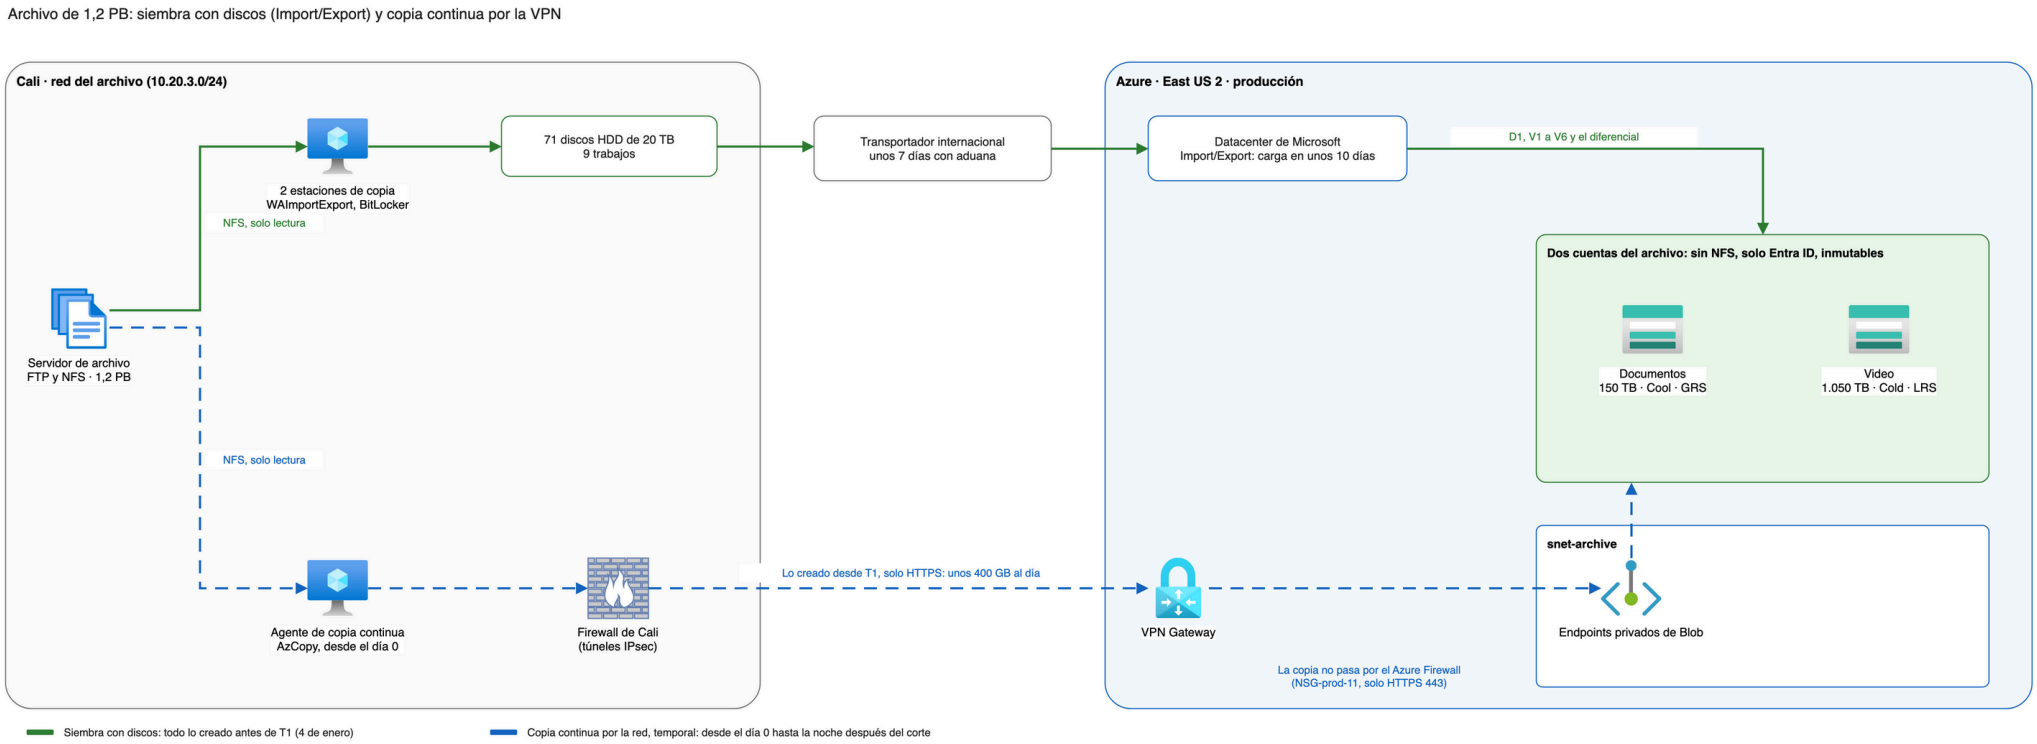


Figura 20: Camino del archivo de Cali a Azure: discos con Import/Export y copia continua por la VPN

El primer diagrama muestra los dos caminos: los discos, desde las estaciones de copia hasta las dos cuentas por Import/Export, y la copia continua, desde el agente de Cali por la VPN hasta los endpoints privados de `snet-archive`.

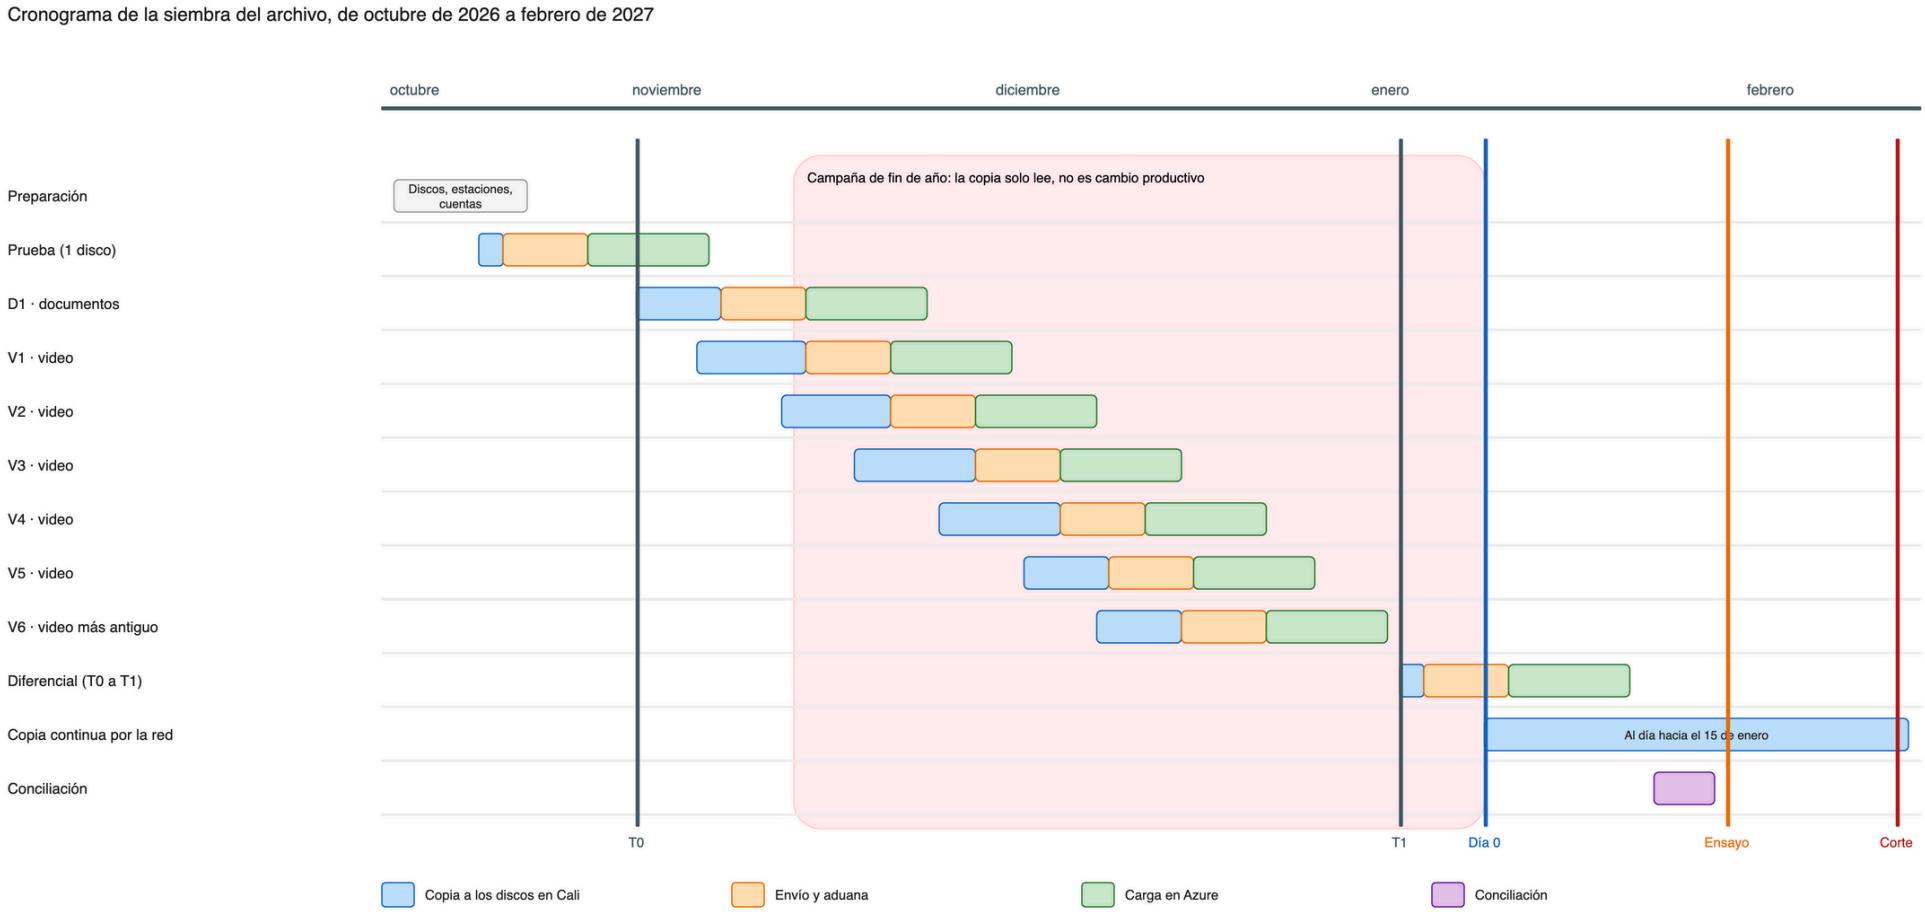


Figura 21: Cronograma de la siembra, de octubre de 2026 a febrero de 2027

El segundo diagrama es el cronograma de la sección 5.3: copia, tránsito y carga de cada trabajo, la copia continua, la conciliación, la campaña de fin de año y los hitos del plan de migración.

Los dos se generan con `tools/build_carga_c_diagrams.py`.

9. Costo

9.1 Líneas para el costo de la migración (#25)

Precios de lista de East US 2, consultados en la API pública de precios de Azure.

Línea	Cálculo	USD	Supuesto
Discos	74 × 450	33.300	HDD de 20 TB, SATA III, 512e, a unos USD 450 puestos en Cali. Se cotiza
Cargo de Import/Export	71 discos × 80	5.680	Precio de lista por disco procesado
Envío internacional de ida y vuelta, con aduana	9 envíos × 2 × unos 600	Unos 10.800	Una caja de hasta 10 discos por envío. Se cotiza con el transportador
Escritura de los documentos	Unos 115 millones de archivos × 0,20 por 10.000 (Cool GRS)	Unos 2.300	Un archivo pequeño es una escritura
Escritura del video	$1{,}05 \times 10^{15}$ / 4 MiB, unos 250 millones de bloques × 0,18 por 10.000 (Cold LRS)	Unos 4.500	El peor caso: cada bloque de 4 MiB cuenta como una escritura
Fecha original e inmutabilidad por archivo	Unos 117 millones de archivos × 2 operaciones	Unos 2.300	Dos escrituras por archivo, al precio de la cuenta de documentos
Estaciones de copia	2 × 3.000	6.000	Si FríoAndes no tiene equipos que sirvan
Almacenamiento antes de que la plataforma entre en operación	Ver la sección 9.3	—	Se cuenta en #25 hasta el corte
Total sin almacenamiento		**Unos 65.000**	

No incluye las horas del equipo: la preparación, unas 7 semanas de cambio de discos en las estaciones y la conciliación.

9.2 Decisiones que bajan o evitan gasto

Decisión	Alternativa descartada	Qué se evita
Siembra con discos propios	Copiar por la red	La red no alcanza: 278 días usando todo el enlace (sección 2)
El video se importa directo a Cold	Importar a Hot y moverlo después	Para 1.050 TB, Hot LRS cuesta unos USD 19.320 al mes y Cold LRS 3.780: unos USD 15.500 al mes mientras se esperaba el cambio de nivel
Video en LRS	Video en GRS	Unos USD 4.650 al mes en Cold (sección 4.1)
Escaneo de malware apagado durante la siembra	Escanear el 1,2 PB al importar	Unos USD 180.000, ya calculados en #10
La copia continua empuja desde Cali por HTTPS	Una máquina de copia en Azure que lee el NFS de Cali por la VPN	La máquina en Azure, su Defender for Servers y, sobre todo, la lentitud del NFS con 90 ms de latencia
No enviar lo que tenga más de cinco años, si FríoAndes lo confirma	Enviarlo todo	Cada 100 TB menos son 6 discos (unos USD 3.200 entre disco y cargo) y unos USD 360 al mes en Cold

9.3 Almacenamiento durante la siembra

Con todo cargado, a precios de lista: video, 1.050.000 GB × 0,0036 = USD 3.780 al mes; documentos, 150.000 GB × 0,02 = USD 3.000 al mes (Cool GRS). Son unos USD 6.780 al mes desde enero, que van creciendo a medida que llegan los trabajos desde finales de noviembre. #25 cuenta los meses hasta el corte y #26 el mes estable, con el crecimiento y los cinco años de retención.

10. Supuestos y confirmaciones pendientes de FríoAndes

10.1 Confirmaciones que necesita el diseño

Tema	Pregunta	Qué pasa si la respuesta cambia
Import/Export desde Colombia	¿Microsoft confirma la recepción en East US 2 de envíos desde Colombia, los tiempos de carga y la capacidad para unos 71 discos?	Si no, el archivo tendría que sembrarse por partes a lo largo de meses, y la convivencia de 90 días no alcanza
Aduana y transportador	¿Qué transportador y agente de aduana usa FríoAndes para exportar e importar temporalmente los discos, y cuánto tarda puerta a puerta?	Mueve el cronograma. El supuesto es de 7 días
Archivos de más de cinco años	¿El 1,2 PB incluye archivos de más de cinco años? ¿Se pueden borrar?	Si se pueden borrar, no se envían: menos discos y menos almacenamiento
Lectura del servidor de archivo	¿Qué velocidad de lectura aguanta el servidor sin degradar a evidencias? ¿Tiene una interfaz de 10 GbE libre?	Cambia la duración de la copia: el supuesto es de 27 TB al día
Organización del archivo	¿El archivo está organizado en carpetas por fecha? ¿Los archivos se modifican después de creados?	Define cómo recorre el archivo la copia continua cada hora
Redundancia del video	¿El contrato con los clientes exige copia geográfica también del video?	El video pasaría a GRS, unos USD 4.650 más al mes

10.2 Supuestos del diseño

Supuesto	Por qué se asume
Los discos son HDD de 20 TB, 3,5" SATA III, con formato 512e, y se llenan hasta 18 TB	Son discos de mercado que cumplen los requisitos de Import/Export
El servidor de archivo entrega 250 MB/s en horario de despacho y 500 MB/s de noche, unos 27 TB al día	No hay datos del servidor. Se mide la primera semana
El tránsito toma 7 días puerta a puerta y la carga en Azure 10 días desde que llegan los discos	Microsoft no publica tiempos. Se mide con el disco de prueba
Las fotos y comprobantes promedian 1 MB, unos 110 millones de archivos	El enunciado dice que la mayoría pesa menos de 2 MB
El crecimiento se reparte en unos 1,1 TB al mes de documentos y unos 10,9 TB de video	Sale de la proporción del archivo actual (110 TB frente a 1,05 PB), como en #10
Los archivos casi no se modifican después de creados	Son video, fotos, comprobantes firmados e históricos. La conciliación encuentra los que sí cambiaron
La importación funciona en contenedores con inmutabilidad por versión	Se comprueba con el disco de prueba. Si no, la inmutabilidad se activa al terminar cada importación
WAImportExport funciona en Windows Server 2022	La lista oficial es antigua. Si no funciona, se usa Windows 10 Enterprise aislada
Las dos cuentas del archivo existen en producción antes del 20 de octubre	Un trabajo de importación necesita su cuenta. Son la primera pieza de producción que se crea con el código de infraestructura (#20 a #22)

11. Validación y cierre

Criterio de aceptación	Evidencia en este documento
El documento muestra el cálculo de tiempo teórico por 400 Mbps compartido y concluye explícitamente que no es viable por red	Sección 2: 278 días con el enlace completo y 556 con la mitad, frente a 90 días de convivencia. "No es viable por la red"
Se dimensiona la cantidad de dispositivos Azure Data Box Heavy necesarios para 1,2 PB, y se define cómo se cierra el diferencial de crecimiento (~12 TB/mes) en el corte	Sección 3.1: con Data Box Heavy harían falta 2, pero está retirado y Data Box no se envía a Colombia; el medio disponible es Import/Export, dimensionado en la sección 5 (71 discos en 9 trabajos). Sección 6: el diferencial se cierra con un envío más de discos (T0 a T1) y la copia continua por la red desde T1, así que el corte solo sincroniza la última hora, unos 17 GB

6. Observabilidad

Observabilidad, objetivos de servicio y transición desde Zabbix

Este documento define cómo FríoAndes ve la salud de su plataforma en Azure: qué se mide en el cómputo, los contenedores, las bases, el almacenamiento y los enlaces hacia Cali y los centros; cómo las señales de seguridad llegan a la operación; qué registros, métricas y trazas dejan el despacho, el rastreo y la ingesta de telemetría; los dos objetivos de servicio de la plataforma; a quién le llega cada alerta, de día y de noche; los tableros de operación y de costo, y cómo se deja Zabbix durante la convivencia. Usa la red, el firewall, la telemetría, los datos personales, la gobernanza, la auditoría, la plataforma logística y la migración ya diseñados, con sus mismos nombres y decisiones.

Términos usados

Término	Significado en este documento
Métrica de plataforma	Valor numérico que cada servicio de Azure publica solo, cada minuto. Se guarda 93 días y no tiene costo
Registro de recurso	Detalle de lo que hace un servicio (por ejemplo, cada solicitud del Application Gateway). Se envía al espacio de Log Analytics con una configuración de diagnóstico
Espacio de Log Analytics	El almacén central de registros. Hay uno solo, en la suscripción de seguridad
Application Insights	El servicio que recibe las trazas, métricas y registros de las aplicaciones. Guarda sus datos en el espacio de Log Analytics
Traza	El recorrido de una solicitud por todos los servicios que toca, con el tiempo de cada paso
Objetivo de servicio	Una meta medible de lo que perciben los usuarios, con su indicador, su ventana y su margen de error
Margen de error	Cuánto incumplimiento se tolera en la ventana antes de fallar el objetivo
Grupo de acción	La lista de destinatarios y canales a los que Azure Monitor envía una alerta
Guardia de plataforma	La persona del equipo de operación que atiende las alertas críticas fuera de horario
Día N	Los días del plan de migración: día 0, inicio de la convivencia; día 34, corte; día 56, cierre del plazo de vuelta atrás; día 61, apagado de Zabbix; día 62, apagado de VMware; día 90, límite de la convivencia

---

1. Contexto y alcance

1.1 Qué necesita FríoAndes

Hoy una sola máquina Ubuntu 20.04 con Zabbix vigila el núcleo de Cali. La plataforma nueva corre en Azure, con servicios administrados que ya publican sus métricas, y con dos capacidades que la operación no puede perder de vista: el portal de rastreo, que usan unos 2.000 clientes corporativos, y la alerta de temperatura, que debe verse en menos de un minuto.

Pieza	Qué necesita FríoAndes	Dónde se responde
Salud de la plataforma	Cómputo, contenedores, bases, almacenamiento	Sección 3
Salud de los enlaces	Los túneles de Cali y de los ocho centros	Sección 3.5
Seguridad en la operación	Que las alertas de Defender for Cloud, del firewall y del portal lleguen a alguien que actúe	Sección 6.4
Aplicaciones	Registros, métricas y trazas de despacho, rastreo e ingesta	Sección 4

Pieza	Qué necesita FríoAndes	Dónde se responde
Objetivos de servicio	Disponibilidad del portal y oportunidad de la alerta, cada uno con su indicador	Sección 5
Tableros	De operación y de costo	Sección 7
Zabbix	Qué sigue vigilando durante la convivencia y cuándo se apaga	Sección 8

El diseño se organiza en cuatro áreas, las mismas del diagrama de la sección 2: salud de la plataforma, enlaces, seguridad, y despacho, rastreo e ingesta.

1.2 Qué toma de los otros diseños

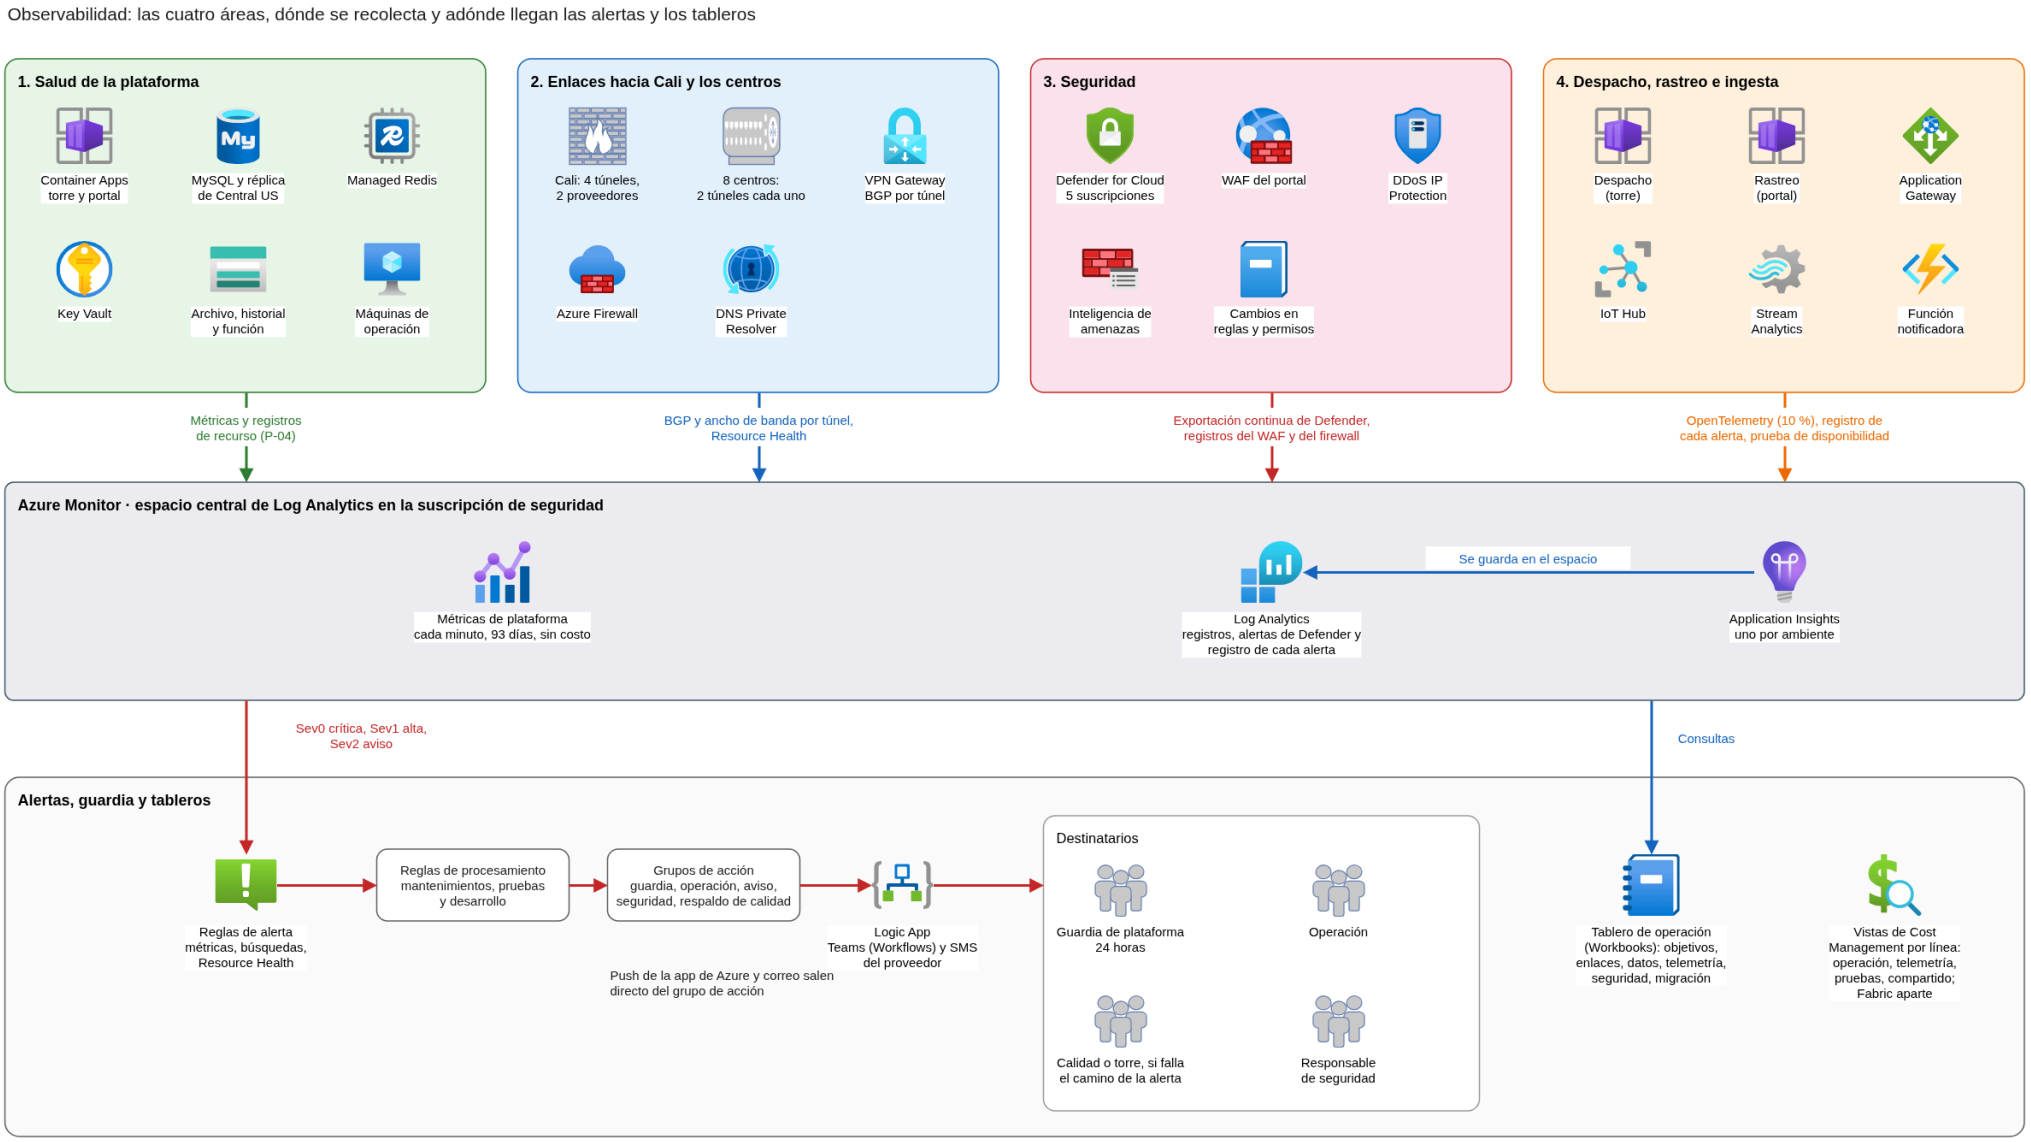
Viene de	Qué se usa aquí
`gobierno-landing-zone.md`	El espacio de Log Analytics vive en `sub-fa-security`; la política P-04 crea los diagnósticos; los grupos de Entra ID (`grp-fa-ops-prod`, `grp-fa-network`, `grp-fa-security`, `grp-fa-dev`, `grp-fa-qa`, `grp-fa-finops`); los presupuestos por suscripción
`gobierno-auditoria-facturacion.md`	Un solo espacio para las cinco suscripciones; retención por tabla (90 días consultables en las tablas técnicas); los eventos de auditoría de negocio por la API de ingesta; las líneas de costo operación, telemetría, pruebas y Fabric aparte
`red-topologia-subnetting.md`	VPN Gateway VpnGw1AZ activo-activo de unos 650 Mbps; Cali con dos proveedores y cuatro túneles con BGP; dos túneles por centro; DNS Private Resolver en el hub
`red-firewall-y-publicacion.md`	Salida a Azure Monitor por el Azure Firewall con la etiqueta `AzureMonitor`; registros y alertas del perímetro (sección 6)
`seguridad-datos-personales-perimetro.md`	Planes de Defender for Cloud por suscripción, las cinco alertas del portal, el procedimiento ante una alerta de seguridad, las alertas que llevan solo identificadores
`carga-b-telemetria.md`	La definición del minuto de la alerta, las cinco marcas de tiempo, la alerta sintética, las señales de salud del camino de la alerta, los canales (Teams por Workflows, correo y SMS por un proveedor con cobertura en Colombia) y la guardia de calidad de noche
`carga-a-plataforma-logistica.md`	Container Apps con entornos de torre y portal, MySQL Flexible Server 8.4 con alta disponibilidad zonal y réplica en Central US para el RPO de 15 minutos, Azure Managed Redis y Key Vault
`carga-c-migracion-y-campana.md`	El calendario de la convivencia y del apagado, el pedido de OpenTelemetry y de un chequeo de salud a los cinco contenedores, las dos señales de la migración (sección 6.4) y el apagado de Zabbix el día 61

1.3 Qué queda en otros diseños

- La observabilidad de Fabric y el apagado de su capacidad: `fabric-acceso-casos-uso-costo.md`. Puede usar el mismo espacio y los mismos grupos de acción de este documento.
- La retención de los registros de auditoría y los eventos de acceso a datos de clientes, evidencias y temperatura: el diseño de auditoría.
- Los montos de los presupuestos y el costo consolidado: el documento de costos. Este documento entrega el costo de la observabilidad (sección 9).

---

2. Dónde se recolecta



Objetivos de servicio: portal de rastreo, 99,9 % de minutos buenos en 28 días; alerta de temperatura, 99 % visible en 60 segundos o menos desde la lectura del sensor. Las métricas no se muestrean. Las vistas de costo leen directamente la facturación de Azure.

Figura 22: Las cuatro áreas, dónde se recolecta y adónde llegan las alertas y los tableros

2.1 Qué viaja y por dónde

Fuente	Cómo se recolecta	Destino
Recursos de Azure: firewall, Application Gateway, VPN Gateway, MySQL, Redis, Key Vault, almacenamiento, IoT Hub, Stream Analytics, Event Hubs	Métricas de plataforma, cada minuto, sin configuración y sin costo	El almacén de métricas de cada recurso, 93 días
Los mismos recursos	Registros de recurso por diagnóstico, en modo de recurso específico, creados por la política P-04	Espacio central
Registro de actividad de las cinco suscripciones	Diagnóstico de suscripción	Espacio central
Container Apps: salida de consola y registros del sistema	Destino "Azure Monitor" del entorno, más un diagnóstico del entorno	Espacio central
Los ocho servicios de torre y portal	Distro de OpenTelemetry de Microsoft dentro de cada contenedor, con la identidad administrada	Application Insights del ambiente
Función notificadora	Integración de Azure Functions con Application Insights, autenticada con Entra ID	Application Insights del ambiente
Registro de cada alerta de temperatura	API de ingesta de registros, desde la función notificadora	Tabla propia en el espacio central (sección 4.5)
Eventos de auditoría de negocio	API de ingesta de registros, como define el diseño de auditoría	Tabla de auditoría
Alertas de Defender for Cloud	Exportación continua de cada suscripción	Espacio central
Máquinas de operación de `snet-admin`	Métricas del host, sin agente	Almacén de métricas

2.2 Decisiones de recolección

Decisión	Alternativa descartada	Por qué
Un Application Insights por ambiente (producción, pruebas y desarrollo), guardado en el espacio central	Uno por servicio, o uno solo para todo	Microsoft recomienda separar las etapas y usar un solo recurso para componentes que se despliegan juntos y maneja el mismo equipo. El mapa de aplicación y las trazas de punta a punta quedan en un lugar
El Distro de OpenTelemetry dentro de cada servicio	El agente OpenTelemetry administrado de Container Apps	Según Microsoft, ese agente no envía métricas a Application Insights, corre en una sola réplica sin alta disponibilidad, no expone su propia salud y exige dejar activa la autenticación local. Con el Distro, cada servicio publica con su identidad administrada (rol Monitoring Metrics Publisher) y Application Insights puede desactivar la autenticación local
Registros de Container Apps con el destino "Azure Monitor" y un diagnóstico	El destino "Log Analytics" directo	Encaja con P-04 y con un espacio en otra suscripción. Es el único que admite Private Link si se activa después

Decisión	Alternativa descartada	Por qué
Salida a Azure Monitor por el Azure Firewall con la etiqueta `AzureMonitor` (reglas FW-304, FW-310 y FW-316)	Private Link de Azure Monitor (AMPLS) en el hub	Los diagnósticos, el mayor volumen, viajan por un canal privado de Microsoft sin pasar por la red. Un AMPLS tiene que ser único para todas las redes que comparten DNS, y aquí son todas, incluidas Cali y los centros; su modo más estricto bloquea cualquier recurso de Azure Monitor fuera de él. Queda como camino de mejora si FríoAndes quiere impedir la salida de datos hacia espacios ajenos
El espacio en East US 2, sin réplica	Réplica del espacio en Central US	La réplica es de pago, el cambio de región es manual y Application Insights no se replica. Durante un failover, el procedimiento de continuidad se apoya en las métricas de plataforma de los recursos de Central US, que no dependen del espacio
Las métricas se quedan en su almacén y las alertas de salud se construyen sobre ellas	Exportar todas las métricas al espacio	La exportación cuesta ingesta, aplana las dimensiones y no admite todas las métricas
Máquinas de operación con métricas del host	Azure Monitor Agent con una regla de recolección	Son máquinas de salto, su seguridad la cubre Defender for Servers, y el agente exigiría abrir `AzureMonitor` desde `snet-admin`

Una regla nueva en el firewall. La API de ingesta de registros (`*.ingest.monitor.azure.com`) no está cubierta por la etiqueta `AzureMonitor`: Microsoft indica que las etiquetas de servicio no incluyen las direcciones de los endpoints de recolección. La necesitan los eventos de auditoría de negocio y el registro de cada alerta. Se agregan FW-322, FW-323 y FW-324, una regla de aplicación HTTPS por ambiente desde la torre, el portal y la función notificadora (`red-firewall-y-publicacion.md`, sección 4.3).

---

3. Salud de la plataforma y de los enlaces

3.1 Criterios comunes

- Las alertas de salud usan métricas de plataforma o Resource Health. Solo lo que no existe como métrica se busca en los registros.
- Hay tres niveles, que la sección 6 convierte en destinatarios: **crítica**, afecta ahora el despacho, el portal o la alerta de temperatura; **alta**, se pierde redundancia o se acerca un límite; **aviso**, una tendencia que se revisa en horario.
- Los umbrales son iniciales y se ajustan con el primer mes de datos, igual que los límites del WAF.
- Cada recurso crítico tiene además una alerta de Resource Health (no disponible o degradado, nivel alto), y la suscripción una alerta de Service Health para East US 2 y Central US.

3.2 Cómputo y contenedores

Componente	Señal	Umbral inicial	Nivel
Cada aplicación de torre y portal	Réplicas por debajo del mínimo configurado	5 minutos	Alta
Ídem	Reinicios	Más de 3 en 15 minutos	Alta

Componente	Señal	Umbral inicial	Nivel
Ídem	Uso de CPU y de memoria (métricas en preview)	Más de 80 % durante 15 minutos	Aviso
Servicios de la torre	Respuestas 5xx	Más del 5 % durante 5 minutos	Crítica
Entornos de torre y portal	Nodos del perfil dedicado (métrica en preview)	Más de 16 de los 20 reservados	Aviso
Máquinas de operación	Resource Health	No disponible	Aviso

La disponibilidad del portal no aparece aquí porque es un objetivo de servicio (sección 5.2). En campaña, la regla de escala por calendario de la torre sube el mínimo de réplicas (`carga-c-migracion-y-campana.md`, sección 7.6); la alerta de réplicas compara contra el mínimo vigente.

3.3 Bases y caché

Componente	Señal	Umbral inicial	Nivel
MySQL Flexible Server	CPU	Más de 70 % durante 30 minutos, el mismo tope que valida la prueba de carga de campaña	Aviso
Ídem	CPU	Más de 90 % durante 15 minutos	Alta
Ídem	Almacenamiento	80 % aviso, 90 % alta	Aviso y alta
Ídem	Memoria y E/S	Más de 90 % durante 15 minutos	Alta
Alta disponibilidad zonal	Hilos de replicación hacia el servidor en espera	Detenidos 5 minutos	Alta
Réplica de Central US	Retraso de replicación	Más de 5 minutos aviso, más de 10 minutos alta	Aviso y alta
Azure Managed Redis	Carga del servidor y memoria usada	Más de 80 % durante 15 minutos	Aviso
Key Vault	Disponibilidad	Menos de 100 % durante 5 minutos	Alta

El retraso de la réplica es la cantidad de datos que se perderían si hubiera que promoverla. Las alertas están por debajo del RPO de 15 minutos para que haya tiempo de actuar.

3.4 Almacenamiento

Componente	Señal	Umbral inicial	Nivel
Cuentas del archivo, del historial de telemetría y de la función	Disponibilidad	Menos de 99,9 % durante 15 minutos	Alta
Ídem	Transacciones con error del servidor o limitadas	Más del 1 % durante 15 minutos	Aviso
Cuentas del archivo	Capacidad usada	Solo en el tablero: crece unos 12 TB al mes	Tablero

3.5 Enlaces hacia Cali y los centros

Componente	Señal	Umbral inicial	Nivel
Túneles del proveedor principal de Cali	Estado BGP de cada túnel	Uno caído 5 minutos alta, los dos crítica	Alta y crítica
Túneles del proveedor de respaldo de Cali	Estado BGP	Caído 15 minutos: no lleva tráfico, pero es la ruta redundante	Alta
Túneles de cada centro	Estado BGP	Uno caído 5 minutos aviso, los dos crítica	Aviso y crítica
VPN Gateway	Ancho de banda total	Más del 80 % de unos 650 Mbps durante 15 minutos	Aviso

Componente	Señal	Umbral inicial	Nivel
Túnel de Cali	Ancho de banda	Más del 80 % de 400 Mbps durante 15 minutos	Aviso
Cada túnel	Paquetes descartados	Sostenidos 15 minutos	Aviso
VPN Gateway, conexiones y DNS Private Resolver	Resource Health	No disponible o degradado	Alta
Azure Firewall	Puertos SNAT y sonda de latencia	SNAT más de 80 %	Aviso

El estado de los túneles se mide por BGP porque los túneles de respaldo de Cali no llevan tráfico: una alerta por ancho de banda no los distinguiría de un túnel caído. Cuando un centro pierde sus dos túneles, también se dispara la alerta "sensor sin señal" de sus cuartos fríos (`carga-b-telemetria.md`, sección 3.3); las dos se confirman entre sí. El umbral del túnel de Cali deja espacio para la copia continua del archivo, que usa hasta 250 Mbps de noche durante la convivencia.

Microsoft ofrece Connection Monitor para medir la latencia y la pérdida de punta a punta, pero exige una extensión en una máquina de Azure y una regla nueva desde `snet-admin` hacia las sedes. Al inicio basta con las métricas del gateway; si la operación necesita la latencia hacia cada sede, se activa con 9 pruebas, dentro de las 10 que Microsoft no cobra.

3.6 Señales de la migración

Solo existen durante la convivencia y responden a las dos señales que pide el plan de migración (`carga-c-migracion-y-campana.md`, sección 6.4).

Señal	Cómo se mide	Umbral	Nivel
Replicación de DMS detenida	Escrituras aplicadas en el MySQL de Azure	Cero durante 10 minutos en horario de despacho	Alta
Retraso de DMS	Campo "Seconds behind source" de la pantalla de DMS	5 minutos, revisado al abrir y al cerrar cada ventana y en el corte	Procedimiento
Copia continua del archivo detenida	Datos que entran a las cuentas del archivo	Cero durante 3 horas en horario de despacho	Alta
Atraso de la copia	Zabbix en Cali: antigüedad de la última pasada exitosa del agente de copia	Más de 24 horas, unos 400 GB	Alta

Microsoft muestra el retraso de DMS en la pantalla de la migración y no lo publica como métrica de Azure Monitor. Por eso la alerta automática vigila que las escrituras sigan llegando, y el retraso exacto lo revisa el equipo de base de datos, como ya hace el guion del corte la noche anterior y antes de iniciar el corte (`carga-c-migracion-y-campana.md`, sección 5.3). El agente de copia vive en Cali, así que lo vigila Zabbix hasta que la copia termina el día 35.

---

4. Registros, métricas y trazas de despacho, rastreo e ingesta

4.1 Reglas para los servicios

Los servicios son los de la plataforma logística: en el entorno de la torre, el front de la torre, guías, asignación de muelle y ruta, inventario, facturación corporativa y evidencias; en el del portal, el front del portal y rastreo.

Regla	Detalle	Por qué
Nombre y versión	Cada servicio declara su nombre (`service.name`) y la versión desplegada (`service.version`)	El mapa de aplicación identifica los componentes por ese nombre, y la versión

Regla	Detalle	Por qué
		separa la telemetría de cada salida a producción
Trazas	Automáticas en HTTP, MySQL, Redis, Key Vault y Blob. El contexto W3C (`traceparent`) viaja entre servicios	Una solicitud se sigue de punta a punta con un solo identificador de operación
Muestreo	Fijo del 10 % de las trazas en torre y portal. Se sube al 100 % durante el ensayo y el corte	Las métricas no se muestrean, así que las alertas, los tableros y los dos objetivos no pierden datos. Con 10 % quedan unas 65.000 trazas al día de la torre para diagnosticar
Registros	Por OpenTelemetry solo ERROR, y WARN cuando haya una acción que tomar. La consola del contenedor queda para el arranque y las caídas	Es lo que recomienda Microsoft y evita pagar dos veces el mismo registro
Datos personales	Solo identificadores internos: guía, cliente, cuarto, camión. Nunca nombres, documentos, firmas ni posiciones. La IP queda enmascarada (0.0.0.0), que es el comportamiento por defecto de Application Insights	Lo mismo que piden el mapa de datos personales y el diseño de auditoría
Telemetría del navegador	No se recolecta al inicio	El SDK de JavaScript no admite ingesta con Entra ID, y el objetivo del portal se mide en el gateway

Estas reglas completan dos ajustes que el plan de migración ya pidió al equipo de desarrollo: emitir métricas, registros y trazas con OpenTelemetry y exponer un chequeo de salud por HTTP (`carga-c-migracion-y-campana.md`, sección 2.4).

4.2 Despacho (torre)

Qué	Señal
Métricas de negocio	Guías creadas por minuto, asignaciones de muelle y ruta por minuto, tiempo de asignación
Métricas técnicas	Solicitudes, duración y fallas por servicio, que Application Insights calcula sin muestreo
Trazas	Front de la torre, guías o asignación, MySQL y Redis
Registros	Errores de negocio, como una asignación rechazada o una guía sin ruta

4.3 Rastreo (portal)

Qué	Señal
Métricas de negocio	Consultas de guía por minuto, respuestas 429 por el límite por cuenta, consultas a guías ajenas
Métricas técnicas	Duración p95 de la consulta de guía, fallas, dependencias lentas
Trazas	Front del portal, rastreo, Redis o MySQL, y Blob cuando se piden comprobantes y fotos
Registros	Errores. Los eventos de seguridad y de auditoría van por su propio camino (`seguridad-datos-personales-perimetro.md`, sección 5.4)

4.4 Ingesta (telemetría)

Qué	Señal
Métricas	Las de plataforma de IoT Hub, Stream Analytics y Event Hubs que ya nombra el diseño de telemetría (sección 6.2): dispositivos conectados, retraso de la marca de agua, alertas acumuladas sin leer

Qué	Señal
Traza de cada alerta	Las cinco marcas de tiempo del diseño de telemetría (sensor, IoT Hub, Stream Analytics, notificador y canal), unidas por el identificador de la alerta. Desde la función notificadora, la traza continúa con W3C hacia la API de la torre y los canales
Registros	Ejecuciones fallidas de la función y fallas de envío por canal

Así, si una alerta llega tarde, se ve en qué tramo del presupuesto de 40 segundos se perdió el tiempo (`carga-b-telemetria.md`, sección 3.1).

4.5 Registro de cada alerta

La función notificadora escribe una fila por alerta, real o sintética, en una tabla propia del espacio central, por la API de ingesta de registros: identificador, sensor, tipo, si es sintética, las cinco marcas de tiempo, el canal y el resultado. Es la fuente del objetivo de la alerta. Va por la API de ingesta porque así no se muestrea ni depende del límite diario de Application Insights, y usa el mismo mecanismo que los eventos de auditoría.

4.6 Durante el corte

Live Metrics muestra en vivo las solicitudes y fallas de los servicios. Lo usa el monitoreo reforzado del corte, hasta las 06:00 del domingo, junto con el criterio "las ocho aplicaciones responden sus chequeos de salud y no hay errores 5xx en el Application Gateway" (`carga-c-migracion-y-campana.md`, sección 5.4). Sus endpoints entran en la etiqueta `AzureMonitor`.

---

5. Los dos objetivos de servicio

5.1 Común a los dos

- **Ventana móvil de 28 días.** Son cuatro semanas completas, con la misma cantidad de lunes y de domingos.
- Se calculan con consultas al espacio central. Las tablas que usan (registros del Application Gateway, resultados de la prueba de disponibilidad y registro de cada alerta) guardan 90 días consultables, más que la ventana.
- **Política del margen.** Si se agota el margen de un objetivo, se suspenden los cambios no urgentes de esa parte hasta recuperarlo y se analiza la causa.

5.2 Disponibilidad del portal de rastreo

Elemento	Definición
Indicador	Porcentaje de minutos buenos en la ventana
Minuto malo	Más del 1 % de respuestas 5xx en el Application Gateway en ese minuto, o la prueba de disponibilidad falla en 3 de sus 5 ubicaciones
No cuentan como error	Las respuestas 4xx: bloqueos del WAF (403), límite por cuenta (429), guías inexistentes (404). Son los límites del diseño de datos personales funcionando como se espera
Prueba de disponibilidad	Prueba estándar de Application Insights cada 5 minutos desde Brazil South, East US, Central US, North Central US y South Central US, con reintentos y validación del certificado. Con cinco ubicaciones, el portal se prueba en promedio una vez por minuto. Llama a la ruta de salud del portal, que pasa por rastreo, Redis y MySQL
Mantenimientos	Los minutos de un mantenimiento aprobado y avisado a los clientes, como el corte, se marcan y no cuentan
Meta	**99,9 % de minutos buenos en 28 días**
Margen	Unos 40 minutos malos (40.320 minutos × 0,1 %)

El indicador combina dos fuentes porque cada una ve lo que la otra no: de noche casi no hay tráfico, y si el gateway cae por completo no deja registros; en los dos casos la prueba sintética muestra la falla. La prueba

llega desde fuera de Colombia, así que la regla 4 del WAF la registra; no afecta las alertas del portal, que se basan en cuentas.

Los mantenimientos anunciados no cuentan porque el corte avisa a los clientes con siete días de anticipación y dura dos horas: contarlo triplicaría el margen y haría fallar el objetivo por diseño en el mes del corte.

Encaje con los SLA de Microsoft. Application Gateway v2 ofrece 99,95 % y MySQL Flexible Server con alta disponibilidad zonal hasta 99,99 %. El SLA de Container Apps depende de las reglas de escala y su cifra está en el documento de SLA de servicios en línea de Microsoft, que se confirma antes de fijar la meta (sección 10.1). Con al menos dos réplicas del portal en zonas distintas, la meta de 99,9 % queda por debajo del SLA del gateway.

5.3 Oportunidad de la alerta de temperatura

Elemento	Definición
Indicador	Porcentaje de alertas de excursión, reales y sintéticas, visibles en 60 segundos o menos desde la hora de la lectura del sensor
Visible	La API de la torre confirma la alerta (de día) o Teams acepta el mensaje (de noche y en el canal de monitoreo)
Exclusión	Las alertas cuya lectura tardó más de 25 segundos del sensor a IoT Hub. El resto del camino tiene un presupuesto de 35 segundos, así que en esos casos la red ya consumió el minuto. Se cuentan aparte
Meta	**99 % en 28 días**
Margen	Con unas 2.700 alertas sintéticas en 28 días (96 al día) más las reales, unas 27 pueden llegar tarde

Coherencia con el requisito de menos de un minuto. El umbral del indicador es el mismo minuto que exige la operación, contado como lo define el diseño de telemetría (desde la lectura del sensor hasta que la alerta se ve), y la exclusión corresponde a "condiciones normales de red". El presupuesto de diseño de 40 segundos queda como alerta temprana.

Las alertas sintéticas cuentan junto con las reales porque recorren el mismo camino: sin ellas, un mes con pocas excursiones tendría tan pocos datos que una sola alerta tarde movería el resultado varios puntos.

5.4 Alertas sobre los objetivos

Objetivo	Alerta	Nivel
Portal	La prueba de disponibilidad falla en 3 de 5 ubicaciones	Crítica
Portal	5 minutos malos en la última hora (12 % del margen)	Crítica
Portal	10 minutos malos en las últimas 6 horas	Alta
Portal	Más de la mitad del margen consumido	Aviso
Alerta	Una alerta sintética no llega en un minuto, dos veces seguidas	Crítica, con aviso de respaldo a calidad o a la torre (sección 6.2)
Alerta	5 alertas tarde en 24 horas	Alta
Alerta	Percentil 95 por encima de 40 segundos durante 24 horas	Aviso
Alerta	Más de la mitad del margen consumido	Aviso
Alerta	Más de 5 alertas excluidas en una hora del mismo centro o del mismo operador	Aviso: problema de red que el objetivo no mide

6. Alertas, guardia y seguridad en la operación

6.1 Niveles, destinatarios y canales

Nivel	Severidad en Azure Monitor	Quién y cuándo	Canal
Crítica	Sev0	Guardia de plataforma, las 24 horas	Push de la app de Azure, correo, Teams del canal de operación y SMS
Alta	Sev1	Equipo de operación, las 24 horas	Push, correo y Teams
Aviso	Sev2	Equipo de operación, en horario	Correo y Teams, con revisión semanal

Canales. Se reutilizan los que ya fijó el diseño de telemetría: Teams por el webhook de Workflows, y SMS por el proveedor con cobertura en Colombia que elige FríoAndes. Los grupos de acción de Azure Monitor no envían SMS ni llamadas a Colombia (el país no está en sus listas) y su webhook no adapta la alerta al formato de Teams. Por eso una Logic App recibe la alerta, la convierte en una tarjeta adaptable y la envía al webhook de Workflows del canal de operación, y en las críticas envía también el SMS por el proveedor. El push y el correo salen directo del grupo de acción. La Logic App corre fuera de las redes de FríoAndes, así que no cambia el firewall.

Los mensajes llevan solo el recurso, la señal y el valor, igual que las alertas de temperatura llevan solo camión, guía y temperatura (`seguridad-datos-personales-perimetro.md`, sección 2.3).

6.2 Grupos de acción

Grupo	Para qué
`ag-fa-guardia`	Alertas críticas: guardia de plataforma
`ag-fa-operacion`	Alertas altas: equipo de operación
`ag-fa-aviso`	Avisos
`ag-fa-calidad-respaldo`	Cuando falla el camino de la alerta de temperatura. Avisa de día al supervisor de turno de la torre y de noche a la guardia de calidad, para que vigilen de forma manual mientras se repara. Sale por la Logic App, sin pasar por la función notificadora: si la falla está en la función, este aviso no depende de ella
`ag-fa-seguridad`	Alertas de seguridad, al nivel que corresponda, más el responsable de seguridad de FríoAndes

La guardia de calidad sigue recibiendo las alertas de temperatura por la función notificadora, con su cadena de escalamiento (`carga-b-telemetria.md`, sección 3.4). De la plataforma solo recibe el aviso de respaldo.

6.3 Reglas de procesamiento

Regla	Qué hace
Pruebas y desarrollo	Toda alerta de esos ambientes va a `ag-fa-aviso`, sin push ni SMS
Mantenimientos aprobados	Suprime las notificaciones de los recursos en cambio durante la ventana, con su programación y la zona horaria de Bogotá. Nunca se aplica al camino de la alerta de temperatura, que sigue operando durante los cambios
Señales de la migración	Las alertas de escrituras de DMS y de la copia del archivo se suprimen de 22:00 a 04:00

6.4 Seguridad en la operación

- **Exportación continua de Defender for Cloud** desde las cinco suscripciones al espacio central. Las alertas de Defender no llegan solas al espacio: se configura por suscripción, con el rol Security Admin. Defender limita sus correos a 4 al día de severidad alta por dirección, así que las alertas se atienden desde el espacio.
- **Severidades.** Una regla de búsqueda sobre las alertas exportadas convierte la severidad alta de Defender en crítica, la media en alta y la baja en aviso, todas con `ag-fa-seguridad`.
- **Alertas del perímetro y del portal**, ya definidas en sus diseños, con su nivel:

Alerta	Origen	Nivel
Destino malicioso en el firewall	`red-firewall-y-publicacion.md`, sección 6.2	Crítica
Mitigación de DDoS en curso	Ídem	Crítica
El Application Gateway pierde acceso al certificado en Key Vault	Ídem	Crítica
Salud del firewall	Ídem	Crítica
Aumento de bloqueos del WAF	Ídem	Alta
Capacidad del portal por encima del 75 %	Ídem	Alta
Rechazos fuera de lo normal en el firewall	Ídem	Aviso
Cambio en reglas del firewall, los NSG o el WAF	Ídem	Aviso, contrastado con los cambios aprobados
Barrido de guías	`seguridad-datos-personales-perimetro.md`, sección 5.4	Alta
Intentos de acceso fallidos	Ídem	Alta
Cuenta desde otro país, volumen anómalo de una cuenta, límites del WAF repetidos	Ídem	Aviso

- **Después de una alerta de seguridad** se sigue el procedimiento del diseño de datos personales: bloquear la IP o la cuenta, avisar al cliente dueño de la cuenta, conservar los registros y evaluar el aviso a la SIC (`seguridad-datos-personales-perimetro.md`, sección 5.6).

6.5 Roles de monitoreo

Grupo	Rol	Ámbito
`grp-fa-ops-prod`	Monitoring Contributor, Log Analytics Reader, Workbook Contributor	Suscripción de producción y espacio central
`grp-fa-network`	Monitoring Reader	Suscripción de conectividad, con acceso a los registros de sus recursos
`grp-fa-security`	Log Analytics Reader	Espacio central
`grp-fa-dev` y `grp-fa-qa`	Monitoring Reader y lectura de su Application Insights	Su suscripción, por contexto de recurso: ven solo los registros de sus recursos, sin lectura global del espacio
`grp-fa-finops`	Cost Management Reader	Las cinco suscripciones
Identidades de los servicios	Monitoring Metrics Publisher	Application Insights de su ambiente
Identidad de la función notificadora	Permiso de envío en la regla de recolección	Tabla del registro de cada alerta
Torre y calidad	Ninguno sobre el espacio	Solo reciben notificaciones

El acceso por contexto de recurso cumple lo que fija el diseño de auditoría: las aplicaciones y los desarrolladores no reciben lectura global del espacio.

---

7. Tableros de operación y de costo

7.1 Tablero de operación

Un libro de Azure Workbooks, versionado como código junto con la infraestructura, con estas pestañas:

Pestaña	Qué muestra
Ahora	Los dos objetivos con su margen, alertas abiertas, réplicas y 5xx de torre y portal, estado de los túneles de Cali y de cada centro, últimas alertas sintéticas
Enlaces	BGP y ancho de banda por sede, paquetes descartados, firewall
Datos	MySQL, retraso de la réplica, Redis, almacenamiento
Telemetría	IoT Hub, Stream Analytics, event hubs, alertas por hora y en qué tramo tardaron
Seguridad	Alertas de Defender abiertas, bloqueos del WAF, inteligencia de amenazas
Migración	Escrituras de DMS, copia del archivo y avance del apagado de Zabbix. Se retira al terminar la convivencia
Costo de la observabilidad	GB ingeridos por tabla y por día, para ver qué fuente crece

Se eligió Workbooks porque combina texto, consultas, métricas y parámetros en el portal, sin costo, y sirve también para el informe mensual de los objetivos. Los dashboards de Grafana del portal tampoco tienen costo, pero no tienen alertas de Grafana y su recurso de definición está en una API preview; Managed Grafana es de pago y solo se justifica con fuentes fuera de Azure.

7.2 Tablero de costo

- Vistas compartidas de Cost Management con las líneas del modelo de facturación interna: operación, telemetría, pruebas y compartido, con Fabric aparte, más una vista por suscripción (`gobierno-auditoria-facturacion.md`, sección 5). Las vistas leen directamente la facturación de Azure.
- Los presupuestos y sus alertas siguen la landing zone y van a finanzas, nunca a la guardia: una alerta de costo no detiene el despacho ni la telemetría.
- La pestaña de costo de la observabilidad del tablero de operación (sección 7.1).

---

8. Transición desde Zabbix

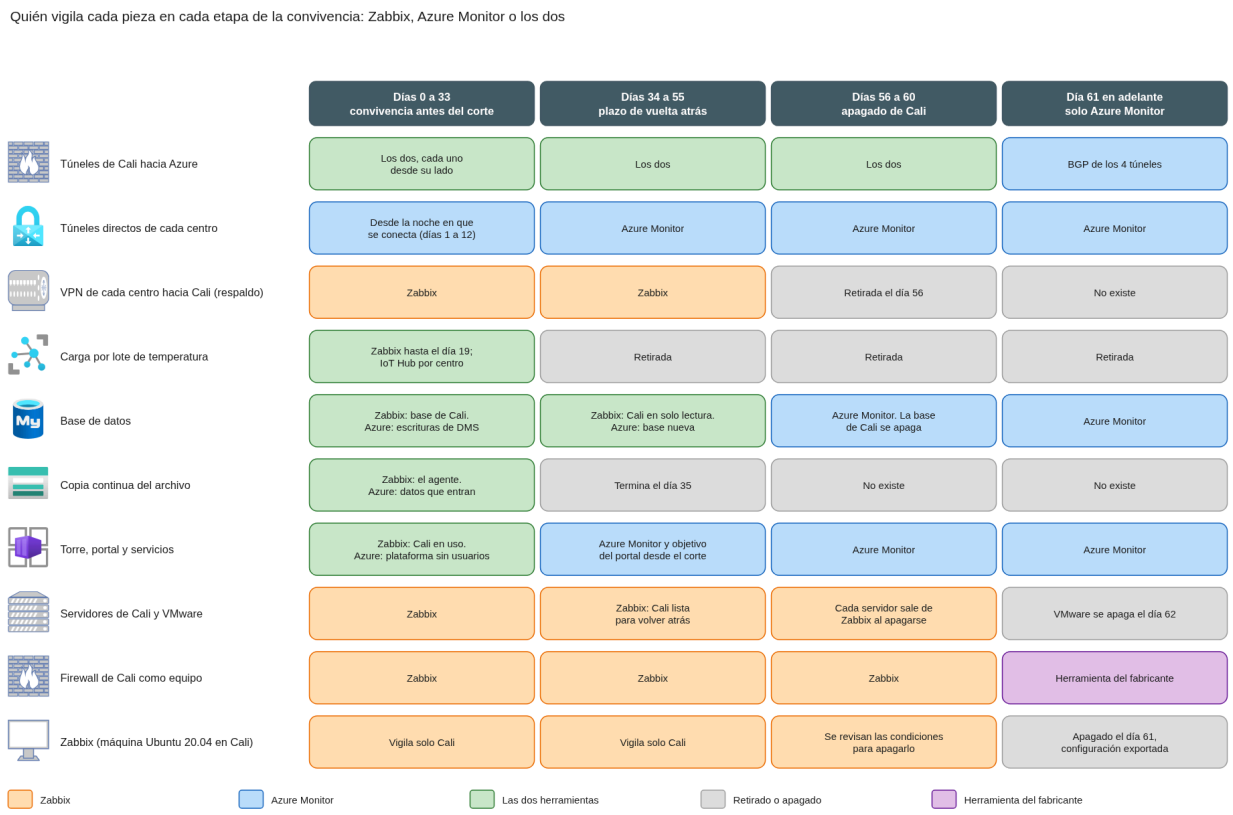


Figura 23: Quién vigila cada pieza en cada etapa de la convivencia

8.1 Principio

Zabbix vigila solo lo que está en Cali y Azure Monitor solo lo que está en Azure. Los túneles cruzan las dos redes, y cada herramienta los ve desde su lado. Zabbix no recibe reglas nuevas hacia Azure y Azure Monitor no instala agentes en Cali: los servidores de Cali se apagan entre los días 56 y 60, y un agente en ellos se pagaría para dos meses.

8.2 Lo que vigila Zabbix hoy

El inventario se deduce del datacenter y se concilia con la exportación de la configuración de Zabbix antes del día 0, igual que la política real del firewall de Cali.

Grupo	Piezas
Servidores	Las 14 máquinas virtuales: MySQL 5.7 de producción, desarrollo y pruebas; Redis 5; 4 de aplicación con Docker; 2 de Nginx; 2 de front; el servidor FTP y NFS; Zabbix
Virtualización	Los 3 clústeres de VMware, 6 servidores físicos
Red de la sede	Firewall de Cali, firewall de aplicaciones, VPN con los ocho centros, enlace de internet
Durante la convivencia	El agente de copia continua del archivo que se instala en la red del archivo de Cali

8.3 Qué deja de cubrir Zabbix y cuándo

Pieza	Zabbix la vigila hasta	Quién la cubre en Azure y desde cuándo	Condición para quitarla de Zabbix
Túneles de Cali hacia Azure	Día 61, desde el lado de Cali	BGP y ancho de banda del VPN Gateway, desde el día 0	Alerta probada al activar los túneles

Pieza	Zabbix la vigila hasta	Quién la cubre en Azure y desde cuándo	Condición para quitarla de Zabbix
Túnel directo de cada centro	Zabbix no los ve	BGP del gateway, desde la noche en que se conecta cada centro (día 1 el piloto, días 3 a 12 los demás)	La alerta de cada centro se crea y se prueba esa misma noche
VPN de cada centro hacia Cali (respaldo)	Día 56	Se retira	Cierre del plazo de vuelta atrás
Carga por lote de temperatura	Día 19	IoT Hub y la alerta "sensor sin señal", desde que cada centro envía en línea	Siete días en paralelo por centro, como fija el plan de migración
Base de Cali	Día 34 como base activa; en solo lectura hasta el día 56	MySQL Flexible Server: escrituras de DMS desde el día 5, toda su salud desde el corte	Corte firmado
Agente de copia del archivo	Día 35	Datos que entran a las cuentas del archivo, desde el día 0	Conciliación final del archivo
Contenedores, Nginx y front de Cali	Día 34 como servicio; hasta su apagado como servidores (días 56 a 60)	Container Apps, Application Gateway y el objetivo del portal, desde el corte	Cada servidor sale de Zabbix el día en que se apaga, para no generar falsas alarmas
Cali lista para volver atrás	Días 34 a 56	No aplica	Cierre del plazo de vuelta atrás
NAT y firewall de aplicaciones del portal	Día 56	El WAF del Application Gateway, desde el corte	Se retiran al cerrar el plazo
VMware	Día 61	Se apaga el día 62	Zabbix corre sobre VMware, así que se apaga antes
Firewall de Cali como equipo	Día 61	Los cuatro túneles quedan en Azure Monitor; la salud del equipo (CPU, sesiones, firmware) la lleva el equipo de redes con la herramienta del fabricante	Herramienta del fabricante configurada

Durante el plazo de vuelta atrás, Zabbix hace su último trabajo útil: confirmar que Cali sigue lista para volver atrás, con la base en solo lectura y los servidores encendidos (`carga-c-migracion-y-campana.md`, sección 6.1).

8.4 Condiciones para apagar Zabbix el día 61

El plan de migración fija el apagado de Zabbix el día 61, un día antes que VMware (`carga-c-migracion-y-campana.md`, sección 6.3). Se apaga si se cumplen estas condiciones:

1. Cada elemento de la configuración exportada de Zabbix está en una de dos listas: "ya no existe" (servidor apagado o regla retirada) o "cubierto en Azure", con su alerta probada.
2. Las alertas de los 4 túneles de Cali y de los 16 de los centros se dispararon al menos una vez en prueba.
3. El objetivo del portal lleva 27 días de datos desde el corte, y el de la alerta al menos 61, porque la alerta sintética corre desde antes del día 0.
4. La configuración final y los eventos de los últimos 90 días de Zabbix se exportan al archivo de Azure, como referencia.
5. Firman operación y redes.

Si una condición falla, Zabbix se apaga en una noche de reserva antes del día 90, y VMware se corre con él. Después del día 61 no queda ninguna herramienta de monitoreo en Cali.

9. Costo

9.1 Volumen mensual estimado en el espacio central

Producción, salvo donde se indica.

Fuente	Supuesto	GB al mes
Trazas de torre y portal	Torre: 300 usuarios activos en promedio, 2 solicitudes por minuto, 18 horas, unos 19,4 millones de solicitudes al mes. Portal: 200 solicitudes por minuto durante 18 horas y 20 de noche, unos 6,7 millones. 4 registros de 1 KB por solicitud. Muestreo del 10 %	10,5
Registros de Container Apps	Solo errores y eventos del sistema	3
Application Gateway y WAF	1 KB por solicitud del portal; el WAF solo con coincidencias	7,7
Azure Firewall	Reglas de red, de aplicación e inteligencia de amenazas	15
MySQL, telemetría y VPN Gateway	Consultas lentas, errores de IoT Hub, Stream Analytics y la función, registro de cada alerta, túneles, IKE y rutas	4
Pruebas y desarrollo	Application Insights con poco tráfico	4
Pruebas de disponibilidad y alertas de Defender		0,2
Total		**44,4**

No incluye los eventos de auditoría de negocio, Entra ID ni los accesos directos a Blob, que dimensiona el diseño de auditoría. El registro de actividad y la tabla `Usage` no cobran ingesta. Los registros de flujo de red virtual van a una cuenta de almacenamiento y ya están en el costo del firewall.

9.2 Costo mensual de producción

Precios de lista en East US 2, con 730 horas al mes.

Concepto	Cálculo	USD al mes
Ingesta en Log Analytics	(44,4 – 5 GB sin costo) × 2,76	108,74
Retención consultable de 90 días en las tablas técnicas	El plan incluye 31 días y Application Insights 90. Unos 29,7 GB al mes de las demás tablas × 59/30 × 0,12	7,01
Alertas de métricas	Unas 102 series, las primeras 10 sin costo: 92 × 0,10	9,20
Alertas de búsqueda	6 cada 5 minutos (tres de los objetivos y Defender, tres del perímetro: destino malicioso, rechazos y bloqueos del WAF) × 1,50 + 6 cada 15 minutos × 0,50	12,00
Prueba de disponibilidad del portal	5 ubicaciones × 12 por hora × 730 = 43.800 × 0,0005	21,90
Logic App de notificaciones	Unas 1.500 acciones × 0,000125	0,19
Métricas de plataforma, workbooks, vistas de costo, Resource Health, push y correo dentro de la cuota mensual		0
Total		**Unos 159**

No incluye el proveedor de SMS, que depende de la cotización, igual que en la telemetría, ni las cinco alertas del portal y los planes de Defender for Cloud, que ya están en el costo del diseño de datos personales. Los cambios en reglas se vigilan con una alerta del registro de actividad, que no tiene medidor en la API de precios.

Campaña. El portal sube hasta 2.000 solicitudes por minuto unas 4 horas al día, y la torre tiene los mismos 450 usuarios. Con un 50 % más de solicitudes del portal en el mes, se suman unos 3,3 GB del gateway y 1,3 GB de trazas: cerca de USD 13. El mes de campaña cuesta unos USD 172.

9.3 Decisiones que bajan o evitan gasto

Decisión	Alternativa descartada	Ahorro al mes
Muestreo del 10 % en las trazas; las métricas no se muestrean	El muestreo por defecto, que con este tráfico guarda casi todo	Unos USD 259: el total pasaría de 159 a unos 418
Workbooks y vistas de Cost Management	Managed Grafana con redundancia de zonas y 10 usuarios	Unos USD 115
Espacio sin réplica	Réplica del espacio en Central US (USD 0,25 por GB)	Unos USD 11
Alertas sobre métricas de plataforma, sin exportarlas	Exportar todas las métricas al espacio	La ingesta de cada métrica exportada
Cali sin agentes de Azure	Azure Arc y agente en 14 servidores durante 61 días	Agentes e ingesta de servidores que se apagan

Después del primer mes, las tablas de tráfico permitido del firewall pueden pasar al plan Basic, como ya propone el diseño del firewall (sección 6.3): con 15 GB son hasta unos USD 34 al mes menos, a cambio de sacar esas tablas del análisis de políticas.

---

10. Supuestos y confirmaciones pendientes de FríoAndes

10.1 Confirmaciones que necesita el diseño

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
Guardia de plataforma	¿Quién integra la guardia de plataforma y cómo rota?	Cambian los destinatarios de las alertas críticas y quién ejecuta el procedimiento de continuidad de la plataforma logística
Metas	¿Se aceptan 99,9 % para el portal y 99 % para la alerta, en 28 días y sin contar los mantenimientos anunciados?	Cambian el margen y las alertas de la sección 5.4
SLA de Container Apps	Cifra vigente en el documento de SLA de servicios en línea de Microsoft	Si queda por debajo de la meta del portal, se ajusta la meta o el número de réplicas
Redirección del portal en un failover	La decide el diseño de continuidad de la plataforma logística	Si el portal pasa a otro Application Gateway en Central US, la consulta del objetivo suma sus registros y la prueba apunta al mismo nombre público
Configuración de Zabbix	Exportación de lo que vigila hoy	Completa la lista de condiciones del día 61
Firewall de Cali	¿Qué herramienta del fabricante vigila el equipo?	Define la salud del equipo después del día 61
Tráfico real	Solicitudes por hora de la torre y del portal	Ajusta el volumen y el costo de la sección 9
Microsoft 365 y proveedor de SMS	Las mismas confirmaciones del diseño de telemetría	Sin Teams, las alertas de operación llegan por push, correo y SMS

10.2 Supuestos del diseño

Supuesto	Por qué se asume
El tráfico de la sección 9.1	El caso solo da los picos del portal. El dato real sale de la tabla `Usage` el primer mes
Cada solicitud deja 4 registros de 1 KB	La solicitud del front, la del servicio y dos dependencias
Los relojes de sensores y camiones se sincronizan por NTP	La exclusión de 25 segundos del objetivo de la alerta usa la hora del sensor
Existe una guardia de plataforma con rotación	Atiende las alertas críticas de noche
El inventario de Zabbix es el de la sección 8.2	Se deduce del datacenter; se concilia con su exportación
Los umbrales de la sección 3 son iniciales	No hay datos reales para calibrarlos. Se ajustan con el primer mes
Los costos son precios de lista en East US 2, con 730 horas al mes, sin descuentos	Es la base común del cálculo de costos de la plataforma
La plataforma de contenedores es Container Apps con perfiles de carga	Lo mismo que la red y la plataforma logística. Con la variante de Kubernetes cambian las métricas de contenedores de la sección 3.2 y se agrega Defender for Containers

7. Inteligencia artificial de la torre de control, sobre Microsoft Fabric

Microsoft Fabric: espacios de trabajo, ingesta sin duplicar y región

Este documento define cómo se organiza Microsoft Fabric para la inteligencia artificial de la torre de control: qué espacios de trabajo y capacidades hay y quién de FríoAndes los administra; cómo llegan a Fabric el libro operativo, la telemetría y el archivo histórico sin una segunda copia de 1,2 PB; qué parte se copia, por qué y qué cuesta leer el resto en su lugar; en qué región vive Fabric y dónde quedan los datos personales de conductores y destinatarios. Usa la red, el firewall, la telemetría, los datos personales, la gobernanza, la plataforma logística, la migración y la siembra del archivo ya diseñados, con sus mismos nombres y decisiones.

Términos usados

Término	Significado en este documento
Capacidad	El recurso de Azure (`Microsoft.Fabric/capacities`) que da el cómputo de Fabric. Se mide en unidades de capacidad (CU), se puede pausar y cambiar de tamaño
Espacio de trabajo	El contenedor de Fabric donde viven los elementos (lakehouse, cuadernos, modelos, reportes) y donde se asignan los roles Admin, Member, Contributor y Viewer
OneLake	El almacenamiento de Fabric. Cada espacio de trabajo es una carpeta de OneLake
Lakehouse	El elemento de Fabric que guarda tablas (carpeta Tables) y archivos (carpeta Files) en OneLake
Atajo	Un acceso directo de OneLake que apunta a datos que viven en otro lugar, sin copiarlos. Se ve como una carpeta más
Identidad del espacio de trabajo	Una entidad de servicio de Entra ID que Fabric crea y administra para un espacio. Sus credenciales nunca se ven ni se rotan a mano
Acceso de confianza	El mecanismo por el que una cuenta de almacenamiento con firewall acepta a un espacio de trabajo concreto, con una regla de instancia que nombra ese espacio
Gateway de red virtual	Un servicio administrado de Fabric que se inyecta en una subred de FríoAndes para llegar a fuentes privadas. Lo usan Copy Job, canalizaciones, réplicas espejo y modelos
Copy Job	El elemento de Fabric que copia datos de una fuente a un destino, completo o solo lo nuevo y cambiado
Región principal	La región de Azure ligada al tenant de Fabric al crearlo. Guarda metadatos aunque la capacidad esté en otra región
Día N	Los días del plan de migración: día 0, inicio de la convivencia; día 34, corte; día 90, límite de la convivencia

---

1. Contexto y alcance

1.1 Qué necesita FríoAndes

La torre de control, el turno de calidad y la vista analítica del cliente corporativo van a consumir inteligencia artificial a través de Microsoft Fabric: aviso temprano de excursiones de temperatura y de sensores caídos, hora estimada de llegada y apoyo al archivo de evidencias. Para eso Fabric necesita leer tres fuentes que ya tienen su lugar en Azure:

Fuente	Dónde vive	Tamaño
Libro operativo: guías, viajes, inventario, evidencias y reclamos	MySQL Flexible Server 8.4 en `snet-data`, East US 2, con alta disponibilidad zonal y réplica en Central US	La base de producción; se estima por debajo de 400 GB
Telemetría	Tres tablas Delta en la cuenta de análisis, East US 2. La evidencia cruda inmutable está en Central US	Unos 15 GB al mes, unos 900 GB en cinco años
Archivo histórico	Dos cuentas en East US 2: documentos (fotos, comprobantes, PDF e históricos de temperatura, 150 TB, Cool GRS) y video (1,05 PB, Cold LRS)	1,2 PB, crece unos 12 TB al mes

Copiar el archivo a Fabric significaría pagar dos veces el almacenamiento de 1,2 PB, más la lectura de todo lo que está en niveles fríos. En este diseño Fabric lee cada fuente en su lugar, y solo copia una parte pequeña y justificada del libro operativo.

1.2 Qué toma de los otros diseños

Diseño	Qué toma
`gobierno-landing-zone.md`	Un solo tenant de Entra ID; suscripciones de producción, desarrollo y pruebas; convención de grupos `grp-fa-*`; PIM para administradores; regiones permitidas East US 2 y Central US (P-02); etiqueta `costo=fabric` y presupuesto propio de Fabric
`gobierno-auditoria-facturacion.md`	Fabric se identifica por recurso y medidor y se clasifica antes que pruebas; no se crean copias permanentes en Fabric
`red-topologia-subnetting.md` y `red-firewall-y-publicacion.md`	`snet-fabric-egress` en los tres ambientes, delegada al gateway de red virtual; el gateway llega a `snet-data` por el puerto 3306 y no sale a internet
`seguridad-datos-personales-perimetro.md`	Inventario de datos personales; envío a Microsoft en Estados Unidos como transmisión a un encargado; región de Fabric en un país de la lista de la SIC; regla de borrado a los cinco años; sin reconocimiento facial
`carga-b-telemetria.md`	La alerta de menos de un minuto no pasa por Fabric; tablas de detalle, resumen de 5 minutos y alertas en la cuenta de análisis; vista del cliente con Power BI insertado y seguridad por filas
`carga-a-plataforma-logistica.md`	MySQL Flexible Server 8.4, alta disponibilidad zonal y réplica en Central US
`carga-c-migracion-y-campana.md`	Calendario de la convivencia y regla de que los cambios de esquema se hacen antes del día 0
`carga-c-siembra-1-2pb.md`	Las dos cuentas del archivo, sin espacio de nombres jerárquico, solo Entra ID, acceso público desactivado al terminar la siembra, inmutabilidad por versión

1.3 Qué queda en otros diseños

- Los tres usos de inteligencia artificial, la matriz de acceso por rol, el tamaño de las capacidades, la pausa fuera de campaña y la observabilidad de Fabric: `fabric-acceso-casos-uso-costo.md`.
- El costo de Fabric en mes normal y de campaña, y el ahorro frente a copiar el archivo: `docs/costs/costo-fabric.md`, con las cifras de la sección 8.
- El paso del video a niveles más baratos: el costo mensual estable, con la regla de la sección 6.4.

- MFA, acceso condicional y la matriz completa de roles: el diseño de identidades, accesos y cifrado, con lo que pide la sección 2.5.

---

2. Espacios de trabajo, capacidades y administración

2.1 Espacios de trabajo

Espacio	Para qué	Qué contiene	Quién lo usa
`ws-fa-datos-prod`	Punto único de entrada de los datos	Un lakehouse con los atajos a la telemetría y al archivo, las tablas copiadas del libro operativo, los resultados de la revisión de evidencias y el cuaderno de mantenimiento	Ninguna persona del negocio. Los otros tres espacios leen de aquí con atajos internos
`ws-fa-torre-prod`	Torre de control	Hora estimada de llegada y aviso temprano para la torre	Despachadores
`ws-fa-calidad-prod`	Calidad y turno de noche	Tableros de calidad de la telemetría, aviso temprano de noche y revisión de fotos	Calidad y guardia de calidad
`ws-fa-cliente-prod`	Vista del cliente corporativo	Solo el modelo semántico con seguridad por filas y el reporte que inserta el portal	Los clientes, a través del portal de rastreo

El video, las posiciones de los camiones y los datos que identifican a la operación quedan en un solo espacio que administra el equipo de datos. El espacio del cliente nunca tiene un atajo al archivo ni a la flota: lo que no está ahí no se puede exponer por error.

Ambientes. Los mismos cuatro espacios existen en desarrollo y en pruebas (`ws-fa-datos-dev`, `ws-fa-datos-test` y así con los demás), unidos por canalizaciones de implementación de tres etapas. Desarrollo y pruebas leen las cuentas y la base de sus propias suscripciones, con datos sintéticos, y usan el `snet-fabric-egress` de su ambiente.

2.2 Capacidades

Capacidad	Espacios	Encendida	Suscripción y grupo de recursos	Región
`fcfaprod`	Los cuatro de producción	Siempre: el aviso temprano de noche y la vista del cliente la necesitan	`sub-fa-prod`, `rg-fa-analitica-prod`	East US 2
`fcfanoprod`	Los ocho de desarrollo y pruebas	En horario de trabajo; se pausa el resto del tiempo	`sub-fa-dev`, `rg-fa-analitica-dev`	East US 2

- El nombre de una capacidad solo admite minúsculas y números, y no se puede cambiar después de creada.
- Las dos llevan `ambiente`, `carga=analitica`, `costo=fabric`, `criticidad` y `responsable`. La no productiva también va a la línea de Fabric, porque la conciliación de costos clasifica Fabric antes que pruebas.
- El presupuesto de Fabric se aplica a los dos grupos de recursos de analítica.
- El tamaño, el crecimiento en campaña y la pausa los fija `fabric-acceso-casos-uso-costo.md`. Los trabajos pesados de Spark (la revisión de fotos) pueden salir del consumo de la capacidad con la facturación a demanda de Spark, que se activa por capacidad y se cobra aparte por uso.
- Las dos capacidades son capacidades F compradas. El acceso de confianza de la sección 3 no funciona en una capacidad de prueba.

2.3 Administradores

Quién	Rol	Ámbito	Cómo se asigna
Dos personas del equipo de datos e IA	Fabric administrator (rol de Entra ID): configuración de todo el tenant de Fabric, uso y auditoría	Tenant	Elegibles con PIM, activación temporal
Las mismas dos personas	Administrador de capacidad: asigna espacios, permisos y cargas	`fcfaprod` y `fcfanoprod`	Por nombre: Azure solo acepta usuarios del tenant como administradores de una capacidad, no grupos ni invitados
`grp-fa-fabric-admin` (equipo de datos e IA)	Admin de cada espacio: gestiona miembros, crea la identidad del espacio	Los doce espacios	Grupo de seguridad
`grp-fa-fabric-admin`	Colaborador de capacidad: puede asignar espacios a la capacidad, sin cambiarla	Las dos capacidades	Grupo de seguridad. Nadie más asigna espacios
`grp-fa-fabric-admin` y la identidad de automatización de la pausa	Rol personalizado "Operador de capacidad Fabric" con `Microsoft.Fabric/capacities/read`, `write`, `suspend/action` y `resume/action`	Recurso de cada capacidad	Azure RBAC, en vez de Owner o Contributor, como recomienda Microsoft
`grp-fa-torre-lideres`	Member: agrega personas con roles iguales o menores	`ws-fa-torre-*`	Grupo de seguridad
`grp-fa-calidad-lideres`	Member	`ws-fa-calidad-*`	Grupo de seguridad
`grp-fa-finops`	Cost Management Reader, ya definido	Grupos de recursos de analítica	Sin cambios

`ws-fa-cliente-*` no tiene responsable de negocio: solo lo administra `grp-fa-fabric-admin` y lo usa la identidad del portal. Quién más entra a cada espacio, con qué rol y sobre qué tablas lo define la matriz de acceso de `fabric-acceso-casos-uso-costo.md`.

2.4 Por qué así

- **Un espacio de datos separado de los de consumo.** Los atajos externos, la identidad que entra a las cuentas de Azure y las credenciales de la base viven en un solo lugar, con un solo grupo administrador.
- **Una capacidad para producción y otra para desarrollo y pruebas.** Las pruebas no compiten con producción y se pueden pausar sin tocar el aviso de noche.
- **La vista del cliente comparte la capacidad de producción.** Los trabajos pesados de Spark pueden ir a la facturación a demanda y dejar de competir con los reportes, así que una tercera capacidad no agrega nada.
- **Líderes del negocio con rol Member.** Un Admin puede agregar o quitar administradores; un Member solo agrega roles iguales o menores.

2.5 Lo que el diseño de identidades tiene que respetar

- Los grupos `grp-fa-fabric-admin`, `grp-fa-torre-lideres` y `grp-fa-calidad-lideres`, con MFA como el resto de los administradores.
- Si se crea una política de acceso condicional para identidades de carga que cubra todas las entidades de servicio, hay que excluir las tres identidades de los espacios de datos: con ellas incluidas, el acceso de confianza deja de funcionar.
- La contraseña del usuario de base de datos `fabric_lector` (sección 4.5) se guarda también en el Key Vault de producción y se rota cada 90 días.

3. Cómo llega Fabric a los datos

3.1 Dos caminos

Fuente	Camino	Pasa por la red virtual
Tabla de análisis de telemetría	Atajo de Azure Data Lake Storage con acceso de confianza	No
Cuentas de documentos y de video	Atajo de Azure Blob Storage con acceso de confianza	No
Evidencia cruda de telemetría (Central US)	Fabric no la lee	
Libro operativo	Copy Job por el gateway de red virtual en `snet-fabric-egress`	Sí

3.2 Acceso de confianza para el almacenamiento

- Cada espacio de datos (`ws-fa-datos-prod`, `-test` y `-dev`) tiene su identidad de espacio de trabajo, con rol Contributor en su propio espacio, como pide Microsoft.
- Cada cuenta que Fabric lee tiene una regla de instancia que nombra solo el espacio de datos de su ambiente. Las reglas de Fabric se crean por ARM o PowerShell (en el código de infraestructura, con AzAPI), no desde el portal.
- Funciona con el acceso público desactivado del todo, como quedan las cuentas del archivo después de la siembra, y con el acceso desde redes seleccionadas, como las cuentas de telemetría. No cambia nada en esas cuentas fuera de agregar la regla.
- No se usa la excepción de servicios de confianza: abriría la cuenta a cualquier espacio del tenant con identidad, y Microsoft no la recomienda.
- El tráfico va por la red de Microsoft entre Fabric y la cuenta; no pasa por las redes virtuales de FríoAndes, por los endpoints privados ni por el Azure Firewall.
- Spark lee a través de los atajos, así que no hacen falta endpoints privados administrados de Fabric.

3.3 Autenticación y permisos

- Los atajos se autentican con la identidad del espacio de trabajo. Fabric administra sus credenciales, no hay secretos que rotar y no depende de que una persona siga en la empresa.
- La autorización de un atajo es delegada: toda lectura usa la credencial del atajo. Por eso el permiso de la identidad es el techo de lo que Fabric puede hacer en la cuenta.
- Permisos sobre el archivo: Storage Blob Delegator en la cuenta y Storage Blob Data Reader solo en los contenedores que Fabric lee (sección 6). Nunca Contributor: un borrado dentro del atajo borra el archivo original si la credencial tiene permiso de escritura.
- Permiso sobre la cuenta de análisis: Storage Blob Data Contributor solo en el contenedor de las tablas de telemetría, para el mantenimiento de la sección 5.3. Es la única escritura de Fabric en Azure.

3.4 El gateway de red virtual

- Microsoft lo ofrece para Dataflow Gen2, canalizaciones, Copy Job, réplicas espejo, modelos semánticos y reportes paginados. Los atajos no lo usan. En este diseño sirve solo para el libro operativo.
- Se inyecta en `snet-fabric-egress`, delegada a `Microsoft.PowerPlatform/vnetaccesslinks`, con el proveedor `Microsoft.PowerPlatform` registrado en la suscripción. Usa 5 direcciones para su funcionamiento más una por miembro; el `/27` alcanza para el máximo de 11 miembros.
- Hay uno por ambiente, vinculado a la capacidad de ese ambiente, que es la que paga su consumo. El de producción tiene de 1 a 2 miembros y se apaga solo después de 30 minutos sin uso.
- Sus metadatos, incluida la credencial cifrada de la base, se guardan en la región principal del tenant (sección 7.2).
- Llega a `snet-data` por el puerto 3306 con la regla que ya existe en el NSG. No necesita salida a internet ni pasa por el Azure Firewall.
- Quién puede crear gateways se limita al grupo `grp-fa-fabric-admin`.

4. Libro operativo

4.1 Por qué no una réplica espejo

La réplica espejo de Fabric para Azure Database for MySQL, en preview, solo admite MySQL 8.0, y no admite alta disponibilidad, réplicas de lectura ni servidores dentro de una red virtual. La plataforma logística tiene las cuatro cosas: MySQL 8.4, alta disponibilidad zonal, servidor en `snet-data` y réplica en Central US.

4.2 Mecanismo

Copy Job incremental por marca de agua, por el gateway de red virtual, hacia tablas Delta del lakehouse de `ws-fa-datos-*`, con escritura merge por clave primaria. Cada ejecución copia solo las filas nuevas o cambiadas desde la anterior, y retoma desde la última ejecución buena si una falla. El conector de MySQL no tiene captura de cambios: los borrados no viajan, y por eso la aplicación no borra físicamente en las tablas copiadas (sección 4.6).

4.3 Qué se copia

Vistas de solo lectura en un esquema `fabric` de la base, que proyectan solo lo que usan los tres usos y la vista del cliente:

Vista	Columnas	Para qué
`guias`	Identificador, cliente, estado, centro de origen, ventana de entrega, ubicación del punto de entrega (latitud y longitud), tipo de carga y rango de temperatura	Hora estimada de llegada, aviso temprano, seguridad por filas de la vista del cliente
`viajes_paradas`	Viaje, camión, guías del viaje, orden de las paradas, horas planeadas y reales	Hora estimada de llegada
`activos`	Camiones y cuartos fríos, centro y sensores asociados	Unir la telemetría con la operación
`clientes`	Identificador y razón social	Seguridad por filas
`evidencias`	Guía, tipo (foto, comprobante o video), ruta del archivo y fecha	Saber qué fotos y comprobantes revisar cada día (sección 6)
`reclamos`	Guía y estado	Saber qué clips de video leer (sección 6)

Quedan fuera: nombre, teléfono, documento y dirección escrita de destinatarios; nombre, documento y teléfono de conductores (el conductor solo aparece a través del camión del viaje); usuarios del portal; facturación. La ubicación del punto de entrega es el único dato personal que entra a Fabric por esta vía: la hora estimada de llegada no se puede calcular sin ella.

4.4 Origen y frecuencia

- Se lee el servidor principal en East US 2. Las consultas van por índice sobre la columna de marca de agua, así que cada ejecución lee pocas filas.
- Cada 15 minutos de 04:00 a 22:00, mientras trabaja el despacho, más una copia a las 22:15 y otra a las 03:45. De noche no hay copias: así el gateway se apaga y deja de consumir capacidad (`fabric-acceso-casos-uso-costo.md`, sección 8.4).
- La copia arranca después del corte (día 34), cuando la base de Azure pasa a ser la principal. Antes del corte la base de Azure es el destino de la replicación desde Cali.
- No se lee la réplica de Central US: sumaría tráfico entre regiones y haría depender a Fabric de la recuperación de la plataforma logística.

4.5 Credencial

Un usuario `fabric_lector` con `SELECT` solo sobre el esquema `fabric`, con conexión cifrada. El conector solo admite autenticación básica, con usuario y contraseña: la contraseña queda cifrada en la conexión de Fabric y en el Key Vault de producción, y `grp-fa-fabric-admin` la rota cada 90 días.

4.6 Ajustes que se piden a la aplicación

Se suman a los ajustes que ya pide la migración y, como ellos, tienen que estar listos y probados antes del día 0, porque durante la convivencia la base no admite cambios de esquema:

Ajuste	Por qué
Cada tabla que alimenta las vistas tiene clave primaria y una columna `actualizado_en` con `ON UPDATE CURRENT_TIMESTAMP`, indexada	Copy Job la usa como marca de agua y hace merge por la clave
En esas tablas no hay borrado físico: la fila se marca como borrada	Los borrados no viajan con la marca de agua
La anonimización a los cinco años actualiza `actualizado_en`	Así la anonimización llega sola a Fabric y se cumple la regla de borrado
Las vistas del esquema `fabric` y el usuario `fabric_lector`	Fabric ve solo lo que necesita

---

5. Telemetría

5.1 Lectura

Un atajo de esquema `telemetria` en la carpeta Tables del lakehouse de `ws-fa-datos-*`, que apunta a la carpeta con las tres tablas de la cuenta de análisis. Fabric reconoce cada tabla Delta y sincroniza su esquema sin intervención.

Tabla	Quién la usa en Fabric
Resumen de 5 minutos	Todos los tableros, con Direct Lake
Detalle	Reclamos y análisis puntual, por el endpoint SQL, consultado por guía o por cuarto frío y fecha
Alertas	Tableros de calidad y tiempos de respuesta

No hay Eventhouse. El aviso temprano no lee estas tablas: usa un Eventstream sobre el Event Hub del estado en vivo, con un endpoint privado administrado, y Activator (`fabric-acceso-casos-uso-costo.md`, sección 3).

5.2 Lo que exige Stream Analytics

La salida Delta de Stream Analytics solo agrega filas y no compacta archivos. Si Stream Analytics crea la tabla, la marca como solo agregar, y así no se podrían borrar las posiciones a los cinco años ni atender una supresión. Además, Stream Analytics no escribe en tablas con deletion vectors y solo lee checkpoints V1 de una parte. Por eso:

- Las tres tablas se crean antes de arrancar Stream Analytics, sin la propiedad de solo agregar y sin deletion vectors.
- El mantenimiento no activa propiedades nuevas en las tablas ni escribe checkpoints que Stream Analytics no pueda leer.

5.3 Mantenimiento

Un cuaderno de Spark programado en `ws-fa-datos-prod`, que trabaja a través del mismo atajo:

Tarea	Frecuencia	Por qué
OPTIMIZE de las tres tablas	Cada noche	Stream Analytics no compacta; Direct Lake admite 1.000 archivos por tabla en las capacidades de F2 a F32
VACUUM con retención de 7 días	Cada noche	Quita del almacenamiento los archivos reemplazados
Borrado de filas de más de cinco años	Cada mes	Regla de borrado de los datos personales
Supresión puntual de posiciones	Cuando la pida el titular o la SIC	Las posiciones identifican al conductor

Tarea	Frecuencia	Por qué
Borrado de resultados de revisión de evidencias de más de cinco años (sección 6.3)	Cada mes	Misma regla

El cuaderno se prueba primero en pruebas con Stream Analytics escribiendo al mismo tiempo. Desarrollo y pruebas tienen el mismo atajo y el mismo cuaderno sobre sus cuentas de análisis, con datos simulados.

---

6. Archivo histórico

6.1 Qué lee Fabric

Contenido	Cuenta y nivel	Lee Fabric	Cómo sabe qué leer
Fotos y comprobantes nuevos	Documentos, Cool	Sí, una vez al día	Vista `evidencias`
Video de entregas con reclamo abierto	Video, Cold	Solo esos clips. En el primer release Fabric lista sus rutas para calidad; leerlos para analizarlos queda para el segundo	Vista `reclamos`
Muestra pequeña de video para calidad	Video, Cold	No en el primer release: el análisis de video queda para el segundo (`fabric-acceso-casos-uso-costo.md`, sección 5.2)	
Resto del video, PDF e históricos de temperatura		No	

Cool y Cold son niveles en línea: un atajo los lee en milisegundos. Fabric no revisa de una vez las fotos históricas (110 TB): ningún uso lo pide y consumiría mucha capacidad.

6.2 Atajos

Un atajo Blob en la carpeta Files del lakehouse de `ws-fa-datos-*` por cada contenedor que se lee, con la identidad del espacio (Storage Blob Data Reader solo en esos contenedores) y la regla de instancia en cada cuenta (sección 3). Los nombres de los contenedores salen de las carpetas de primer nivel del servidor de Cali, que FríoAndes tiene que confirmar.

6.3 Nada del archivo se copia

Fabric lee cada archivo en su lugar y escribe en OneLake solo el resultado de la revisión: ruta, guía, fecha y resultado (legible o no, carga visiblemente dañada o no), sin imágenes ni recortes. Ese resultado se borra a los cinco años con el cuaderno mensual de la sección 5.3.

6.4 Lo que el diseño de costos tiene que respetar

- Fabric no exige que el video esté en un nivel en línea, salvo los clips de reclamos abiertos. El resto del video puede pasar a Archive, que la cuenta de video admite por ser LRS, respetando los 180 días mínimos de ese nivel.
- Un archivo en Archive no se puede leer sin rehidratarlo, lo que tarda hasta 15 horas. Si un clip de reclamo está en Archive, el proceso de reclamos lo rehidrata antes; Fabric no rehidrata.
- Las fotos y comprobantes nuevos tienen que seguir en un nivel en línea al menos hasta su revisión del día siguiente.

---

7. Región, residencia y datos personales

7.1 Región de las capacidades: East US 2

- Es la región de todas las fuentes que Fabric lee: la base, la cuenta de análisis y las cuentas del archivo. No hay transferencia entre regiones ni datos que crucen de geografía.
- Tiene todas las cargas de Fabric sin funciones excluidas.
- Está en la lista de regiones permitidas de la landing zone.
- Estados Unidos está en la lista de países con nivel adecuado de protección de la SIC, y el envío de datos a Microsoft en Estados Unidos ya se trata como transmisión a un encargado.

Si FríoAndes no acepta Estados Unidos, la alternativa es la misma del diseño de datos personales: Mexico Central, que también tiene todas las cargas de Fabric. Exige mover también las fuentes, porque si no cada lectura cruzaría de geografía, y agregar la región a las permitidas.

7.2 Región principal del tenant

La región principal la fija la dirección de facturación del primer usuario que se registró en el tenant; este diseño no la elige. Aunque la capacidad esté en East US 2, en la región principal quedan permisos, metadatos de reportes y paneles (nombres y consultas de mosaicos), credenciales de modelos, metadatos del gateway (incluida la contraseña cifrada de `fabric_lector`) y algunas funciones como las capturas y las alertas de datos.

- Antes de comprar la capacidad, el equipo de datos revisa en Fabric (Ayuda, Acerca de) el valor "Your data is stored in".
- Si queda en Estados Unidos o en México, no hay nada que agregar.
- Si queda en un país fuera de la lista de la SIC (por ejemplo Brasil o Chile), esos metadatos se registran como una transmisión más en el registro de bases de datos, y rige una regla: ningún nombre de reporte, mosaico, filtro ni parámetro lleva datos de conductores o destinatarios.

7.3 Datos personales que toca Fabric

Dato	Dónde está	Qué hace Fabric
Posiciones de los camiones	Tabla de análisis, East US 2	Las lee por atajo; no las copia
Ubicación del punto de entrega	Lakehouse de `ws-fa-datos-prod`, OneLake en East US 2	La copia (sección 4.3)
Fotos, comprobantes y clips de reclamos	Cuentas del archivo, East US 2	Los lee por atajo; guarda solo el resultado de la revisión
Identidades de empleados	Entra ID y permisos de Fabric en la región principal	Las usa para el acceso

Nombres, teléfonos, documentos y direcciones escritas no entran a Fabric. Todo queda en la geografía de Estados Unidos: OneLake replica sus datos en reposo dentro de la misma geografía.

Borrado. Lo que Fabric lee por atajo se borra en el origen, con las reglas de cada cuenta. Lo que copia (las vistas del libro operativo) recibe la anonimización de la base por la marca de agua. Los resultados de la revisión y las filas de telemetría de más de cinco años los borra el cuaderno mensual.

Sin reconocimiento facial. La revisión de fotos y clips solo marca imágenes ilegibles o carga visiblemente dañada; no identifica personas.

7.4 Recuperación ante desastres

El interruptor de recuperación de la capacidad queda apagado. Solo replicaría OneLake, que guarda el subconjunto del libro operativo y los resultados, y los dos se reconstruyen desde las fuentes.

Si East US 2 falla:

1. Se crea una capacidad en Central US, misma geografía y región permitida.
2. Se crean los espacios y se despliegan los elementos desde Git y las canalizaciones de implementación.
3. Se crea un gateway en la subred de salida a Fabric de la red de recuperación (bloque reservado `10.104.0.0/15`) y se vuelve a correr Copy Job contra la base promovida en Central US.

Microsoft sugiere recuperar en otra geografía para tener más capacidad disponible; aquí no se hace, para no sacar los datos de un país de la lista de la SIC. Ni el despacho ni la alerta de temperatura dependen de Fabric mientras tanto.

---

8. Lo que se copia y lo que cuesta

8.1 Lo único que se copia

Qué	Dónde	Por qué	Tamaño
Vistas del libro operativo	Lakehouse de `ws-fa-datos-prod`, OneLake	La base no admite réplica espejo y los modelos no deben consultar en vivo la base de despacho	Una fracción de la base, que se estima por debajo de 400 GB
Resultados de la revisión de evidencias	Mismo lakehouse	Son datos nuevos, no una copia	Una fila por archivo revisado

Del archivo de 1,2 PB no se copia nada.

8.2 Cifras para el costo de Fabric

Precios de lista de East US 2, consultados en la API pública de precios de Azure, sin descuentos:

Concepto	Precio	Quién lo cobra
Capacidad, gateway, Copy Job, Spark y Direct Lake	USD 0,18 por CU hora, dentro de la capacidad	La capacidad
OneLake Hot	USD 0,023 por GB al mes	La capacidad
Lectura de fotos y comprobantes nuevos (Cool)	USD 0,01 por GB y 0,01 por 10.000 lecturas: unos 1.100 GB y 1,1 millones de lecturas al mes, unos USD 12	La cuenta de documentos
Lectura de clips de reclamos (Cold), desde el segundo release	USD 0,03 por GB y 0,10 por 10.000 lecturas	La cuenta de video

Las lecturas las cobra la cuenta de almacenamiento, en la suscripción de producción. El documento de costo de Fabric las atribuye a la línea de Fabric.

Referencia de lo que se evita. Copiar el video completo a OneLake costaría 1.050.000 GB × 0,023 = USD 24.150 al mes en Hot, o × 0,004 = USD 4.200 al mes en el nivel frío de OneLake, más una lectura única desde Cold de 1.050.000 GB × 0,03 = USD 31.500.

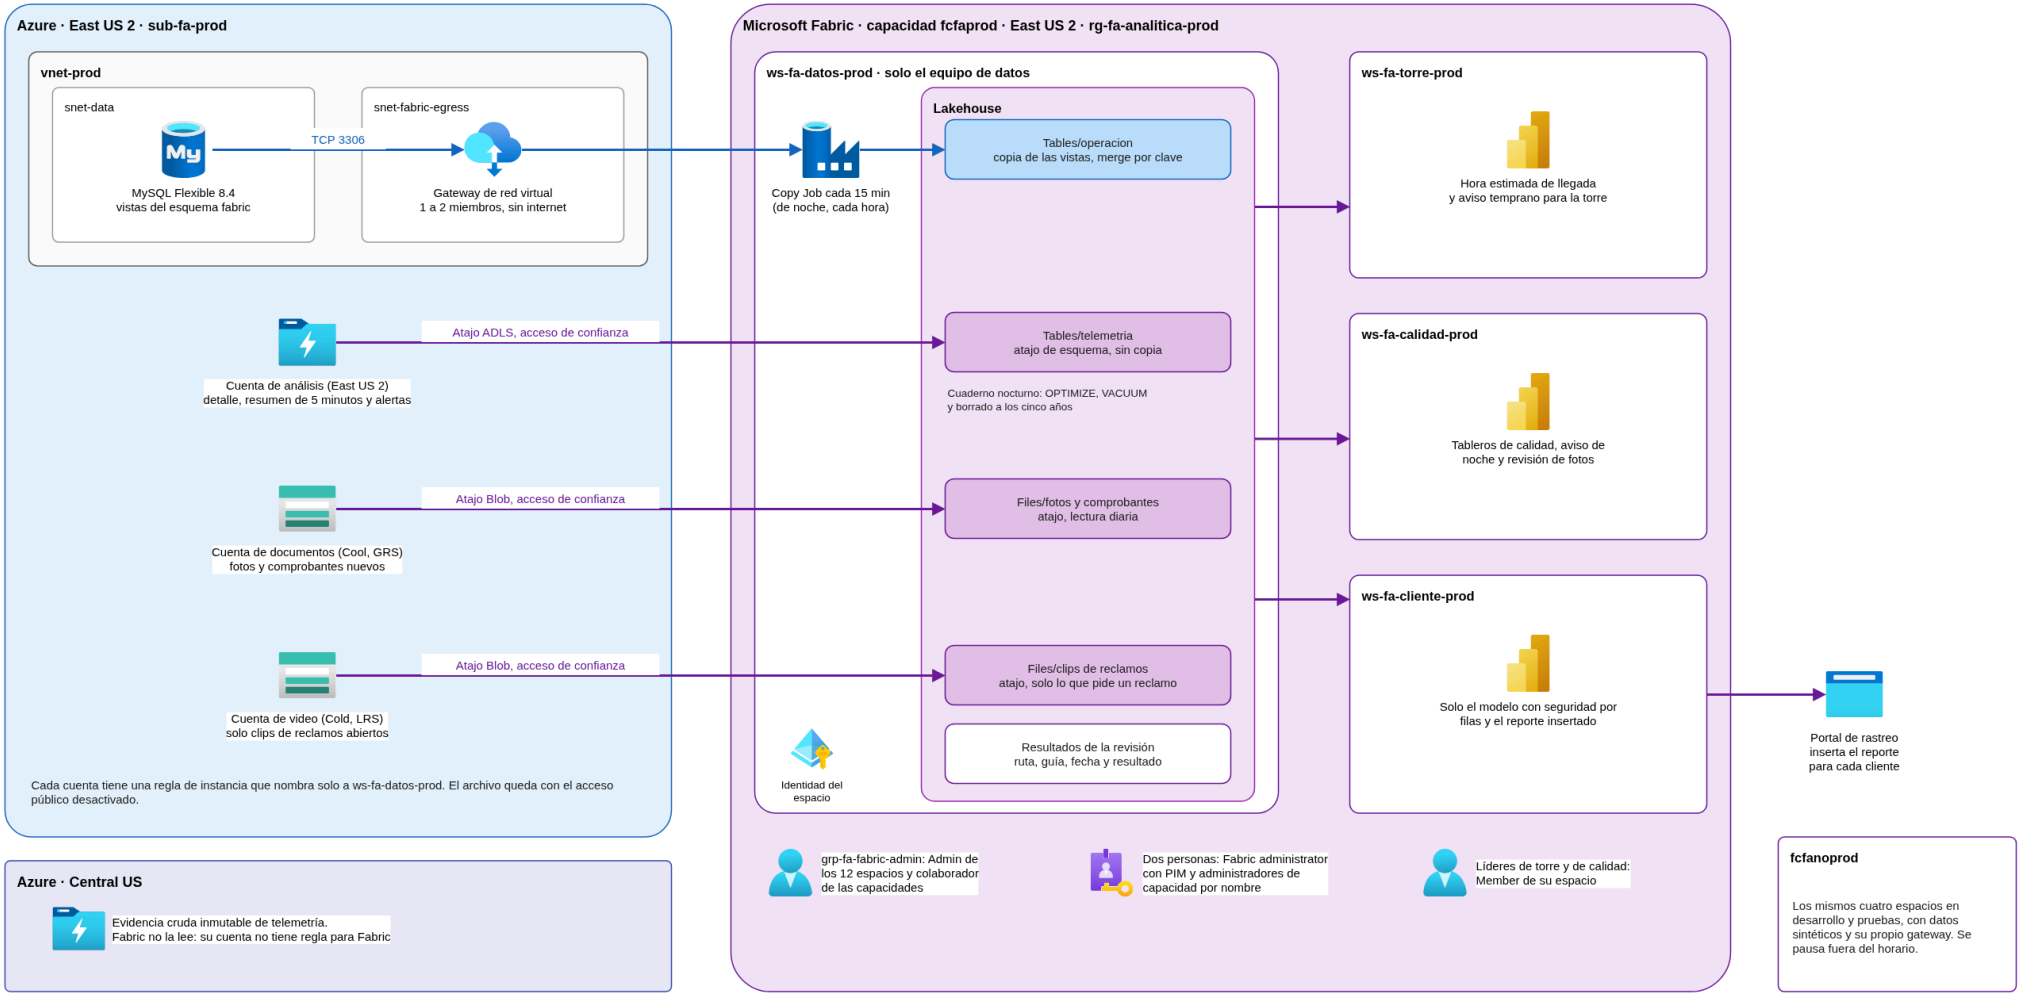
8.3 Decisiones que bajan o evitan gasto

Decisión	Alternativa descartada	Efecto
Atajos a la telemetría y al archivo	Copiar a OneLake	Evita una segunda copia de 1,2 PB (sección 8.2)
Solo fotos nuevas y clips de reclamos	Revisar el archivo entero	Lecturas de unos USD 12 al mes en vez de leer 1,2 PB
Capacidad no productiva pausada fuera del horario de trabajo	Encendida todo el mes	Paga solo las horas de uso
Interruptor de recuperación apagado	Replicar OneLake	Sin almacenamiento ni operaciones de recuperación por datos que se reconstruyen
Gateway con apagado por inactividad	Gateway siempre encendido	Consume capacidad solo mientras copia

---

9. Diagramas

Fabric: espacios de trabajo, capacidades y caminos de los datos, sin copiar el archivo

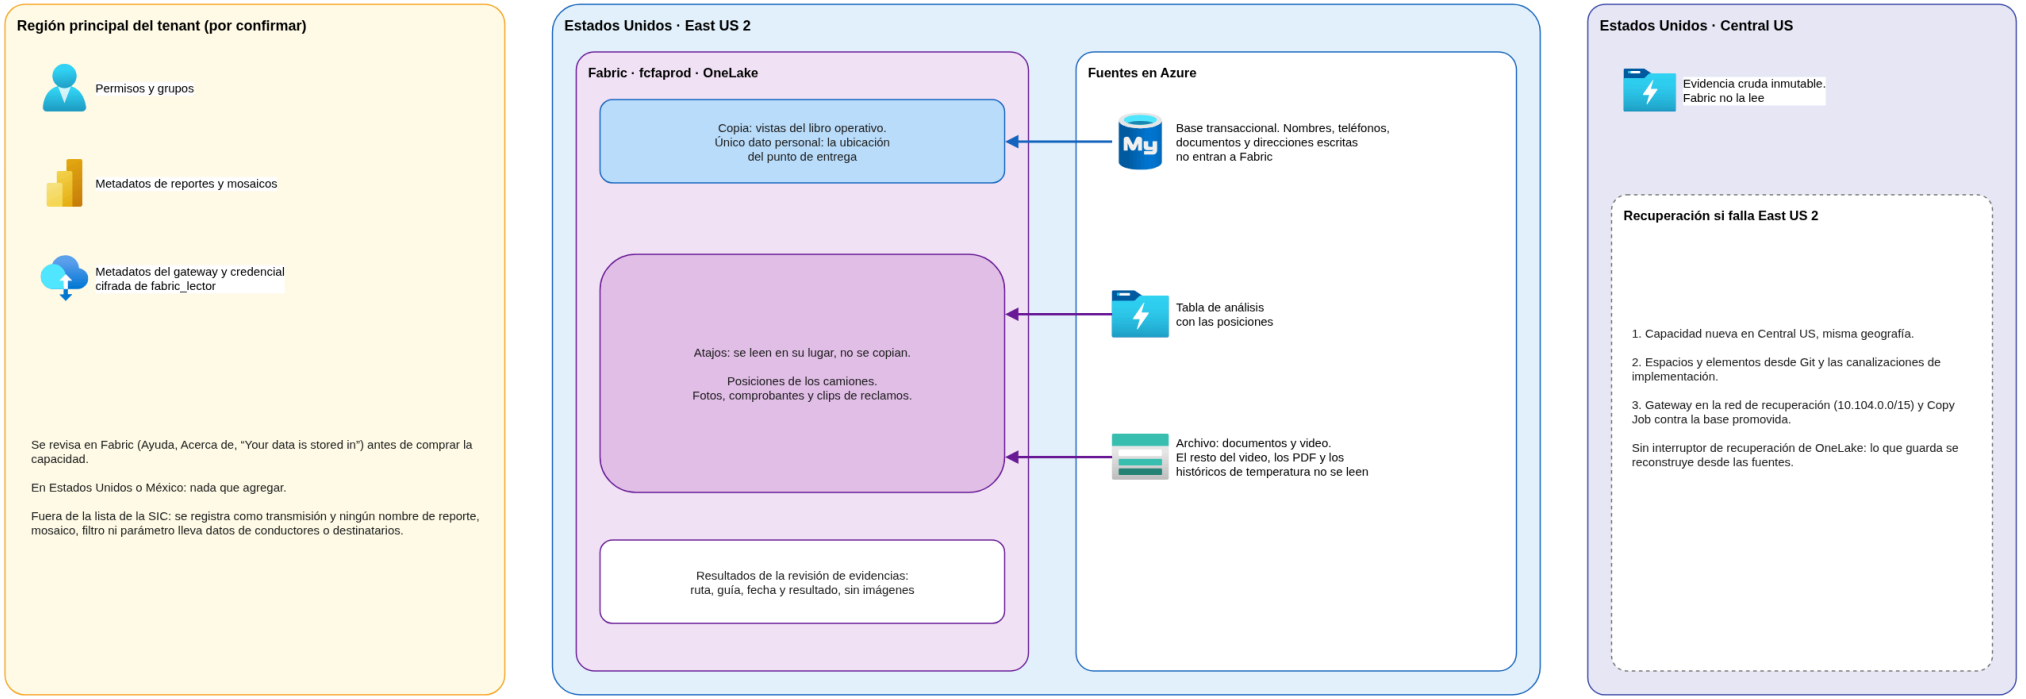


Azul: copia del libro operativo por Copy Job y el gateway de red virtual. Morado: atajos de OneLake, que leen en su lugar con la identidad del espacio y el acceso de confianza, sin pasar por las redes virtuales ni el firewall. Los tres espacios de consumo leen el lakehouse de datos con atajos internos, solo las tablas que autoriza la matriz de acceso.

Figura 24: Espacios de trabajo, capacidades y caminos de los datos hacia Fabric

El primer diagrama muestra las tres fuentes en Azure, los dos caminos (atajos con acceso de confianza y Copy Job por el gateway), el espacio de datos y los tres espacios de consumo con sus administradores.

Fabric: región, residencia y datos personales



Azul: lo único que se copia. Morado: lo que Fabric lee sin copiar. Todo queda en la geografía de Estados Unidos, en la lista de países con nivel adecuado de la SIC. OneLake replica sus datos en reposo dentro de la misma geografía. La revisión de imágenes solo marca fotos ilegibles o carga dañada; no identifica personas.

Figura 25: Región, residencia y datos personales en Fabric

El segundo muestra qué queda en East US 2, qué queda en la región principal del tenant, qué se copia, qué se lee en su lugar y cómo se recupera en Central US.

Los dos se generan con `red/tools/build_drawio_diagrams.py`.

---

10. Supuestos y confirmaciones pendientes de FríoAndes

10.1 Confirmaciones que necesita el diseño

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
Región principal del tenant	¿Qué muestra "Your data is stored in" en Fabric? ¿Ya existe el tenant de Microsoft 365?	Si está fuera de la lista de la SIC, se registra la transmisión y rige la regla de metadatos de la sección 7.2
Estados Unidos	¿Acepta que los datos personales queden en Estados Unidos?	Si no, Fabric y sus fuentes van a Mexico Central (sección 7.1)
Libro operativo	¿Las tablas de guías, viajes, evidencias y reclamos tienen clave primaria? ¿La aplicación borra filas físicamente?	Cambian los ajustes de la sección 4.6
Archivo	¿En qué carpetas del servidor de Cali están las fotos y los comprobantes?	Definen los contenedores con permiso de lectura
Reclamos	¿Cuántos reclamos hay al mes y cuánto video tiene cada uno?	Define el costo de lectura de clips
Equipo de datos e IA	¿Quiénes administran Fabric?	Son los administradores de capacidad, por nombre

10.2 Supuestos del diseño

Supuesto	Por qué se asume
Las tablas que alimentan las vistas admiten clave primaria, columna de última modificación y borrado lógico	Copy Job incremental con merge; el conector de MySQL no tiene captura de cambios
La ubicación del punto de entrega es el único dato personal que se copia a Fabric	La hora estimada de llegada la necesita; lo demás no
Fabric lee cada día las fotos y comprobantes nuevos y los clips de reclamos abiertos	Es lo que piden los usos; el resto del archivo no se lee
La región principal del tenant queda en un país de la lista de la SIC	Ahí quedan permisos, metadatos y credenciales
Las fotos y comprobantes nuevos suman unos 1,1 TB al mes, con archivos de 1 MB en promedio	Mismo supuesto de la siembra del archivo
La base de producción pesa menos de 400 GB	Mismo supuesto de la migración
Los costos son precios de lista en East US 2, sin descuentos	Es la base común del cálculo de costos de la plataforma

Microsoft Fabric: acceso, usos de inteligencia artificial, observabilidad y capacidad

Este documento define cómo usan Microsoft Fabric la torre de control, el equipo de calidad y el cliente corporativo: quién ve qué y con qué permisos; cómo funcionan los tres usos de inteligencia artificial (aviso temprano de excursión o de sensor caído, hora estimada de llegada y apoyo al archivo de evidencias); cómo se observa el flujo; qué tamaño tiene la capacidad y cómo se reduce fuera de campaña. Parte de los espacios de trabajo, capacidades, caminos de datos y región de `fabric-workspaces-ingesta-region.md`, y

usa la telemetría, los datos personales, las identidades, la observabilidad y la migración ya diseñadas, con sus mismos nombres.

Términos usados

Término	Significado en este documento
Rol de seguridad de OneLake	Un permiso de lectura sobre tablas o carpetas concretas de un lakehouse, asignado a grupos de Entra ID. Afecta a los usuarios con rol Viewer o con permiso de lectura del elemento
Atajo interno	Un atajo de OneLake entre espacios de trabajo. Lee con la identidad de quien consulta, así que el rol de OneLake del destino es el techo
Direct Lake	El modo en que un modelo semántico lee las tablas Delta de OneLake sin copiarlas ni programar actualizaciones
Token de inserción	El permiso temporal que el servidor del portal pide a Power BI para mostrar el reporte a un cliente, con su identidad efectiva
Eventstream	El elemento de Fabric que lee eventos en tiempo real, en este caso del Event Hub del estado en vivo
Activator	El motor de reglas de Fabric que evalúa eventos por objeto (por sensor) y envía avisos
Funciones de IA	Funciones de Fabric que aplican un modelo de lenguaje ya entrenado (gpt-5-mini por defecto) a texto o imágenes desde un cuaderno
Suavizado	La forma en que Fabric reparte el consumo de una operación: 24 horas para las de segundo plano y de 5 a 64 minutos para las interactivas
CU	Unidad de capacidad. Una capacidad F16 tiene 16 CU

---

1. Contexto y alcance

1.1 Qué necesita FríoAndes

La torre de control, el turno de calidad y la vista analítica del cliente corporativo consumen inteligencia artificial a través de Fabric, con tres reglas que no se negocian:

- La decisión de despacho sigue siendo de una persona en la torre. La inteligencia artificial sugiere.
- El cliente no ve la flota completa ni el video.
- La alerta de temperatura de menos de un minuto no depende de Fabric: vive en la telemetría y funciona aunque Fabric no esté.

Las cifras que dimensionan el diseño: 120 camiones en ruta (180 en campaña), 32 cuartos fríos, 450 usuarios internos, unos 2.000 clientes corporativos, despacho de 04:00 a 22:00 y vigilancia las 24 horas, con la guardia de calidad de noche.

1.2 Qué toma de los otros diseños

Diseño	Qué toma
`fabric-workspaces-ingesta-region.md`	Espacios `ws-fa-datos`, `ws-fa-torre`, `ws-fa-calidad` y `ws-fa-cliente` por ambiente; capacidades `fcfaprod` y `fcfanoprod` en East US 2; atajos a la telemetría y al archivo; Copy Job del libro operativo por el gateway de red virtual; grupos de administración
`carga-b-telemetria.md`	Alerta de menos de un minuto, reglas y destinatario según la hora; Event Hub del estado en vivo; tablas de detalle, resumen de 5 minutos y alertas; topes de Direct Lake; reglas de licencias de Power BI
`seguridad-iam-cifrado.md`	Grupos `grp-fa-despacho` y `grp-fa-calidad`; clientes como invitados ligados a un `cliente_id`; MFA; Key Vault
`seguridad-datos-personales-perimetro.md`	Qué no ve el cliente; sin reconocimiento facial; transmisión a Microsoft en Estados Unidos

Diseño	Qué toma
observabilidad-slo-zabbix.md	Espacio central de Log Analytics, Application Insights por ambiente, grupos de acción, Logic App para Teams
carga-c-migracion-y-campana.md	Tres campañas (fin de año, Semana Santa, mitad de año), sin cambios productivos durante una campaña

1.3 Qué queda en otros diseños

- El precio de cada mes de Fabric, normal y de campaña, y el ahorro frente a copiar el archivo: `docs/costs/costo-fabric.md`, con los tamaños y horas de la sección 8.
- La lista consolidada de decisiones que bajan gasto, con las de la sección 8.4.
- La aplicación de la torre, del portal y de evidencias: los ajustes que piden se listan en la sección 10.2.

---

2. Acceso por rol

2.1 Cómo consume cada público

Público	Grupo	Dónde ve la inteligencia artificial	Rol en Fabric	Licencia de Power BI
Despachadores	grp-fa-despacho	En la consola de la torre: hora estimada de llegada junto a cada guía, y avisos en Teams	Ninguno	No necesita
Líderes de la torre	grp-fa-torre-lideres	Reportes de ws-fa-torre, incluida la precisión de la hora estimada	Member de ws-fa-torre-*	Pro
Calidad, incluida la guardia de noche	grp-fa-calidad	Tableros de ws-fa-calidad y avisos en Teams	Viewer de ws-fa-calidad-prod	Pro
Líderes de calidad	grp-fa-calidad-lideres	Los mismos tableros, y crean reportes	Member de ws-fa-calidad-*	Pro
Cliente corporativo	Invitado ligado a un cliente_id	Reporte insertado en el portal de rastreo	Ninguno: el portal entra con su entidad de servicio	No necesita
Equipo de datos	grp-fa-fabric-admin	Todo	Admin de los espacios	Pro

Así, la mayoría de los usuarios internos no necesitan licencia de Power BI: los despachadores ven la inteligencia artificial dentro de la consola que ya usan.

2.2 Qué datos ve cada uno

Roles de seguridad de OneLake en el lakehouse de `ws-fa-datos-prod`. Los espacios de consumo leen por atajos internos con la identidad de quien consulta, así que estos roles son el techo de lo que cualquier reporte puede mostrar.

Rol	Miembros	Lee	No lee
torre_lectura	Identidad administrada del servicio de la torre y grp-fa-torre-lideres	Guías (sin la ubicación del punto de entrega), viajes y paradas, activos, resumen y alertas de telemetría, eta_viaje y precisión de la hora estimada	Detalle de telemetría, imágenes, resultados de evidencias

Rol	Miembros	Lee	No lee
`calidad_lectura`	`grp-fa-calidad` y `grp-fa-calidad-lideres`	Activos, guías (sin ubicación), telemetría completa, alertas, resultados de la revisión de evidencias y su confirmación	Imágenes: se abren en la aplicación de evidencias, que registra cada acceso
`cliente_vista`	Identidad fija del modelo del cliente	Solo `cliente_guias`	Todo lo demás

`cliente_guias` es una tabla curada, una fila por guía: cliente, estado, temperatura mínima, máxima y promedio del viaje o de la permanencia en bodega, excursiones y cuándo se resolvieron, y hora estimada de llegada. La escribe el mismo cuaderno que calcula la hora estimada (sección 4.2). Nunca lleva posición, camión, conductor ni video.

2.3 Vista del cliente

- Modelo semántico en `ws-fa-cliente-prod` con Direct Lake sobre `cliente_guias` y seguridad por filas por `cliente_id`.
- El servidor del portal pide un token de inserción V2 con su entidad de servicio, que se autentica con un certificado guardado en Key Vault y es Member de `ws-fa-cliente-prod`. Pone como identidad efectiva el `cliente_id` del usuario, que sale del vínculo que administra FríoAndes y nunca de un parámetro del navegador.
- El cliente no necesita licencia de Power BI: es el modelo en que la aplicación es dueña de los datos.

2.4 La decisión de despacho

- Ningún elemento de Fabric escribe en el libro operativo ni llama a la API de despacho.
- Las acciones de Activator solo notifican (Teams y correo).
- La consola de la torre muestra la hora estimada y los avisos como sugerencias; asignar, reprogramar o desviar lo hace siempre un despachador.
- Las marcas de la revisión de evidencias son sugerencias que calidad confirma o descarta (sección 5.3).

2.5 Ajustes del tenant de Fabric

Ajuste	Para quién
Embed content in apps	Solo el grupo de la entidad de servicio del portal
Allow service principals to use Power BI APIs	Solo ese grupo
Users can access data stored in OneLake with apps external to Fabric	Activo: lo exige el uso de atajos con seguridad de OneLake
Copilot y funciones con Azure OpenAI	Activo para `ws-fa-datos-*`. Con la capacidad en Estados Unidos no hace falta el procesamiento entre geografías
Azure Log Analytics connections for workspace administrators	Solo `grp-fa-fabric-admin`

---

3. Aviso temprano de excursión y de sensor caído

3.1 Qué agrega a la alerta

La alerta de la telemetría avisa cuando la lectura ya salió del rango o el sensor lleva 90 segundos sin señal. El aviso temprano llega antes: cuando la temperatura se acerca al límite, cuando una puerta lleva más de lo normal abierta o cuando un sensor empieza a fallar a ratos. No reemplaza la alerta ni su escalamiento.

3.2 Cómo se calcula

Un Eventstream en `ws-fa-datos-prod` lee el Event Hub del estado en vivo, el mismo que alimenta el mapa de la torre, con un grupo de consumidores propio (`fabric`) y por un endpoint privado administrado que aprueba el namespace de Event Hubs. Activator evalúa reglas por sensor sobre ese flujo.

Aviso	Regla en Activator	Cuánto se adelanta
Cerca del límite	El promedio de 5 minutos de la temperatura sube por encima del umbral de aviso del sensor (máximo del rango menos el margen que fija calidad), o baja por debajo del umbral inferior	Minutos antes de salir del rango
Puerta abierta de más	Puerta abierta, verdadera durante 3 minutos en cuartos fríos y 10 en camiones	La alerta salta a los 5 y 15 minutos
Sensor intermitente	Total de lecturas en 10 minutos por debajo del 70 % de lo esperado (20 en cuartos fríos, 10 en camiones con viaje activo)	La alerta de sin señal solo salta cuando se corta del todo

Los umbrales son propiedades de cada evento: Activator compara la temperatura con el umbral del mismo sensor, sin reglas fijas por tipo de carga.

3.3 Destinatarios

Activator publica en el canal de Teams "Avisos de cadena de frío". De día lo sigue la torre y de noche la guardia de calidad, con notificación en el teléfono. No hay SMS ni escalamiento: siguen siendo exclusivos de la alerta.

3.4 Lo que pide a la telemetría

- La tabla de rangos que mantiene calidad suma una columna de margen de aviso por cuarto frío y por tipo de carga.
- Stream Analytics agrega a cada evento del estado en vivo los dos umbrales de aviso del sensor.
- El namespace de Event Hubs suma el grupo de consumidores `fabric` y aprueba el endpoint privado administrado de Fabric.

3.5 Segundo release

El pronóstico con funciones de series de tiempo (una curva que estima cuándo cruzará el límite cada sensor) necesita meses de historial para calibrar los márgenes y un Eventhouse encendido las 24 horas. Se evalúa con los datos del primer trimestre de operación.

---

4. Hora estimada de llegada

4.1 Método

Estadística del propio historial, sin entrenar un modelo:

1. **Tiempos por tramo**, recalculados cada semana: para cada tramo (centro a parada y parada a parada), la mediana y el percentil 80 del tiempo real de viaje, por franja horaria y tipo de día, con los viajes y paradas del libro operativo. Un tramo con pocos viajes usa la mediana de su franja en la misma ciudad.
2. **Hora estimada** de cada guía pendiente: la hora de la última posición o de la última parada cumplida, más las medianas de los tramos que faltan, ajustada por el atraso que ya lleva el viaje frente a su plan. Se muestra como un rango entre la mediana y el percentil 80.
3. **Precisión**: cada llegada real se compara con la hora estimada que había 60 y 30 minutos antes. Los líderes de la torre ven el error por ruta y franja.

4.2 Cálculo y frecuencia

Un cuaderno de Python en `ws-fa-datos-prod` corre cada 5 minutos de 04:00 a 22:00 y cada 15 minutos de noche. Lee la última posición de cada camión con viaje activo (detalle de telemetría del día en curso), los viajes y paradas y los tiempos por tramo; sobrescribe `eta_viaje` (una fila por guía pendiente) y actualiza `cliente_guias`.

4.3 Cómo llega a la torre

- El servicio de la torre consulta `eta_viaje` por el endpoint SQL del lakehouse cada minuto, con su identidad administrada, miembro del rol `torre_lectura`, y reintenta ante errores transitorios.
- La consola muestra la hora junto a cada guía como "estimada", con su rango y su antigüedad.
- Si Fabric no responde, la consola muestra la última hora conocida con su antigüedad y, pasados 15 minutos, vuelve a la hora planeada.
- Red: TDS por TCP 1433 desde `snet-app-torre` hacia las etiquetas de servicio `PowerBI` y `Sql`, como pide Microsoft para el endpoint SQL (reglas FW-325 a 327 de `red-firewall-y-publicacion.md`).

---

5. Apoyo al archivo de evidencias

5.1 Qué se revisa y con qué

Un cuaderno nocturno en `ws-fa-datos-prod` revisa las fotos y comprobantes del día anterior, unos 37.000 archivos con el supuesto de 1 MB por archivo:

Etapa	A qué archivos	Cómo	Qué marca
1. Calidad de imagen	Todas las fotos y comprobantes nuevos	Medidas de imagen en Spark, sin inteligencia artificial: nitidez, brillo y resolución	"Posible ilegible"
2. Revisión con inteligencia artificial	Fotos de carga de entregas con reclamo abierto o con excursión en el viaje, las marcadas en la etapa 1 y una muestra aleatoria del 10 % del resto	Función de IA multimodal de Fabric (gpt-5-mini) con salida estructurada	"Ilegible", "carga visiblemente dañada", motivo corto y confianza

Antes de activar la etapa 2 completa, una semana piloto mide los tokens reales con `ai.stats`: Microsoft no publica cuántos tokens cuenta una imagen.

5.2 Video

Segundo release. Las funciones de IA aceptan imágenes, no video, así que analizar un clip exige extraer cuadros, y su costo se estima con los datos del piloto de fotos. En el primer release, el tablero de calidad lista los clips de cada reclamo abierto con su enlace a la aplicación de evidencias; Fabric no analiza video.

5.3 Uso del resultado

- Las marcas son sugerencias. El tablero de calidad las lista con un enlace a la aplicación de evidencias, donde calidad ve la imagen y confirma o descarta la marca. La aplicación guarda esa respuesta en la tabla `revision_evidencias` de la base, que vuelve a Fabric con Copy Job.
- Fabric solo lee el archivo; no borra, mueve ni modifica evidencias.
- La instrucción al modelo evalúa solo la legibilidad y el estado de la carga, nunca identifica personas: no hay reconocimiento facial.
- Las imágenes se procesan en el servicio de Azure OpenAI de Fabric en Estados Unidos, que no guarda las instrucciones, las entradas ni las salidas. Es la misma transmisión a Microsoft como encargado de los demás datos.

---

6. Resumen de los tres usos

Uso	Fuente de datos	Consumidor	Frecuencia	Release
Aviso temprano de excursión y de sensor caído	Event Hub del estado en vivo (temperatura, puertas, lecturas, umbrales de aviso)	Torre de día y guardia de calidad de noche, en Teams	Continua, por evento	Primero; el pronóstico con series de tiempo, segundo
Hora estimada de llegada	Posiciones (detalle de telemetría), viajes y paradas (libro operativo), tiempos por tramo	Consola de la torre; vista del cliente por `cliente_guias`	Cada 5 minutos de día y 15 de noche; tiempos por tramo cada semana	Primero
Apoyo al archivo de evidencias	Fotos y comprobantes nuevos (cuenta de documentos), reclamos y excursiones	Calidad, en su tablero y en la aplicación de evidencias	Cada noche	Primero para fotos y comprobantes; video, segundo

---

7. Observabilidad del flujo

Azure Monitor no tiene métricas de plataforma para la capacidad de Fabric. Por eso el flujo se observa en cinco tramos que terminan en los mismos destinatarios de la observabilidad de la plataforma:

Tramo	Señal	Dónde	Quién recibe
Fuentes en Azure	Métricas y registros de la base, el Event Hub, Stream Analytics y las cuentas	Azure Monitor, espacio central	Los grupos de acción ya definidos
Trabajos de Fabric (Copy Job, cuadernos de hora estimada, mantenimiento, evidencias)	Trabajo fallido o atascado	Activator suscrito a los eventos de trabajos de `ws-fa-datos-prod` (misma región)	`grp-fa-fabric-admin`, canal "Operación de datos" y correo
Lo que ven la torre y el cliente	Antigüedad de la hora estimada y de `cliente_guias`; errores al pedir el token de inserción	Application Insights de cada servicio; alertas de Azure Monitor	Operación y equipo de datos: antigüedad mayor a 15 minutos de 04:00 a 22:00, errores de token por encima del 5 % en 5 minutos
Modelos de calidad y del cliente	Errores de consulta y demoras por estrangulamiento (`capacityThrottlingMs` mayor que 0)	`ws-fa-cliente-prod` y `ws-fa-calidad-prod` conectados al espacio central de Log Analytics (tabla `PowerBIDatasetsWorkspace`); alerta con consulta	Equipo de datos
Capacidad	Uso suavizado por hora y estrangulamiento	App de métricas de capacidad y notificaciones de la capacidad	Equipo de datos, revisión mensual

La falla de Fabric aparece donde la operación ya mira (la antigüedad en la consola y en Azure Monitor), aunque Fabric no publique métricas en Azure Monitor.

---

8. Capacidad, licencias y reducción fuera de campaña

8.1 Carga estimada de `fcfaprod`

Componente	Cálculo	CU promedio
Eventstream	0,222 CU hora por hora activa + procesador de rendimiento bajo 0,778 + tráfico (unos 487.000 eventos al día de 0,5 KB, entrada y salida, a 0,342 por GB)	1,0
Activator	5 reglas × 0,02222 por hora + 487.000 eventos × 0,000011111 + 3 cálculos por evento × 0,00000278, por día	0,5
Gateway de red virtual	4 CU mientras está encendido, unas 19 horas al día	3,2
Copy Job	72 ejecuciones de 1 minuto a 3 CU hora	0,15
Cuaderno de Python de hora estimada	240 ejecuciones de 3 minutos × 2 vCores × 0,5 CU	0,5
Spark nocturno (mantenimiento de tablas y etapa 1 de evidencias)	365 horas de vCore al mes × 0,5 CU, suavizadas en 24 horas	0,25
Reservas sin tasa publicada	Reportes 1,5; funciones de IA 1,0; consultas SQL de la torre 0,1	2,6
Mes normal		**unos 8,2**
Mes de campaña	Eventos y fotos +40 %, reportes ×2,5	**unos 10,7**

El mantenimiento nocturno de las tablas y la etapa 1 de evidencias corren en Spark dentro de la capacidad: suman unos 182 CU hora al mes, que suavizados en 24 horas casi no se notan. La facturación a demanda de Spark costaría unos USD 33 al mes sin bajar el tamaño; queda como opción si la medición muestra estrangulamiento.

Casi toda la carga es de segundo plano, que Fabric suaviza en 24 horas. Por eso bajar de tamaño de noche no sirve: el uso de noche arrastra el del día. Real-Time Intelligence, además, no aplica la demora de 20 segundos y solo rechaza cuando la capacidad agota una hora completa.

8.2 Tamaño

Capacidad	Tamaño	Horas	Precio de lista mensual
`fcfaprod`	F16 en mes normal y en campaña al arranque (51 % y 67 % del estimado)	730	USD 2.102,40
`fcfanoprod`	F4: el gateway de pruebas consume 4 CU mientras está encendido	Lunes a viernes de 07:00 a 19:00, unas 261 horas	USD 187,71

Después del primer mes de operación, el equipo de datos mide el uso suavizado con la app de métricas. Si queda por debajo del 40 % de F16, `fcfaprod` pasa a F8 (USD 1.051,20) fuera de campaña y vuelve a F16 una semana antes de cada campaña.

8.3 Licencias

Licencias Pro para quien crea o ve reportes internos: equipo de datos, líderes de torre y de calidad, calidad y guardia. Con el supuesto de 40 personas son USD 560 al mes, o ninguna compra adicional si FríoAndes tiene Microsoft 365 E5, que incluye Pro. Una capacidad F64, que deja ver reportes con la licencia gratuita, solo compensa con más de unas 525 personas viendo reportes. Los despachadores y los clientes no necesitan licencia.

8.4 Cómo se reduce fuera de campaña

1. **Runbook de Azure Automation**, con identidad administrada y el rol personalizado "Operador de capacidad Fabric" (read, write, suspend y resume sobre cada capacidad). Pausa y reanuda `fcfanoprod` según el horario y cambia el tamaño de `fcfaprod` con el calendario de campañas. El calendario se aprueba antes

de cada campaña, y el cambio se hace en la ventana de 22:00 a 04:00: durante la campaña no se toca nada.
2. **Reserva de 8 CU por un año**, el piso que `fcfaprod` no baja nunca (F8 o F16).
3. **Sobreconsumo de la capacidad con umbral del 10 %**, en vez del 25 % que Microsoft activa por defecto, como red de seguridad con tope.
4. **Gateway con apagado a los 30 minutos sin uso** y copias del libro operativo solo de 04:00 a 22:00, más una a las 22:15 y otra a las 03:45.
5. **Sin F64**: licencias Pro para los pocos usuarios que ven reportes.

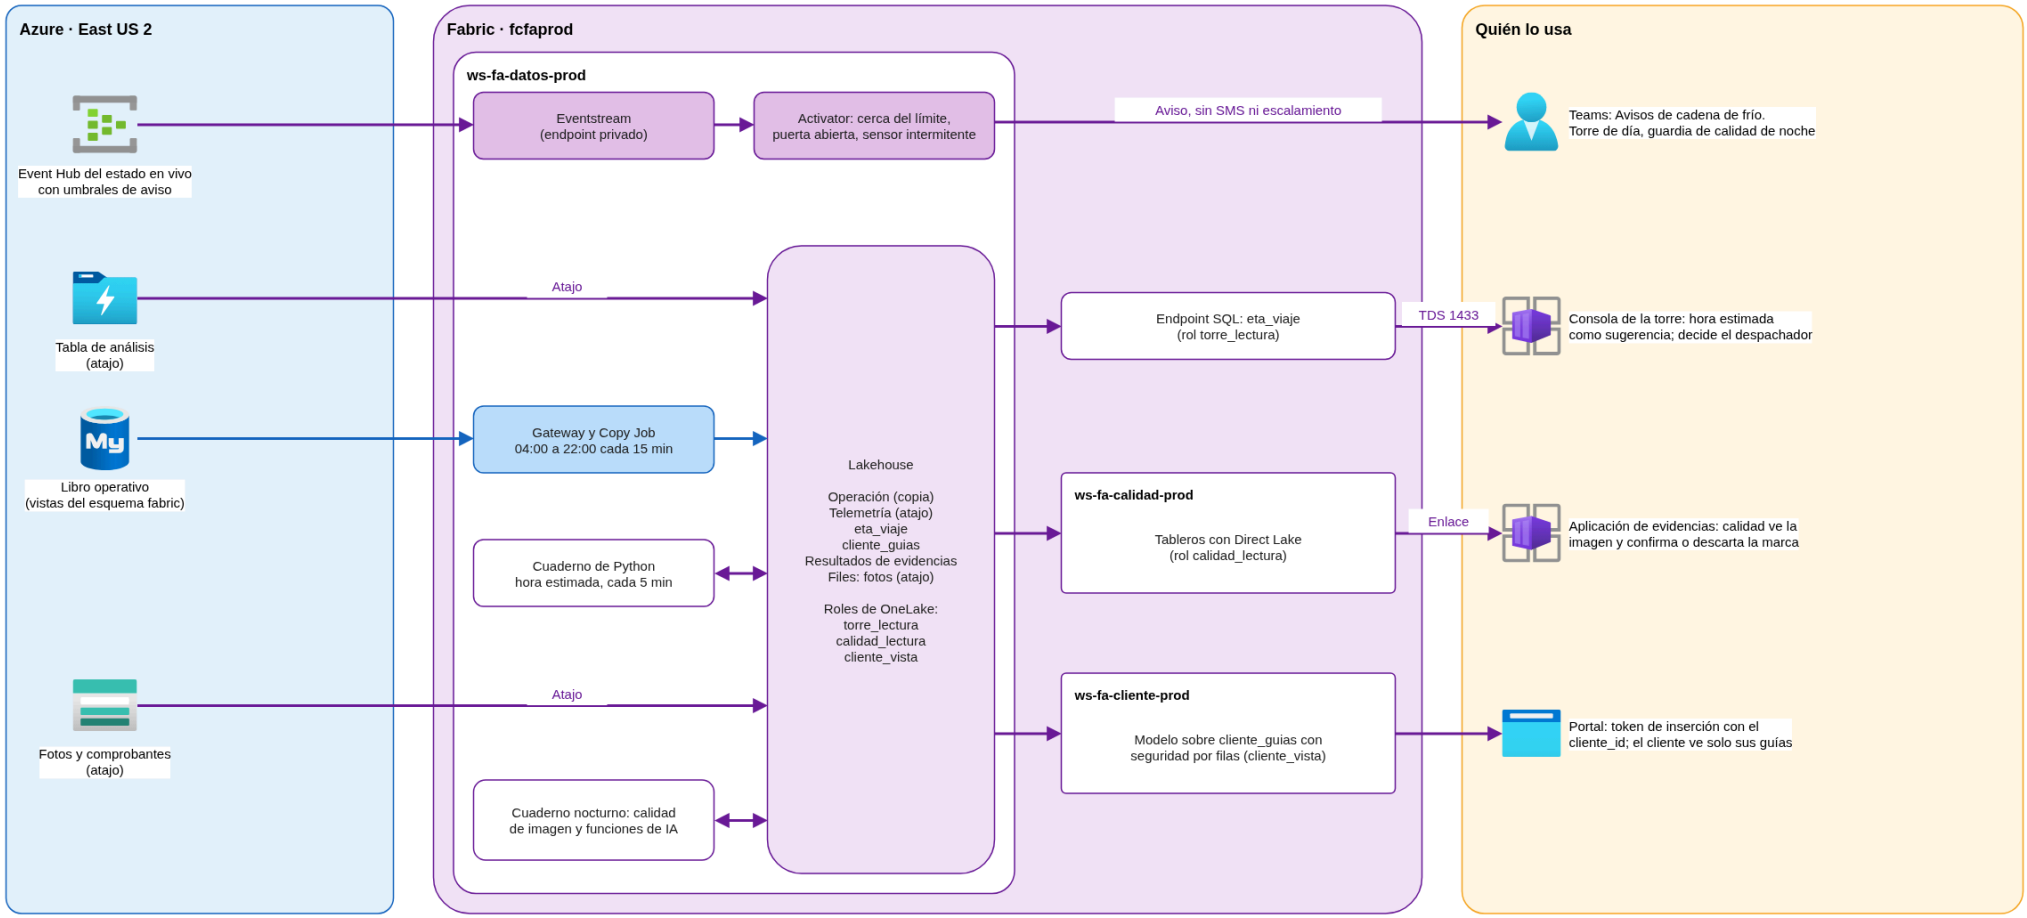
Las cifras de cada mes y de cada decisión están en `docs/costs/costo-fabric.md`.

`fcfaprod` no se pausa nunca: el aviso de noche, la hora estimada y la vista del cliente la necesitan encendida. Al pausar una capacidad, Fabric cobra el consumo suavizado pendiente, así que la pausa de `fcfanoprod` se programa después de los trabajos de prueba.

---

9. Diagramas

Fabric: quién ve qué y cómo llegan los tres usos a la torre, a calidad y al cliente

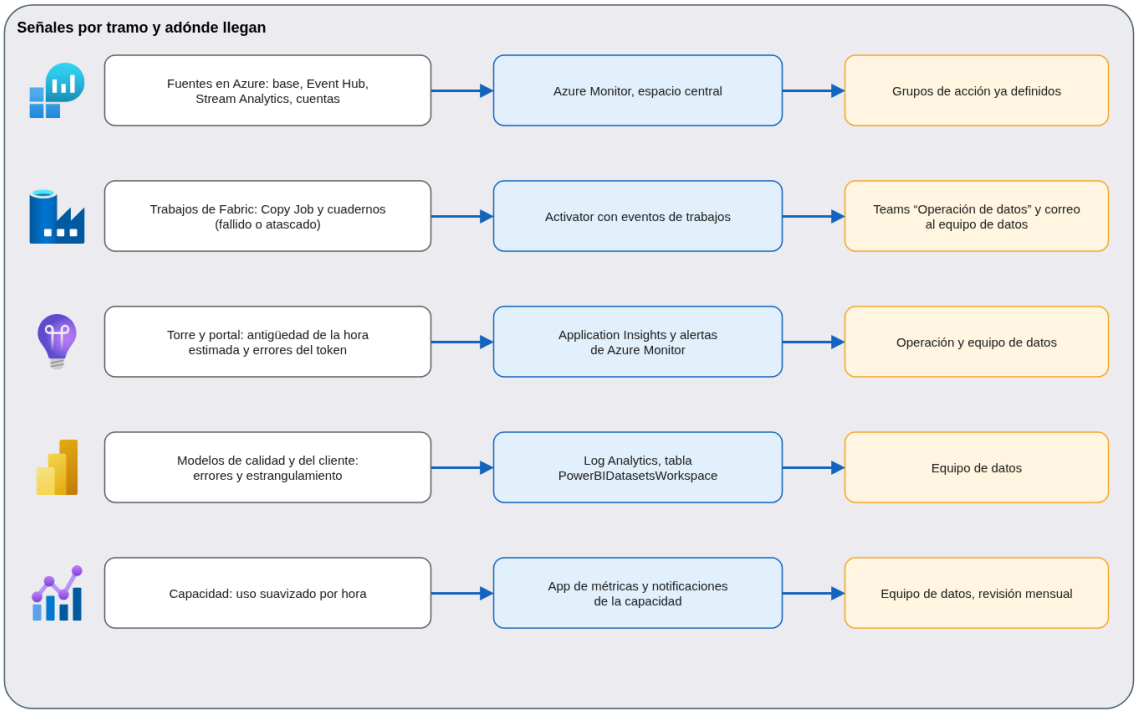


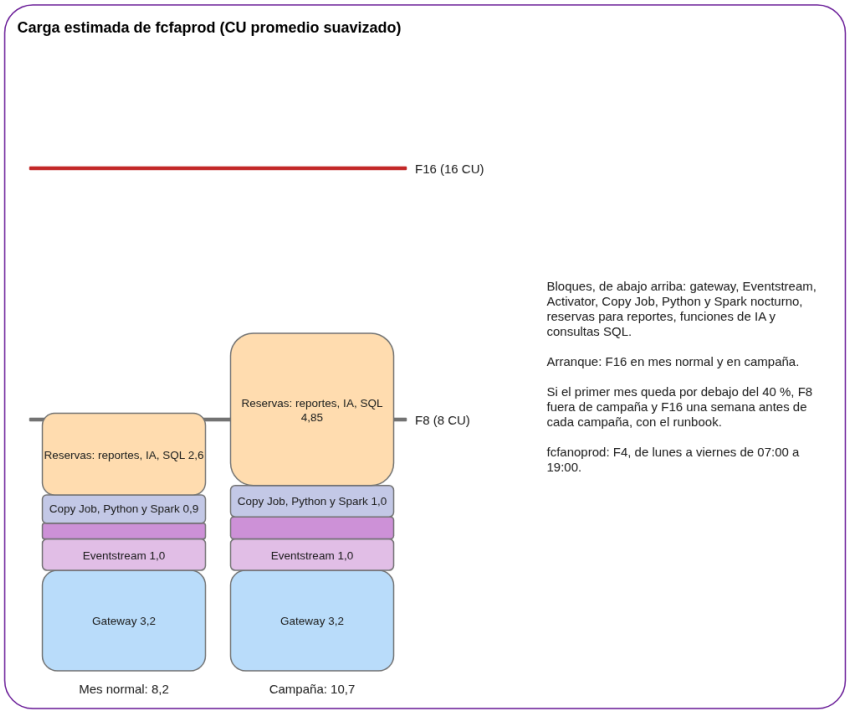
Morado: lo que ocurre en Fabric y sale de Fabric. Azul: copia del libro operativo. Ningún elemento de Fabric escribe en el libro operativo ni en la API de despacho; la confirmación de calidad vuelve por la base (revision_evidencias) y Copy Job. Los despachadores y los clientes no necesitan licencia de Power BI.

Figura 26: Quién ve qué en Fabric y cómo llegan los tres usos a la torre, a calidad y al cliente

El primer diagrama muestra el lakehouse de datos con sus roles de OneLake, los tres usos con sus fuentes y consumidores, y por dónde llega cada uno: Teams, la consola de la torre por el endpoint SQL, el portal con el token de inserción y la aplicación de evidencias.

Fabric: cómo se observa el flujo y cuánto pesa cada componente en la capacidad





Azure Monitor no tiene métricas de plataforma para Fabric: la falla de Fabric se ve por la antigüedad que publican la torre y el portal, por los eventos de trabajos y por los registros de los modelos. Casi toda la carga es de segundo plano y se suaviza en 24 horas, por eso no se cambia de tamaño entre el día y la noche.

Figura 27: Observabilidad del flujo y tamaño de la capacidad

El segundo muestra las señales de cada tramo con su destino y la carga estimada de la capacidad con su mecanismo de reducción.

Los dos se generan con `red/tools/build_drawio_diagrams.py`.

---

10. Supuestos, ajustes a la aplicación y confirmaciones pendientes de FríoAndes

10.1 Confirmaciones que necesita el diseño

Tema	Pregunta para FríoAndes	Qué pasa si la respuesta cambia
Licencias	¿Tiene Microsoft 365 E5 o licencias Pro? ¿Cuántas personas de calidad y de liderazgo verán reportes?	Cambia el costo de licencias; con más de unas 525 personas conviene F64
Hora estimada	¿La aplicación registra la hora real de llegada a cada parada?	Sin ella, los tiempos por tramo salen de las posiciones y la precisión baja
Teams	¿Quién sigue de noche los canales "Avisos de cadena de frío" y "Operación de datos"?	Cambian los destinatarios de los avisos
Márgenes de aviso	¿Qué margen fija calidad por tipo de carga y por cuarto frío?	Cambia cuántos avisos salen al día
Evidencias	¿Cuántos reclamos y excursiones hay al mes?	Define el tamaño de la etapa 2 y su costo

10.2 Ajustes que se piden a la aplicación

Servicio	Ajuste
Torre	Consultar `eta_viaje` por el endpoint SQL con su identidad administrada y reintentos; mostrar la hora como "estimada" con rango y antigüedad; volver a la hora planeada después de 15 minutos sin dato; publicar la antigüedad como métrica
Portal	Pedir el token de inserción V2 con la entidad de servicio (certificado en Key Vault), con el `cliente_id` del vínculo como identidad efectiva; publicar errores y antigüedad
Evidencias	Mostrar las marcas de la revisión desde el enlace del tablero de calidad y guardar la confirmación en `revision_evidencias`

10.3 Supuestos del diseño

Supuesto	Por qué se asume
Unas 40 personas crean o ven reportes internos	Calidad, guardia, líderes y equipo de datos; los despachadores usan la consola
Los eventos del estado en vivo pesan unos 0,5 KB	El estado de un sensor o camión con sus umbrales
El cuaderno de Python consume a la tasa de Spark por vCore	Microsoft no publica una tasa propia
El gateway de red virtual consume 4 CU encendido	Blog oficial de Fabric; se confirma con la app de métricas
Reservas de 1,5 CU para reportes y 1,0 para funciones de IA	Sin tasa publicada; se miden el primer mes y en el piloto de fotos
La base registra la hora real de llegada a cada parada	La hora estimada se calcula con ese historial
Las fotos y comprobantes nuevos son unos 37.000 al día	1,1 TB al mes con archivos de 1 MB, el mismo supuesto de la siembra del archivo
Los costos son precios de lista en East US 2, con 730 horas al mes, sin descuentos	Es la base común del cálculo de costos de la plataforma

8. Sistema de diseño

Logo y paleta de color — FríoAndes

HU F5-02 · Fase 5 (Diseño) · Estado: propuesta v1 para revisión del equipo.

FríoAndes no tiene manual de marca. Este documento fija el logo y la paleta que usan la torre de control (de noche), el portal público (de día) y las notas de versión, para que las tres superficies se vean como la misma empresa. La paleta sale de los colores que ya usamos en la presentación de avance, así que no hay que rehacer nada de lo entregado.

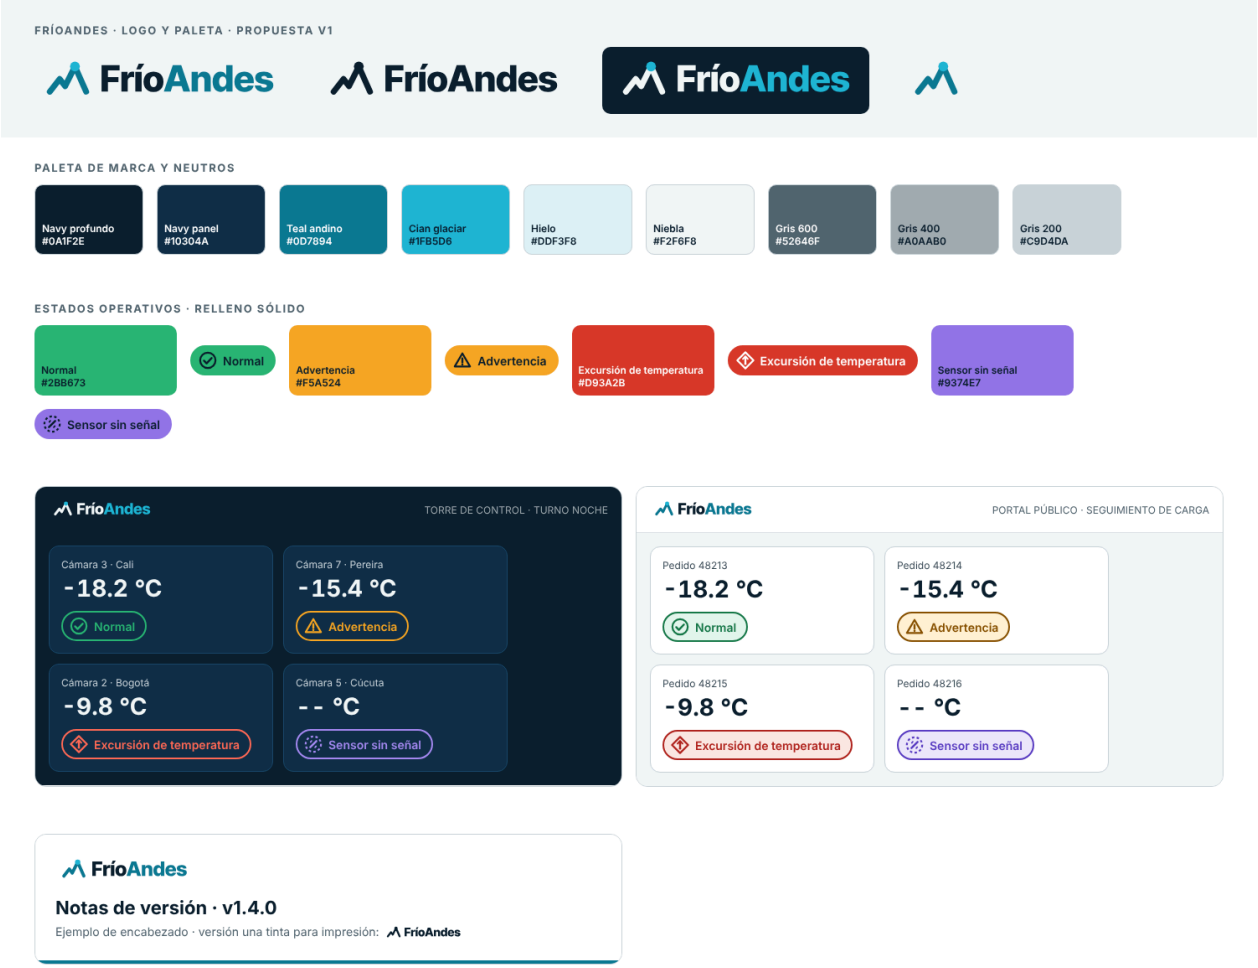


Figura 28: Hoja previa

1. Idea del logo

- **Nombre:** FríoAndes = frío (cadena de frío) + Andes (la empresa es colombiana, sede en Cali).
- **Isotipo:** una cresta de montaña dibujada como una traza de temperatura (línea de un gráfico). La cumbre termina en un punto: el sensor que mide. Una sola figura cuenta las dos cosas: montañas y monitoreo.
- **Wordmark:** «Frío» + «Andes» en Inter Tight ExtraBold (licencia OFL). Las letras van convertidas a trazos en el SVG, así el logo no depende de ninguna fuente instalada.
- **Por qué funciona en las tres superficies:** son solo trazos gruesos y un punto, sin degradados ni sombras. Se lee desde 16 px (favicon) y se imprime bien en una tinta.

2. Versiones del logo (criterio de aceptación 1)

Versión	Archivo	Dónde se usa	Colores
Principal (a color, para fondos claros)	`logo/logo-principal.svg`	**Portal público** (encabezado, de día), pie de correos	«Frío» #0A1F2E, «Andes» y cresta #0D7894, punto #1FB5D6
Negativo (para fondos oscuros)	`logo/logo-negativo.svg`	**Torre de control** (barra superior, turno noche)	«Frío» y cresta #F2F6F8, «Andes» y punto #1FB5D6
Una tinta	`logo/logo-una-tinta.svg` (oscuro) y `logo/logo-una-tinta-blanco.svg` (blanco)	**Notas de versión** impresas o en PDF en blanco y negro, sellos, fax/etiquetas	Todo #0A1F2E, o todo blanco sobre fondo oscuro
Isotipo	`logo/isotipo-principal.svg`, `isotipo-una-tinta.svg`, `isotipo-negativo.svg`	Favicon, avatar, espacios cuadrados	Igual que arriba
Icono de app	`logo/icono-app.svg`	Pestaña fijada de la torre, ícono de instalación	Fondo #0A1F2E, isotipo negativo

Las notas de versión usan la versión principal en pantalla y la de una tinta cuando se imprimen o van en blanco y negro.

Reglas de uso

- Espacio libre alrededor: no recortar el SVG; ya trae un margen de 16 unidades (un cuarto de la altura del isotipo) y ningún otro elemento debe entrar en él.
- Tamaño mínimo: isotipo 16 px; logo horizontal 24 px de alto.
- No recolorear fuera de las versiones de arriba, no estirar, no poner sobre fotos sin una capa oscura.
- Sobre fondo claro siempre principal o una tinta; sobre fondo oscuro siempre negativo o una tinta blanca.

3. Paleta

3.1 Marca y neutros

Token	Hex	Uso
navy-profundo	`#0A1F2E`	Fondo de la torre de noche, texto principal de día
navy-panel	`#10304A`	Tarjetas y paneles en la torre
teal-andino	`#0D7894`	Color primario: enlaces, botones, «Andes» sobre fondo claro
cian-glaciar	`#1FB5D6`	Acento: punto del sensor, «Andes» sobre fondo oscuro, foco de teclado
hielo	`#DDF3F8`	Fondos suaves, selección
niebla	`#F2F6F8`	Fondo del portal de día
gris-600	`#52646F`	Texto secundario
gris-400	`#A0AAB0`	Texto secundario en la torre, íconos inactivos
gris-200 / gris-100	`#C9D4DA` / `#DDE3E6`	Bordes y separadores
blanco	`#FFFFFF`	Superficies del portal

3.2 Los 4 estados operativos (criterio de aceptación 2)

Cada estado tiene un color de relleno (el que se ve en puntos, barras y gráficos) y una «tinta» más oscura para texto sobre fondo claro, porque los colores de relleno por sí solos no alcanzan el contraste de texto sobre blanco.

Estado	Relleno	Texto sobre relleno	Tinta de día (portal)	Fondo suave de día	Tinta de noche (torre)	Forma / ícono
Normal	`#2BB673`	`#0A1F2E`	`#17794A`	`#E3F5EC`	`#2BB673`	Círculo con check

Estado	Relleno	Texto sobre relleno	Tinta de día (portal)	Fondo suave de día	Tinta de noche (torre)	Forma / ícono
Advertencia	`#F5A524`	`#0A1F2E`	`#8A5300`	`#FFF1D6`	`#F5A524`	Triángulo con !
Excursión de temperatura	`#D93A2B`	`#FFFFFF`	`#B3261E`	`#FDE6E3`	`#FF6B57`	Rombo con flecha hacia arriba
Sensor sin señal	`#9374E7`	`#0A1F2E`	`#5B3FC4`	`#EEE9FC`	`#A58BF0`	Círculo punteado con raya diagonal

Regla de oro: el color nunca va solo. Cada estado lleva siempre su ícono con forma distinta y su texto. Así se distingue aunque la persona sea daltónica, mire la pantalla de lejos o esté en un turno de noche con brillo bajo.

3.3 Insignias de estado

Las insignias combinan ícono, texto y color, y son la base de la insignia de temperatura de F5-03. Hay tres variantes por estado, todas en `insignias/`:

Variante	Carpeta	Dónde	Composición
Día	`insignias/dia/`	Portal público	Fondo suave, borde y texto en tinta de día, ícono
Noche	`insignias/noche/`	Torre de control	Fondo navy-panel, borde, texto e ícono en tinta de noche
Sólida	`insignias/solido/`	Listas densas, boletines, fondos de cualquier tema	Relleno del estado, texto e ícono en el color «sobre relleno»

Medidas: 32 px de alto, texto Inter SemiBold 14 px (convertido a trazos en el SVG), ícono de 22 px.

Decisiones respecto de la presentación: el rojo pasó de `#FF5A3C` a `#D93A2B` (con el anterior no llegaba a 4,5:1 con texto blanco ni se separaba bien del ámbar con daltonismo) y el violeta de `#8D6BE3` a `#9374E7` (con texto navy subía de 4,28:1 a 4,72:1). Los verdes y ámbar se mantienen.

4. Verificación

Calculado con las fórmulas de WCAG 2.x (script `fuentes-editables/pal.py`). Meta: ≥ 4,5:1 para texto y ≥ 3:1 para gráficos.

Texto

Estado	Texto sobre relleno	Tinta de día / blanco	Tinta de día / fondo suave	Tinta de noche / navy	Tinta de noche / panel
Normal	6,44	5,43	4,79	6,44	5,21
Advertencia	8,24	6,33	5,67	8,24	6,67
Excursión	4,57	6,54	5,48	6,00	4,85
Sin señal	4,72	7,11	5,99	6,05	4,89

Marca: teal sobre blanco 5,08; teal sobre niebla 4,67; cian sobre navy 6,92; gris-600 sobre blanco 6,16; hielo sobre navy 14,62.

Daltonismo. Se simularon protanopía, deuteranopía y tritanopía (matrices de Machado 2009) y se midió la diferencia de color (ΔE Lab) entre los rellenos de los 4 estados. Menor valor por tipo: visión normal 54, protanopía 28 (normal–excursión), deuteranopía 30 (advertencia–excursión), tritanopía 45 (normal–sin señal). Todos son distinguibles, pero la distancia en protanopía y deuteranopía es moderada, y por eso la forma y el texto son obligatorios.

Límites de esta verificación

- Rellenos sobre fondo claro (verde 2,61:1, ámbar 2,04:1 sobre blanco) no cumplen 3:1 como gráficos aislados; por eso en día se usa la insignia con borde y tinta oscura, no el relleno suelto.
- No se probó con personas ni con las pantallas reales de la torre. Pendiente: revisar en el monitor real del turno de noche (F5-03).

5. Archivos

Todo vive en `docs/design/brand/` (junto a este documento). Los scripts de `fuentes-editables/` son de referencia: para volver a generar los logos hay que ajustar la ruta de la fuente Inter Tight 800 (paquete npm `@fontsource/inter-tight`) en `build_logo.py`.

Archivo	Para qué
`logo/*.svg`	Fuentes editables de todas las versiones (se abren en Figma, Inkscape o Illustrator)
`iconos/neutro`, `iconos/dia`, `iconos/noche`	Los 4 íconos de estado (24 px, trazo editable): neutro (#0A1F2E) para recolorear, y ya coloreados con la tinta de día y de noche
`insignias/dia`, `insignias/noche`, `insignias/solido`	Las 4 insignias de estado en 3 variantes (12 SVG, con el texto ya convertido a trazos)
`logo/*.png`	Exportaciones con fondo transparente (3x)
`tokens.json` / `tokens.css`	Colores como variables para el diseño de componentes (F5-03)
`hoja-previa.png`	Vista conjunta: logo, paleta, torre, portal y notas de versión
`fuentes-editables/build_logo.py`	Genera todos los SVG (cambiar colores o la cresta y volver a correr)

6. Criterios de aceptación

Criterio	Cómo se cumple
3 versiones del logo (principal, una tinta, negativo) referidas a las 3 superficies (torre, portal, notas de versión)	Sección 2: torre = negativo, portal = principal, notas de versión = principal en pantalla y una tinta impresa
Los 4 estados operativos con color distinto y código exacto	Sección 3.2: `#2BB673`, `#F5A524`, `#D93A2B`, `#9374E7` (y sus tintas de día y noche)
Se distinguen en la insignia de temperatura y en el turno de noche (F5-03)	Sección 3.3: ícono de forma distinta + texto; sección 4: contraste de la variante de noche entre 4,85 y 8,24
Archivos fuente editables	Sección 5: SVG, tokens y script

Si el tablero tiene criterios adicionales que no se vean en la captura, hay que revisarlos contra esta tabla.

7. Pendientes y decisiones para el equipo

1. Confirmar con el cliente (o con el profesor) si el color de marca puede ser teal y cian, ya que no hay manual previo.
2. Validar el nombre con tilde «FríoAndes» en las tres superficies (nombres de archivo y URLs usan `frioandes`).
3. Revisar el contraste final de F5-03 (insignia de temperatura) con estos tokens.

9. Cronograma general del proyecto

Cronograma general del proyecto

Este documento junta en un solo calendario todo el proyecto de FríoAndes, desde el diseño hasta el cierre: el diseño de la arquitectura, la construcción del código de infraestructura y del pipeline, el despliegue de los ambientes, las adaptaciones de la aplicación, la siembra del archivo, los 90 días de convivencia con el ensayo y el corte, el retiro de Zabbix, el apagado de Cali, el primer release de Fabric y el cierre. No cambia ninguna fecha ya decidida: las toma de los documentos que las fijan y completa con supuestos las fases que nadie había fechado.

1. Contexto y alcance

1.1 De dónde salen las fechas

Fecha o fase	Documento que la fija
Campañas, día 0, ensayo, corte, plazo de vuelta atrás, apagado de Cali y día 90	`carga-c-migracion-y-campana.md`, secciones 4.1 a 4.3
Preparación de la siembra, trabajos de discos, T0, T1 y conciliación	`carga-c-siembra-1-2pb.md`, sección 5
Despliegue de pruebas y desarrollo el 1 de diciembre y de hub y producción el 14 de diciembre	`docs/costs/costo-migracion.md`, sección 4
Retiro de Zabbix el día 61 y vigilancia de Azure Monitor desde el despliegue	`observabilidad-slo-zabbix.md`, sección 8
Copia de la base hacia Fabric desde el corte y ajustes de la aplicación para Fabric antes del día 0	`fabric-workspaces-ingesta-region.md`, secciones 4.4 y 4.6
Primer y segundo release de los usos de IA, y medición de la capacidad después del primer mes	`fabric-acceso-casos-uso-costo.md`, secciones 6 y 8

Las fases que no tenían fecha (diseño, código de infraestructura, landing zone, adaptaciones, pruebas de carga, capacitación, preparación de Fabric y cierre) se fechan aquí con los supuestos de la sección 9.

1.2 Términos usados

Término	Significado en este documento
Día N	Los días del plan de migración: día 0, inicio de la convivencia (11 de enero de 2027); día 34, corte; día 90, límite de la convivencia
Hito	Fecha que cierra una fase y abre la siguiente. Si se mueve, se mueve lo que depende de ella
Ruta crítica	Cadena de fases sin holgura: un día de atraso en cualquiera atrasa el corte
Holgura	Días que una fase puede atrasarse sin mover la fase siguiente
Cambio productivo	Cambio sobre algo que usan despacho, calidad o los clientes. Solo de 22:00 a 04:00 y fuera de campaña, salvo incidente

---

2. Hitos

Hito	Fecha	Qué cierra	Quién lo aprueba
Arranque del proyecto	Lunes 28 de septiembre de 2026	—	Gerencia de FríoAndes

Hito	Fecha	Qué cierra	Quién lo aprueba
Arranque de la siembra	Martes 13 de octubre	Compra de discos y estaciones aprobada por separado (sección 4.1)	Gerencia y arquitecto cloud
Diseño y presupuesto aprobados	Viernes 13 de noviembre	Fase 1 (arquitectura), Fase 3 (costos) y Fase 4 (plantillas de cambio)	Arquitecto cloud del cliente y gerencia
Pruebas y desarrollo desplegados	Martes 1 de diciembre	Código de infraestructura y pipeline (Fase 2)	Equipo de plataforma
Hub y producción desplegados	Lunes 14 de diciembre	Landing zone y red de producción, sin usuarios	Comité de cambios
Listo para el día 0	Viernes 8 de enero de 2027	Adaptaciones probadas, prueba de carga, capacitación de operación	Comité de cambios
Día 0	Lunes 11 de enero	Inicio de la convivencia	Comité de cambios
Siembra conciliada	Viernes 29 de enero	Archivo completo en Azure, salvo la copia continua	Base de datos y migración
Ensayo del corte	Domingo 31 de enero, 01:00 a 03:00	Criterios del ensayo cumplidos	Líder del corte
Corte	Domingo 14 de febrero, 01:00 a 03:00	Azure pasa a ser la plataforma principal	Comité de cambios y líder del corte
Cierre del plazo de vuelta atrás	Lunes 8 de marzo (día 56)	Ya no se vuelve a Cali	Comité de cambios
Fabric en producción	Viernes 12 de marzo	Primer release de los tres usos de IA	Equipo de datos e IA y calidad
Cali apagada	Domingo 14 de marzo (día 62)	Zabbix retirado el día 61 y VMware el 62	Equipo de plataforma
Día 90	Domingo 11 de abril	Límite de la convivencia	—
Cierre del proyecto	Viernes 30 de abril	Entrega a operación, informe de cierre y lecciones aprendidas	Gerencia de FríoAndes

---

3. Fases

Cronograma general del proyecto, de septiembre de 2026 a mayo de 2027

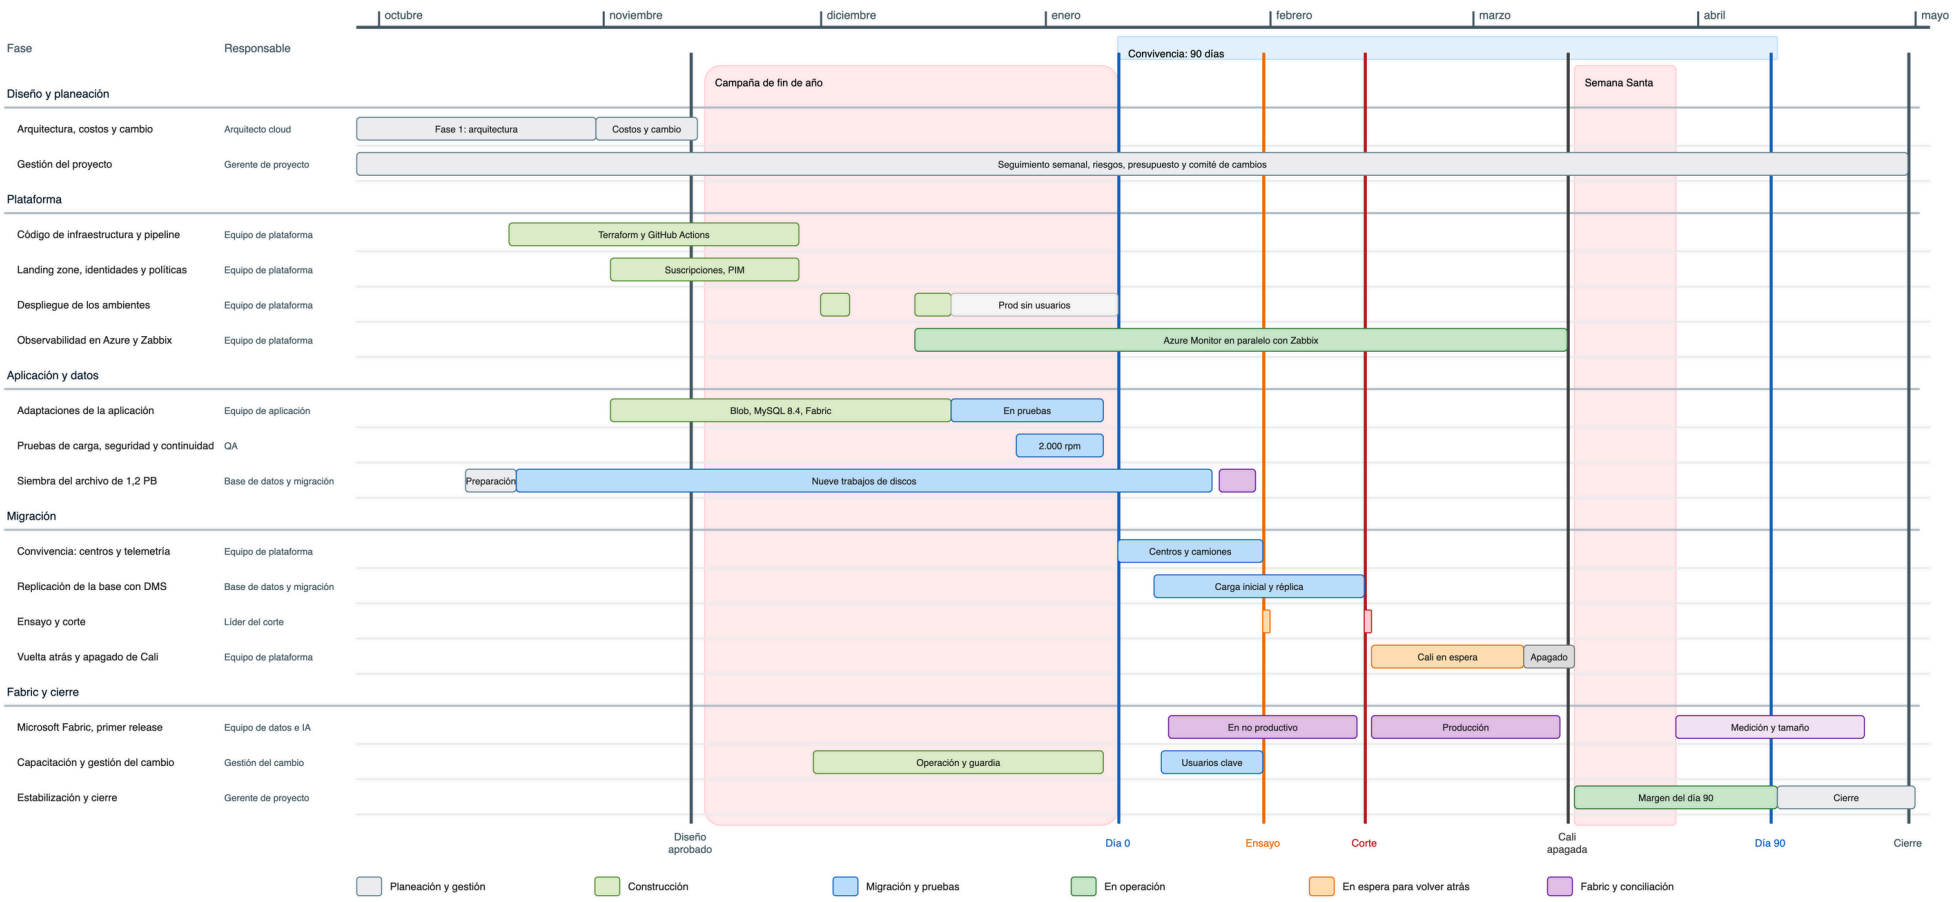


Figura 29: Cronograma general del proyecto, de septiembre de 2026 a mayo de 2027

Fase	Fechas	Responsable	Qué incluye	Depende de
Arquitectura	28 de septiembre al 30 de octubre de 2026	Arquitecto cloud	Los documentos de la Fase 1 (#5 a #18) y este documento	—
Costos y cambio	31 de octubre al 13 de noviembre	Arquitecto cloud	Costo de la migración, del mes estable y de campaña, de Fabric y del proyecto completo (Fase 3); plantillas de release notes (Fase 4)	Arquitectura
Gestión del proyecto	28 de septiembre al 30 de abril de 2027	Gerente de proyecto	Seguimiento semanal, riesgos, presupuesto, comité de cambios y comunicación con FríoAndes	—
Código de infraestructura y pipeline	19 de octubre al 27 de noviembre	Equipo de plataforma	Módulos de red, seguridad y cómputo, pipeline con aprobación y bloqueo de la ventana, `plan` limpio (#20 a #24)	Diseño de red y firewall (#8, #9)
Landing zone, identidades y políticas	2 al 27 de noviembre	Equipo de plataforma	Grupos de administración, cinco suscripciones, Azure Policy, etiquetas, presupuestos, grupos de Entra ID, MFA, acceso condicional y PIM (#5 a #7)	Diseño de gobierno y seguridad
Despliegue de los ambientes	1 al 4 de diciembre (pruebas y desarrollo) y 14 al 18 de diciembre (hub y producción)	Equipo de plataforma	Todo desde el pipeline. Producción queda encendida al mínimo y sin usuarios hasta el día 0	Código de infraestructura y landing zone
Observabilidad	14 de diciembre al 14 de marzo	Equipo de plataforma	Azure Monitor, alertas y tableros desde el despliegue; Zabbix sigue vigilando Cali hasta el día 61	Despliegue de producción
Adaptaciones de la aplicación	2 de noviembre al 18 de diciembre (desarrollo) y 19 de diciembre al 8 de enero (pruebas)	Equipo de aplicación	Evidencias en Blob sin NFS, compatibilidad con MySQL 8.4, contenedores, columnas y borrado lógico para Fabric	Diseño de la plataforma (#12) y de Fabric (#17)
Pruebas de carga, seguridad y continuidad	28 de diciembre al 8 de enero	QA	2.000 solicitudes por minuto en el portal, WAF en modo detección y luego prevención, prueba de la réplica en Central US	Adaptaciones en pruebas y producción desplegada

Fase	Fechas	Responsable	Qué incluye	Depende de
Siembra del archivo	13 de octubre al 29 de enero	Base de datos y migración	Preparación, nueve trabajos de discos (una prueba, siete principales y el diferencial) y conciliación (#15)	Compra de discos aprobada
Convivencia: centros y telemetría	11 al 30 de enero	Equipo de plataforma	Túneles, centros uno por uno, sensores y camiones en IoT Hub, fin de la carga por lote	Día 0
Replicación de la base	16 de enero al 14 de febrero	Base de datos y migración	Carga inicial con DMS, réplica, alta disponibilidad y réplica en Central US	Día 0
Ensayo y corte	31 de enero y 14 de febrero	Líder del corte	Corte completo sobre un servidor temporal, y luego el corte real	Siembra conciliada y réplica al día
Vuelta atrás y apagado de Cali	15 de febrero al 14 de marzo	Equipo de plataforma	21 días con Cali intacta y en espera; apagado en el orden de `carga-c-migracion-y-campana.md`, sección 6.3	Corte
Microsoft Fabric, primer release	18 de enero al 12 de febrero (no productivo) y 15 de febrero al 12 de marzo (producción)	Equipo de datos e IA	Capacidades, espacios, gateway, Copy Job, accesos directos al archivo, Activator, hora estimada de llegada y fotos ilegibles	Corte (la copia lee la base de Azure)
Medición de Fabric	29 de marzo al 23 de abril	Equipo de datos e IA	Uso real de la capacidad después del primer mes; decisión de pasar a F8 fuera de campaña	Fabric en producción
Capacitación y gestión del cambio	30 de noviembre al 8 de enero (operación y guardia) y 17 al 30 de enero (usuarios clave)	Gestión del cambio	Operación de Azure, runbooks, guardia nocturna; pruebas de los usuarios clave de despacho y facturación con datos replicados; avisos a clientes	Despliegue de pruebas
Estabilización	15 de marzo al 11 de abril	Gerente de proyecto	Semana Santa sin cambios; lo pendiente se cierra del 29 de marzo al 11 de abril	Cali apagada
Cierre	12 al 30 de abril	Gerente de proyecto	Entrega a operación, ajuste de tamaños tras el primer mes (registros del firewall, Fabric), compra de	Estabilización

Fase	Fechas	Responsable	Qué incluye	Depende de
			reservas, informe de cierre y lecciones aprendidas	

---

4. Ruta crítica y holgura

4.1 La siembra es la ruta más larga

La ruta crítica es la del archivo: **preparación de la siembra → nueve trabajos de discos → conciliación → ensayo → corte → plazo de vuelta atrás → apagado de Cali**. Dura del 13 de octubre al 14 de marzo y tiene muy poca holgura:

Paso	Termina	Lo necesita	Holgura
Conciliación de la siembra	29 de enero	Ensayo del 31 de enero	2 días
Ensayo	31 de enero	Corte del 14 de febrero	Una semana de reserva (7 de febrero)
Corte	14 de febrero	Día 90 (11 de abril)	Hasta el 7 de marzo (`carga-c-migracion-y-campana.md`, sección 4.4)

Por eso la siembra arranca el 13 de octubre, un mes antes de que se apruebe el diseño completo. La compra de discos y estaciones se aprueba por separado: no depende de ninguna otra decisión del diseño y es la única fase que, si espera la aprobación del 13 de noviembre, empuja el corte más allá del 7 de marzo.

4.2 La segunda cadena: la plataforma

Código de infraestructura → despliegue de pruebas y desarrollo → adaptaciones probadas → prueba de carga → día 0.

Paso	Termina	Lo necesita	Holgura
Código de infraestructura y pipeline	27 de noviembre	Despliegue de pruebas, 1 de diciembre	3 días
Despliegue de hub y producción	18 de diciembre	Prueba de carga, 28 de diciembre	9 días
Adaptaciones en pruebas y prueba de carga	8 de enero	Día 0, 11 de enero	2 días; luego, el día 0 puede correrse hasta el 1 de febrero

Esta cadena se puede atrasar más que la siembra, porque el día 0 se corre sin romper el día 90 mientras el corte no pase del 7 de marzo. Pero durante la convivencia la base no admite cambios de esquema: cualquier adaptación que no esté lista el día 0 espera hasta después del corte.

---

5. Campañas y ventanas de cambio

Campaña	Fechas supuestas	Qué pasa en el proyecto
Fin de año	15 de noviembre de 2026 al 10 de enero de 2027	Se construye y se despliega, pero nada que use la operación: producción queda sin usuarios hasta el día 0. La siembra solo lee el servidor de archivo
Semana Santa	15 al 28 de marzo de 2027	Ningún cambio. Cali ya está apagada desde el 14 de marzo y la medición de Fabric empieza después, el 29 de marzo
Mitad de año	15 de junio al 15 de julio de 2027	Después del cierre. Es la primera campaña completa en Azure, y la capacidad de Fabric sube a F16 una semana antes si ya pasó a F8

Los cambios productivos van de 22:00 a 04:00, fuera de campaña, y los aprueba el comité de cambios con la plantilla de release notes que corresponde (aplicación o infraestructura). El pipeline bloquea el despliegue automático a producción fuera de esa ventana (#23).

Desplegar en campaña no es un cambio productivo. El despliegue de hub y producción del 14 de diciembre cae dentro de la campaña de fin de año, pero producción no tiene usuarios hasta el día 0. Las conexiones hacia Cali, que sí tocan la operación, no se abren hasta el día 0, ya fuera de campaña.

---

6. Responsables

Los responsables son roles, no personas: FríoAndes los asigna a su equipo o a un proveedor. El costo de cada rol por fase va en el costo total del proyecto (#28).

Rol	Responde por	Fases principales
Gerente de proyecto	Calendario, presupuesto, riesgos, comité de cambios, informe de cierre	Todo el proyecto
Arquitecto cloud	Diseño, coherencia entre documentos, decisiones de arquitectura y aprobación técnica de cambios	Arquitectura, costos y cambio; acompaña el ensayo y el corte
Equipo de plataforma	Código de infraestructura, pipeline, landing zone, red, firewall, observabilidad y apagado de Cali	Fase 2, despliegue, convivencia y apagado
Equipo de aplicación	Adaptaciones de los cinco contenedores y del front; pruebas funcionales	Adaptaciones, ensayo y corte
Base de datos y migración	DMS, compatibilidad con MySQL 8.4, siembra y conciliación del archivo	Siembra, replicación, ensayo y corte
QA	Pruebas de carga, de seguridad y de continuidad; criterios del ensayo	Pruebas y ensayo
Equipo de datos e IA	Capacidades y espacios de Fabric, Copy Job, Activator, hora estimada de llegada y evidencias	Fabric
Gestión del cambio	Capacitación de operación y de usuarios, avisos a despacho, calidad y clientes	Capacitación y convivencia
Líder del corte	Guion del corte, decisión de seguir o volver atrás	Ensayo y corte

---

7. Si se mueve una fecha

Si pasa esto	Qué se hace
La compra de discos no se aprueba el 13 de octubre	Cada semana de atraso mueve la conciliación una semana. Con más de una semana, el ensayo pasa al 7 de febrero y el corte al 21 (`carga-c-migracion-y-campana.md`, sección 4.4)
El diseño no se aprueba el 13 de noviembre	La construcción sigue, porque no toca la operación, pero el despliegue de pruebas se corre. Con más de tres semanas de atraso, el día 0 pasa al 18 o al 25 de enero y el corte sigue dentro del 7 de marzo
El código de infraestructura no está el 27 de noviembre	Se despliega primero lo que esté listo (red y seguridad) y el cómputo después; el despliegue de producción del 14 de diciembre tiene 9 días de holgura hasta la prueba de carga

Si pasa esto	Qué se hace
El ensayo no cumple los criterios	Se repite el 7 de febrero y el corte pasa al 21 de febrero. Cali se apaga el 29 de marzo, después de Semana Santa, y el cierre del proyecto se mantiene
El corte se atrasa más de dos semanas	El primer release de Fabric pasa a después de Semana Santa (29 de marzo al 23 de abril) y la medición de la capacidad a mayo. El cierre del proyecto se corre hasta el 28 de mayo, antes de la campaña de mitad de año

---

8. Después del cierre

Quedan fuera del proyecto y pasan a la operación o a un proyecto nuevo:

Tema	Cuándo	Documento
Segundo release de Fabric: pronóstico de temperatura y análisis de clips de video de reclamos	Después de la campaña de mitad de año	`fabric-acceso-casos-uso-costo.md`, sección 3.5
Segunda nube	Horizonte de 24 meses, cuando haya una necesidad aprobada	`red-acceso-remoto-segunda-nube.md`
Revisión de reservas y tamaños	Cada trimestre, con los datos de Cost Management	`gobierno-auditoria-facturacion.md` y `docs/costs/`
Pruebas de continuidad hacia Central US	Cada semestre	`carga-a-plataforma-logistica.md`, sección 6

---

9. Supuestos

Supuesto	Por qué se asume
El proyecto arranca el lunes 28 de septiembre de 2026	Es la semana en que empezó el diseño; el enunciado no da fecha de inicio
La Fase 1 dura cinco semanas y los costos y el cambio dos más, con aprobación el viernes 13 de noviembre	Deja la aprobación antes de la campaña de fin de año y un mes completo para construir
La compra de discos y estaciones se aprueba por separado el 13 de octubre	La siembra es la ruta crítica y no depende del resto del diseño
El código de infraestructura y la landing zone se construyen en seis semanas, del 19 de octubre al 27 de noviembre	Cuatro módulos, un pipeline y un `plan` limpio con el equipo de plataforma; el diseño de red ya fija direcciones y reglas
Las adaptaciones de la aplicación toman siete semanas en desarrollo y tres en pruebas	Son cambios acotados: evidencias en Blob, MySQL 8.4, columnas y borrado lógico para Fabric
Fabric se prepara en no productivo durante la convivencia y entra a producción después del corte	La copia de la base lee la base de Azure, que solo es la principal desde el corte
El proyecto se cierra el 30 de abril de 2027, tres semanas después del día 90	Tiempo para entregar a operación, ajustar tamaños con el primer mes de datos y documentar
Los responsables son roles, no personas	FríoAndes decide si los cubre su equipo o un proveedor; el costo por rol va en #28

Anexo. Registro de supuestos

Registro de supuestos

Supuestos que no están en el enunciado y que tomó el equipo al diseñar la plataforma. Cada historia agrega sus filas.

Supuesto	Justificación	Issue que lo originó	Estado
Cinco suscripciones (seguridad, conectividad, producción, pruebas y desarrollo) bajo `mg-frioandes`, con una rama de plataforma y otra de cargas, y los nombres propuestos en el diseño	FríoAndes no tiene una estructura previa en Azure; separa seguridad, red y ambientes sin multiplicar directorios	#5	Asumido en el diseño
Las regiones autorizadas para recursos regionales son East US 2 y Central US, con excepciones justificadas para servicios globales	Son las regiones que fija el diseño de red; la política P-02 las hace cumplir	#5	Asumido en el diseño
Cada suscripción tiene un presupuesto mensual con alertas al 80 %, 100 % y 120 % del gasto real y al 100 % del previsto; las alertas avisan y nunca apagan recursos de despacho ni de telemetría	Decisión inicial mientras FríoAndes no tenga una política de FinOps; los montos salen del documento de costos	#5	Por confirmar con el cliente
Desarrollo y pruebas se etiquetan `costo=pruebas`, aunque allí se pruebe telemetría	Evita contar el mismo recurso como telemetría productiva y como pruebas	#5	Asumido en el diseño
La pista de auditoría de accesos a datos de clientes, evidencias y lecturas de temperatura se conserva cinco años en total, con 90 días consultables	El contrato fija cinco años para las evidencias; extenderlo a los registros de acceso es una decisión de diseño para poder reconstruir un reclamo	#6	Por confirmar con el cliente
Lo compartido (red y seguridad) se reparte cada mes en proporción a los costos directos de operación y telemetría, como showback	Criterio inicial, a falta de una regla de FinOps de FríoAndes	#6	Por confirmar con el cliente
FríoAndes define el responsable de auditoría, las personas autorizadas y el procedimiento de conservación por litigio	Son decisiones de la empresa, no de la plataforma	#6	Por confirmar con el cliente
Los clientes corporativos entran al portal como invitados B2B del tenant corporativo, sin roles de Azure, y el administrador de	Evita un segundo tenant para clientes; depende del sistema de identidad real de los clientes y de las licencias	#7	Por confirmar con el cliente

Supuesto	Justificación	Issue que lo originó	Estado
cada cliente aprueba sus altas y bajas			
El cifrado administrado por Azure es la base; los almacenes de evidencia contractual usan clave administrada por FríoAndes y la base solo si FríoAndes lo exige	La clave propia agrega dependencia de disponibilidad y costo de operación de Key Vault	#7	Por confirmar con el cliente
Los accesos productivos y los invitados se revisan cada trimestre, y la baja es inmediata al terminar el empleo o el contrato	Práctica de mínimo privilegio sin política previa de FríoAndes	#7	Asumido en el diseño
El acceso administrativo remoto es Azure Bastion Standard en el hub; la VPN de usuario queda como alternativa futura	Da sesiones a máquinas concretas sin abrir la red de despacho a los equipos remotos	#11	Asumido en el diseño
La segunda nube se conecta al mismo hub, con el DNS Private Resolver y el tenant de Entra ID actuales; el proveedor y las cargas se deciden cuando haya una necesidad aprobada	El enunciado da un horizonte de 24 meses sin proveedor	#11	Por confirmar con el cliente
La cantidad de administradores simultáneos, sus herramientas y sistemas operativos caben en Bastion Standard y dos máquinas de administración por ambiente	No hay inventario de administradores ni de herramientas	#11	Por confirmar con el cliente
La base relacional es MySQL 8.4 LTS en Flexible Server	Es la serie con soporte extendido vigente; MySQL 8.0 ya no tiene soporte de la comunidad	#12	Asumido en el diseño
Los entornos de Container Apps de Central US quedan apagados hasta que el runbook de continuidad los activa	Cumple el RTO de 4 horas sin pagar un segundo entorno encendido	#12	Por confirmar con el cliente
Cómo se redirige el tráfico del portal en una conmutación regional (DNS manual, Front Door o Traffic Manager) y quién ejecuta el runbook lo decide FríoAndes	Cambia cómo se cumple el RTO y si hace falta un servicio adicional	#12	Por confirmar con el cliente
La asignación de muelle y ruta sigue siendo una decisión de la torre; la hora estimada de llegada de IA es una entrada, no un reemplazo	Ningún modelo de IA decide el despacho por sí solo	#12	Asumido en el diseño
El firewall de Cali es un solo equipo; la contingencia (segundo equipo, VPN de	El enunciado describe un único firewall en Cali; dos	#8	Por confirmar con el cliente

Supuesto	Justificación	Issue que lo originó	Estado
usuario o aceptar el riesgo) la decide FríoAndes	proveedores no protegen contra su falla		
Cali contrata un segundo proveedor de internet por una ruta física distinta, sin compartir última milla, ducto ni nodo, usado como respaldo (activo-pasivo)	El enunciado pide ruta redundante para Cali; es la opción más barata y rápida frente a ExpressRoute	#8	Decidido en el diseño; el cliente confirma proveedor y ruta
Los equipos de red de los centros soportan IKEv2, dos túneles simultáneos y BGP	Permite conectar cada centro directo a Azure con conmutación automática; si no, se usa túnel activo y de respaldo con rutas fijas	#8	Por confirmar con el cliente
Una VPN de usuario con Entra ID y MFA podría contar como red corporativa para usar la torre de control	Es una de las opciones de contingencia si cae el firewall de Cali	#8	Por confirmar con el cliente
Los camiones envían su telemetría a un endpoint público de IoT Hub, con una credencial por camión	Los camiones no tienen subred corporativa y salen por la red móvil del operador	#8	Por confirmar con el cliente
Pruebas y desarrollo publican su portal solo a orígenes autorizados, sin entrada pública abierta	No manejan datos reales ni usuarios externos	#8	Por confirmar con el cliente
Se acepta sembrar el archivo de 1,2 PB con Azure Import/ Export (discos propios enviados a Microsoft)	Data Box Heavy está retirado y Data Box no se envía a Colombia; por la red tomaría unos 278 días	#8	Dimensionado en la siembra (#15): 71 discos en 9 trabajos; por confirmar con el cliente y con Microsoft
El video y las fotos de evidencias después de la migración se generan en sitios que no saturan la VPN de ninguna sede	Define por dónde llegan los unos 12 TB al mes	#8	Por confirmar con el cliente
Es aceptable que los datos y el procesamiento queden en Estados Unidos (East US 2 y Central US)	La medición de latencia confirmó East US 2; FríoAndes maneja datos personales sujetos a la Ley 1581	#8	Por confirmar con el cliente
El segundo proveedor cuesta unos COP 3.000.000 al mes por 200 Mbps	No hay cotización; es un valor de referencia del mercado para ese tamaño de enlace	#8	Asumido en el diseño
Cada usuario genera unos 300 Kbps de tráfico hacia la plataforma	Se usa para comparar la carga del enlace de Cali con y sin los centros pasando por la sede	#8	Asumido en el diseño
Los cambios por centro se hacen en la ventana de 22:00 a 04:00, uno o dos centros por noche, con un piloto primero	El despacho diurno no puede detenerse	#8	Asumido en el diseño
Plan de ASN: Azure 65515, Cali 65020, centros 65031 a 65038	Valores privados que no chocan entre sí y se leen fácil	#8	Asumido en el diseño

Supuesto	Justificación	Issue que lo originó	Estado
Máximos de capacidad usados para los tamaños: Application Gateway hasta 10 instancias, base de datos con 2 réplicas y 1 servidor temporal, hasta 10 endpoints por subred, hasta 11 miembros del gateway de Fabric	Una subred no se puede agrandar con recursos dentro; se dimensiona para el máximo con margen	#8	Asumido en el diseño
Unas 60 personas de desarrollo y operación trabajan fuera de la sede	Define el tamaño de la reserva para VPN de usuario	#8	Asumido en el diseño
La plataforma de aplicación es Container Apps con perfiles de carga, con un máximo de 20 nodos dedicados y 200 réplicas por entorno	Se confirma con el diseño de la plataforma logística. Si fuera AKS, aplica la sección 7.3	#8	Asumido en el diseño
Cada mensaje de telemetría pesa alrededor de 1 KB	Se usa para estimar el volumen de los dos caminos	#8	Asumido en el diseño
La copia continua del archivo mueve unos 12.154 GB al mes (37 Mbps)	Sale del crecimiento de 12 TB al mes que indica el reto	#8	Asumido en el diseño
El portal se publica con Application Gateway v2 y WAF, el firewall de nube es Azure Firewall Standard y el acceso administrativo es Azure Bastion	El portal y el firewall quedaron confirmados en el diseño del firewall de nube (#9). El acceso administrativo se confirma con el diseño del acceso remoto	#8	Portal y firewall decididos; acceso remoto por confirmar
La migración en línea de la base usa una cuenta de almacenamiento con token SAS temporal	El servicio de migración no admite una cuenta restringida a la red virtual; se confirma con el diseño de la migración	#8	Confirmado en el diseño de la migración (#14): DMS usa la cuenta hasta el corte
Una diferencia de latencia menor al 30 % no justifica cambiar de región	La plataforma es una consola web, un portal y alertas con margen de 60 segundos; 10 a 30 ms no cambian la experiencia	#8	Asumido en el diseño
El plazo de vuelta atrás después del corte dura como máximo hasta el día 90 y lo fija el plan de migración	Mantener el camino de vuelta no cuesta más en la red; define cuándo se retiran las reglas temporales, el NAT del portal y la VPN de los centros hacia Cali	#9	El diseño de la migración (#14) lo fija en 21 días, del 14 de febrero al 7 de marzo de 2027; por confirmar con el cliente
FríoAndes exporta la política real del firewall de Cali antes del inicio de la convivencia	Las políticas actuales del diseño son deducidas del inventario de redes y de las cargas descritas	#9	Por confirmar con el cliente
Los centros envían los históricos de temperatura por FTP pasivo al servidor de archivo de Cali	El enunciado dice que se cargan por lote cada hora y que ese servidor ofrece FTP y NFS; define la regla temporal FW-402	#9	Por confirmar con el cliente

Supuesto	Justificación	Issue que lo originó	Estado
El plan de vuelta atrás puede replicar los datos de Azure hacia la base de Cali después del corte	Si no se usa, la regla temporal FW-505 y su pareja en el NSG no se crean	#9	Descartado en el diseño de la migración (#14): MySQL no replica de 8.4 hacia 5.7. FW-505 y su pareja se retiraron de la tabla
La integración entre los servidores de Cali y la plataforma nueva usa solo HTTPS (443)	Es la base de las reglas temporales FW-503 y FW-504	#9	Por confirmar con el cliente
La respuesta media del portal pesa unos 150 KB	Define la capacidad del Application Gateway (20 unidades reservadas en producción); se confirma con la prueba de carga antes del corte	#9	Asumido en el diseño
Cada unidad de cómputo del WAF atiende unas 10 solicitudes por segundo	Referencia de Microsoft para WAF v2; depende del tamaño de las solicitudes y se confirma con la prueba de carga	#9	Asumido en el diseño
El equipo que prueba la torre en pruebas y desarrollo trabaja desde Cali o con el acceso remoto definido	Por eso solo los usuarios de Cali llegan a la torre de esos ambientes	#9	Asumido en el diseño
Pruebas y desarrollo usan datos de sensores simulados	No se llevan datos reales a ambientes con menos controles; los sensores reales solo llegan a producción	#9	Asumido en el diseño
El volumen de registros del firewall, del WAF y de flujos se mide en el primer mes de operación	No hay tráfico real para estimarlo; con ese dato se decide qué tablas pasan al plan Basic	#9	Asumido en el diseño
El minuto de la alerta se cuenta desde la hora en que el sensor mide hasta que la alerta se ve en pantalla	Con lecturas cada 60 s en los camiones, contarlo desde el cruce real del límite no lo cumple ninguna arquitectura	#13	Por confirmar con el cliente
Los equipos de los camiones hablan MQTT o AMQP con TLS, soportan certificados X.509 y guardan al menos 18 horas de lecturas sin señal	Permite la identidad por camión con DPS y no perder lecturas en un corte de señal	#13	Por confirmar con el cliente
Los sensores de los cuartos fríos se conectan directo, sin un equipo del centro que los reúna	Si son antiguos, se agrega un recolector con IoT Edge por centro, sin cambiar la red	#13	Por confirmar con el cliente
Una puerta abierta alerta a los 5 minutos en los cuartos fríos y a los 15 en los camiones	El enunciado no da el tiempo. Calidad lo ajusta en la tabla de referencia	#13	Por confirmar con el cliente
FríoAndes usa Microsoft 365 y Teams	Teams es el canal principal de la torre y de la guardia de noche	#13	Por confirmar con el cliente
FríoAndes contrata un proveedor de SMS con cobertura en Colombia	Azure Communication Services no envía SMS directo a Colombia; sus	#13	Por confirmar con el cliente

Supuesto	Justificación	Issue que lo originó	Estado
	dominios completan FW-319 a FW-321		
Cada cuarto frío registra unas dos aperturas de puerta por hora y cada camión unas diez paradas al día	El enunciado no da la cifra; aunque fuera diez veces mayor, seguiría siendo una parte menor del volumen	#13	Asumido en el diseño
Un equipo por camión envía temperatura, posición y puerta, en una jornada de 18 horas	Define las identidades en IoT Hub y el volumen de los camiones	#13	Asumido en el diseño
El objetivo de la alerta es el 99 % de las alertas visibles en 60 segundos o menos, medido en 28 días	Propuesta del diseño de telemetría; el valor definitivo lo fija el diseño de observabilidad	#13	Asumido en el diseño
Stream Analytics trabaja con 1/3 de unidad de streaming en producción	Lo confirma la prueba de carga de campaña en pruebas, que arranca con 1 unidad	#13	Asumido en el diseño
Las operaciones de la cuenta de almacenamiento de la función notificadora se miden en pruebas	Dependen de cómo trabaja Durable Functions con el volumen real de alertas	#13	Asumido en el diseño
Los datos personales de conductores y destinatarios pueden quedar en Estados Unidos	Microsoft los trata como encargado (transmisión con contrato) y Estados Unidos está en la lista de países adecuados de la SIC. Si no se acepta, la alternativa es otra región de un país de la lista, como México	#10	Por confirmar con el cliente
Los campos de cada titular son los que necesita la operación (nombre, documento, licencia, teléfono, dirección, firma, imagen, posición)	El enunciado no enumera los campos; se deducen de despachar, entregar y responder reclamos	#10	Por confirmar con el cliente
El cliente corporativo ve el comprobante y las fotos de sus propias entregas	Los necesita para sus reclamos; nunca ve la flota, la posición exacta, el video ni los datos del conductor	#10	Por confirmar con el cliente
Los contratos con los clientes corporativos incluyen que ellos obtienen la autorización de los destinatarios para compartir sus datos	FríoAndes es responsable de esos datos, pero el dato inicial llega en la guía que crea el cliente	#10	Por confirmar con el cliente
La adenda de protección de datos de Microsoft cubre lo que exige el artículo 25 del Decreto 1377	Es la base de la transmisión a Estados Unidos sin autorización expresa de cada titular	#10	Por confirmar con el cliente
Ningún cliente corporativo genera más del 10 % del pico de campaña (unas 200 solicitudes por minuto desde su IP)	Define los umbrales de límite del WAF; se ajusta con la prueba de carga y el primer mes	#10	Asumido en el diseño

Supuesto	Justificación	Issue que lo originó	Estado
Cada usuario del portal hace hasta 60 solicitudes por minuto y cada cliente hasta 200	Valores iniciales del límite por cuenta en la aplicación	#10	Asumido en el diseño
Las fotos y comprobantes van en una cuenta de almacenamiento separada del video, y suman unos 1.138 GB al mes	Permite escanear malware solo en esos archivos; la proporción sale del archivo actual (110 TB de fotos frente a 1,05 PB de video)	#10	Confirmado en la siembra (#15): cuenta de documentos (Cool, GRS) y cuenta de video (Cold, LRS)
Defender cobra por separado cada servidor MySQL (principal y dos réplicas) y hay 2 máquinas de administración en producción	Define el costo de Defender for Cloud; se confirma con la primera factura	#10	Asumido en el diseño
Ningún componente identifica personas por su rostro	Si un uso lo hiciera, las imágenes serían datos biométricos con autorización especial (Ley 1581, artículo 6)	#10	Asumido en el diseño
Las campañas van del 15 de noviembre al 10 de enero, del 15 al 28 de marzo de 2027 (Semana Santa) y del 15 de junio al 15 de julio	El enunciado nombra las tres campañas sin fechas; durante ellas no hay cambios productivos	#14	Por confirmar con el cliente
La convivencia empieza el lunes 11 de enero de 2027, el corte es el domingo 14 de febrero y Cali se apaga el domingo 14 de marzo (día 62)	Es la primera fecha libre de campaña con tiempo para preparar, y termina antes de Semana Santa. El corte no puede pasar del 7 de marzo	#14	Por confirmar con el cliente
La base de producción pesa menos de unos 400 GB	Es el tamaño que la carga inicial de DMS copia en una ventana de 6 horas con la mitad del enlace; si pesa más, usa el fin de semana	#14	Por confirmar con el cliente
La base de producción de Cali necesita activar el registro binario en formato ROW, con un reinicio corto el día 1	DMS en línea lo exige; si ya está activo, se evita el reinicio	#14	Por confirmar con el cliente
Una réplica de rastreo de 1 vCPU atiende 15 solicitudes por segundo	Define 2 réplicas normales y 4 en campaña en el portal; se confirma con la prueba de carga	#14	Asumido en el diseño
El +40 % de campaña se aplica a los servicios del entorno de la torre de 04:00 a 22:00, con una regla de escalado por calendario configurada antes de cada campaña	La torre no se usa de noche y durante la campaña no se hacen cambios	#14	Asumido en el diseño
El plazo de vuelta atrás dura 21 días y después del punto de no retorno volver a Cali exige recargar lo creado en Azure con una exportación de la aplicación	No hay replicación de 8.4 hacia 5.7; el plazo cubre el primer cierre de facturación en Azure	#14	Por confirmar con el cliente

Supuesto	Justificación	Issue que lo originó	Estado
Entre el arranque de DMS y el corte no se cambia el esquema de la base de Cali	DMS no replica cambios de esquema hacia un destino 8.4	#14	Asumido en el diseño
La aplicación tiene un modo de mantenimiento que la deja en solo lectura, y evidencias pasa a leer y escribir en Blob Storage antes del día 0	Son adaptaciones pedidas al equipo de desarrollo: el corte detiene escrituras sin apagar el servicio, y Container Apps no monta Blob Storage	#14	Por confirmar con el cliente
El ensayo del corte usa el servidor temporal reservado en snet-data de producción y se borra al terminar	Usa datos personales reales, que pruebas no lleva	#14	Asumido en el diseño
Las evidencias solo llegan al archivo a través del contenedor evidencias, no por FTP directo	Si alguien sube por FTP, ese flujo también cambia de destino en el corte	#14	Por confirmar con el cliente
Las cuentas del archivo no usan NFS 3.0 ni espacio de nombres jerárquico	Import/Export no admite NFS 3.0, y sin NFS Azure permite la inmutabilidad que pide #6. evidencias ya no lo necesita (#14)	#15	Decidido en el diseño
Los discos son HDD de 20 TB, 3,5" SATA III con formato 512e, y se llenan hasta 18 TB	Cumplen los requisitos de Import/Export; el 10 % queda para el sistema de archivos y la herramienta	#15	Asumido en el diseño
El servidor de archivo entrega 250 MB/s en horario de despacho y 500 MB/s de noche sin degradar a evidencias, unos 27 TB al día	No hay datos del servidor; se mide la primera semana de copia	#15	Por confirmar con el cliente
El envío tarda 7 días puerta a puerta con aduana y Microsoft carga los discos en 10 días	Microsoft no publica tiempos; se mide con el disco de prueba antes del primer envío grande	#15	Por confirmar con Microsoft y el transportador
T0 es el 2 de noviembre de 2026 y T1 el 4 de enero de 2027: lo anterior a T0 va en los discos principales, lo de T0 a T1 en un envío de diferencial y lo posterior por la red desde el día 0	Los túneles hacia Azure llegan el día 0; por la red, 25 TB más el crecimiento tardarían más de un mes en ponerse al día	#15	Asumido en el diseño
El video queda en LRS y los documentos e históricos de temperatura en GRS	El video es el 88 % del volumen; en Cold, GRS costaría unos USD 4.650 más al mes	#15	Por confirmar con el cliente
La inmutabilidad de lo sembrado se fija por versión, hasta la fecha original de cada archivo más cinco años; lo que ya pasó los cinco años no se bloquea	Un archivo importado tiene como fecha de creación la de la importación, no la original	#15	Asumido en el diseño
Durante la siembra las cuentas del archivo aceptan la excepción de servicios de	Import/Export escribe por esa excepción, que Azure no	#15	Asumido en el diseño

Supuesto	Justificación	Issue que lo originó	Estado
confianza de Microsoft, sin redes ni IP permitidas; al terminar, el acceso público se desactiva del todo	admite con el acceso público desactivado		
La copia continua la hace un agente con AzCopy en la red del archivo de Cali, por HTTPS y con una entidad de servicio con certificado que vence el día 90	Leer el NFS desde Azure por la VPN sería lento con 90 ms de latencia y 110 millones de archivos	#15	Asumido en el diseño
Las dos cuentas del archivo de producción existen antes del 20 de octubre de 2026	Un trabajo de importación necesita su cuenta; son la primera pieza de producción del código de infraestructura	#15	Por confirmar con el equipo de infraestructura
WAImportExport funciona en Windows Server 2022	La lista oficial de sistemas es antigua; si no funciona, se usa Windows 10 Enterprise aislada	#15	Asumido en el diseño
El portal de rastreo tiene como objetivo 99,9 % de minutos buenos en 28 días, sin contar los mantenimientos aprobados y avisados a los clientes	Un minuto es malo si más del 1 % de las respuestas del Application Gateway son 5xx o si la prueba de disponibilidad falla en 3 de 5 ubicaciones; el corte se avisa con siete días	#16	Por confirmar con el cliente
La alerta de temperatura tiene como objetivo 99 % visible en 60 segundos o menos en 28 días, contando alertas reales y sintéticas y excluyendo las lecturas que tardaron más de 25 segundos del sensor a IoT Hub	El resto del camino tiene un presupuesto de 35 segundos; las sintéticas dan datos aunque haya pocas excursiones	#16	Por confirmar con el cliente
FríoAndes tiene una guardia de plataforma con rotación que atiende las alertas críticas de noche	La guardia de calidad atiende la temperatura, no la plataforma; solo recibe un aviso si falla el camino de la alerta	#16	Por confirmar con el cliente
Los relojes de los sensores y de los equipos de los camiones se sincronizan por NTP	La exclusión del objetivo de la alerta usa la hora del sensor	#16	Por confirmar con el cliente
Zabbix vigila hoy los 14 servidores, VMware, el firewall de Cali y la VPN con los centros	Se deduce del datacenter; se concilia con la exportación de su configuración antes del día 0	#16	Por confirmar con el cliente
Después del día 61 la salud del firewall de Cali la vigila el equipo de redes con la herramienta del fabricante, y sus túneles Azure Monitor	No queda ningún servidor ni herramienta de monitoreo en Cali	#16	Por confirmar con el cliente
Tráfico promedio: 300 usuarios activos en la torre con 2 solicitudes por minuto y 200 solicitudes por minuto en	El caso solo da los picos del portal; define el costo de la observabilidad y se mide el primer mes	#16	Asumido en el diseño

Supuesto	Justificación	Issue que lo originó	Estado
el portal durante 18 horas, con 4 registros de 1 KB por solicitud			
Las tablas del libro operativo que alimentan las vistas de Fabric tienen clave primaria y admiten una columna de última modificación y borrado lógico	Copy Job copia lo nuevo y cambiado por marca de agua y hace merge por clave; el conector de MySQL no tiene captura de cambios	#17	Por confirmar con el cliente
La ubicación del punto de entrega es el único dato personal que se copia a Fabric	La hora estimada de llegada la necesita; nombres, teléfonos, documentos y direcciones escritas quedan fuera	#17	Decidido en el diseño
Fabric lee cada día las fotos y comprobantes nuevos y los clips de reclamos abiertos; del archivo no copia nada	Es lo que piden los usos de IA; copiar el video a OneLake costaría unos USD 24.150 al mes	#17	Decidido en el diseño
La región principal del tenant de Fabric queda en un país de la lista de la SIC	Ahí quedan permisos, metadatos de reportes y credenciales cifradas, aunque la capacidad esté en East US 2	#17	Por confirmar con el cliente
Las capacidades de Fabric quedan en East US 2, en `sub-fa-prod` y `sub-fa-dev`, con la línea de costo de Fabric	Es la región de todas las fuentes; no hay transferencia entre regiones	#17	Decidido en el diseño
Los administradores de Fabric son dos personas del equipo de datos e IA, con PIM	Azure solo acepta usuarios del tenant como administradores de una capacidad	#17	Por confirmar con el cliente
Unas 40 personas crean o ven reportes internos de Fabric y necesitan licencia Pro	Calidad, guardia, líderes de torre y calidad y equipo de datos; los despachadores ven la IA en la consola y los clientes en el reporte insertado	#18	Por confirmar con el cliente
La base registra la hora real de llegada a cada parada	La hora estimada de llegada se calcula con los tiempos reales por tramo	#18	Por confirmar con el cliente
`fcfaprod` usa unos 8,2 CU en mes normal y 10,7 en campaña, con Spark nocturno dentro, y arranca en F16	Estimado con las tasas publicadas de Eventstream, Activator, Copy Job y gateway, más reservas para reportes y funciones de IA; se mide el primer mes	#18	Asumido en el diseño
El gateway de red virtual consume 4 CU mientras está encendido	Blog oficial de Fabric; Learn no publica la tasa; se confirma con la app de métricas	#18	Asumido en el diseño
El cuaderno de Python consume a la tasa de Spark por vCore	Microsoft no publica una tasa propia	#18	Asumido en el diseño

Supuesto	Justificación	Issue que lo originó	Estado
Calidad fija un margen de aviso por tipo de carga y por cuarto frío	Activator compara la temperatura con el umbral de aviso de cada sensor	#18	Por confirmar con el cliente
Unos 102 días de campaña al año, con una semana previa en F16	Calendario supuesto del plan de migración; define cuántos meses puede estar `fcfaprod` en F8	#27	Por confirmar con el cliente
OneLake guarda unos 90 GB	Vistas del libro operativo hasta 80 GB, eventos de Activator de 30 días y tablas curadas	#27	Asumido en el diseño
Los registros de los modelos son unos 10 GB al mes (25 en campaña)	Sin dato de uso; se mide con la tabla de uso de Log Analytics	#27	Asumido en el diseño
Se reservan 8 CU de Fabric por un año	Es el piso de `fcfaprod`; uno y tres años cuestan lo mismo por mes	#27	Decidido en el diseño
El sobreconsumo de la capacidad queda activo con umbral del 10 %	Red de seguridad con tope de unos USD 631 al mes; Microsoft lo activa por defecto al 25 %	#27	Decidido en el diseño
El costo recurrente empieza el día del corte (14 de febrero de 2027) y el mes estable en marzo de 2027, con Cali apagada	Sigue la regla de #25: lo anterior al corte es costo de la migración, sin contar dos veces	#26	Asumido en el diseño
El 1,2 PB se acumuló parejo en unos 100 meses al ritmo actual: el 60 % tiene menos de cinco años y el 40 % más	1,2 PB a 12 TB al mes son unos 8 años; cuadra con los 110 TB de fotos que crecen 1,1 TB al mes	#26	Por confirmar con el cliente
Lo de más de cinco años se guarda durante los cinco años del presupuesto	Es el escenario más caro mientras FríoAndes no responda si se puede borrar (pregunta 1)	#26	Por confirmar con el cliente
El archivo crece 12 TB al mes durante cinco años (1,1 de documentos y 10,9 de video), y los históricos de temperatura dejan de crecer	Es el crecimiento del enunciado; la temperatura pasa a IoT Hub	#26	Asumido en el diseño
La fecha original de lo sembrado es una etiqueta de índice por archivo, que Azure cobra cada mes	Es lo que diseña la siembra (#15, sección 4.3); se propone pasarla a metadato	#26	Asumido en el diseño
La salida de Azure hacia los usuarios se calcula con 450 usuarios, la mitad conectados durante 18 horas, a 300 Kbps	Es el valor de la red y de #25; es un techo que se mide el primer mes	#26	Por confirmar con el cliente
El portal recibe 6,7 millones de solicitudes al mes de unos 100 KB, con réplicas de consumo de 1 vCPU y 2 GiB	Las solicitudes vienen de la observabilidad (#16); respuesta y réplica se confirman en la prueba de carga	#26	Asumido en el diseño

Supuesto	Justificación	Issue que lo originó	Estado
La auditoría ingiere unos 18 GB al mes, con 90 días consultables y cinco años de retención a largo plazo	El diseño de auditoría (#6) fija la retención pero no el volumen	#26	Asumido en el diseño
Cada ambiente tiene un ejecutor del pipeline B2s en `snet-admin`, y hay un registro de contenedores Premium	Lo piden el diseño de automatización y el acceso privado a las imágenes	#26	Asumido en el diseño
El sobrecosto de campaña se calcula con un pico de 4 horas por día de campaña y 102 días de campaña al año; el presupuesto usa la regla de calendario de la torre de 04:00 a 22:00	El enunciado da unas 4 horas; la regla es la que configura #14	#26	Asumido en el diseño
El segundo proveedor de internet de Cali se queda después del apagado	Es la ruta redundante de la sede hacia la torre	#26	Asumido en el diseño
Todos los roles del proyecto usan la tarifa promedio de COP 120.000 por hora, y un año de tiempo completo son 1.920 horas	Es la tarifa de #25, que el issue pide mantener; 48 semanas de 40 horas	#28	Por confirmar con el cliente
Las horas por rol salen de personas × semanas × dedicación en las fases del cronograma, sin las 828 horas que ya cuenta #25	No hay un plan detallado por equipo; así no se cuenta nada dos veces	#28	Asumido en el diseño
Los costos únicos nuevos llevan una contingencia del 15 %; la migración conserva la suya	Horas sin plan detallado, cursos y partner sin cotizar	#28	Asumido en el diseño
La capacitación son 10 cupos de curso a USD 1.200, exámenes a USD 165, y sesiones para operación, usuarios clave y los 450 usuarios internos	Referencia sin cotización	#28	Por confirmar con el cliente
Un partner de Microsoft revisa el diseño y acompaña el ensayo, el corte y el primer mes: 96 horas a USD 100	Segunda mirada en los momentos de más riesgo; sin cotización	#28	Por confirmar con el cliente
FríoAndes no tiene Entra ID P1: se compran P1 para 435 usuarios internos y P2 para 15 administradores y aprobadores	El acceso condicional exige P1 por usuario y PIM exige P2; con Microsoft 365 E3 o E5 la línea casi desaparece	#28	Por confirmar con el cliente
El plan de soporte de Azure es Standard	Respuesta en menos de una hora para casos críticos, las 24 horas	#28	Asumido en el diseño
La plataforma la operan 2 personas de tiempo completo repartidas en cinco roles, desde marzo de 2027	Servicios administrados: el trabajo es de cambios, accesos, costos y respuesta	#28	Asumido en el diseño

Supuesto	Justificación	Issue que lo originó	Estado
La guardia de la plataforma paga la disponibilidad al 10 % de la hora, con unos 24 incidentes al año a 1,6 veces la hora	Referencia sin política de FríoAndes; los recargos son los de la Ley 2466 de 2025	#28	Por confirmar con el cliente
Los precios se mantienen constantes en los cinco años del costo total de propiedad	Sin inflación ni cambios de precio; se revisa cada año con Cost Management	#28	Asumido en el diseño
La comparación con Cali queda como umbral: Azure cuesta menos en cinco años si Cali cuesta más de USD 29.796 al mes, sin su equipo de operación	El enunciado no da el costo de Cali	#28	Por confirmar con el cliente
Las notas de versión se aprueban al menos dos días hábiles antes de la ventana; un corte o un cambio que no se deshace con un `apply`, con al menos cinco días y, si es un corte, después de su ensayo	Da tiempo a revisar el `plan` y a avisar a despacho, calidad y clientes. Cinco días y no una semana porque la reserva del ensayo del corte es el 7 de febrero y el comité aprueba el lunes 8 (`carga-c-migracion-y-campana.md`, sección 5.6)	#29	Asumido en el diseño
Producción tiene un cliente de verificación con guías sintéticas para las pruebas de humo de las salidas del portal	Permite probar una revisión nueva sin datos personales reales	#29	Por confirmar con el cliente
Las revisiones anteriores de Container Apps se mantienen activas siete días después de una salida	La vuelta atrás es mover el tráfico, en minutos, sin desplegar de nuevo	#29	Asumido en el diseño
A los clientes corporativos se les avisa antes solo si el portal se interrumpe; si no, se les avisa de la novedad cuando ya está en servicio	Evita avisos de mantenimiento que no afectan al cliente	#29	Asumido en el diseño
Lo que no se deshace con un `apply` lleva una aprobación adicional de la gerencia de FríoAndes	`automatizacion-devops.md` pide una aprobación adicional sin decir de quién	#30	Por confirmar con el cliente
Los cambios de Azure del corte van en dos `plan` aprobados: réplicas a la 01:40 y retiro de lo temporal de la migración a las 03:10, solo si se sigue	Separa lo que se revierte con un `apply` de lo que se borra	#30	Asumido en el diseño
El registro interno de la torre vive en el DNS de Cali y lo cambia el equipo de red en el corte	Es el DNS que usan hoy Cali y los centros	#30	Por confirmar con el cliente
Solo cuenta como cambio sujeto a la ventana lo que modifica producción o el hub; la observación, las decisiones, los avisos, las aprobaciones y lo que se hace en pruebas no	La regla del enunciado y el bloqueo del pipeline se refieren a cambios productivos	#31	Asumido en el diseño

Supuesto	Justificación	Issue que lo originó	Estado
Una vuelta atrás o una corrección entre las 04:00 y las 22:00 se trata como excepción por incidente; si puede esperar, va en la ventana siguiente	El pipeline no distingue un `apply` de avance de uno de vuelta atrás; sin esta regla, la vuelta atrás sería una puerta para cambiar de día	#31	Asumido en el diseño
El ensayo del corte sobre el servidor temporal de producción respeta la ventana como cualquier cambio en producción	Está en la subred de datos de producción y usa el mismo DMS	#31	Asumido en el diseño
Es costo de la migración todo lo que se paga antes del corte del 14 de febrero de 2027, más los costos únicos de la migración; desde el corte el costo es recurrente	Separa con una fecha el costo de la migración y el mensual, sin contar dos veces	#25	Asumido en el diseño
Pruebas y desarrollo se despliegan el 1 de diciembre de 2026, y el hub y producción el 14 de diciembre	Dejan tiempo para probar adaptaciones y carga de campaña antes del día 0	#25	Asumido en el diseño
La base de producción es MySQL Flexible General Purpose de 4 vCores con 512 GB, y pruebas y desarrollo usan Burstable B2s con 64 GB	Alcanza para 450 usuarios internos y 33 solicitudes por segundo en campaña; se confirma con la prueba de carga	#25	Asumido en el diseño
Azure Bastion es Standard, con las 2 instancias incluidas	Lo decide el diseño del acceso remoto (#11)	#25	Decidido en el diseño
180 de los 450 usuarios internos trabajan en los centros	Define el tránsito por Azure hacia la torre de Cali antes del corte	#25	Por confirmar con el cliente
El equipo cuesta COP 120.000 por hora, con recargo nocturno del 35 % y dominical del 90 % (Ley 2466 de 2025)	Tarifa promedio de referencia; los recargos son los vigentes desde julio de 2026	#25	Por confirmar con el cliente
Los pesos se convierten a 3.311 por dólar	Es la tasa implícita del diseño de red (COP 3.000.000 = USD 906)	#25	Asumido en el diseño
La migración lleva una contingencia del 15 %	Cubre discos y envío sin cotizar, la velocidad real de la siembra y un posible segundo ensayo	#25	Asumido en el diseño
El proyecto arranca el lunes 28 de septiembre de 2026 y se cierra el viernes 30 de abril de 2027, tres semanas después del día 90	El enunciado no da fechas de inicio ni de cierre; el cierre deja tiempo para entregar a operación y ajustar tamaños con el primer mes de datos	#19	Asumido en el diseño
El diseño y el presupuesto se aprueban el viernes 13 de noviembre de 2026	Deja la aprobación antes de la campaña de fin de año y un mes completo para construir	#19	Por confirmar con el cliente

Supuesto	Justificación	Issue que lo originó	Estado
La compra de discos y estaciones de la siembra se aprueba por separado el 13 de octubre de 2026	La siembra es la ruta crítica: la conciliación termina dos días antes del ensayo	#19	Por confirmar con el cliente
El código de infraestructura, el pipeline y la landing zone se construyen del 19 de octubre al 27 de noviembre de 2026	Cuatro módulos, un pipeline y un `plan` limpio; el diseño de red ya fija direcciones y reglas	#19	Asumido en el diseño
Las adaptaciones de la aplicación toman siete semanas en desarrollo y tres en pruebas	Son cambios acotados: evidencias en Blob, MySQL 8.4, columnas y borrado lógico para Fabric	#19	Asumido en el diseño
Fabric se prepara en no productivo durante la convivencia y entra a producción después del corte, antes de Semana Santa	La copia de la base lee la base de Azure, que solo es la principal desde el corte	#19	Asumido en el diseño
Los responsables del cronograma son roles (gerente de proyecto, arquitecto, plataforma, aplicación, base de datos, QA, datos e IA, gestión del cambio, líder del corte)	FríoAndes decide si los cubre su equipo o un proveedor; el costo por rol va en #28	#19	Asumido en el diseño
El estado de Terraform va en una cuenta de almacenamiento por ambiente, en su propia suscripción	Aísla el estado igual que los ambientes	#19	Asumido en el diseño
La aprobación de producción en el pipeline la dan dos personas del comité de cambios, y el calendario de campañas vive en un archivo del repositorio	Separa quien escribe el cambio de quien lo autoriza; el pipeline necesita leer las campañas para bloquear despliegues	#19	Asumido en el diseño
El informe de la estrategia es lo que se entrega para la aprobación del diseño y el presupuesto del 13 de noviembre de 2026, junto con los documentos de arquitectura y de costos como anexos	Es el hito del cronograma en que el arquitecto cloud de FríoAndes aprueba el diseño	#36	Asumido en el diseño
Los documentos del paquete usan Helvetica Neue hasta que el sistema de diseño fije la tipografía	La tipografía de la marca (#33) todavía no está definida; la plantilla común permite cambiarla en un solo lugar	#36	Asumido en el diseño
La carta y la portada van firmadas por el equipo de arquitectura cloud del proyecto, sin nombres de personas	Los responsables del proyecto son roles; FríoAndes decide quién los ocupa	#36	Asumido en el diseño
Los colores de marca pueden ser teal andino y cian glaciar	FríoAndes no tiene manual de marca; salen de la presentación de avance	#32	Por confirmar con el cliente

Supuesto	Justificación	Issue que lo originó	Estado
El nombre se escribe «FríoAndes», con tilde, en las tres superficies; los nombres de archivo y las URL usan `frioandes`	Evita problemas de codificación en archivos y direcciones	#32	Por confirmar con el cliente
La paleta cumple el contraste en las pantallas reales de la torre de noche	Se calculó con las fórmulas de WCAG y simulación de daltonismo, sin probar en el monitor real del turno de noche	#32	Asumido en el diseño
Una diferencia de redondeo dentro del mismo orden entre un documento de arquitectura y el de costos no es una inconsistencia	Los documentos de arquitectura redondean a propósito y remiten al documento de costos para la cifra exacta	#39	Asumido en el diseño
La revisión preliminar del módulo de red vale para la pareja arquitectura e IaC hasta que cierren #21 a #24	Es el único código que existe al 20 de octubre de 2026	#39	Asumido en el diseño
El informe de la estrategia cuenta dentro del entregable de la presentación de sustentación	La guía de lectura señala que el informe está en la Tarea 5 y no en la lista de entrega, y que lo más seguro es entregar todo	#40	Asumido en el diseño
Un supuesto queda referenciado desde el informe si está en su anexo B o en el registro completo que acompaña al documento de arquitectura	El informe es breve y no puede listar todos los supuestos	#40	Asumido en el diseño